MSAS-GNN：谱驱动自适应稀疏图神经网络的鲁棒高效推理

北京师范大学统计学院硕士学位论文答辩

答辩人：常昊　导师：翟铮 副教授

北京师范大学　统计学院

2026 年 5 月

论文结构总览

本次答辩汇报结构

1. **研究背景与问题动机**（第 1–2 章）
2. **问题形式化与图复杂度指标**（第 3 章）
3. **谱驱动三维自适应稀疏机制**（第 4 章）
4. **算法整合、误差分析与复杂度**（第 5 章）
5. **实验评估**（第 6 章）——主实验·消融·效率
6. **总结与展望**（第 7 章）

全文核心约束

在 SDGNN 稀疏分解接口内，保持在线推理主项复杂度 $\boldsymbol{O(n\bar{k}d)}$ 不变，其中 $\bar{k} \ll \bar{d}^L$

主要实验结论（预告）

- vs. SDGNN（6 个数据集，$p < 0.05$）：
  - 引文网络均值 ↑1.3%
  - 网页图均值 ↑1.9%
  - ogbn-arxiv ↑0.86%
- 推理加速 8.0×（四数据集均值）
- ogbn-arxiv 加速 14.7×
- 峰值显存节省 74.8%

在线图推理的效率瓶颈

问题一：推理复杂度爆炸

- L 层 GCN 单次前向主项复杂度：$O(L \cdot m \cdot d)$，$m = \mathrm{nnz}(A)$
- 有效感受野随层数指数膨胀：$O(\bar{d}^L)$ 个节点
- 3 层、$\bar{d} = 10$：需聚合 ≈ 1000 个邻居
- 在线预测时延可超过 **100 ms**（实时系统不可接受）

问题二：加深网络的两大病态

- 过平滑（Over-smoothing）：节点表示趋同，信息区分度丧失
- 过压缩（Over-squashing）：远端信息丢失，多跳瓶颈效应
- 简单加深层数无法获得更好的感受野-效率平衡

已有代表性方向及不足

- 邻居采样（GraphSAGE、FastGCN）：推理仍需访图
- 预计算线性化（SGC、APPNP）：缺节点级自适应
- 稀疏分解（**SDGNN**）：本文直接扩展基线

在线服务场景的刚性约束

- 推荐系统：**QPS > 1000**，毫秒级响应
- 实时风控：延迟 $<$ **10 ms**
- 大规模图（$n > 10^6$）：内存访问成为主瓶颈

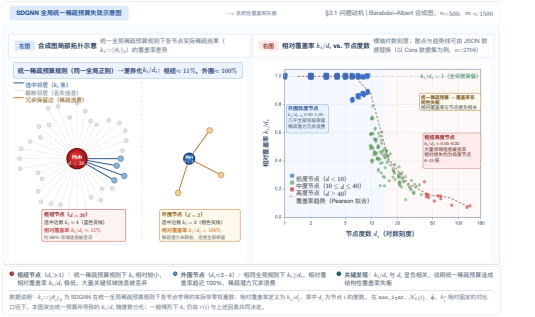

图：SDGNN 全局统一稀疏预算失效示意

SDGNN 的突破与局限——本文的问题来源

SDGNN 核心思想（Hu et al., 2024）

以单次稀疏分解替代多层消息传递，推理阶段仅执行：

$$\hat{H} = \Theta^\top \tilde{\Phi}$$

$\tilde{\Phi} \in \mathbb{R}^{n\times d}$：预缓存特征；$\Theta \in \mathbb{R}^{n\times n}$：离线固化稀疏权重

主项复杂度：$O(L \cdot m \cdot d) \longrightarrow O(n\bar{k}d)$

ogbn-arxiv 批次前向：9.2 ms，相对 GCN 加速 **13.6**×

核心局限：全局统一稀疏预算

- 以同一 λ_{reg} 约束**所有节点**
- **枢纽节点**（高度数）：稀疏化过强 → 丢失关键邻居
- **外围节点**（低度数）：稀疏化不足 → 保留冗余连接
- 复杂图（异配、重尾度）：失配更明显

本文问题：能否在保持 $O(n\bar{k}d)$ 接口不变的前提下，引入**节点级差异化稀疏预算**？

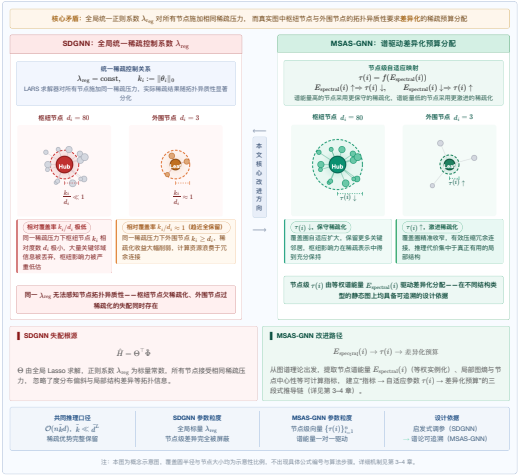

图 1.1：SDGNN 全局统一稀疏预算局限与 MSAS-GNN 自适应改进示意

研究目标与全文技术路线

研究目标

- 在保持推理主项复杂度 $O(\bar{n}\bar{k}d)$ 不变的前提下
- 利用可计算图结构统计量构建节点级差异化稀疏预算
- 使不同结构角色的节点获得更匹配的信息保留强度
- 设计具有可解释、可分析和可验证依据的参数体系

全文方法链（四层递进）

- **第 3 章**：图复杂度指标提取
  λ_{gap}、$E_{\text{spectral}}(i)$、$H_{\text{norm}}(i)$、$C_{\text{deg}}(i)$
- **第 4 章**：三维自适应参数设计
  频率维 $w_k(i)$ ·节点维 $\tau(i)$ ·跳距维 $k_i^{(l)}$
- **第 5 章**：分层 LARS 算法整合
  交替优化 $\rightarrow$ 固化 $\Theta^{\text{fixed}} \rightarrow O(\bar{n}\bar{k}d)$ 推理
- **第 6 章**：6 数据集实验验证
  主实验·消融·效率分析

第 3 章：问题形式化与优化目标

在 SDGNN 接口内引入节点级正则

训练阶段（对每个节点 i 求解带节点级正则的加权 Lasso）：

$$\min_{\theta_i} \left\|h_i^* - \tilde{\Phi}^\top \theta_i\right\|_2^2 + \tau(i)\|\theta_i\|_1 \text{ s.t. } \|\theta_i\|_0 \le \sum_{l=1}^{L} k_i^{(l)}$$

推理阶段（Θ^{fixed} 离线固化后）：

$$\hat{H} = \left(\Theta^{\text{fixed}}\right)^\top \tilde{\Phi}_{\text{cache}} \quad \Rightarrow \quad \mathbf{O(n\bar{k}d)}$$

三项设计准则

- **可解释性**：$\tau(i)$ 与 $k_i^{(l)}$ 由可计算统计量确定，参数意义明确
- **复杂度不变**：在线推理严格保持 $O(n\bar{k}d)$
- **任务无关性**：不依赖标签统计量，等权实例化

表示近似误差：$\mathcal{E}_{\text{approx}} = \frac{1}{\sqrt{n}}\|H^* - \hat{H}\|_F$

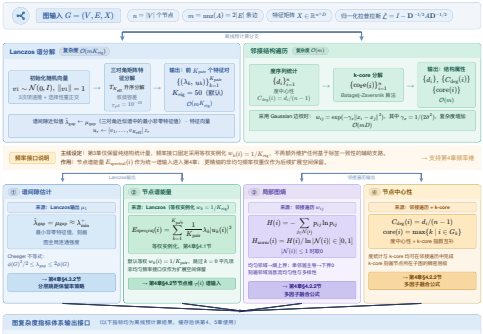

图 3.1：第 3 章整体流程图——从图输入到四类复杂度指标输出

第 3 章：四类图复杂度指标——自适应参数的统一输入接口

1 谱间隙 λ_{gap}（全图级·频率维）

- 归一化拉普拉斯第二小特征值，刻画代数连通度
- Lanczos 迭代谱估计，$O(m \cdot t)$
- λ_{gap} 大 $\Rightarrow$ 连通性强 $\Rightarrow$ 近跳信息充足
- 驱动分层跳距保留率 p_l 的整体设计

2 节点谱能量 $E_{\text{spectral}}(i)$（节点级·频率维）

$$E_{\text{spectral}}(i) = \sum_{k=1}^{K} w_k \, |U_{ik}|^2, \quad w_k = \tfrac{1}{K} \text{（等权）}$$

- 节点 i 在各谱分量上的参与强度
- Lanczos 近似特征向量投影，$O(K \cdot m)$
- 直接进入 $\tau(i)$ 多因子融合

3 归一化局部图熵 $H_{\text{norm}}(i)$（节点维）

$$H_{\text{norm}}(i) = -\frac{1}{\log d_i} \sum_{j \in \mathcal{N}(i)} \frac{1}{d_i} \log \frac{1}{d_i}$$

- 节点局部邻域的信息丰富程度
- $H_{\text{norm}} \uparrow \Rightarrow$ 邻域多样 $\Rightarrow \tau(i)$ 偏小

4 度中心性 $C_{\text{deg}}(i)$ 与 k-core 指数（节点维）

$$C_{\text{deg}}(i) = \frac{d_i}{n-1}, \qquad \text{core}(i) \in \mathbb{Z}^+$$

- 节点在全局连接中的枢纽地位
- 枢纽节点（$C_{\text{deg}} \uparrow$、core $\uparrow$）：$\tau(i)$ 应**偏小**
- 外围节点：局部冗余多，$\tau(i)$ 应**偏大**

四类指标的接口关系

全部四类统计量在第 4 章统一进入自适应参数设计；在第 5 章通过分层 LARS 进入稀疏权重学习流程

第 4 章：三维自适应稀疏机制整体框架

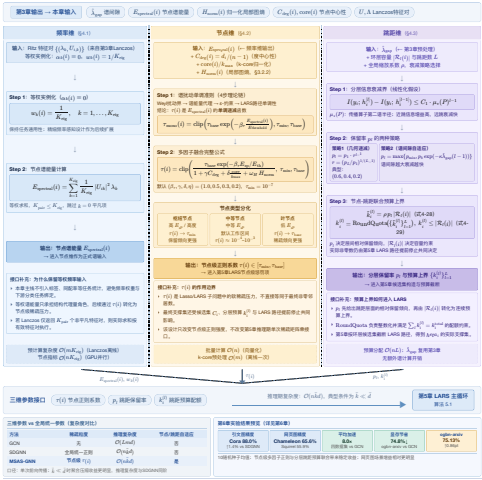

图 4.1：三维自适应稀疏机制整体框架

频率维（§4.1）：放松”统一低通传播”假设

- 节点谱能量 $E_{\text{spectral}}(i)$ 作为**等权统一谱输入** $w_k(i)$
- 任务无关，不引入标签统计量或同配性假设

节点维（§4.2）：放松”统一稀疏压力”假设

- 多因子融合构造节点级正则系数 $\tau(i)$
- 输入：$E_{\text{spectral}}(i)$、$H_{\text{norm}}(i)$、$C_{\deg}(i)$、$\text{core}(i)$
- 结构信息贡献高的节点 $\Rightarrow \tau(i)$ 较小 $\Rightarrow$ 保留更多邻居

跳距维（§4.3）：放松”各跳贡献均等”假设

- 近邻优先分层预算 $k_i^{(l)}$，保留率随跳距递减
- $p_l = p_{\text{base}} \cdot \varrho^{l-1}$ $(\varrho \in (0,1))$，$k_i^{(l)} = \lfloor p_l \cdot |\mathcal{R}_l(i)| \rfloor$
- §4.3.1 多跳传播信息衰减界分析提供理论依据

关键约束

三个维度均不改变推理接口：$\hat{H} = (\Theta^{\text{fixed}})^\top \tilde{\Phi}_{\text{cache}}$，主项复杂度 $O(\bar{n}kd)$ 严格保持不变

节点级正则系数 $\tau(i)$ 的多因子融合构造（§4.2）

多因子融合公式

$$\tau(i) = \tau_{\text{base}} \cdot \exp\big(-\beta_\tau\, E_{\text{spectral}}(i)\big) \cdot f\big(H_{\text{norm}}(i),\ C_{\text{deg}}(i),\ \text{core}(i)\big)$$

其中 $f(\cdot)$ 为单调递减映射。

各因子贡献方向（均为单调递减关系）

- $E_{\text{spectral}}(i) \uparrow \Rightarrow$ 高频参与强 $\Rightarrow \tau(i) \downarrow$（保留更多）
- $H_{\text{norm}}(i) \uparrow \Rightarrow$ 邻域多样 $\Rightarrow \tau(i) \downarrow$
- $C_{\text{deg}}(i) \uparrow \Rightarrow$ 枢纽节点 $\Rightarrow \tau(i) \downarrow$
- $\text{core}(i) \uparrow \Rightarrow$ 核心层级高 $\Rightarrow \tau(i) \downarrow$

超参数经验稳健区间（Cora 验证集，10 次随机种子）

- $\beta_\tau \in [0.8, 1.2]$：准确率波动 $\leq 0.3\%$
- $\tau_{\text{base}} \in [5 \times 10^{-4}, 5 \times 10^{-3}]$：87.7%–88.0%
- B2-RND（随机化 τ 对照）未带来稳定收益，证明结构驱动有效

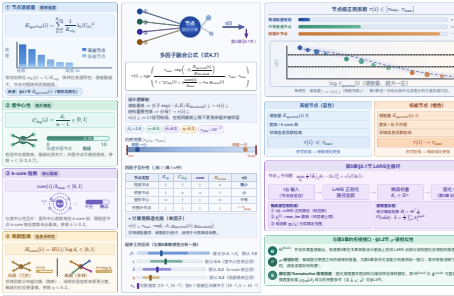

图 4.2：节点级正则系数 $\tau(i)$ 三维自适应框架示意图

节点类型	$\tau(i)$	保留邻居
枢纽节点（高度、高 core）	较小	较多
外围节点（低度、低 core）	较大	较少
普通节点	中等	中等

分层跳距预算与 LARS 算法整合（§4.3 + §5.1）

分层跳距预算 $k_i^{(l)}$（§4.3）

理论依据（§4.3.1 信息衰减界分析）：多跳传播中近跳贡献更大，信息边际贡献随 l 单调递减

近邻优先保留率（参考分配策略）：

$$p_l = p_{\text{base}} \cdot \varrho^{l-1}, \quad \varrho \in (0, 1)$$

$$k_i^{(l)} = \lfloor p_l \cdot |\mathcal{R}_l(i)| \rfloor \leq |\mathcal{R}_l(i)|$$

跳距策略消融验证（Cora，表 6.4）：

策略	准确率	$\mathcal{E}_{\text{approx}}$
近邻优先（参考分配）	**88.0%**	**0.151**
均匀分配	87.2%	0.182
反向分配（深层更多）	**86.5%**	**0.218**

LARS 分层稀疏求解与交替优化（算法 5.1/5.2）

训练阶段（算法 5.1）

- **输入**：图 G，教师表示 H^*，$\tau(i)$，$k_i^{(l)}$
- **Phase** W：固定 Θ，更新特征变换参数 W
- **Phase** Θ：固定 W，对每节点 i 执行分层 LARS，以 $\tau(i)$ 为正则，$k_i^{(l)}$ 为截断上界
- **输出**：固化 Θ^{fixed}，缓存 $\tilde{\Phi}_{\text{cache}}$

推理阶段（算法 5.2）

- 输入 Θ^{fixed}，$\tilde{\Phi}_{\text{cache}}$
- 执行：$\hat{H} = (\Theta^{\text{fixed}})^\top \tilde{\Phi}_{\text{cache}}$
- 主项复杂度：$O(n\bar{k}d)$（单次稀疏矩阵乘）
- 无需访图，无需多跳邻域展开

第 5 章：条件化误差分析与复杂度全景（§5.2–5.3）

条件化误差分析（§5.2）

前提条件（σ-谱相似性）：稀疏图 $\tilde{G}$ 满足对原图 G 的 σ-近似，即对任意向量 x：

$$(1-\sigma)x^\top Lx \;\le\; x^\top \tilde{L} x \;\le\; (1+\sigma)x^\top Lx$$

结论：在此条件下，$\mathcal{E}_{\text{approx}}$ 可由稀疏支撑质量与 λ_{gap} 控制，为第 4 章自适应参数设计提供**误差方向解释**

诚实说明（§7.3）

该分析为条件化解释，非对所有图结构最优稀疏性的严格保证

各阶段复杂度汇总（§5.3）

阶段	主项复杂度	口径
图指标计算	$O(m \cdot t_{\text{LAn}})$	一次性预处理
节点级参数	$O(n \cdot K)$	一次性预处理
LARS 训练	$O(n\bar{k}^2 d)$	单轮训练
在线推理	$O(n\bar{k}d)$	**单次前向**

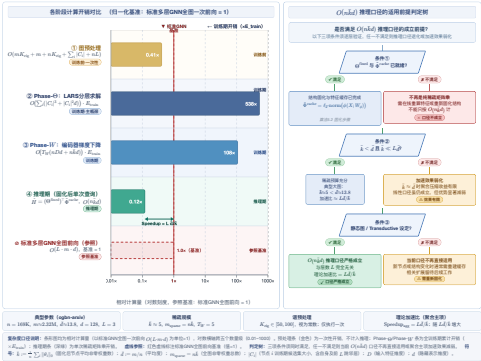

图 5.2：复杂度分解与线性推理适用边界示意图

第 6 章：实验设置与评估协议

六个静态节点分类基准数据集

图类型	数据集	节点数	类别数
引文网络	Cora	2,708	7
	Citeseer	3,327	6
	PubMed	19,717	3
大规模图	ogbn-arxiv	169,343	40
网页图（异配）	Chameleon	2,277	5
	Squirrel	5,201	5

Chameleon/Squirrel：度分布重尾，节点拓扑异质性显著

评估协议

- **重复次数**：10 个随机种子，报告均值 ± 标准差
- **显著性检验**：Wilcoxon 符号秩检验（双侧），$p < 0.05$
- **效率测量**：批次前向时间（ms/batch），峰值显存（MB），batch_size $= 1024$，GPU
- **统一口径**：相同教师模型、相同数据划分、相同硬件

基线方法分组

直接对比基线（主配对显著性检验，相同教师模型）：

- GCN 教师模型
- **SDGNN**（本文直接扩展基线）

补充参照（外部精度参考，推理机制不同）：

- 预计算类：SGC、PPRGo、GLNN
- 采样类：GraphSAINT
- 图 Transformer 类：
  - NodeFormer、DIFFormer
  - SGFormer、NAGphormer

口径说明

补充参照方法的推理范式与 MSAS-GNN 不同（无固化稀疏权重接口），主要用于提供外部精度参照；本文主要结论针对 SDGNN 配对比较

主实验结果（一）：引文网络与 ogbn-arxiv

方法	Cora	Citeseer	PubMed	ogbn-arxiv
补充参照（推理机制不同，仅供外部精度参考）				
SGFormer	87.4±0.6	81.1±0.7	89.2±0.4	74.96±0.17
NAGphormer	87.0±0.7	80.6±0.8	88.9±0.5	74.68±0.19
稀疏分解接口（主配对比较，相同教师模型与数据划分）				
GCN 教师	87.0±0.8	80.7±1.0	88.9±0.5	74.42±0.22
SDGNN	86.6±0.9	80.3±1.1	88.7±0.5	74.27±0.21
MSAS-GNN	**88.0±0.7**	**82.1±0.9**	**89.4±0.4**	**75.13±0.23**
提升 vs. SDGNN	**+1.4**	**+1.8**	**+0.7**	**+0.86**

† 所有提升满足 $p < 0.05$（Wilcoxon 检验：Cora $p = 0.002$，Citeseer $p = 0.001$，PubMed $p = 0.048$，ogbn-arxiv $p = 0.009$）

关键发现

- Citeseer 提升最大（+1.8%）：标准差从 1.1 降至 0.9，**精度更高且更稳定**
- ogbn-arxiv（n=169K）：+0.86%，大规模图上节点级机制可扩展
- 全部 4 个数据集均优于 SGFormer（最强补充基线），且推理时延更低

核心结论

- 节点级自适应正则使精度提升、结果方差下降
- 验证了统一预算失配假设：不同节点确实需要差异化稀疏约束
- 在保持相同推理接口和复杂度下，改进显著

主实验结果（二）：网页图——复杂拓扑下的效果验证

网页图节点分类准确率（%，10 次重复）

方法	Chameleon	Squirrel
H2GCN（异配参照）	*63.6±0.9*	*53.8±1.2*
SGFormer	65.2±0.8	55.4±1.1
GCN 教师	64.1±1.0	54.5±1.3
SDGNN	63.5±1.1	54.2±1.4
MSAS-GNN	**65.6±0.9**	**55.9±1.2**
提升 vs. SDGNN	**+2.1**	**+1.7**

Chameleon $p = 0.003$，Squirrel $p = 0.011$（Wilcoxon）
网页图均值提升 +1.9%，高于引文网络的 +1.3%

为何网页图提升更大？

- 节点角色差异**更明显**：度分布更重尾，异配性更强
- 统一稀疏约束的预算失配**更严重**：枢纽与外围节点信息保留需求差距更大
- 节点级 $\tau(i)$ 能更精准区分不同拓扑角色，差异化分配效益更高

重要口径说明

- 正文主线采用**等权谱能量输入**，不引入同配性或标签统计量依赖
- 网页图提升主要来自：**节点级多因子正则 + 近邻优先跳距预算**
- 非异配图标签频率校正效应（通过 §6.3 消融独立验证）

MSAS-GNN 在 Chameleon 上超越 SGFormer（65.6% vs. 65.2%），
证明稀疏分解框架内的节点级适配可达到图 Transformer 的精度

消融实验——逐模块与跳距策略的独立贡献验证（§6.3）

逐模块消融（Cora，干净图 / 30% 噪声准确率）

配置	模块描述	干净图	噪声	时延
SDGNN	原始基线（全局 λ，平坦池）	86.6	80.6	2.0 ms
B0	分层 BFS 候选池 + 统一 λ	87.0	81.0	6.7 ms
B1	B0 + 谱能量驱动 $\tau(i)$	87.3	82.8	10.4 ms
B5	**完整 MSAS-GNN**	**88.0**	**84.1**	—

跳距预算策略消融（相同节点级正则，Cora）

策略	准确率	$\mathcal{E}_{\text{approx}}$
近邻优先（参考分配）	**88.0%**	**0.151**
均匀分配（各跳相等）	87.2%	0.182
反向分配（深层更多）	**86.5%**	**0.218**
B2-RND（随机化 τ）	87.1%	—

逐模块累积贡献分析

- **B0 vs. SDGNN**：分层候选池 → +0.4%
- **B1 vs. B0**：谱能量驱动 $\tau(i)$ → +0.3%（干净图）；30% 噪声下 +1.8%（**抗噪性显著提升**）
- **B5 vs. B1**：多因子 + 跳距预算 → +0.7%（协同效果）

核心结论

- **单一结构因子不足以**稳定解释性能提升
- **节点级多因子正则 + 近邻优先跳距预算**共同作用，是三维机制有效性的主要来源
- B2-RND 对照：随机化 τ 未带来稳定收益，证明**结构驱动设计有效**
- 近邻优先 vs. 反向分配：$\mathcal{E}$ 下降 30.7%，准确率提升 1.5%

效率分析——推理时延、显存与预处理摊销（§6.4）

推理效率与显存综合对比（GPU，batch_size = 1024）

方法	Cora	ogbn-arxiv	加速比	峰值显存
GCN	12.5 ms	125.3 ms	1×	2,500 MB
SGFormer	—	39.0 ms	—	1,180 MB
SDGNN	2.0 ms	9.2 ms	9.0×	589 MB
MSAS-GNN	**1.8 ms**	**8.5 ms**	**8.0×**	**630 MB**

加速比为四数据集算术均值；ogbn-arxiv 相对 GCN 实现约 **14.7×**；MSAS-GNN 相对 SDGNN 显存仅多 +41 MB，推理时延反而更低

预处理摊销 Break-even 分析

数据集	t_{pre}	每次节省	摊销次数
Cora	≈1,080 s	≈0.033 s	≈32,727 次
PubMed	≈2,700 s	≈0.762 s	≈3,543 次
ogbn-arxiv	≈9,000 s	≈19.39 s	**≈464 次**

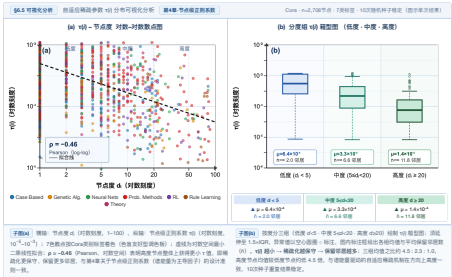

图 6.2：节点级 $\tau(i)$ 参数分布可视化（Cora）

效率分析结论

- 在 $\tilde{\Phi}$ 与 Θ^{fixed} 固化后，推理退化为单次稀疏矩阵乘，**自适应机制不引入在线开销**
- ogbn-arxiv：每日数百次全图刷新，约 1–2 天摊销完毕
- 适用场景：教师表示已给定、结构可离线固化、**高频全图调用**

主要贡献与创新点

贡献一：在 SDGNN 接口内引入节点级自适应稀疏分配

- 以可计算图结构统计量（谱间隙、谱能量、局部图熵、中心性）驱动"哪个节点保留多少邻居"的参数化设计
- 将统一稀疏控制问题转化为具体的节点级参数设计问题
- 保留单次稀疏矩阵乘推理形式与 $O(n\bar{k}d)$ 复杂度保证

贡献二：构建三维自适应参数体系

- **频率维**：等权节点谱能量（任务无关）
- **节点维**：多因子融合 $\tau(i)$（谱能量 + 图熵 + 度中心性 +k-core）
- **跳距维**：近邻优先分层预算 $k_i^{(l)}$（随跳距递减）
- 三个维度在第 5 章共同进入分层 LARS 求解流程，图结构统计量从解释变量转化为稀疏权重学习的实际调节因素

贡献三：在统一实验口径下验证精度与效率

精度（vs. SDGNN，Wilcoxon $p < 0.05$，全部 6 个数据集）：

- 引文网络均值 +1.3%，结果方差同步下降
- 网页图均值 +1.9%，复杂拓扑下更优
- ogbn-arxiv +0.86%，大规模图上有效

效率（推理阶段，相对 GCN）：

- 四数据集推理加速 8.0×（均值）
- ogbn-arxiv 加速 14.7×
- 峰值显存节省 74.8%
- 相对 SDGNN 额外显存增量仅 +41 MB

方法适用范围

教师表示已给定、稀疏权重可离线固化、在线推理需低时延的 SDGNN 式稀疏分解场景

研究局限与未来展望

研究局限性（§7.3）

1. **启发式近似性质**
   $\tau(i)$ 基于代理变量构造，尚未严格刻画与最优稀疏支撑的充要关系；重尾度分布、强异配图上的适用边界待进一步分析
2. **静态图假设**
   方法适用 transductive 设定，Θ^{fixed} 在新节点或边结构变化时未必继续适用；动态场景的稀疏权重维护未系统讨论
3. **误差界的条件化性质**
   谱相似性分析提供误差**方向解释**，非对所有图结构最优稀疏性的严格保证

未来研究方向（§7.4）

1. **理论深化**
   引入局部谱扰动分析，建立 $\tau(i)$、$k_i^{(l)}$ 与 σ-谱相似性的可检验关系，将条件化误差解释推进为直接参数设计指导
2. **结构可靠性增强**
   引入边级可靠性评分（结构相似性 + 对比学习表征），通过软门控调节 LARS 候选集，联合优化图结构质量与预算分配
3. **动态图适配**
   设计增量维护机制，局部变化时对受影响节点进行 warm-start 重估；实现分层更新策略（局部微调/部分重训练/全局热启动）

感谢翟铮副教授的悉心指导与北京师范大学统计学院各位老师的支持

欢迎各位评委老师提问与批评指正