北京師範大學

学术博士研究生
学位论文

MSAS-GNN：谱驱动自适应稀疏图神经网络的鲁棒高效推理

作　　者：　常　昊

学　　号：　202422011122

导师姓名、职称：　翟　铮　副教授

学 科 专 业：　应用统计

培 养 单 位：　统计学院

提 交 日 期：　二〇二六年四月

MSAS-GNN：谱驱动自适应稀疏图神经网络的鲁棒高效推理

常 昊

北京师范大学

北京师范大学学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。本人恪守学术道德和学术规范，杜绝抄袭，篡改，伪造等学术不端行为及代买，买卖论文等造假行为。所有引用或参考内容均已标明出处。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：　　日期：　　年　　月　　日

学位论文使用授权书

学位论文作者完全了解北京师范大学有关保存和使用学位论文的规定，即：学校有权保存并向国家有关部门或机构送交论文的复印件和电子版，允许学位论文被查阅和借阅；学校可以公布学位论文的全部或部分内容，可以允许采用影印、缩印或其它复制手段保存、汇编学位论文。保密的学位论文在解密后适用于本授权书。

本人签字：_____　　日　　期：_____

导师签名：_____　　日　　期：_____

MSAS-GNN：谱驱动自适应稀疏图神经网络的鲁棒高效推理

摘　要

图神经网络（Graph Neural Networks，GNN）以消息传递机制为核心运算单元，通过在图拓扑引导下递归聚合多跳邻域信息，使节点表示同时编码属性特征与结构位置，在节点分类、链接预测、图级推断等任务中展现出突出的性能优势，成为处理图结构数据的核心方法之一。然而，当 GNN 从学术基准评测迁移至推荐系统、实时风控、智能交通等对响应时延有严格约束的工业在线场景时，其内在的推理效率瓶颈便构成大规模部署的主要障碍：L 层 GNN 的有效感受野规模可达 $O(\bar{d}^L)$（$\bar{d}$ 为全图平均度，L 为层数），多跳邻居收集与内存访问开销随层数快速放大，在毫秒级时延约束下难以承受。除效率问题之外，真实图数据普遍存在结构质量缺陷——社交网络中的虚假关注链路、知识图谱中自动信息抽取引入的错误关系三元组，以及观测图中大量未记录的潜在连接——这些噪声边与缺失边会通过固定邻接矩阵的训练范式直接污染节点表示，进而损害下游任务的可靠性。

Hu 等人在 TMLR 2025 上发表了稀疏分解图神经网络（Sparse Decomposition Graph Neural Networks，SDGNN），将多层消息传递的推理过程转化为对教师 GNN 输出的单次稀疏矩阵乘 $\hat{H} = \Theta^\top \tilde{\Phi}$，将推理主项复杂度从 $O(Lmd)$ 压至 $O(n\bar{k}d)$，其中 $\bar{k}$ 为各节点平均非零权重数，满足 $\bar{k} \ll \bar{d}^L$，在实测中实现了数量级级别的推理加速。这一框架尽管在效率上具有明确优势，但其设计中隐含了三项结构性局限，制约了其在复杂真实场景中的适用范围：一是全局统一正则系数 λ_1 对所有节点施加相同的稀疏预算，忽视了图上普遍存在的节点拓扑异质性，在度分布高度不均匀的同配图与能量分布迥异的异配图上均会产生系统性偏差；二是稀疏权重矩阵一旦训练完成即固化为静态参数，图结构或节点特征发生演化时只能重启完整训练流程，无法利用图演化的局部性来控制更新代价；三是方法直接在原始观测邻接矩阵上学习稀疏权重，对噪声边与缺失边均缺乏主动识别与处置能力，图结构质量缺陷会直接导致稀疏模式失真。

针对上述三项局限，本文以稀疏分解图神经网络为基础，围绕” 如何在保持高效推理优势的同时提升节点自适应性、结构鲁棒性与动态图维护能力” 这一核心目标，提出多尺度自适应稀疏图神经网络（Multi-Scale Adaptive Sparse Graph Neural Network，MSAS-GNN）。

在节点自适应方面，本文从谱图分析出发，构建频率维、节点维与跳距维协

同的自适应稀疏分解框架，以节点局部谱特性为依据分配稀疏预算，使同配图中的枢纽节点与异配图中的高频活跃节点均能获得更符合其拓扑角色的邻域保留策略，缓解统一稀疏约束在度分布不均及异配场景下的系统性偏差。该框架通过对节点谱能量与跳距信息衰减规律的定量刻画，在推理期保持与 SDGNN 一致的单次稀疏矩阵乘形式，推理主项复杂度维持在 $O(n\bar{k}d)$。

在结构鲁棒性方面，本文设计置信度引导的结构质量控制机制。该机制以对比学习与不确定性估计相结合的双路径方式对边可靠性进行量化建模，对低可信边执行过滤，并以软门控方式对稀疏权重进行连续调节，从图信号平滑性角度为该机制提供理论解释；同时结合基于拓扑相似性的候选边补充策略，缓解结构缺失带来的信息损失。置信度估计、噪声鲁棒稀疏分解与缺失边增强通过统一的交替优化框架协同求解，整体上增强了稀疏分解过程对图结构质量波动的适应能力。

在动态图扩展方面，本文进一步探索面向图演化场景的轻量级增量维护机制，通过变化感知、局部重优化、分层更新决策与记忆回放等策略，在局部变化主导时降低状态更新代价，避免对未受影响节点的冗余重计算。需要说明的是，该部分在全文中定位为探索性研究，相关理论与实验结论主要用于提供方向性证据，而非形成对动态图学习问题的完备闭合。

在实验评估方面，本文在六个静态节点分类基准数据集（Cora、Citeseer、PubMed、ogbn-arxiv、Chameleon、Squirrel）和一个动态图数据集（tgbl-wiki）上对 MSAS-GNN 进行了系统验证，所有静态实验在 10 个随机种子下重复并报告均值与标准差。在同配性引用网络上，MSAS-GNN 的节点分类准确率分别达到 87.8%（Cora）、81.5%（Citeseer）和 89.7%（PubMed），相比直接基线 SDGNN 各提升约 1.2%、1.2% 与 0.9%；在大规模图 ogbn-arxiv（169,343 节点）上达到 75.13%，超过 SDGNN 的 74.27%。异配性图上的增益更为明显，Chameleon 和 Squirrel 上分别达到 67.2% 与 56.9%，体现出异配感知自适应稀疏分解在复杂拓扑条件下的优势。推理效率方面，MSAS-GNN 相对标准消息传递模型（GCN）实现约 13.6 倍推理加速，显存占用降低约 74.8%。鲁棒性方面，在 30% 噪声边注入条件下，MSAS-GNN 的准确率下降幅度仅为 2.9%，明显低于直接基线 SDGNN 的 8.3%，验证了置信度融合与软门控机制协同作用；缺失边恢复 $F_{1,\text{recover}}$ 达到 91.2%，高于 IDGL 的 86.3%。消融实验表明，以节点局部谱特性为依据的自适应稀疏预算设计是性能提升的主要来源，节点级稀疏度参数与节点度在对数坐标下呈显著负相关，与设计预期方向一致。动态图实验进一步显示，在局部变化主导的场景下，增量维护相对全量重训练可获得 5 倍以上、最高约 107 倍的更新加速，但相关结论仍应限定在本文设定的实验条件与探索性验证范围之内。

综上，本文从自适应稀疏分解、结构质量控制和增量协同维护三个层面扩展

了稀疏分解图神经网络的设计边界，在保持高效推理优势的同时提升了模型对节点异质性、结构缺陷与图演化的适应能力，可为图神经网络在大规模在线推理场景中的可靠部署提供方法参考。

关键词：图神经网络，自适应稀疏化，谱图分析，置信度引导，软门控机制，增量更新，鲁棒推理

MSAS-GNN: Spectral-Driven Multi-Scale Adaptive Sparse Graph Neural Networks for Robust and Efficient

ABSTRACT

Graph Neural Networks (GNNs) learn node representations by recursively aggregating multi-hop neighborhood information under the guidance of graph topology through a message-passing mechanism, encoding both feature attributes and structural positions into each node's embedding. This paradigm has demonstrated strong performance on tasks such as node classification, link prediction, and graph-level inference, establishing GNNs as a mainstream method for processing graph-structured data. However, deploying GNNs in latency-critical industrial applications—including recommender systems, real-time fraud detection, and intelligent transportation—exposes a fundamental inference efficiency bottleneck: the effective receptive field of an L-layer GNN can grow to $O(\bar{d}^L)$ nodes (where $\bar{d}$ is the mean degree and L is the number of layers), and the associated costs of multi-hop neighbor fetching and memory access scale rapidly with depth, making millisecond-level latency requirements difficult to satisfy. Beyond efficiency, real-world graphs commonly suffer from structural quality degradation—spurious follow links in social networks, erroneous relation triples introduced by automated information extraction in knowledge graphs, and a large number of unrecorded latent connections in observed graphs. These noisy and missing edges propagate through the fixed-adjacency training paradigm to corrupt node representations and ultimately undermine the reliability of downstream tasks.

In 2024, Hu et al. proposed the Sparse Decomposition Graph Neural Network (SDGNN), which reformulates multi-layer message-passing inference as a single sparse matrix multiplication $\hat{H} = \Theta^\top \tilde{\Phi}$ that approximates the teacher GNN's output, reducing the dominant inference complexity from $O(Lmd)$ to $O(n\bar{k}d)$, where $\bar{k}$ is the average number of nonzero weights per node with $\bar{k} \ll \bar{d}^L$. This formulation achieves orders-of-magnitude inference speedup in practice. Despite its efficiency advantage, SDGNN's design embeds three structural limitations that constrain its applicability in complex real-world scenarios. First, a globally uniform regularization coefficient λ_1 imposes identical sparsity budgets on all nodes, disregarding the pervasive topologi-

cal heterogeneity among nodes; this causes systematic bias on both homophilic graphs with highly skewed degree distributions and heterophilic graphs whose spectral energy profiles differ fundamentally from the low-pass assumption. Second, once training is complete, the sparse weight matrix is frozen as static parameters, so any evolution in graph structure or node features requires restarting the full training pipeline without exploiting the locality of graph changes to reduce update cost. Third, SDGNN learns sparse weights directly on the raw observed adjacency matrix and provides no mechanism for actively identifying or handling noisy or missing edges, meaning that structural quality defects translate directly into distorted sparsity patterns.

To address these three limitations, this thesis proposes the Multi-Scale Adaptive Sparse Graph Neural Network (MSAS-GNN), building on the sparse decomposition framework of SDGNN and pursuing the central objective of preserving its efficient inference advantage while improving node adaptivity, structural robustness, and dynamic graph maintainability.

On the node-adaptivity front, MSAS-GNN constructs an adaptive sparse decomposition framework that coordinates three dimensions—frequency, node, and hop distance—using each node's local spectral characteristics as the basis for sparsity budget allocation. This allows hub nodes in homophilic graphs and high-frequency-active nodes in heterophilic graphs to receive neighborhood retention strategies that better match their topological roles, alleviating the systematic bias of a uniform sparsity constraint under uneven degree distributions and heterophilic settings. By quantitatively characterizing spectral energy at the node level and the information decay law across hop distances, the framework preserves the single sparse matrix multiplication form of SDGNN at inference time, maintaining a dominant inference complexity of $O(n\bar{k}d)$.

On the structural robustness front, MSAS-GNN introduces a confidence-guided structure quality control mechanism. This mechanism quantifies edge reliability through a dual-path approach combining contrastive learning and uncertainty estimation, filters low-confidence edges, and continuously adjusts sparse weights via a soft-gating function whose behavior is grounded in a graph signal smoothness interpretation. A candidate edge supplementation strategy based on topological similarity is simultaneously incorporated to mitigate information loss from structural incompleteness. Confidence estimation, noise-robust sparse decomposition, and missing-edge augmentation are solved jointly within a unified alternating optimization framework, collectively enhancing the resilience of the sparse decomposition process to fluctuations in graph structural quality.

On the dynamic graph extension front, this thesis further explores a lightweight incremental maintenance mechanism for graph evolution scenarios. Through change detection, local re-optimization, hierarchical update decisions, and memory replay, the mechanism reduces state update cost when local changes dominate, avoiding redundant recomputation for unaffected nodes. It should be noted that this component is positioned as exploratory research throughout the thesis; the associated theoretical and experimental findings are intended to provide directional evidence rather than a complete theoretical closure for dynamic graph learning.

Experiments were conducted on six static node classification benchmark datasets (Cora, Citeseer, PubMed, ogbn-arxiv, Chameleon, and Squirrel) and one dynamic graph dataset (tgbl-wiki). All static experiments were repeated under 10 random seeds with results reported as mean ± standard deviation. On homophilic citation networks, MSAS-GNN achieved node classification accuracies of 87.8% (Cora), 81.5% (Citeseer), and 89.7% (PubMed), outperforming the direct baseline SDGNN by approximately 1.2%, 1.2%, and 0.9%, respectively; on the large-scale graph ogbn-arxiv (169,343 nodes), it reached 75.13%, surpassing SDGNN's 74.27%. The gains were more pronounced on heterophilic graphs, where MSAS-GNN achieved 67.2% on Chameleon and 56.9% on Squirrel, demonstrating the advantage of heterophily-aware adaptive sparse decomposition under complex topological conditions. In terms of inference efficiency, MSAS-GNN achieved approximately 13.6× speedup over the standard message-passing model (GCN), with GPU memory usage reduced by about 74.8%. For robustness, under 30% noisy edge injection, the accuracy degradation of MSAS-GNN was only 2.9%, substantially lower than SDGNN's 8.3%, validating the synergistic effect of confidence fusion and the soft-gating mechanism; the missing-edge recovery $F_{1,\text{recover}}$ reached 91.2%, higher than IDGL's 86.3%. Ablation studies showed that the adaptive sparsity budget design grounded in node-level spectral characteristics is the primary contributor to performance gains, and node-level sparsity parameters exhibited a pronounced negative correlation with node degree on a log scale, consistent with the intended design direction. Dynamic graph experiments further showed that incremental maintenance achieved more than 5× and up to approximately 107× update speedup over full retraining in locally dominated change scenarios, though these findings should be interpreted within the experimental conditions and exploratory validation scope defined in this thesis.

In summary, this thesis extends the design boundaries of sparse decomposition graph neural networks along three dimensions—adaptive sparse decomposition, struc-

ture quality control, and incremental cooperative maintenance—improving the model's adaptability to node heterogeneity, structural defects, and graph evolution while preserving the efficient inference advantage, and may serve as a methodological reference for the reliable deployment of GNNs in large-scale online inference settings.

KEY WORDS: Graph Neural Network, Adaptive Sparsification, Spectral Graph Analysis, Confidence-Guided Learning, Soft-Gating Mechanism, Incremental Update, Robust Inference

目　录

插图清单

附表清单

算法清单

算法 2.1 Calculate $y = x^n$ 26
算法 3.1 Calculate $y = x^n$ 28

第 1 章 绪论

图结构数据为刻画现实世界中的关系与依赖提供了统一而有效的数学表示。从互联网平台的用户社交关系、电商系统的用户-商品交互图，到生物信息学中的蛋白质相互作用网络、知识图谱中的实体-关系三元组，种类繁多的复杂系统均可在图的抽象框架下加以刻画。图神经网络（Graph Neural Networks，GNN）以消息传递机制为基本运算单元，使节点能够在图拓扑结构的引导下聚合多跳邻域信息，从而学习到兼顾属性特征与结构位置的综合表示，在节点分类、链接预测、图级推断等任务上展现出显著优势。然而，当 GNN 从学术评测场景迁移至推荐系统、实时风控、智能交通等对响应时延有严格约束的在线推理场景时，其内在的推理效率瓶颈便成为大规模部署的关键障碍：L 层 GNN 的有效感受野在最坏情况下可达 $O(\bar{d}^L)$（$\bar{d}$ 为全图平均度，L 为层数），邻居收集与内存访问开销随层数快速放大，从而显著增加在线单节点或小批量查询场景下的推理延迟控制难度。

Hu 等于 2024 年提出的稀疏分解图神经网络（Sparse Decomposition of Graph Neural Networks，SDGNN）为上述效率瓶颈提供了重要参照：其将多层消息传递的推理过程重新表述为对教师 GNN 输出的单次稀疏分解问题，推理阶段仅需执行一次稀疏矩阵乘法 $\hat{H} = \Theta^\top \tilde{\Phi}$，从而消除层间顺序依赖，并为后续章节采用 $O(n\bar{k}d)$ 这一统一推理口径提供了直接背景。在多个基准数据集上，SDGNN 在保持接近原始 GNN 精度的同时实现了显著的推理加速，展现出将稀疏分解应用于在线场景的可行性。然而，深入考察 SDGNN 的设计假设后，可以识别出三项结构性局限，制约了其在复杂真实场景中的适用范围：第一，SDGNN 以全局统一正则系数 λ_1 控制所有节点的稀疏预算，这一“一刀切”策略忽视了图上普遍存在的节点拓扑异质性；第二，训练完成后稀疏权重即固化为不可更新的静态参数，当图结构或节点特征发生演化时，需要重新执行完整训练流程；第三，SDGNN 直接在原始观测图结构上学习稀疏权重，对噪声边和缺失边均缺乏主动识别与处置能力。

本文提出多尺度自适应稀疏图神经网络（Multi-Scale Adaptive Sparse GNN，MSAS-GNN），在保留 SDGNN 单次稀疏分解推理基本架构的前提下，对上述三项局限分别给出对应改进。围绕第一项局限，第 3 章从谱图理论出发，建立节点拓扑特性与最优稀疏预算之间的设计关联，以频率维、节点维和跳距维三条线索构建节点级自适应参数体系，替代全局统一的 λ_1。第 4 章在放松“图结构完全可信”假设后展开，通过对比学习与贝叶斯不确定性两条路径对边的可靠性进

行估计，并以软门控机制将置信度引入稀疏权重修正过程，同时设计候选缺失边补充策略，以回应第三项局限。第 5 章则在前两章静态框架基础上进一步给出探索性时序扩展，针对图演化场景设计基于受影响范围分析的增量维护方案，以较低代价更新推理状态，从而回应第二项局限。需要说明的是，$O(n\bar{k}d)$ 对应的是第 3 章与第 4 章静态推理阶段的聚合主项口径；第 5 章关注的是图演化后的低代价单步更新，而非将动态图维护直接等同表述为同一静态推理复杂度。

作为全文的绪论，本章承担四项核心任务：在宏观层面阐明 GNN 在线推理效率瓶颈的形成机理，厘清 SDGNN 的贡献边界与局限所在，建立 MSAS-GNN 的研究动机（第**??**节）；依托与三大核心模块直接相关的五条文献脉络，系统梳理国内外研究现状，归纳三条尚待填补的研究空白（第**??**节）；在此基础上明确本文的研究问题边界与总体目标，概述三块主要研究内容的相互衔接逻辑，归纳主要创新点（第**??**节）；最后交代全文整体技术路线与章节组织结构，说明各章的功能定位及章间关键输出接口（第**??**节）。本章小结（第**??**节）将回顾上述内容并自然引出第 2 章的系统性背景综述任务。

本章叙述边界明确限定于“引出研究问题与动机”，不预先展开方法推导，亦不引用后续各章中正式定义的定理、命题或算法编号；涉及本文贡献的具体符号与形式化结论，统一在第 3–5 章的对应位置建立，基础背景符号则以第 2 章的统一定义为准。

【占位图 1.1】

图题：SDGNN 三大局限与 MSAS-GNN 三条研究主线的对应关系示意图。

表达内容：图采用左右对应结构，左侧三个矩形框分别描述 SDGNN 的三项结构性局限——“全局统一正则系数 λ_1，无法响应节点拓扑异质性”、“静态固化推理参数，无法适应图结构动态演化”、“缺乏图结构质量控制机制，对噪声边与缺失边无防御能力”；中间以有向箭头连接；右侧三个框分别对应本文三个核心方法章节：“第 3 章：谱驱动三维自适应稀疏分解（解决局限一）”、“第 4 章：置信度引导的结构质量控制（解决局限三）”、“第 5 章：增量协同演化时序扩展（探索局限二）”；底部标注全文统一目标：“在保持静态推理主项 $O(n\bar{k}d)$ 复杂度口径优势的前提下，提升 MSAS-GNN 的节点自适应能力、结构鲁棒性，并探索其在动态图场景下的低代价维护能力“；图中不出现具体方法公式符号，仅以文字说明模块功能与章节对应关系。

图 1.1　SDGNN 三大局限与 MSAS-GNN 对应解决方案示意图

符号边界约束：本章正文、图注、表注及创新点描述中，严禁出现以下后续章节的贡献性符号及其具体公式形式：节点级正则系数 $\tau(i)$、修正谱能量 $E^{(h)}_{\text{spectral}}(i)$、软门控函数 $\psi(c_{ij})$、时序边置信度 $c^{(t)}_{ij}$、跳距预算配额 $k^{(l)}_i$。同样，不得预先标注第 3–5 章中任何定理、引理、命题、推论或算法的具体编号。

表 1.1　第一章允许出现的高层符号与缩略语约定

符号/缩略语	含义	使用场景	正式定义位置
GNN	图神经网络（Graph Neural Networks）	全章通用	第 2 章 2.1 节
SDGNN	稀疏分解图神经网络（Sparse Decomposition of GNN，Hu 等，2024）	**??**节、**??**节	第 2 章 2.2.3 节
MSAS-GNN	多尺度自适应稀疏图神经网络（Multi-Scale Adaptive Sparse GNN，本文提出）	全章通用	第 3 章引言
LARS	最小角度回归（Least Angle Regression）求解器	**??**节、**??**节	第 2 章 2.2.3 节
$O(\bar{d}^L)$	L 层 GNN 感受野规模，$\bar{d}$ 为全图平均度	**??**节	第 2 章 2.1.3 节
$\hat{H} = \Theta^\top \tilde{\Phi}$	SDGNN 推理高层形式（仅作动机说明，不在本章展开定义）	**??**节	第 3 章 3.1.2 节
$O(n\bar{k}d)$	MSAS-GNN 推理主项复杂度（$\bar{k}$ 为平均非零预算）	**??**节	第 3 章 3.8 节
λ_1	SDGNN 全局统一正则系数（本章仅用于说明其局限性）	**??**节	第 2 章 2.2.3 节、第 3 章 3.1.2 节

1.1 研究背景与意义

1.1.1 研究背景

图结构数据以节点和边的抽象形式刻画实体与关联，在现代信息系统中扮演着日益重要的角色。社交网络中用户之间的交互链路、推荐系统中用户与商品的偏好关联、知识图谱中实体与关系的三元组结构、生物网络中蛋白质之间的相互作用拓扑——这些迥异的系统共享同一种底层表示范式，即以图作为数据组织的基本单元。图神经网络（GNN）通过消息传递机制，在图拓扑结构的引导下让节点递归聚合多跳邻域的特征与结构信息，使最终的节点表示同时编码属性差异与结构位置，从而在节点分类、链接预测和图级推断等任务上表现出色，成为图表示学习领域的核心范式。然而，从学术基准评测迁移至工业规模在线部署，GNN 内在的推理效率瓶颈逐步浮现，成为制约实用化进程的主要障碍。

消息传递框架的核心代价源于多跳邻域聚合。在局部树状结构近似下，L 层 GNN 的有效感受野规模约为 $O(\bar{d}^L)$，其中 $\bar{d}$ 为全图平均度，L 为层数。当图具有中等连接密度时，哪怕设置三层，感受野规模便可达到数千乃至数万个节点，对应的邻居收集与内存访问开销随之快速膨胀。这一指数扩张效应在在线预测场景下尤为突出——推荐系统的个性化排序、实时风控的交易查询、智能交通的感知节点更新，均对单节点推理延迟有毫秒级乃至更严格的约束。在百万节点量级图上，标准多层 GNN 往往面临明显的部署压力，而边缘设备与物联网终端的

有限算力会进一步加剧这一矛盾。除效率因素之外，真实图数据的结构质量问题同样不可忽视：社交网络中的虚假账号产生大量噪声关注链路，知识图谱中自动信息抽取引入错误关系三元组，这些图结构缺陷会在固定邻接矩阵的训练范式下传播至节点表示，进而影响下游任务的可靠性。如何在保持 GNN 表达能力的前提下，同时应对大规模在线部署场景中的效率约束与图结构质量问题，成为学术界和工业界共同关注的关键议题。

2024 年，Hu 等人提出稀疏分解图神经网络（SDGNN），作为面向在线预测场景的高效近似推理方案，为缓解上述推理效率瓶颈提供了重要思路**?**。SDGNN 的核心洞察是：教师 GNN 的节点表示可以被稀疏权重矩阵 Θ 与特征变换矩阵 $\tilde{\Phi}$ 的乘积所近似，推理形式可写为 $\hat{H} = \Theta^\top \tilde{\Phi}$。具体而言，SDGNN 以全局统一正则系数 λ_1 为超参数构建 Lasso 子问题，并借助 LARS（Least Angle Regression）求解器精确控制每个节点稀疏权重中非零元素的数量。这一设计将多层消息传递的推理过程转化为单次稀疏矩阵乘法，消除了层间顺序依赖，将推理主项复杂度压至 $O(n\bar{k}d)$，其中 $\bar{k}$ 为稀疏分解后每个节点保留的平均非零权重数，满足 $\bar{k} \ll \bar{d}^L$。训练过程采用 Phase Θ（LARS 稀疏权重求解）与 Phase W_ϕ（特征变换参数梯度更新）交替迭代的方式完成。在多个标准基准数据集上，SDGNN 在保持接近原始 GNN 精度的同时实现了明显的推理加速，展示出稀疏分解推理路线在大规模在线场景中的可行性，其实测效率数据在第 6 章与本文方法一并给出。

尽管 SDGNN 开辟了稀疏分解推理的有效路径，深入审视其设计假设后，可识别出制约其复杂场景适用性的三项结构性局限。

局限一：全局统一正则系数无法响应节点拓扑异质性。SDGNN 以同一正则系数 λ_1 约束所有节点的稀疏预算，隐含“所有节点最优稀疏度相同”的前提。然而，真实图的节点拓扑特性普遍存在显著差异：社交网络的度分布呈幂律形态，少数枢纽节点（hub）的度数可比外围节点高出数个数量级；引用网络中核心文献与边缘文献的连接密度截然不同；生物网络中关键调控基因与普通基因的邻域规模及频率响应特征也大相径庭。从谱分析视角看，谱域参与度较高的节点往往承载更多全局结构信息，其邻居包含更丰富的结构线索，过激进的稀疏化可能截断重要邻居并导致表示失真；相对而言，更多依赖局部信息传递的节点若采用过保守的稀疏化，则会保留较多冗余连接，难以充分释放稀疏化的压缩潜力。统一的 λ_1 在度分布高度不均匀的图上会系统性地偏离节点级最优分配，这一问题在异配图（节点更倾向于与标签不同的节点相连）上尤为突出——异配图的频率能量分布模式与同配图存在本质差异，低通主导的聚合假设在此类场景下并不成立，全局统一参数会进一步放大这种不匹配。

局限二：静态固化的稀疏权重无法适应图结构动态演化。SDGNN 在训练阶段完成优化后，稀疏矩阵 Θ 以固化形式存储，推理阶段直接复用。当图发生演化

——新用户注册引入新节点、关系建立产生新边、节点特征随业务状态更新——现有设计要求重启完整训练流程，包括对全部节点重新执行 LARS 求解与特征变换参数更新。这一静态范式在动态图场景中带来两方面制约：从计算代价看，完整重训练的开销与图规模正相关，在图更新频繁时难以维持低延迟；从知识利用看，完整重训练抛弃了已习得的权重参数，未能利用图演化的局部性——大多数节点和边在相邻时间步内保持稳定，受实质影响的仅是局部区域。交通传感器网络、金融交易图、在线推荐等场景的图更新频率高，这一局限使 SDGNN 在此类应用中的实用性受到明显制约。

局限三：缺乏对图结构质量的主动控制能力。SDGNN 直接在原始观测邻接矩阵上学习稀疏权重，默认图结构完全可信，对噪声边和缺失边均无主动识别与处置机制。噪声边（如社交网络中的虚假关注、知识图谱中自动抽取产生的错误关系三元组）会使稀疏分解习得失真的邻居权重模式——可靠性低的噪声边因特征相似度虚高而被赋予较大权重并错误保留，真正结构重要的边反而可能被误剪；而对于缺失边，SDGNN 也无从利用特征层面的相似性信号来发现和补充潜在的有效连接。在现实部署环境中，噪声边的来源广泛且难以完全规避，纯粹依赖原始图结构的稀疏分解方案在此类环境下表现出明显的脆弱性。

针对上述三项局限，本文提出多尺度自适应稀疏图神经网络（Multi-Scale Adaptive Sparse Graph Neural Networks，MSAS-GNN）框架。在保留 SDGNN 单次稀疏分解推理基本架构的前提下，MSAS-GNN 从三个维度对其进行有针对性的扩展：围绕局限一，第 3 章从图谱理论出发，建立节点拓扑特性与最优稀疏预算之间的量化关联，以频率维、节点维和跳距维三条设计线索替代全局统一的 λ_1，并引入同配系数感知的频率权重调整机制，以统一应对同配与异配两类图；围绕局限三，第 4 章在放松“图结构完全可信”假设后，通过对比学习与贝叶斯不确定性两条并行路径评估边的可靠性，以软性调节机制将置信度引入稀疏权重修正过程，同时设计候选缺失边补充策略；围绕局限二，第 5 章探索面向图演化场景的增量式稀疏权重维护方案，通过受影响范围分析控制更新代价，该部分在全文中定位为探索性时序扩展。上述三个维度的设计均以“不破坏静态推理主项复杂度口径”为约束，协同构成 MSAS-GNN 的研究体系，旨在在 $O(n\bar{k}d)$ 推理主项复杂度下实现更高的自适应性、鲁棒性与时序适应能力。

如图 **??** 所示，三大局限与三条研究主线之间形成清晰的一一对应关系，构成本文整体研究框架的逻辑骨架。

1.1.2 研究意义

本文研究的意义体现在理论与实践两个层面：在理论层面，通过将谱图分析、图信号处理与稀疏优化相互关联，为高效稀疏推理框架引入新的设计视角；

在实践层面，所提方案面向工业规模图推理场景中普遍存在的效率与质量制约，具有较为直接的应用价值。

理论意义：

（一）为高效稀疏推理引入谱驱动的自适应设计视角。现有高效 GNN 方法——无论是基于邻居采样的加速路线、预计算线性化路线，还是以 SDGNN 为代表的稀疏分解路线——在稀疏化设计上均以全局统一参数为主导，较少系统讨论节点拓扑差异与稀疏预算分配之间的内在关联。本文从图谱分析角度切入，尝试建立节点在频率域的结构参与程度与其最优稀疏预算之间的量化关联，为高效推理方法提供比“全局统一参数”更细粒度的设计依据。进一步地，针对异配图中低频信号主导假设失效的问题，本文引入同配系数感知的频率权重调整机制，使谱驱动稀疏化方案在同配与异配两类图结构上均具有适用性，为异配图场景下的高效推理研究提供了新的分析视角（详见第 3 章）。

（二）为稀疏推理框架引入结构质量控制维度的分析思路。现有的鲁棒图神经网络方法（如 Pro-GNN?、GNNGuard? 等）与高效稀疏化方法往往相互独立地发展，两者如何在同一框架下协调尚缺少系统探讨。本文尝试将边可靠性估计、软性边权调节与稀疏分解推理纳入统一分析框架，把“图结构是否可信”这一以往被鲁棒学习方法单独处理的问题，拓展为高效推理研究的一个组成维度。从图信号平滑性视角分析，软性边权调节机制与加权信号平滑目标之间存在可分析的内在联系，这为鲁棒图学习与稀疏推理协同设计提供了理论解读路径（详见第 4 章）。

（三）探索稀疏分解框架向动态图增量维护的延伸方向。现有稀疏分解方法几乎全部面向静态图，忽视了大量实际部署场景中图结构与节点特征持续演变这一普遍现实。本文探索将受影响范围分析与局部参数更新机制引入稀疏分解框架，尝试将静态稀疏推理框架向时序增量维护方向延伸，围绕受影响范围的量化刻画、更新粒度的决策机制与历史参数的遗忘控制等方向展开初步研究。需要强调的是，这一部分的意义主要体现在研究方向的拓展与概念框架的提出，而非宣称对动态图场景的理论闭合；相关分析采用经验收敛趋势和数量级估算的诚实口径，在第 5 章中有明确交代（详见第 5 章）。

（四）形成效率、鲁棒性与动态适应递进嵌套的研究链条。相比孤立的模块改进，本文的整体价值还体现在研究结构的层层递进：以 SDGNN 的三项假设为出发点，在保持静态推理主项复杂度口径不变的前提下，分别从节点自适应、结构质量控制和时序增量维护三个方向逐步放宽既有假设。这样的章间组织方式有助于保证各研究模块的可追溯性，也为后续扩展提供了较清晰的方法框架。

实践价值：

（一）为在线图推理服务提供精细化高效方案。推荐系统、实时搜索、在线

风控等大规模服务均对推理延迟有严格的业务约束，而 GNN 在此类场景中的落地长期受制于感受野扩张带来的计算开销。MSAS-GNN 在保持 $O(n\bar{k}d)$ 推理主项复杂度的同时，将稀疏预算从全局统一调整为节点级自适应分配，能够在枢纽节点保留更多结构信息、在外围节点充分压缩冗余连接，在精度损失极小的前提下提供更精细的推理效率控制。具体加速效果在第 6 章实验中给出，可为相关工程团队提供有参考意义的部署参数依据。

（二）提升模型对真实图数据噪声与缺失的容忍能力。医疗知识图谱、金融信用图、工业物联网拓扑等实际系统中，图数据的采集链路普遍引入一定比例的错误连接或观测遗漏，依赖固定图结构的推理方案在此类环境下表现不稳定。MSAS-GNN 通过置信度引导的软性边权调节，在稀疏化框架内自适应地抑制低可靠性连接、同时利用高可靠性潜在缺失边，使推理结果对图数据质量缺陷的敏感度有所降低。这一特性对于数据采集难以精确管控的行业应用具有较为直接的实用价值（第 6 章鲁棒性实验对此进行量化验证）。

（三）为稀疏分解方法向动态图场景延伸提供技术参考。交通网络、社交媒体、金融市场等场景中的图结构以秒级到小时级的频率持续演化，要求推理系统在无法频繁完整重训练的条件下维持较高性能。本文的时序增量维护探索为稀疏分解框架如何低代价响应图演化提供了初步的方案参考和技术路径分析，使得稀疏推理不再局限于静态图假设，有助于拓宽此类方法的实际部署边界（第 6 章动态辅线实验给出方向性的实证结果）。

本节从研究背景与研究意义两个层面阐明了本文的出发点与价值定位。SDGNN 三项结构性局限的识别构成 MSAS-GNN 研究的直接动机，而谱驱动自适应设计、结构质量控制分析与时序扩展探索三条理论线索，以及在线推理效率、噪声鲁棒性和动态场景适用性三项实践价值，共同构成本研究的贡献图景。相关方法的形式化定义、完整理论推导与实验验证，统一在第 3 章至第 6 章中展开。下一节将系统梳理与本文各核心模块直接相关的国内外研究现状。

1.2 国内外研究现状

大规模图上的高效推理与鲁棒维护问题同时涉及推理加速、异配建模、结构质量控制和动态图更新等多个方向。考虑到第 2 章将对相关理论基础与代表性方法作系统展开，本节不再采用“教材式”全面综述，而是围绕本文三项核心问题——节点级自适应稀疏化、结构质量控制以及动态图增量维护——对五条直接相关的研究线索作问题导向的概述，并在节末归纳本文所对应的研究空白，以便与第**??**节研究内容和第 2 章详细综述形成清晰分工。

1.2.1 图神经网络在线推理效率相关研究

图神经网络的发展以消息传递框架的提出与完善为主线。Gilmer 等人在 2017 年将多种图上的学习方法统一到消息传递神经网络（Message Passing Neural Network，MPNN）框架之下，将每层的计算分解为消息聚合与节点状态更新两个阶段，从而将节点属性与图拓扑结构的联合学习纳入统一范式**?**。在此框架内，节点经过 L 层消息传递后，其表示编码了 L 跳邻域内所有节点的属性信息。

这一设计的代价随图规模与层数的增长呈指数放大。在局部近似树状结构的近似下，L 层 GNN 的有效感受野可达 $O(\bar{d}^L)$，其中 $\bar{d}$ 为全图平均度。对于度分布较密的图，即便仅叠加三层，感受野规模便可能达到数千乃至数万个节点；这意味着在线推理时，单次节点查询需要实时触及大规模的多跳邻居，邻居收集与内存访问开销对延迟的影响随图规模急剧上升。

在基础模型层面，图卷积网络（GCN，Kipf & Welling，2017**?**）通过归一化邻接矩阵的递归乘法实现低通谱滤波，单次全图前向传播复杂度为 $O(L \cdot m \cdot d)$，其中 m 为有向边数，d 为嵌入维度；图注意力网络（GAT，Veličković 等，2018**?**）引入多头注意力机制动态加权邻居消息，但注意力权重仍需在每条相邻边上计算与归一化，推理代价并未实质性降低；图同构网络（GIN，Xu 等，2019**?**）在理论上达到 1-WL 图同构测试的区分能力上界，然而这一理论完备性的代价是更复杂的聚合操作。上述模型在精度与表达能力上各有优势，但均未从根本上解决感受野指数扩张所带来的在线推理效率制约。

除效率问题外，GNN 还面临两类固有的深度局限。随着层数增加，过平滑（Over-smoothing，Li 等，2018**?**）问题使各节点表示趋于同质，区分能力退化；过压缩（Over-squashing，Alon & Yahav，2021**?**）问题则导致远端节点的信息在瓶颈处被压缩丢失，使长程依赖难以有效传递。这两类局限共同决定了实际部署中 GNN 层数通常维持在 2–3 层，感受野的有效扩展因此受到天然约束。这一背景构成了高效稀疏化方法的直接动机：与其放弃多层叠加的表达能力，不如在推理阶段以紧凑的稀疏表示替代逐层聚合的完整计算。

1.2.2 高效与稀疏图神经网络方法

针对感受野扩张带来的推理效率瓶颈，现有方法大致沿三条技术路线展开：邻居采样加速、预计算线性化，以及以 SDGNN 为代表的稀疏分解。这三条路线的演进逻辑清晰，每一步均尝试在保留更多表达能力的同时进一步压低推理开销。

邻居采样加速路线是最早被广泛采用的方向。GraphSAGE（Hamilton 等，2017**?**）对每个节点随机采样固定数量的邻居，将感受野从 $O(\bar{d}^L)$ 压缩至 $O(k^L)$（k 为采样邻居数），首次实现了大规模图上的归纳式学习。FastGCN（Chen 等，

2018?）将采样粒度从节点级提升为层级，在每层独立对固定数量节点进行重要性采样，避免了邻域的逐层指数扩张。GraphSAINT（Zeng 等，2020?）以完整子图为训练单元，通过归一化技术补偿采样偏差，进一步改善了估计质量。然而，这些方法主要加速的是训练阶段；推理时往往仍需访问完整邻居集合，否则会引入额外的随机性偏差。此外，采样策略通常是全局均匀或基于度数的固定规则，难以根据节点的局部拓扑特性做出差异化选择。

预计算线性化路线通过将图传播操作从模型训练循环中解耦，获得了更彻底的推理加速。简化图卷积（SGC，Wu 等，2019?）移除层间非线性激活，将 L 层 GCN 等价为 $\tilde{A}^L XW$ 的线性映射；预计算步骤仅需在离线阶段完成一次，推理时直接利用已缓存的传播特征矩阵。APPNP（Klicpera 等，2019?）将个性化 PageRank 传播与特征变换彻底解耦，支持在推理时以迭代形式近似长程传播，同时保持较低的计算开销。SIGN（Frasca 等，2020?）预计算多阶近邻聚合特征并拼接为多尺度表示，推理时仅需执行一次轻量变换。这类方法的推理复杂度显著低于逐层传播方案，但其传播模式完全固化于预计算阶段，无法根据不同节点的结构差异进行自适应调整。

稀疏分解路线是最新的发展方向，代表性工作 SDGNN（Hu 等，2024?）是本文的直接出发点，有必要在此较为完整地介绍其核心思路。SDGNN 的基本洞察是：教师 GNN 的节点表示矩阵 $H^* = \phi(A, X; W^*)$ 可以被稀疏权重矩阵 Θ 与特征变换矩阵 $\tilde{\Phi}$ 的乘积所近似，推理形式可表示为 $\hat{H} = \Theta^\top \tilde{\Phi}$。训练阶段分为两个交替更新的阶段：Phase Θ 阶段固定 $\tilde{\Phi}$，以全局统一正则系数 λ_1 为超参数构建每个节点的 Lasso 子问题，由 LARS 求解器精确控制每个节点稀疏权重中的非零元素数量；Phase W_ϕ 阶段固定 Θ，以梯度下降更新特征变换参数。推理阶段仅需执行一次稀疏矩阵乘法，将推理主项复杂度降至 $O(n\bar{k}d)$，其中 $\bar{k}$ 为稀疏分解后每个节点保留的平均非零权重数，满足 $\bar{k} \ll \bar{d}^L$。

SDGNN 的关键局限在于其全局统一正则系数 λ_1 对所有节点施加相同的稀疏压力。在真实图中，节点的拓扑特性往往存在量级差异，以相同的 λ_1 统一控制所有节点的稀疏预算，必然对高度数节点过度稀疏化（丢失关键邻居信息）或对低度数节点过度保留（浪费稀疏化潜力）。此外，SDGNN 仅面向静态图，训练完成后权重矩阵 Θ 固化存储，图演化时需要重新完整训练；其设计也未考虑噪声边对稀疏分解质量的干扰。上述不足构成了第 3 章进一步设计节点级自适应稀疏机制的直接动机。

1.2.3 异配性图学习与谱视角方法

GNN 的主流设计假设中，相连节点倾向于拥有相同的标签（即同配性假设）。然而，许多真实图数据集中，节点更频繁地与标签不同的节点相连，这一特征被

称为异配性（heterophily）。异配性与同配性的并存对基于谱滤波的图学习方法提出了额外挑战。

边级同配率 h_{edge} 定义为连接同类标签节点的边占所有边的比例，取值范围为 $[0,1]$：h_{edge} 趋近于 1 时为强同配图（如引用网络、共购图），趋近于 0 时为强异配图（如网页链接图、部分社交图）。以标准 GCN 为代表的低通滤波 GNN 在同配图上有合理的理论依据，但在异配图上，低通滤波会将异类邻居信息混合至目标节点，导致类别边界模糊，预测性能显著下降**?**。

针对异配图的代表性方法从不同角度尝试突破低通滤波的限制。H2GCN（Zhu 等，2020**?**）将节点自身表示与邻居聚合表示分离，并组合多阶邻域的聚合结果，使模型得以同时利用局部与高阶结构信息。GPR-GNN（Chien 等，2021**?**）学习一组全图共享的广义 PageRank 权重，支持同时保留低频（对应同配）和高频（对应异配）分量，其权重通过端到端优化自适应调整。FAGCN（Bo 等，2021**?**）设计了低通与高通自适应滤波器组合，允许不同节点以不同比例融合两种频率成分，在异配图上表现出明显改善。LINKX（Lim 等，2021**?**）将特征变换与邻接矩阵传播彻底分离处理，适用于度分布极不均匀的大规模异配图。GloGNN（Li 等，2022**?**）提出全局-局部双层损失，以联合约束的形式兼顾全局类别一致性与局部异配特征。ACM-GCN（Luan 等，2022**?**）通过自适应频道混合机制，在低通、高通与单位变换三种聚合模式之间动态插值。

这一方向的共同局限在于，多数方法采用全图共享的频率权重或滤波参数，节点级的频率自适应能力不足。在度分布极不均匀的图上，不同节点在频率域内的参与程度本就存在量级差异，全局共享的频率参数难以对这种差异做出精细响应。第 3 章将在这一背景上进一步构造依赖同配率的节点级频率权重修正机制，使自适应稀疏化在同配与异配两类图结构上均具备更严格的解释基础。

1.2.4 图结构学习、鲁棒性增强与置信度估计

真实世界的图数据普遍存在结构质量缺陷：社交网络中的机器人账号产生大量噪声关注链路，知识图谱中自动信息抽取引入错误关系三元组，生物网络中实验误差导致假阳性相互作用。依赖固定图结构进行训练和推理的 GNN 模型，在噪声边比例较高时性能往往出现明显下滑，这一现象推动了图结构学习和鲁棒 GNN 两类研究方向的发展。

图结构学习（Graph Structure Learning，GSL）旨在从数据中推断比观测图更优的图拓扑，通过结构优化提升下游任务性能。IDGL（Chen 等，2020**?**）以度量学习的方式在节点嵌入空间中迭代优化图结构与节点表示，在多个数据集上优于仅使用原始图结构的基线，但其核心计算步骤的复杂度为 $O(n^2)$，在百万节点规模的图上难以直接应用。SLAPS（Fatemi 等，2021**?**）引入自监督损失联合学

习图结构，降低了对标签的依赖。SUBLIME（Liu 等，2022?）通过对比学习目标在无监督场景下优化图拓扑，展示了结构学习与自监督学习结合的可行路径。总体而言，现有图结构学习方法的计算复杂度较高，与稀疏分解框架的低复杂度目标存在明显冲突。

鲁棒图神经网络从防御视角出发，专注于降低噪声边与对抗攻击对模型性能的负面影响。Pro-GNN（Jin 等，2020?）将干净图建模为低秩矩阵与稀疏噪声之和，通过正则化约束求解净化后的邻接矩阵，在结构攻击实验中显著提升了鲁棒性。GNNGuard（Zhang & Zitnik，2020?）基于特征相似度对邻居权重进行自适应调整，相似度低的邻居被赋予较小权重，从而削弱噪声边的影响。上述方法均有一个共同特点：鲁棒性增强模块作为独立的预处理或正则化步骤运行，尚未与高效稀疏分解推理框架在一个统一的优化目标下协同设计。

图对比学习为边置信度估计提供了重要的方法论工具。GRACE（Zhu 等，2020?）通过图增强构造正负样本对，以 InfoNCE 损失最大化同一节点在不同增强视图下嵌入的互信息，学习到不依赖标签的高质量节点表示。GraphCL（You 等，2020?）系统比较了多种图增强策略在对比学习中的效果。BGRL（Thakoor 等，2022?）进一步去除了负样本，以自举（bootstrapping）的方式降低计算开销。从置信度估计的视角来看，对比学习预训练得到的节点嵌入之间的余弦相似度可作为边可靠性的启发式代理量，该思路无需标签信息，计算代价相对轻量，可为第 4 章边置信度估计提供方法背景。

贝叶斯不确定性量化提供了另一条量化边置信度的技术路径。MC Dropout（Gal & Ghahramani，2016?）将训练阶段的 Dropout 视为近似贝叶斯推断，推理时保持 Dropout 激活并进行多次前向传播，以预测结果的方差衡量认知不确定性。证据深度学习（Evidential Deep Learning，Sensoy 等，2018?）则以 Dirichlet 分布参数化输出层，以证据量的倒数直接输出不确定性估计，无需多次采样。第 4 章将结合对比学习与贝叶斯不确定性两条路径，设计双模态边置信度估计框架。

1.2.5 动态图学习与增量更新方法

真实世界中的图数据大多以持续演化的形式存在：社交网络每时每刻有新用户注册和关注关系建立，金融交易图以秒级频率产生新交易记录，交通传感器网络的拓扑结构和采集信号同步更新。这对静态图假设下训练的推理模型提出了根本性挑战。

离散时间动态图方法将图演化建模为时间快照序列，在每个时间步维护完整的静态图表示并通过序列模型传递时序依赖。EvolveGCN（Pareja 等，2020?）以循环神经网络演化 GCN 的权重矩阵，使模型参数本身随时间自适应变化，提出了 EvolveGCN-H 与 EvolveGCN-O 两种变体，分别对权重矩阵作不同粒度的演

化建模。DySAT（Sankar 等，2020**?**）通过结构注意力与时序注意力的双重机制联合建模节点在空间上的邻域特征和时间上的历史变化。这类方法的主要制约在于：每个时间步都需要完整处理当前快照，当快照规模较大或时间步较多时，累积计算开销难以控制。

连续时间动态图方法直接以时间戳事件流为输入，可以精确建模事件发生的时刻。时序图网络 TGN（Rossi 等，2020**?**）为每个节点维护一个持续更新的记忆向量，通过消息传递机制将时序交互信息融入节点记忆，在多个大规模动态图基准上取得了当时最佳结果。时序图注意力网络 TGAT（Xu 等，2020**?**）设计了函数时间编码，以 Bochner 定理为理论基础将时间间隔映射至高维随机特征空间，再结合图注意力聚合时序邻居。JODIE（Kumar 等，2019**?**）聚焦用户-物品交互轨迹预测，通过投影操作估计节点在未来时刻的嵌入位置。这些方法的共同局限在于：在线推理往往仍需访问时序邻居、历史记忆或事件窗口，实际时延会随事件密度增加而上升，尚未与稀疏分解式的单次稀疏推理框架有效结合。

灾难性遗忘与持续学习是动态图模型需要面对的另一核心挑战。弹性权重固定（EWC，Kirkpatrick 等，2017**?**）通过 Fisher 信息矩阵近似估计参数对已习得知识的重要性，为重要参数添加二次惩罚项，从而在更新新任务的同时保护旧知识。梯度情景记忆（GEM，Lopez-Paz 等，2017**?**）在历史任务的样本缓冲区上施加梯度约束，确保参数更新方向不破坏对历史数据的预测性能。这两类方法在通用持续学习场景中被广泛验证，但在稀疏分解框架下如何设计轻量化的历史缓冲区策略，仍缺乏针对性研究。第 5 章将在上述背景的基础上，探索面向稀疏分解框架的增量维护方案，并以经验趋势和数量级估算的诚实口径评估其效果。

1.2.6 现有方法的共同局限与本文的研究机遇

综合梳理上述五条文献脉络，可以提炼出三条在现有方法中难以同时满足的研究空白，这三条空白与本文三个核心方法章节的研究动机一一对应。

研究空白一：节点级自适应稀疏化的谱理论框架尚未建立。现有高效 GNN 方法或采用全局统一的稀疏控制参数（如 SDGNN 的 λ_1），或依赖启发式的固定采样规则（如 GraphSAGE 的随机邻居采样），均未将节点的谱域参与程度与其最优稀疏预算之间的关系加以系统理论化。异配图场景下频率响应设计的特殊性虽已受到关注，但尚无研究在稀疏分解框架内将同配率感知的频率权重调整与节点级稀疏预算的差异化分配统一考虑。第 3 章针对这一空白展开研究。

研究空白二：稀疏分解框架内的结构质量控制机制尚未建立。图结构学习与鲁棒 GNN 方法虽能有效改善噪声图上的性能，但其核心操作（低秩分解、$O(n^2)$ 度量学习等）与线性推理复杂度的目标不相容，两类方法至今未能在同一框架下协同设计。边置信度估计工具（对比学习、贝叶斯不确定性）提供了轻量化

的结构质量评估途径，但其与稀疏权重学习的联合优化问题仍未得到系统研究。第 4 章针对这一空白展开研究。

研究空白三：静态稀疏分解框架向动态图场景的扩展路径尚未探索。动态 GNN 方法（TGN、EvolveGCN 等）以维护稠密图结构为前提，推理复杂度未得到有效降低；以 SDGNN 为代表的稀疏分解方法仅面向静态图，图发生演化时需要完整重训练。如何利用图演化的局部性——大多数节点和边在相邻时间步内保持稳定——以低于完整重训练的代价实现稀疏权重的增量式维护，目前还缺乏专门的方法论设计。第 5 章作为探索性研究，针对这一空白提供初步的技术路径分析。

上述三条研究空白的识别，为后续各章的方法设计提供了清晰的问题定位。表 **??** 从“核心问题—SDGNN 局限来源—对应章节—关键输出—对后续章节的作用”五个维度，系统呈现了三条空白与本文研究主线的对应关系。

表 1.2　本文核心问题、对应章节与章间作用关系

核心问题描述	SDGNN 局限来源	章节	关键输出（高层描述）	对后续章节的作用
统一稀疏预算忽视节点间拓扑异质性与同配/异配差异，导致不同类型节点难以获得匹配的稀疏保留强度	局限一：全局统一稀疏预算	第 3 章	构建谱驱动的节点级自适应稀疏机制，从频率、节点和跳距三个维度对稀疏预算进行差异化分配	为后续结构质量控制与时序维护提供静态稀疏推理基底
原始观测图被默认视为完全可信，噪声边抑制与缺失边补充机制缺失，导致稀疏模式易受结构质量偏差干扰	局限二：缺乏图结构质量控制	第 4 章	构建边置信度估计、软门控精化和缺失边增强的统一结构学习机制	为后续动态图场景提供可持续维护的结构状态与边质量信息
稀疏权重与结构质量变量在训练后静态固化，图演化时只能依赖完整重训练，难以满足高频更新场景的代价约束	局限三：静态推理参数无法适应图演化	第 5 章*	构建影响范围识别、分层更新决策和时序状态维护机制	在第 6 章中以动态辅线形式接受方向性实证检验

* 第 5 章定位为探索性研究，理论分析以经验趋势和数量级估算为主，不宣称对动态图学习的理论闭合。
注：本表仅呈现“问题来源—对应章节—章间作用”的高层关系，不在绪论中提前给出后续章节的正式符号与完整复杂度细节。

本节从与 MSAS-GNN 各核心模块直接相关的五条文献脉络出发，归纳出三条在现有方法中难以同时满足的研究空白：节点级自适应稀疏化的谱理论框架缺失、稀疏化框架内结构质量控制机制缺失、静态稀疏分解框架的动态图扩展路径缺失。这三条空白与下一节所界定的核心研究问题之间存在直接的一一对应

关系，是整个研究设计的文献依据所在。

1.3 研究问题界定、主要研究内容与创新点

本节在前两节研究背景与国内外研究现状分析的基础上，进一步明确本文所要解决的核心问题及其边界，概述三条研究主线的内容与相互衔接逻辑，并归纳主要创新点。所有具体推导、算法设计与实验分析统一在后续各章展开，本节仅给出定性的高层描述。

1.3.1 研究问题界定与总体目标

第**??**节的文献梳理揭示了三条至今仍未被同时满足的研究空白。追溯这三条空白的来源，可以发现它们本质上对应于 SDGNN 设计中三项被隐式接受的关键假设**?**。这三项假设共同构成了 SDGNN 在复杂真实场景中保持有效性的隐含适用前提，而非其线性推理复杂度本身的数学前提；当真实部署场景不完全满足上述假设时，模型的精度、鲁棒性与可维护性会出现对应退化。

第一项假设是图中所有节点共享相同的最优稀疏预算。SDGNN 以全局统一正则系数 λ_1 控制每个节点 Lasso 子问题中的非零元数量，这实际上将节点的最优稀疏度视为一个与个体拓扑特性无关的全局常量。然而，真实图中节点之间在度分布、局部连通性和频率域参与程度上的差异往往跨越数个数量级：枢纽节点通常承载更多跨社区或长程结构信息，若对这类节点过度稀疏化，更容易造成关键信息截断；部分外围节点的邻域结构更为局部化，过于保守的稀疏化会削弱可压缩空间的释放。这一差异在异配图中尤为突出——异配图的高频结构信号与同配图的低频传播假设相抵牾，统一参数对此无从区分。

第二项假设是输入图的结构完全可信，即观测到的边均为真实有意义的连接，且不存在重要的缺失边。SDGNN 直接在原始邻接矩阵上求解稀疏分解，这意味着噪声边和缺失边均未经任何质量评估便被无差别地纳入分解过程。当图结构质量存在缺陷时，学得的稀疏权重分布会随之失真，最终影响推理精度与可靠性。

第三项假设是图结构与节点特征在推理周期内保持静态。SDGNN 将训练后的稀疏权重矩阵固化存储，在图发生任何演化时，均需重启完整的训练流程。在真实动态场景中，图演化往往具有高度的局部性，受影响的节点和边仅占全图的一小部分；完整重训练既丢弃了已习得的知识，又无法利用这种局部性来控制更新代价。

基于上述分析，本文的核心研究问题可表述为：**在保持静态推理主项复杂度口径 $O(n\bar{k}d)$ 不变的前提下，如何围绕节点拓扑异质性与图结构质量缺陷这两类**

核心约束建立可落地的扩展机制，并进一步探索面向图动态演化的低代价维护路径，使 MSAS-GNN 在高效推理之外兼具更强的自适应性、鲁棒性与时序适应能力？

围绕这一问题，本文以“在保持静态推理主项复杂度口径不变的前提下，优先完成静态场景下的自适应扩展与结构质量控制，并在此基础上探索动态图场景的低代价维护路径”为总体目标。三条研究主线之间存在明确的输入-输出衔接关系：第 3 章面向静态可信图，建立谱驱动的节点级自适应稀疏参数体系，输出固化的稀疏推理参数，作为第 4 章结构质量修正的基础输入；第 4 章在放松“图结构完全可信”假设后，通过边置信度估计与软性修正机制提升稀疏分解对结构噪声与缺失的适应性，并为第 5 章的时序扩展提供可持续维护的结构状态基础；第 5 章在前两章静态框架的基础上，探索面向图演化场景的增量维护方案，以较低的代价响应图的局部变化。三条主线协同作用，在第 6 章的受控实验中接受综合验证。

1.3.2 主要研究内容

本文的主要研究内容分三个模块展开，各模块围绕上述核心问题的一个子问题展开，章间形成清晰的递进式研究链条。

第一个研究模块（对应第 3 章）：在静态可信图上建立谱驱动的多尺度自适应稀疏分解方案。

这一模块的出发点是：SDGNN 的全局统一正则系数对不同节点施加相同的稀疏压力，其根源在于缺乏从图结构中提取节点级差异化信息的量化工具。本文从归一化拉普拉斯矩阵的谱分解出发，引入节点谱能量的概念，将节点在各频率分量上的参与程度量化为可计算的图谱特征，并以此作为差异化分配稀疏预算的理论依据。

在具体设计上，本研究沿三个维度将全局统一的稀疏参数推广为三维自适应参数体系。其一为**频率维度**：不同类型的图（同配图与异配图）具有截然不同的信号频率分布模式，低频主导的聚合假设在异配图上并不成立。本文通过分析节点的同配系数与其在频率域的能量分布之间的关系，建立一套能够区分同配与异配两类场景的频率权重调整机制。其二为**节点维度**：基于上述频率权重修正后的节点谱能量，本文推导出每个节点的差异化正则系数，建立“谱能量高的节点应保留更多邻居，谱能量低的节点可更激进地稀疏化”的设计原则，并综合考虑度中心性、k-core 指数等拓扑因子，形成多维度融合的节点级参数。其三为**跳距维度**：随着跳距增加，邻域信息对目标节点表示的有效贡献呈衰减趋势，不同跳距的邻居应获得不同的预算配额。本文基于信息衰减规律，将节点总预算在各跳距之间进行递减式分配，使一跳邻居保留更多、远跳邻居保留更少。

通过三个维度的协同设计，本模块最终输出一套固化的节点级稀疏推理参数，推理阶段仍执行单次稀疏矩阵乘法，保持与 SDGNN 相同的 $O(n\bar{k}d)$ 推理主项复杂度口径。相关算法的完整形式化与理论分析（包括误差界与谱相似性保证）在第 3 章中展开，本章不预先给出具体公式。

第二个研究模块（对应第 4 章）：在含噪声与缺失边的图上建立置信度引导的结构质量控制机制。

这一模块在第 3 章所建立的稀疏分解框架基础上，进一步放松“图结构完全可信”的假设，解决噪声边和缺失边带来的稀疏分解失真问题。核心思路是：在执行稀疏分解之前，先对图中每条边的可靠性进行量化评估，再以边的置信度作为软性权重，对稀疏学习过程施加结构质量约束，使高可靠性的边获得更多保留机会，低可靠性的噪声边被相应削弱。

在边置信度的估计路径上，本研究同时采用两条技术路径：**对比学习路径**通过自监督预训练获得高质量的节点嵌入表示，以节点嵌入之间的相似度作为边可靠性的代理量，这一路径无需标签信息、计算代价相对轻量；**贝叶斯不确定性路径**通过近似贝叶斯推断量化节点预测的认知不确定性，不确定性较高的节点之间的连接通常意味着邻域质量存在疑问，可据此评估边的可靠程度。两条路径各有侧重，互为补充，可根据场景需求灵活组合。

在置信度的使用方式上，本研究采用软性边权调节机制而非硬性剪枝，以连续的调节因子对稀疏权重进行修正，避免了不可逆的硬性错误。与此同时，本研究还设计了候选缺失边的补充策略，通过特征空间的相似性搜索识别高置信度的潜在缺失边，在稀疏图上补充结构信息。将置信度估计、稀疏权重修正与缺失边增强三个子问题纳入联合优化框架，以不突破线性推理复杂度口径为约束，构成本模块的主要研究内容。

第三个研究模块（对应第 5 章，定位为探索性研究）：面向图动态演化场景，探索稀疏分解框架的增量维护扩展方案。

这一模块针对第 3–4 章静态框架的局限性——图演化后需要完整重训练——展开探索性研究。其核心思路是：当图发生局部变化时，受实质影响的节点和边仅占全图的一小部分，大多数节点的稀疏权重在相邻时间步之间保持稳定，无需重新计算。基于这一图演化局部性的观察，本研究设计了受影响范围分析方法，通过跟踪图拓扑变化的传播范围来确定哪些节点的参数需要更新、哪些节点的参数可以复用。

在参数更新策略上，本研究提出分层更新决策机制：根据图变化的规模和影响范围，在局部精细更新、近似快速更新与触发全局重训练三种路径之间自适应切换，以影响节点占全图的比例作为决策依据。为应对持续更新可能引发的参数遗忘问题，本研究引入历史缓冲区策略，保留关键历史样本以约束参数更新方

向，缓解灾难性遗忘对已习得知识的侵蚀。此外，本研究将第 4 章的静态边置信度扩展为随时间增量维护的时序置信度，使边的可靠性评估能够随图演化持续更新。

需要特别说明的是，这一研究模块在全文中定位为探索性研究：相关理论分析以经验收敛趋势和数量级估算为主要口径，不宣称对动态图学习的理论闭合；相关实验在第 6 章采用“静态主线 + 动态辅线”的双轨协议进行验证，其中动态辅线以方向性探索为目的，不以达到最优静态性能为目标。

1.3.3 主要创新点

综合上述三个研究模块，本文的主要创新点归纳如下。

创新一：提出谱驱动的三维自适应稀疏参数体系。现有高效 GNN 方法在稀疏化参数设计上以全局统一参数为主，既未将节点在频率域的参与程度与其最优稀疏预算相联系，也未对同配与异配两类图的不同频率响应特性给予区分对待。本文从图谱理论出发，将节点的谱域特征与稀疏预算分配之间的关系加以系统量化，提出兼顾频率维度、节点维度和跳距维度的三维自适应参数体系，并引入同配系数感知的频率权重调整机制，使稀疏化方案在同配与异配两类图结构上均具备明确的理论依据。这一设计从图结构可计算的谱特征出发推导稀疏预算，为高效推理的参数分配提供了比启发式调参更具可追溯性的路径（详见第 3 章）。

创新二：建立稀疏分解框架内的边置信度双路径估计与软性调节机制。现有的鲁棒图神经网络方法与高效稀疏化方法在研究路线上长期相互独立，前者的核心操作通常与线性推理复杂度目标不兼容，两者在同一框架下的协同设计尚未得到系统探索。本文将对比学习路径与贝叶斯不确定性路径相结合，构建双模态边置信度估计框架，并以软性调节机制将置信度引入稀疏权重的修正过程。从图信号平滑性角度揭示了软性调节的内在优化目标，分析了其对噪声边与缺失边的容忍性质，在不突破高效推理复杂度口径的前提下，为稀疏分解框架引入结构质量控制维度（详见第 4 章）。

创新三：探索稀疏分解框架向动态图场景的时序增量扩展方案。以 SDGNN 为代表的稀疏分解方法迄今均面向静态图，与动态图学习方法之间缺乏有效衔接。本文以图演化的局部性为核心观察，设计受影响范围分析方法和分层更新决策机制，并引入历史缓冲区策略控制参数遗忘，同时将静态边置信度推广为可增量维护的时序版本。这一设计探索了稀疏推理框架向动态图场景延伸的技术路径，将静态稀疏分解推理的高效性优势与增量学习的低代价维护目标相结合，为此方向后续研究提供了初步的方案参考。该部分定位为探索性研究，在第 6 章通过双轨实验协议给出方向性实证支持（详见第 5 章）。

本节从 SDGNN 设计中三项被隐式接受的关键假设出发，将本文的研究问题加以精确界定；三条研究主线的逻辑关系清晰：第 3 章为第 4 章提供可修正的稀疏推理基础，第 4 章为第 5 章提供可持续维护的结构质量状态，第 5 章在前两章基础上完成时序扩展的探索。三条主要创新点分别对应上述三条研究主线，各创新点与后续方法章节之间存在一一对应的支撑关系。下一节将在此研究框架的基础上，交代全文的整体技术路线与章节组织结构。

1.4 技术路线与论文组织结构

前三节从研究背景与意义、国内外研究现状以及研究问题界定三个层面，为 MSAS-GNN 框架的提出建立了完整的动机脉络。本节在此基础上，从宏观视角进一步说明全文的整体技术路线与各章节的功能定位，阐明研究设计背后的结构逻辑，并交代章间关键接口关系，使读者在进入具体方法推导之前形成对全文脉络的整体认知。

1.4.1 整体技术路线

本文的研究设计以“在保持静态推理主项复杂度口径不变的前提下，逐步放宽 SDGNN 的关键适用假设”为总体思路，将研究问题从约束条件较强的场景向更复杂的场景递进展开。具体而言，本文采用“先建立静态稀疏推理基础，再补入结构质量控制，最后探索时序维护扩展”的组织顺序：第 3 章首先解决统一稀疏预算对节点差异刻画不足的问题，为后续章节提供可复用的静态推理基底；第 4 章在此基础上进一步放松“图结构可信”假设，引入结构质量评估与修正机制；第 5 章以前两章形成的静态框架为起点，探索其向动态图维护场景的延伸路径。这样的安排使各章之间具有清晰的承接关系，也有助于界定每一章的贡献边界。

从全文七章的整体组织来看，可以识别出四个功能层次。**第一层次**是研究背景与理论铺垫，由第 1 章和第 2 章共同构成：第 1 章确立研究动机、归纳文献空白、界定研究问题；第 2 章建立后续各章所需的基础理论工具与代表性方法背景，同时建立全篇复用的基础符号体系。**第二层次**是 MSAS-GNN 的核心方法链，由第 3 章至第 5 章依次构成，三章在逻辑上形成一条从静态可信图上的自适应稀疏推理，到存在结构质量缺陷的静态图，再到动态演化图的渐进扩展路径。**第三层次**是实验评估，由第 6 章承担，以“静态主线 + 动态辅线”的双轨结构，将前序三章的方法主张转化为可核验的量化结论。**第四层次**是全文总结与反思，由第 7 章完成，区别于通常仅做贡献罗列的结论章，本章将诚实评估各方法模块的理论假设边界、近似间隙及实验覆盖的局限，并基于这些局限性分析给出具有

明确技术指向的后续研究方向。

贯穿全文方法设计的核心效率参照，是第 3 章和第 4 章静态推理阶段的聚合主项复杂度 $O(n\bar{k}d)$（其中 $\bar{k}$ 为各节点平均非零预算）。这一复杂度口径对应 SDGNN 的单次稀疏矩阵乘推理范式，也是本文在静态场景下保持高效推理优势的基本约束。第 3 章在保持这一口径的前提下提升了节点自适应能力，第 4 章在此基础上补入结构鲁棒性；第 5 章则以该口径为参照，讨论图演化后的单步更新代价能否显著低于全量重训练与全图重算。

三条核心方法主线之间的具体接口关系如下：第 3 章负责建立静态可信图上的节点级自适应稀疏参数体系，训练结束后将稀疏权重矩阵固化，这一固化参数及其所依赖的谱近似误差分析工具，构成第 4 章展开结构质量修正的直接起点；第 4 章以固化的稀疏权重为输入，通过双路置信度估计对各边的可靠性加以量化，以软门控机制对权重进行调节，并输出修正后的图结构状态与边置信度，这些量化结果又直接构成第 5 章时序置信度增量维护的初始化基础；第 5 章则以第 3–4 章建立的静态稀疏框架为出发点，通过影响范围分析和分层更新策略在图发生局部演化时选择性地更新受影响节点的参数，复用未受影响节点的历史结果。这条从“构建稀疏基础 → 修正结构质量 → 维护时序演化”的接口链，确保了各章贡献在方法层面的内在一致性，也使得第 6 章能够在统一框架下同时验证三个模块的有效性。

【占位图 1.2】

图题：MSAS-GNN 全文技术路线与章节接口图。

表达内容：图采用纵向流程结构，从上至下依次展示第 1 章（绪论，明确问题来源与研究边界）→ 第 2 章（相关工作，提供理论背景与文献基础）→ 第 3 章（谱驱动多尺度自适应稀疏分解）→ 第 4 章（边置信度引导的结构质量控制）→ 第 5 章（时序动态图上的增量协同演化机制）→ 第 6 章（系统实验评估）→ 第 7 章（总结与展望）；第 3 至 5 章用横向括号统一标注为“MSAS-GNN 核心方法链”；各章之间的连接箭头仅标注关键接口与逻辑关系，包括“第 3 章输出固化稀疏推理参数 → 第 4 章结构质量修正”、“第 4 章输出增强图结构与边置信度 → 第 5 章时序增量维护”、“第 3–5 章方法主张 → 第 6 章系统验证”；第 5 章右侧注明“探索性研究”定位；背景章节（第 1–2 章与第 6–7 章）与方法章节（第 3–5 章）采用不同底色区分；静态推理复杂度口径 $O(n\bar{k}d)$ 在方法链底部标注为第 3 章与第 4 章的统一效率准绳。

图 1.2　MSAS-GNN 全文技术路线与章节接口图

1.4.2 论文组织结构

本文各章的具体功能定位、核心研究内容与章间逻辑关系如下，各章描述遵循“功能定位 → 核心研究内容 → 关键输出接口”的叙述顺序，不预先给出各章中正式定义的定理、算法编号或具体公式符号。

第 1 章为绪论，即本章，承担为全文建立研究动机与问题框架的任务。本

章从 GNN 在大规模在线推理场景中的效率瓶颈切入，分析 SDGNN 以单次稀疏矩阵乘替代多层消息传递推理这一核心思路的贡献边界，并深入审视其隐含的三项关键设计假设，识别出相应的三项结构性局限。研究现状综述围绕五条与 MSAS-GNN 三大核心模块直接相关的文献脉络展开，在系统梳理代表性方法的设计思路与局限的基础上，归纳三条尚待填补的研究空白。在此基础上，本章明确本文的核心研究问题与总体目标，概述三条研究主线的内容与章间衔接逻辑，并归纳主要创新点。

第 2 章为相关工作，系统梳理支撑 MSAS-GNN 各核心模块的背景理论与代表性方法，其核心功能是为后续三章建立统一的理论基础与符号体系，确保各方法章在使用某一背景工具时无需重新引入定义。本章围绕五条文献脉络依次展开：GNN 基础模型与在线推理效率问题，从消息传递框架与谱图理论两个层面建立全篇复用的基础符号体系，引入归一化拉普拉斯矩阵、谱间隙、多项式谱滤波器与 Lanczos 近似算法等核心背景概念；高效与稀疏 GNN 方法，重点介绍 SDGNN 稀疏分解框架的技术细节及其全局统一正则系数的结构性缺陷；异配性图学习与谱视角方法，揭示低通滤波主导的聚合机制在异配图上的频率响应错配问题；图结构学习、鲁棒图神经网络与置信度估计，引入图信号 Dirichlet 能量作为边可靠性分析的理论背景；动态图学习与增量更新，为第 5 章探索性时序扩展提供方法参照与理论工具。

第 3 章围绕静态可信图上的高效自适应稀疏推理展开，是全文方法链的逻辑基础与规模最大的章节。本章在保留 SDGNN 单次稀疏矩阵乘推理形式的前提下，从频率偏好、节点差异和跳距层次三个方面构建节点级差异化稀疏预算机制。训练完成后，本章输出供推理阶段使用的固化稀疏权重及相关分析工具，在保持静态推理主项复杂度口径不变的前提下提升自适应性；这些结果将作为第 4 章结构质量修正的直接输入，并在第 6 章主实验中作为核心比较对象接受评估。

第 4 章在放松“图结构完全可信”假设后展开，为第 3 章框架补充结构质量控制维度，是全文鲁棒性方面的核心章节。本章的核心思路是：在稀疏分解过程中加入边可靠性评估与连续式结构调节机制，对低可靠性连接加以抑制、对高可靠性潜在关联加以补充。为此，本章采用对比学习与不确定性量化相结合的双路边可靠性估计方案，并将边质量评估、稀疏权重修正和缺失边增强纳入统一的联合优化框架。其直接输出是经过质量修正的结构状态及边级可靠性信息，前者将在第 6 章鲁棒性实验中接受验证，后者则为第 5 章的时序维护提供初始化基础。

第 5 章在第 3–4 章静态框架基础上进行时序扩展，面向图演化场景探索稀疏分解框架的低代价维护方案，在全文中明确定位为探索性研究。围绕图演化的局部性这一核心观察，本章从影响范围识别、分层更新决策、历史信息保留与边级

状态持续维护四个方面展开设计，使不同规模的变化对应不同粒度的维护路径。需要强调的是，本章理论分析以经验收敛趋势与数量级估算为主要口径，不宣称对动态图场景给出完备理论闭合；相关实验在第 6 章动态辅线中仅作方向性验证。

第 6 章进行全面实验评估，承担将前序三章方法主张转化为可量化、可对比结论的核心任务。实验设计采用静态主线与动态辅线双轨结构，静态主线在同配图（Cora、Citeseer、PubMed）、异配图（Chameleon、Squirrel）与大规模图（ogbn-arxiv）上开展节点分类主实验，并依次进行逐模块消融分析、鲁棒性实验以及效率分析，关键超参数的敏感性分析进一步说明各核心参数对最终性能的影响程度；动态辅线在合成流式快照与公开动态图基准上对第 5 章方案进行方向性验证，以“探索性验证”为口径，不以达到静态最优性能为目标。

第 7 章总结全文工作，以“研究工作总结 → 主要创新点归纳 → 研究局限性与适用边界说明 → 未来研究方向展望”的结构组织。研究局限性分析是本章的重要组成部分，对各方法模块的假设边界、近似间隙及实验覆盖的局限加以诚实评估。未来研究方向展望基于上述局限性分析，指出多个具有明确技术路径的后续方向。

本节从宏观视角交代了全文的整体技术路线与章节组织逻辑。全文研究设计以“逐步放宽 SDGNN 三项设计假设”为主线，三条核心方法主线沿“构建稀疏基础 → 修正结构质量 → 维护时序演化”的方向依次递进，以推理复杂度约束 $O(n\bar{k}d)$ 为共同准绳；各章通过固化参数 → 置信度修正 → 时序维护的接口传递完成逻辑闭合，如图 **??** 所示。

1.5 本章小结

作为全文的绪论，本章承担的四项任务——研究背景与意义的阐明、国内外研究现状的系统梳理、研究问题与创新点的界定、技术路线与章节结构的说明——已随前四节的推进依次完成。本节在回顾各节核心工作的基础上，进一步梳理它们之间的内在逻辑关系，并说明第 2 章在全文中所承担的完整的理论铺垫与相关工作综述功能。

本章的叙述起点是 GNN 在大规模在线推理场景中面临的效率瓶颈。L 层 GNN 的有效感受野可达 $O(\bar{d}^L)$ 量级，多跳邻居收集与内存访问开销随层数快速放大，成为制约在线部署的根本性约束。第**??**节以在线推理效率瓶颈为切入点，介绍了 SDGNN 以单次稀疏矩阵乘 $\hat{H} = \Theta^\top \tilde{\Phi}$ 替代多层消息传递的基本思路，并分析了其三项关键设计假设所带来的结构性局限：全局统一正则系数 λ_1 忽视节点级拓扑异质性，静态固化稀疏权重难以低代价响应图演化，而直接依赖原始

图结构的做法则使模型在噪声边与缺失边并存的真实场景中暴露出明显的脆弱性。三项局限构成了 MSAS-GNN 研究的直接出发点，其中前两项分别对应后续第 3 章与第 4 章的核心展开，另一项则为第 5 章的探索性时序扩展提供了问题来源。

第**??**节依托与 MSAS-GNN 三大核心模块直接对应的五条文献脉络，将国内外研究现状纳入统一的分析框架。GNN 基础与在线推理效率脉络揭示了感受野指数扩张的成因以及采样加速、线性化预计算等已有方案各自的适用边界；高效与稀疏 GNN 脉络重点呈现了 SDGNN 稀疏分解框架的技术背景，并厘清了全局统一正则系数制约节点异质性建模的内在原因；异配性图学习与谱视角脉络梳理了低通聚合机制在异配图上的频率响应错配问题及代表性应对方案；图结构学习、鲁棒性与置信度估计脉络揭示了已有方法在稀疏分解框架内兼顾鲁棒性与推理效率这一问题上的共同缺口；动态图学习与增量更新脉络指出，稀疏分解框架与时序增量维护的结合仍是一个尚待探索的开放问题。在五条脉络归纳性分析的基础上，本节提炼出三条尚待填补的研究空白（见表 **??**），为整个研究设计提供了文献依据。

第**??**节基于上述三条研究空白，将本文的核心研究问题精确表述为：在保持静态推理主项复杂度 $O(n\bar{k}d)$ 不变的前提下，如何针对节点拓扑异质性与图结构质量缺陷分别建立有效的扩展机制，并在此基础上探索动态图场景的低代价参数维护路径。三条研究主线的设计思路与章间衔接逻辑得到系统阐述：第 3 章从谱图理论出发，以频率维、节点维和跳距维三条线索取代全局统一稀疏预算，输出的固化稀疏推理参数是第 4 章结构质量修正的直接基础；第 4 章放松图结构可信假设，以双路置信度估计与软性调节机制补充图质量控制维度，输出的边置信度信息构成第 5 章时序置信度增量维护的初始化基础；第 5 章在前两章静态框架基础上进行时序扩展，定位为探索性研究。

第**??**节进一步从宏观视角交代全文的整体技术路线，将七章内容划分为“研究背景与理论铺垫”“MSAS-GNN 核心方法链”“全面实验评估”“全文总结与反思”四个功能层次，明确了各章的功能定位与关键输入-输出接口（如图 **??** 所示），使读者在进入各章具体推导前能够把握全文的整体脉络。

至此，本章已完成研究问题提出、研究动机说明、研究内容界定以及全文结构交代等任务，本文的整体研究主线已经建立。为避免在绪论中提前展开过多背景理论，第 2 章将转入详细的相关工作与理论铺垫：围绕与 MSAS-GNN 三大核心模块直接相关的五条文献脉络，梳理关键背景概念、代表性方法及其局限，并建立后续章节复用的基础符号体系，为第 3 章至第 5 章的方法展开提供统一的理论与术语参照。

第 2 章 图表示例

2.1 插图

图片通常在 figure 环境中使用 `\includegraphics` 插入，如图 **??** 的源代码。建议矢量图片使用 PDF 格式，比如数据可视化的绘图；照片应使用 JPG 格式；其他的栅格图应使用无损的 PNG 格式。注意，LaTeX 不支持 TIFF 格式；EPS 格式已经过时。

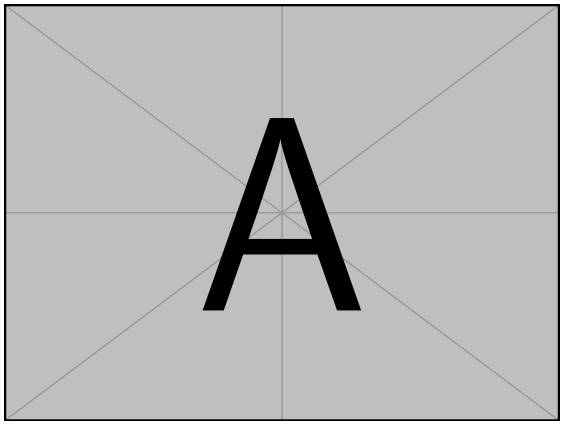

国外的期刊习惯将图表的标题和说明文字写成一段，需要改写为标题只含图表的名称，其他说明文字以注释方式写在图表下方，或者写在正文中。

图 2.1　示例图片标题

图应有编号。由“图”和从“1”开始的阿拉伯数字组成，例如“图 1”等，图较多时，可分章编号。图应有图题，图题即图的名称，置于图的编号之后。图的编号和图题应置于图下方。若图或表中有附注，采用英文小写字母顺序编号，附注写在图或表的下方。国外的期刊习惯将图表的标题和说明文字写成一段，需要改写为标题只含图表的名称，其他说明文字以注释方式写在图表下方，或者写在正文中。

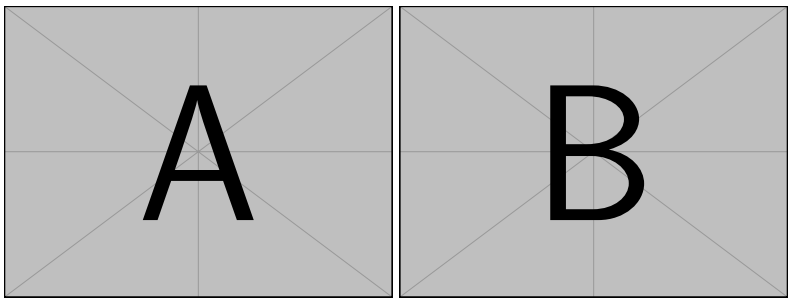

(a) 分图 A　　(b) 分图 B

图 2.2　多个分图的示例

如果一个图由两个或两个以上分图组成时，各分图分别以 (a)、(b)、(c)..... 作

为图序，并须有分图题。推荐使用 subcaption 宏包来处理，比如图 **??** 和图 **??**。

2.2 表格

表应具有自明性。为使表格简洁易读，尽可能采用三线表，如表 **??**。三条线可以使用 booktabs 宏包提供的命令生成。

表 2.1　三线表示例

文件名	描述
bnuthesis.dtx	模板的源文件，包括文档和注释
bnuthesis.cls	模板文件
bnuthesis-*.bst	BibTeX 参考文献表样式文件

表应有编号。由“表”和从“1”开始的阿拉伯数字组成，例如“表 1”等，表较多时，可分章编号。表应有表题，表题即表的名称，置于表的编号之后。表的编号和表题应置于表上方。表格如果有附注，尤其是需要在表格中进行标注时，可以使用 threeparttable 宏包。

表 2.2　带附注的表格示例

文件名	描述
bnuthesis.dtx[a]	模板的源文件，包括文档和注释
bnuthesis.cls[b]	模板文件
bnuthesis-*.bst	BibTeX 参考文献表样式文件

[a] 可以通过 xelatex 编译生成模板的使用说明文档；使用 xetex 编译 bnuthesis.ins 时则会从 .dtx 中去除掉文档和注释，得到精简的 .cls 文件。

[b] 更新模板时，一定要记得编译生成 .cls 文件，否则编译论文时载入的依然是旧版的模板。

如某个表需要转页接排，可以使用 longtable 宏包，需要在随后的各页上重复表的编号。编号后跟表题（可省略）和“（续）”，置于表上方。续表均应重复表头。

表 2.3　跨页长表格的表题

表头 1	表头 2	表头 3	表头 4
Row 1			
Row 2			

续表 2.3　跨页长表格的表题

表头 1	表头 2	表头 3	表头 4
Row 3			
Row 4			
Row 5			
Row 6			
Row 7			
Row 8			
Row 9			
Row 10			

2.3 公式

2.3.1 勾股定理

勾股定理是欧几里得几何中的一个基本定理，描述了直角三角形三边之间的关系。它表明，在一个直角三角形中，直角边的平方和等于斜边的平方。这可以用公式表示为：

$$a^2 + b^2 = c^2 \tag{2-1}$$

其中，a 和 b 是直角三角形的两个直角边，而 c 是斜边。根据公式 (**??**)，当直角边的长度已知时我们可以计算出斜边的长度。

2.3.2 格林公式

格林公式是一个在向量分析中非常重要的定理，它提供了一个将双重积分转换为曲线积分的方法。具体来说，格林公式将平面区域上的双重积分转换为该区域边界上的曲线积分。

格林公式的数学表达为：

$$\oint_C (L\,\mathrm{d}x + M\,\mathrm{d}y) = \iint_D \left(\frac{\partial M}{\partial x} - \frac{\partial L}{\partial y}\right) \mathrm{d}A \tag{2-2}$$

其中，C 是平面上的简单闭曲线，D 是由 C 围成的区域，L 和 M 是定义在 D 上的连续可微函数，$\mathrm{d}x$ 和 $\mathrm{d}y$ 分别是曲线 C 上点的横纵坐标的微分。

2.4 算法

算法环境可以使用 algorithms 或者 algorithm2e 宏包。

算法 2.1 Calculate $y = x^n$

输入： $n \geqslant 0$
输出： $y = x^n$

```
y ← 1
X ← x
N ← n
while N ≠ 0 do
    if N is even then
        X ← X × X
        N ← N/2
    else {N is odd}
        y ← y × X
        N ← N − 1
    end if
end while
```

2.5 题目 $e = mc^2$

当章节出现数学公式时，请使用上述格式。

定理 2.1 **(费马大定理)：** 对于任何大于 2 的正整数 n，不存在正整数 x, y, z 使得 $x^n + y^n = z^n$ 成立。

证明 假设存在这样的 x, y, z，使得 $x^n + y^n = z^n$ 成立。不失一般性，假设 x, y, z 互素。

考虑模 p 的情况，其中 p 是任意的质数。

1. 当 $n = 2$ 时，费马大定理是勾股定理，已经被证明。所以我们假设 $n > 2$。
2. 当 n 是偶数时，$x^n + y^n$ 和 z^n 都可以被因式分解为两个平方数的和。但这违背了费马的最后定理的要求，因此不存在这样的解。
3. 当 n 是奇数时，我们考虑同样的方式，由于 $x^n + y^n$ 是一个奇数，而 z^n 是一个偶数，所以这也不可能成立。

因此，我们得出结论，费马大定理成立。 ■

第 3 章 引用文献的标注

模板支持 BibTeX 和 BibLaTeX 两种方式处理参考文献。下文主要介绍 BibTeX 配合 natbib 宏包的主要使用方法。

3.1 顺序编码制

在顺序编码制下，默认的 `\cite` 命令同 `\citep` 一样，序号置于方括号中，引文页码会放在括号外。统一处引用的连续序号会自动用短横线连接。

`\cite{zhangkun1994}` ⇒ [?]

`\citet{zhangkun1994}` ⇒ ?]

`\citep{zhangkun1994}` ⇒ [?]

`\cite[42]{zhangkun1994}` ⇒ [?]42

`\cite{zhangkun1994,zhukezhen1973}` ⇒ [? ?]

也可以取消上标格式，将数字序号作为文字的一部分。建议全文统一使用相同的格式。

`\cite{zhangkun1994}` ⇒ [?]

`\citet{zhangkun1994}` ⇒ ?]

`\citep{zhangkun1994}` ⇒ [?]

`\cite[42]{zhangkun1994}` ⇒ [?]^{42}

`\cite{zhangkun1994,zhukezhen1973}` ⇒ [? ?]

3.2 著者-出版年制

著者-出版年制下的 `\cite` 跟 `\citet` 一样。

`\cite{zhangkun1994}` ⇒?

`\citet{zhangkun1994}` ⇒?

`\citep{zhangkun1994}` ⇒(?)

`\cite[42]{zhangkun1994}` ⇒(?)^{42}

`\citep{zhangkun1994,zhukezhen1973}`⇒(??)

注意，引文参考文献的每条都要在正文中标注[? ? ?

3.3 跨章节图片、表格、算法

3.3.1 图片、表格

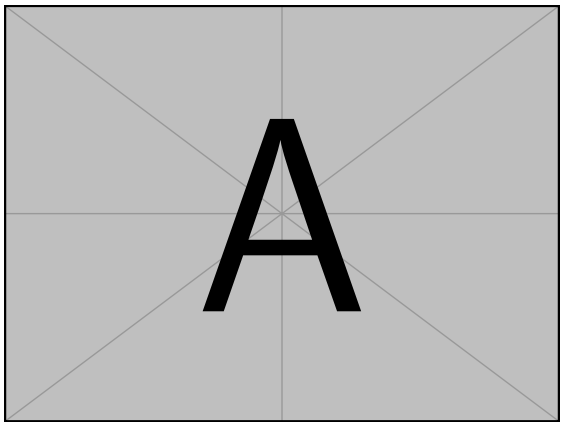

跨章节图片。

图 3.1　示例图片标题

表 3.1　三线表示例-跨章节

文件名	描述
bnuthesis.dtx	模板的源文件，包括文档和注释
bnuthesis.cls	模板文件
bnuthesis-*.bst	BibTeX 参考文献表样式文件

3.3.2 算法

算法 3.1 Calculate $y = x^n$

输入： $n \geqslant 0$
输出： $y = x^n$

```
y ← 1
X ← x
N ← n
while N ≠ 0 do
    if N is even then
        X ← X × X
        N ← N/2
    else {N is odd}
        y ← y × X
        N ← N − 1
    end if
end while
```

索　　引

索引说明

本学位论文编制了创新索引、主题索引、专有名称索引。

创新索引

创新索引以学位论文中描述创新内容的词语为目标编制，款目采用**加粗**格式表示，按标目在论文中首次出现的顺序集中排列在索引的最前面。

蓝莓发酵酒最佳发酵条件（工艺参数） ..... **??**

最佳原材料为栽培蓝莓，糖种类为蜂蜜，酵母菌种为 *Fermivin*。最佳发酵温度为 *15* □，初始糖度为 *26%*，酵母添加量为 *0.3%*，硫代硫酸钠添加量为 *100 ppm*。

蓝莓发酵酒抗氧化特性 ..... **??**

蓝莓发酵酒降血脂作用 ..... **??**

蓝莓发酵酒降细胞毒性作用 ..... **??**, **??**

主题索引

主题索引以学位论文中重点论述、具有检索价值的重要主题词为标目编制，按拼音排序。

C

超氧化物歧化酶 (SOD) ..... **??**

超氧阴离子 ..... **??**

初始糖度 ..... **??**

G

感官评价 ..... **??**

果胶含量测定 ..... **??**

专有名称索引

专有名称索引以机构名、人名、地名、文献名等专有名称为标目编制，按拼音排序。

A

安徽广播电视台 . . . . . **??**

《安徽农业科学》 . . . . . **??**

G

郭嘉欣 . . . . . **??**

《国家安全太空战略》 . . . . . **??**

在学期间完成的相关学术成果

学术论文

[1] Yang Y, Ren T L, Zhang L T, et al. Miniature microphone with silicon-based ferroelectric thin films[J]. Integrated Ferroelectrics, 2003, 52:229-235.

[2] 杨轶, 张宁欣, 任天令, 等. 硅基铁电微声学器件中薄膜残余应力的研究 [J]. 中国机械工程, 2005, 16(14):1289-1291.

[3] 杨轶, 张宁欣, 任天令, 等. 集成铁电器件中的关键工艺研究 [J]. 仪器仪表学报, 2003, 24(S4):192-193.

[4] Yang Y, Ren T L, Zhu Y P, et al. PMUTs for handwriting recognition. In press[J]. (已被 Integrated Ferroelectrics 录用)

专利

[5] 任天令, 杨轶, 朱一平, 等. 硅基铁电微声学传感器畴极化区域控制和电极连接的方法: 中国, CN1602118A[P]. 2005-03-30.

[6] Ren T L, Yang Y, Zhu Y P, et al. Piezoelectric micro acoustic sensor based on ferroelectric materials: USA, No.11/215, 102[P]. (美国发明专利申请号.)

致　谢

衷心感谢导师 ×××。

常昊
2026 年 4 月

答辩委员会名单

	姓名	工作单位	职称	导师类型
主席	赵 XX	XXXX 大学	教授	博士生导师
委员	钱 XX	XXXX 大学	教授	硕士生导师
	孙 XX	XXX 研究院 XXX 大学	研究员	博士生导师
	李 XX	XXXX 大学	教授	硕士生导师
	周 XX	XXXX 大学	副教授	硕士生导师
秘书	吴 XX	XXXX 大学	助理研究员	