北京師範大學

专业硕士研究生
学位论文

MSAS-GNN：谱驱动自适应稀疏图神经网络的鲁棒高效推理

作　　者：　常　昊

学　　号：　202422011122

导师姓名、职称：　翟　铮　副教授

学 科 领 域：　应用统计

培 养 单 位：　统计学院

提 交 日 期：　二〇二六年五月

MSAS-GNN：谱驱动自适应稀疏图神经网络的鲁棒高效推理

常 昊

北京师范大学

北京师范大学学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。本人恪守学术道德和学术规范，杜绝抄袭，篡改，伪造等学术不端行为及代买，买卖论文等造假行为。所有引用或参考内容均已标明出处。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：　　日期：　　年　　月　　日

学位论文使用授权书

学位论文作者完全了解北京师范大学有关保存和使用学位论文的规定，即：学校有权保存并向国家有关部门或机构送交论文的复印件和电子版，允许学位论文被查阅和借阅；学校可以公布学位论文的全部或部分内容，可以允许采用影印、缩印或其它复制手段保存、汇编学位论文。保密的学位论文在解密后适用于本授权书。

本人签字：_____　　日　　期：_____

导师签名：_____　　日　　期：_____

MSAS-GNN：谱驱动自适应稀疏图神经网络的鲁棒高效推理

摘　要

图神经网络通过沿图结构聚合多跳邻域信息，在节点分类、链接预测等任务中表现出较好的建模能力，已成为图数据学习中的重要方法。随着相关模型逐步走向推荐系统、实时风控等对响应时延较为敏感的应用场景，推理阶段的效率问题开始变得突出。多层消息传递会带来感受野的持续扩张，邻居检索与特征聚合开销随之迅速上升，模型因而难以直接用于大规模在线服务。另一方面，真实图中普遍存在噪声边、缺失边等结构缺陷，这些问题会在固定邻接矩阵的传播过程中累积到节点表示中，进一步影响下游任务的稳定性。

稀疏分解图神经网络（Sparse Decomposition of Graph Neural Networks，SDGNN）将教师模型的表示逼近写成单次稀疏矩阵乘法，在明显降低推理开销的同时保持了较好的近似能力。不过，这一方法对所有节点使用同一个正则系数来控制稀疏强度，没有反映节点之间实际存在的拓扑差异。对于连接范围较广、承担更多结构信息的枢纽节点，过强的稀疏约束容易删去关键邻居；对于局部连接较少的外围节点，过弱的稀疏约束又会留下较多冗余连接。统一稀疏控制在结构差异较强的图上往往难以同时兼顾精度与压缩效果，这也是 SDGNN 进一步改进时最需要处理的问题。

围绕这一局限，本文在 SDGNN 基础上提出多尺度自适应稀疏图神经网络（MSAS-GNN），根据节点所处的局部结构环境分配差异化稀疏预算。本文从图结构中提取谱间隙、节点谱能量、归一化局部图熵和节点中心性四类可计算指标，用于描述图的全局连通性、节点谱域参与强度和局部邻域结构特征，并据此构建频率、节点和跳距三个维度的自适应稀疏机制。频率维度采用节点谱能量的等权实例化作为统一频率接口，以避免引入与具体任务强绑定的额外统计量；节点维度结合节点谱能量与邻域结构复杂度构造节点级正则系数，使信息贡献更高的节点受到较弱稀疏约束，从而保留更多关键邻居；跳距维度结合多跳传播中信息贡献随距离递减的现象，对不同环层分配预算，并在均匀分配与几何衰减分配之间进行自适应选择。完成参数设计后，推理阶段仍保持单次稀疏矩阵乘法形式，主项复杂度维持在线性量级。

本文在 Cora、Citeseer、PubMed、ogbn-arxiv、Chameleon 和 Squirrel 六个静态节点分类基准数据集上对 MSAS-GNN 进行了验证。主实验与显著性检验均在 10 个随机种子下重复，并采用 Wilcoxon 符号秩检验评估差异。结果表明，MSAS-

GNN 在六个数据集上均优于基线 SDGNN，且逐数据集差异均达到显著水平。在引文网络数据集上，Cora 的准确率达到 88.0%，Citeseer 与 PubMed 相比 SDGNN 也均有提升，三个引文网络数据集平均提升约 1.3 个百分点；在大规模图 ogbn-arxiv 上，准确率由 74.27% 提升至 75.13%；在 Chameleon 和 Squirrel 上，准确率分别达到 65.6% 和 55.9%。为进一步检验本文方法在近年高效图学习方法下的相对表现，本文进一步补充 GraphSAINT、NodeFormer、DIFFormer、SGFormer 和 NAGphormer 等基线。补充结果显示，SGFormer 在多项数据集上是最接近本文方法的近期基线，在 ogbn-arxiv 上达到 74.96%，在 Chameleon 和 Squirrel 上分别达到 65.2% 和 55.4%；MSAS-GNN 对应结果为 75.13%、65.6% 和 55.9%，仍保持更高准确率。效率测试表明，MSAS-GNN 在 ogbn-arxiv 上相对标准消息传递基线实现约 13.6 倍加速，四个代表性数据集上的平均加速比约为 8.0 倍，峰值前向显存占用减少约 74.8%。消融结果进一步说明，性能改善并不能由单一结构因子单独解释，节点级多因子正则与近邻优先的分层跳距预算需要共同作用，才能稳定体现出方法优势。

本文从图结构统计量出发，构建面向节点差异的稀疏分配方式，降低稀疏推理对全局统一预算的依赖。在保持线性推理复杂度的前提下，该方法提升了不同拓扑角色节点的适配性，也为大规模图上的高效推理提供了较为直接的实现路径。

关键词：图神经网络，自适应稀疏化，谱图分析，节点异质性，跳距预算分配

MSAS-GNN: Spectral-Driven Multi-Scale Adaptive Sparse Graph Neural Networks for Robust and Efficient Inference

ABSTRACT

Graph Neural Networks (GNNs) have become an important tool for learning from graph-structured data because they build node representations by aggregating information from multi-hop neighborhoods. As these models move from benchmark studies to latency-sensitive applications such as recommender systems and real-time risk control, inference efficiency becomes a practical concern. Multi-layer message passing continuously enlarges the receptive field, which quickly increases the cost of neighbor retrieval and feature aggregation during inference and makes direct deployment difficult in large-scale online settings. In addition, real-world graphs often contain noisy edges and missing connections, and such structural defects can propagate through a fixed adjacency matrix and eventually affect the stability of downstream predictions.

Sparse Decomposition of Graph Neural Networks (SDGNN) rewrites the approximation of teacher representations as a single sparse matrix multiplication, substantially reducing inference cost while preserving good approximation quality. However, SDGNN uses one global regularization coefficient to control sparsity for all nodes, which does not reflect the topological differences among them. For hub nodes that carry richer structural information, overly strong sparsification may remove critical neighbors; for peripheral nodes with limited local connectivity, overly weak sparsification may keep redundant connections and reduce compression gains. This mismatch makes it difficult for a uniform sparsity policy to balance accuracy and efficiency on graphs with pronounced structural heterogeneity.

Starting from this limitation, this thesis develops the Multi-Scale Adaptive Sparse Graph Neural Network (MSAS-GNN) on top of SDGNN. Instead of assuming that all nodes should receive the same sparsity pressure, the proposed method allocates different sparsity budgets according to the local structural environment of each node. To support this design, four computable graph indicators are first extracted from the graph structure, namely spectral gap, node spectral energy, normalized local graph entropy, and node centrality. These quantities are then used to characterize global connectiv-

ity, spectral participation at the node level, and local neighborhood structure. Based on them, an adaptive sparsification scheme is built from three perspectives: frequency, node, and hop distance. In the frequency dimension, an equal-weight instantiation of node spectral energy is adopted as the common frequency interface so that the method does not rely on additional task-specific statistics. In the node dimension, node spectral energy and neighborhood structural complexity are combined to construct node-wise regularization coefficients, allowing nodes with higher information contribution to receive weaker sparsity constraints and retain more critical neighbors. In the hop-distance dimension, budgets are assigned across different neighborhood rings according to the observed decay of information contribution with hop distance, with adaptive selection between uniform allocation and geometric-decay allocation. After these parameters are determined, inference still takes the form of a single sparse matrix multiplication, so the dominant complexity remains at a linear scale.

Experiments are conducted on six static node classification benchmarks: Cora, Citeseer, PubMed, ogbn-arxiv, Chameleon, and Squirrel. All main experiments and significance tests are repeated with 10 random seeds, and the Wilcoxon signed-rank test is used to evaluate the differences. The results show that MSAS-GNN outperforms the baseline SDGNN on all six datasets, and every per-dataset improvement is statistically significant. On the citation-network benchmarks, the accuracy on Cora reaches 88.0%, while Citeseer and PubMed also improve over SDGNN, giving an average gain of about 1.3 percentage points across the three datasets. On the large-scale graph ogbn-arxiv, the accuracy increases from 74.27% to 75.13%. On Chameleon and Squirrel, the accuracies reach 65.6% and 55.9%, respectively. To further evaluate the proposed method against recent efficient graph learning and structure-adaptive approaches, additional baselines including GraphSAINT, NodeFormer, DIFFormer, SGFormer, and NAGphormer are included. Among these recent baselines, SGFormer is the closest competitor in several settings, reaching 74.96% on ogbn-arxiv and 65.2% and 55.4% on Chameleon and Squirrel, while MSAS-GNN achieves 75.13%, 65.6%, and 55.9% on the same datasets. Efficiency evaluation shows that MSAS-GNN achieves about 13.6× speedup over the standard message-passing baseline on ogbn-arxiv, with an average speedup of about 8.0× across four representative datasets, while reducing peak forward GPU memory usage by about 74.8%. Ablation results further indicate that the gain cannot be attributed to any single structural factor alone; instead, it emerges from the combined effect of multi-factor node-wise regularization and near-neighbor-priority layer-wise hop-budget allocation.

In summary, this thesis develops a node-differentiated sparsity allocation scheme from computable graph statistics, so that sparse inference no longer relies on a globally uniform budget. While preserving linear inference complexity, the proposed method adapts better to nodes with different topological roles and provides a practical route toward efficient inference on large-scale graphs.

KEY WORDS: Graph Neural Network, Adaptive Sparsification, Spectral Graph Analysis, Node Heterogeneity, Hop-Distance Budget Allocation

目 录

符号和缩略语说明.....XII

第 1 章 绪论.....1

1.1 研究背景与意义.....2

1.2 国内外研究现状.....3

1.2.1 图神经网络在线推理效率相关研究.....3

1.2.2 高效与稀疏图神经网络方法.....4

1.2.3 复杂图结构学习与谱视角方法.....4

1.3 研究内容与创新点.....5

1.4 技术路线与论文组织结构.....5

1.5 本章小结.....6

第 2 章 相关工作.....8

2.1 图神经网络基础与谱图理论.....8

2.2 高效与稀疏图神经网络方法.....10

2.3 复杂图结构与谱视角相关方法.....12

2.3.1 图结构差异与频率响应.....12

2.3.2 代表性复杂图结构处理方法.....12

2.4 本章小结与研究空白.....13

第 3 章 问题形式化与图复杂度指标体系.....16

3.1 问题形式化与优化目标.....16

3.1.1 图学习基本设定与 SDGNN 基准.....16

3.1.2 统一优化目标与预算约束.....19

3.1.3 近似误差度量与三项设计准则.....21

3.2 图复杂度量化指标体系.....24

3.2.1 谱间隙与节点谱能量.....24

3.2.2 局部图熵.....26

3.2.3 节点中心性.....26

3.3 本章小结.....27

第 4 章 谱驱动三维自适应稀疏机制.....30

4.1 频率维度：节点谱能量的统一谱输入.....30

4.2 节点维度：节点级自适应正则系数 33
4.2.1 节点级正则系数的构造原则 33
4.2.2 多因子融合的完整公式 35
4.2.3 算法实现 36
4.3 层级维度：分层跳距预算分配 37
4.3.1 分层信息衰减界分析 37
4.3.2 分层保留率 p_l 的两种策略 41
4.3.3 节点-跳距联合预算分配策略 43
4.4 本章小结 44
第 5 章 算法整合、误差分析与复杂度分析 46
5.1 LARS 分层稀疏求解与交替优化 46
5.1.1 分层 LARS 的候选集构造与方案选定 46
5.1.2 完整交替优化算法 48
5.1.3 优化稳定性与实现说明 52
5.2 误差分析与适用条件 52
5.2.1 自适应参数设计与误差分析的接口 53
5.2.2 谱相似性与图稀疏化 53
5.2.3 多项式谱滤波器的近似误差界 54
5.3 复杂度分析 60
5.4 本章小结 64
第 6 章 实验评估 65
6.1 实验设置 65
6.2 节点分类主实验 70
6.3 消融实验与分析结论验证 73
6.3.1 逐模块消融分析 73
6.3.2 跳距预算分配策略消融 76
6.3.3 超参数敏感性分析 77
6.4 效率分析 78
6.4.1 推理效率与内存综合对比 78
6.4.2 预处理摊销与 break-even 分析 80
6.5 可视化分析 81
6.6 本章小结 83

第 7 章　总结与展望 84
7.1　研究工作总结 84
7.1.1　问题背景与核心挑战 84
7.1.2　各章核心工作回顾 84
7.1.3　方法、分析与实验结果的一致性说明 85
7.2　主要贡献与创新点 86
7.3　研究局限性 87
7.4　未来研究方向 88
参考文献 89
索　　引 93
在学期间完成的相关学术成果 96
致　谢 97
答辩委员会名单 98

插图清单

图 1.1 SDGNN 全局统一稀疏预算局限与 MSAS-GNN 谱驱动自适应改进示意图 1
图 1.2 本文技术路线与章节接口示意图 7
图 2.1 本章三条文献脉络与后续方法章节的对应关系 9
图 2.2 消息传递 GNN 感受野扩张与在线推理瓶颈示意图 10
图 2.3 三大研究空白与本文方法链的对应关系图 15
图 3.1 第 3 章整体流程图：从图输入到四类复杂度指标输出 17
图 3.2 SDGNN 全局统一稀疏预算失效示意图 20
图 4.1 第 4 章三维自适应稀疏机制整体框架图 31
图 4.2 节点级正则系数 $\tau(i)$ 的三维自适应框架示意图 33
图 4.3 层级维度——分层跳距预算分配示意图 37
图 4.4 跳距预算衰减分配示意图（策略 1 vs 策略 2） 41
图 5.1 共享目标与残差级联两种分层 LARS 方案对比 49
图 5.2 复杂度分解与线性推理适用边界示意图 63
图 6.1 关键超参数敏感性分析（Cora） 77
图 6.2 节点级自适应稀疏参数 $\tau(i)$ 分布分析（Cora） 81
图 6.3 t-SNE 节点表示可视化对比（Cora，7 类） 82

附表清单

表 2.1 现有方法研究空白与后续章节对应关系汇总 14
表 4.1 节点级正则系数因子方案及其作用特征（具体准确率见第 6 章消融实验）..... 36
表 4.2 策略 1 与策略 2 的对比分析 43
表 5.1 各方法推理与训练复杂度对比（固定图、全图一次前向/结构固化后查询口径；$m = \mathrm{nnz}(A)$，$m_{\text{sparse}} = n\bar{k}$，$K_{\text{eig}} \in [50, 100]$ 视为常数）..... 63
表 6.1 MSAS-GNN 主实验涉及的核心超参数与 Cora 上的代表性默认配置 .. 66
表 6.2 节点分类数据集统计信息 69
表 6.3 引文网络与大规模图节点分类准确率（%，均值 ± 标准差，10 次重复）71
表 6.4 网页图节点分类准确率（%，均值 ± 标准差，10 次重复）..... 72
表 6.5 综合消融实验（Cora，准确率%，10 次重复均值 ± 标准差）..... 75
表 6.6 跳距预算分配策略消融（准确率%）..... 76
表 6.7 推理效率与显存占用综合对比（GPU，batch_size = 1024）..... 78
表 6.8 近年高效图学习方法推理效率补充对比（ogbn-arxiv，GPU，batch_size = 1024）..... 79
表 6.9 预处理摊销与 break-even 估计（时间单位统一为秒）..... 80

算法清单

算法 3.1　图复杂度指标预处理（含谱估计、节点谱能量与局部图熵批量计算） 28
算法 4.1　节点级自适应正则系数批量计算流程 36
算法 5.1　MSAS-GNN 三维自适应稀疏分解主循环（完整交替优化版）..... 51
算法 5.2　推理期稀疏固化 52

符号和缩略语说明

MSAS-GNN	多尺度自适应稀疏图神经网络（Multi-Scale Adaptive Sparse Graph Neural Network，本文提出）
SDGNN	稀疏分解图神经网络（Sparse Decomposition of Graph Neural Networks，Hu 等，2024）
GNN	图神经网络（Graph Neural Network）
GCN	图卷积网络（Graph Convolutional Network）
GAT	图注意力网络（Graph Attention Network）
GIN	图同构网络（Graph Isomorphism Network）
SGC	简单图卷积（Simple Graph Convolution）
MPNN	消息传递神经网络（Message Passing Neural Network）
APPNP	近似个性化 PageRank 传播图网络（Approximate Personalized PageRank Propagation of Neural Predictions）
SIGN	可扩展 Inception 图神经网络（Scalable Inception Graph Neural Network）
FAGCN	频率自适应图卷积网络（Frequency Adaptive Graph Convolution Network）
GPR-GNN	广义 PageRank 图神经网络（Generalized PageRank Graph Neural Network）
H2GCN	面向异配图的图卷积网络（Beyond Homophily Graph Convolutional Network）
Geom-GCN	几何聚合图卷积网络（Geometric Graph Convolutional Network）
GLNN	无图神经网络（Graph-less Neural Network）
GloGNN	全局同配建模图神经网络（Global Homophily based Graph Neural Network）
LINKX	面向大规模异配图的线性图学习方法（Linear Graph Model for Heterophilous Graphs）
FastGCN	快速采样图卷积网络（Fast Graph Convolutional Network）
GraphSAGE	归纳式大规模图表示学习方法（Graph Sample and Aggregate）
GraphSAINT	基于图采样的归纳学习方法（Graph Sampling Based Inductive Learning Method）
DropEdge	随机边丢弃正则化方法（DropEdge）

PPRGo	基于近似 Personalized PageRank 的可扩展图神经网络（Scaling Graph Neural Networks with Approximate PageRank）
NodeFormer	可扩展图结构学习 Transformer（Scalable Graph Structure Learning Transformer）
DIFFormer	基于能量约束扩散的可扩展图 Transformer（Scalable Graph Transformers Induced by Energy Constrained Diffusion）
SGFormer	简化图 Transformer（Simplified Graph Transformer）
NAGphormer	邻域聚合图 Transformer（Neighborhood Aggregation Graph Transformer）
LARS	最小角回归（Least Angle Regression）
MLP	多层感知机（Multilayer Perceptron）
GSP	图信号处理（Graph Signal Processing）
OGB	开放图基准（Open Graph Benchmark）
Wilcoxon	Wilcoxon 符号秩检验（Wilcoxon Signed-Rank Test）
GPU	图形处理器（Graphics Processing Unit）
Adam	自适应矩估计优化器（Adaptive Moment Estimation）
t-SNE	t 分布随机近邻嵌入（t-distributed Stochastic Neighbor Embedding）
$G=(V,E,X)$	属性图，V 为节点集，E 为边集，X 为节点特征矩阵
n	节点总数，$n=\|V\|$
m	邻接矩阵非零元数，统一记为 $m:=\mathrm{nnz}(A)=2\|E\|$
D	节点输入特征维度
d	节点嵌入维度或隐藏维度
C	下游任务类别数
A	图邻接矩阵
D_{deg}	度矩阵，对角元素为节点度数
d_i	节点 i 的度
$\bar{d}$	全图平均度，$\bar{d}=m/n$
V_{train}	训练节点集合，满足 $V_{\mathrm{train}}\subseteq V$
$f_{\mathrm{cls}}(\cdot;W_{\mathrm{cls}})$	节点分类头或下游分类映射
W_{cls}	分类头参数
$\hat{y}_i$	节点 i 的预测类别分布，$\hat{y}_i\in\Delta^{C-1}$
Δ^{C-1}	C 维概率单纯形
$\mathcal{N}(i)$	节点 i 的一跳邻域

$\mathcal{N}_l(i)$	节点 i 的 l 跳邻域
$\mathcal{N}_L(i)$	节点 i 的 L 跳感受野邻域
$\mathcal{R}_l(i)$	节点 i 的第 l 跳邻居环层，$\mathcal{R}_l(i) = \mathcal{N}_l(i) \setminus \mathcal{N}_{l-1}(i)$
$d_G(i,j)$	图 G 上节点 i 与 j 的最短路径距离
$\tilde{\mathcal{L}}$	归一化图拉普拉斯矩阵，$\tilde{\mathcal{L}} = I - D_{\text{deg}}^{-1/2} A D_{\text{deg}}^{-1/2}$
U, Λ	$\tilde{\mathcal{L}}$ 的谱分解矩阵，$\tilde{\mathcal{L}} = U \Lambda U^\top$
λ_k	归一化拉普拉斯的第 k 个特征值，满足 $0 \leqslant \lambda_k \leqslant 2$
λ_{gap}	谱间隙，即最小非零特征值；在连通图上有 $\lambda_{\text{gap}} = \lambda_1$
$\hat{\lambda}_{\text{gap}}$	由 Lanczos 预处理得到的谱间隙近似值
K_{eig}	Lanczos 迭代中保留的特征对数量
K_{pair}	预处理中实际返回并用于后续计算的特征对数量
K_{eff}	Lanczos 迭代的有效终止步数
τ_{tol}	Lanczos 迭代提前停止所用数值容差
$T_{K_{\text{eff}}}$	Lanczos 过程生成的三对角矩阵
$g(\tilde{\mathcal{L}})$	作用于归一化拉普拉斯的谱滤波器
K_{poly}	多项式谱滤波器的阶数
$\bar{\mathcal{L}}$	平移后的拉普拉斯矩阵，$\bar{\mathcal{L}} := \tilde{\mathcal{L}} - I$
a_r	多项式谱滤波器单项式展开的第 r 阶系数
S	无自环对称归一化传播算子，$S = D_{\text{deg}}^{-1/2} A D_{\text{deg}}^{-1/2}$
S_{lazy}	懒化传播算子，$S_{\text{lazy}} = (I + S)/2$
P	分层信息衰减分析中的线性传播算子，可取 S 或 S_{lazy}
$\mu_k(P)$	传播算子 P 的第 k 个特征值
$\mu_\star(P)$	传播算子 P 在 $\mathbf{1}^\perp$ 子空间上的第二谱半径
$h_i^{[l]}$	节点 i 在第 l 次线性传播后的累计表示
$\Delta h_i^{[l]}$	第 l 次传播相对第 $l-1$ 次传播的边际表示增量
e_i	第 i 个标准基向量
C_0	分层信息衰减界中的全局保守常数，$C_0 = \|(P - I)X\|_F$
σ	原图与稀疏图之间的谱相似性参数，$\sigma \geqslant 1$
$\tilde{\sigma}_{\text{proxy}}$	基于 Lanczos 的 σ-谱相似性代理估计量
K_{Lanczos}	估计 $\tilde{\sigma}_{\text{proxy}}$ 时采用的 Lanczos 固定步数
$\hat{G}$	由稀疏结构诱导的稀疏图
$\tilde{\mathcal{L}}_G$	原图 G 的归一化拉普拉斯矩阵
$\tilde{\mathcal{L}}_{\hat{G}}$	稀疏图 $\hat{G}$ 的归一化拉普拉斯矩阵
$\Delta_{\mathcal{L}}$	稀疏图与原图归一化拉普拉斯之差，$\Delta_{\mathcal{L}} = \tilde{\mathcal{L}}_{\hat{G}} - \tilde{\mathcal{L}}_G$
M	谱相似性推导中的半正定上界矩阵，$M = (\sigma - 1)\tilde{\mathcal{L}}_G$
$\lambda_{\max}(M)$	矩阵 M 的最大特征值

$A \preceq B$	Loewner 半序，表示 $B - A$ 为半正定矩阵
η	原图与稀疏图平移拉普拉斯之差的谱范数，$\eta = \lVert \bar{\mathcal{L}}_G - \bar{\mathcal{L}}_{\hat{G}} \rVert_2$
$w_k(i)$	节点 i 对第 k 个频率分量的权重；正文主线取等权形式
$E_{\text{spectral}}(i)$	节点谱能量，衡量节点在各谱分量上的参与强度
$H(i)$	节点 i 的局部图熵
$H_{\text{norm}}(i)$	节点 i 的归一化局部图熵，$H_{\text{norm}}(i) \in [0,1]$
$C_{\text{deg}}(i)$	节点 i 的度中心性
$\text{core}(i)$	节点 i 的 k-core 指数
$k_{\max}$	全图节点 k-core 指数的最大值，$k_{\max} = \max_{j \in V} \text{core}(j)$
w_{ij}	构造局部图熵时节点 i 与 j 之间的边权
Z_i	节点 i 局部熵计算中的归一化常数，$Z_i = \sum_{j \in \mathcal{N}(i)} w_{ij}$
$\hat{\sigma}^2$	高斯核边权中使用的经验带宽估计
γ_x	高斯核带宽参数，满足 $w_{ij} = \exp(-\gamma_x \lVert x_i - x_j \rVert_2^2)$
$\text{CV}(\{k_i\})$	节点稀疏预算分布的变异系数，用于辅助分析节点间差异性
L	图传播层数或最大跳数
$H^{(l)}$	第 l 层节点表示矩阵，$H^{(l)} \in \mathbb{R}^{n \times d}$
H^*	教师 GNN 的目标表示矩阵，$H^* \in \mathbb{R}^{n \times d}$
h_i^*	教师 GNN 在节点 i 处的目标表示向量
$\phi(\cdot; W_\phi)$	节点特征变换函数
W_ϕ	特征变换函数的可学习参数
W_ϕ^*	交替优化初始化时使用的预训练特征变换参数
$\Phi = \phi(X; W_\phi)$	特征变换后的节点表示矩阵
$\tilde{\Phi}$	行 ℓ_2 归一化后的特征变换矩阵
$\tilde{\Phi}^{\text{cache}}$	推理期缓存的归一化特征变换矩阵
θ_i	节点 i 对应的稀疏权重向量
Θ	全图稀疏权重矩阵，$\Theta \in \mathbb{R}^{n \times n}$，其第 i 列为节点 i 的稀疏权重向量 θ_i
Θ^{fixed}	推理期固化后的稀疏权重矩阵
$\hat{h}(i)$	节点 i 的稀疏推理表示
$\hat{H}$	稀疏分解推理输出矩阵，$\hat{H} = \Theta^\top \tilde{\Phi}$
m_{sparse}	稀疏结构的非零元数，$m_{\text{sparse}} := \text{nnz}(\Theta)$
k_i	节点 i 最终保留的非零邻居数，常记为 $k_i = \lVert \theta_i \rVert_0$
$\bar{k}$	全图平均非零权重数或平均稀疏预算，$\bar{k} = \frac{1}{n} \sum_{i=1}^n k_i$；按预算上限估计复杂度时，可用 $\frac{1}{n} \sum_i k_i^{\text{total}}$ 近似

λ_W	特征变换参数的 ℓ_2 正则系数
λ_{reg}	SDGNN 使用的全局统一正则系数
$\mathcal{L}_{\text{task}}$	下游任务损失，在节点分类实验中取交叉熵损失
$\mathcal{E}_{\text{approx}}$	表示近似误差，定义为 $\mathcal{E}_{\text{approx}} = \frac{1}{\sqrt{n}}\|H^* - \hat{H}\|_F$
$\varepsilon_i^{\text{rep}}$	节点 i 的表示误差范数，$\varepsilon_i^{\text{rep}} = \|h_i^* - \hat{h}_i\|_2$
$\mathcal{S}(t)$	在误差阈值 t 下的节点子集，用于第 3 章的设计准则分析
ε_0	第 3 章性能保持准则中的总体表示误差容许阈值
$\tau(i)$	节点级正则系数，取值区间为 $[\tau_{\min}, \tau_{\text{base}}]$
τ_{base}	节点级正则系数的基准上界
$\tau_{\min}$	节点级正则系数的下界
$\tau_{\text{mono}}(i)$	仅由节点谱能量驱动的单因子节点级正则系数
β_τ	节点谱能量到正则系数映射中的响应强度系数
γ	多因子节点级正则系数中度中心性项的权重
δ	多因子节点级正则系数中 k-core 项的权重
ω_H	多因子节点级正则系数中归一化局部熵项的权重
c_E	节点谱能量阈值的尺度系数
$E_{\text{threshold}}$	节点谱能量阈值，定义为 $E_{\text{threshold}} = c_E \cdot \text{median}_{j\in V} E_{\text{spectral}}(j)$
k_i^{total}	节点 i 的总稀疏预算
p_l	第 l 跳的保留率，满足 $p_l \in (0, 1]$
ϱ	跳距保留率的几何衰减公比
p_{base}	谱间隙自适应跳距分配中的第 1 跳基准保留率
$p_{\min}$	跳距保留率下界，用于避免高跳距预算被完全压缩
κ	谱间隙自适应跳距保留率中的响应系数，$\kappa > 0$
ρ	跳距预算分配中的全局预算缩放系数，$\rho \in (0, 1]$
$\tilde{k}_i^{(l)}$	节点 i 第 l 跳环层的连续预算上界
$\text{RoundQuota}(\cdot)$	将连续预算上界转化为整数预算配额的舍入算子
ξ	跳距预算分配中的整数化控制参数
$k_i^{(l)}$	节点 i 在第 l 跳邻居环层上的预算配额，满足 $\sum_{l=1}^{L} k_i^{(l)} = k_i^{\text{total}}$
ε_l	第 l 跳传播允许的信息损失预算
$\varepsilon_{\text{total}}$	第 5 章条件化误差上界中的整体误差目标
C_i	节点 i 的候选节点集合，$C_i = \{i\} \cup \bigcup_{l=1}^{L} \mathcal{R}_l(i)$
Ω_i	节点 i 的目标表示向量，$\Omega_i := H^*_{i,:}$
$\tilde{\phi}_i$	行归一化特征矩阵 $\tilde{\Phi}$ 的第 i 行向量

$\tilde{\Phi}_{\mathcal{R}_l(i)}$	$\tilde{\Phi}$ 在节点 i 第 l 跳邻居环层上的行子矩阵
$\theta_i^{(0)}$	节点 i 的第 0 跳自特征通道系数
$\theta_i^{(l)}$	节点 i 在第 l 跳邻居环层上的稀疏系数向量
$\theta_{i,\text{share}}^{(l)}$	共享目标方案下节点 i 第 l 个候选块的稀疏系数
$r_i^{(l)}$	节点 i 完成第 0 跳至第 l 跳拟合后的剩余残差
$\Theta_{j,i}$	稀疏权重矩阵 Θ 的第 j 行第 i 列元素
$\text{AdamStep}(\cdot)$	对参数执行一次 Adam 更新的算子
T_{epoch}	第 5 章主循环中的外层交替优化轮数
T_W	每轮外层迭代中 Phase W 的更新步数
η_W	Phase W 中的学习率
q	早停窗口长度
$O(Lmd)$	标准消息传递 GNN 在全图一次前向口径下的主项复杂度
$O(n\bar{k}d)$	MSAS-GNN / SDGNN 在推理阶段的主项复杂度口径
t_{dense}	稠密基线模型推理时间
t_{sparse}	MSAS-GNN 稀疏推理时间
Speedup	推理加速比，$\text{Speedup} = t_{\text{dense}}/t_{\text{sparse}}$
t_{pre}	总预处理时间，包括指标计算、LARS 求解与结构固化
Q_{be}	预处理的 break-even 调用次数，$Q_{\text{be}} = t_{\text{pre}}/(t_{\text{dense}} - t_{\text{sparse}})$
B_t	第 t 轮 mini-batch 中采样的节点子集
`batch_size`	mini-batch 训练或批次推理中的批大小
p 值	统计检验中的显著性概率值
r_{Pearson}	Pearson 相关系数，用于描述实验可视化中的线性相关程度

第 1 章 绪论

在线图推理的核心矛盾在于，多层消息传递虽然能够提升节点表示能力，但多跳邻域的持续扩张也会显著推高推理代价。针对这一矛盾，稀疏分解图神经网络（Sparse Decomposition of Graph Neural Networks，SDGNN）以单次稀疏分解替代逐层消息传递，为高效在线推理提供了可行思路。然而，其全局统一的稀疏预算机制仍难以适应真实图中普遍存在的节点拓扑异质性。围绕这一局限，本文提出多尺度自适应稀疏图神经网络（Multi-Scale Adaptive Sparse Graph Neural Network，MSAS-GNN）。本章将从研究背景与意义、国内外研究现状、研究内容与创新点，以及技术路线与论文组织结构四个方面，说明本文的研究动机、问题来源与整体安排。与方法相关的核心符号、形式化定义和理论分析将在第 3–5 章中进一步展开。

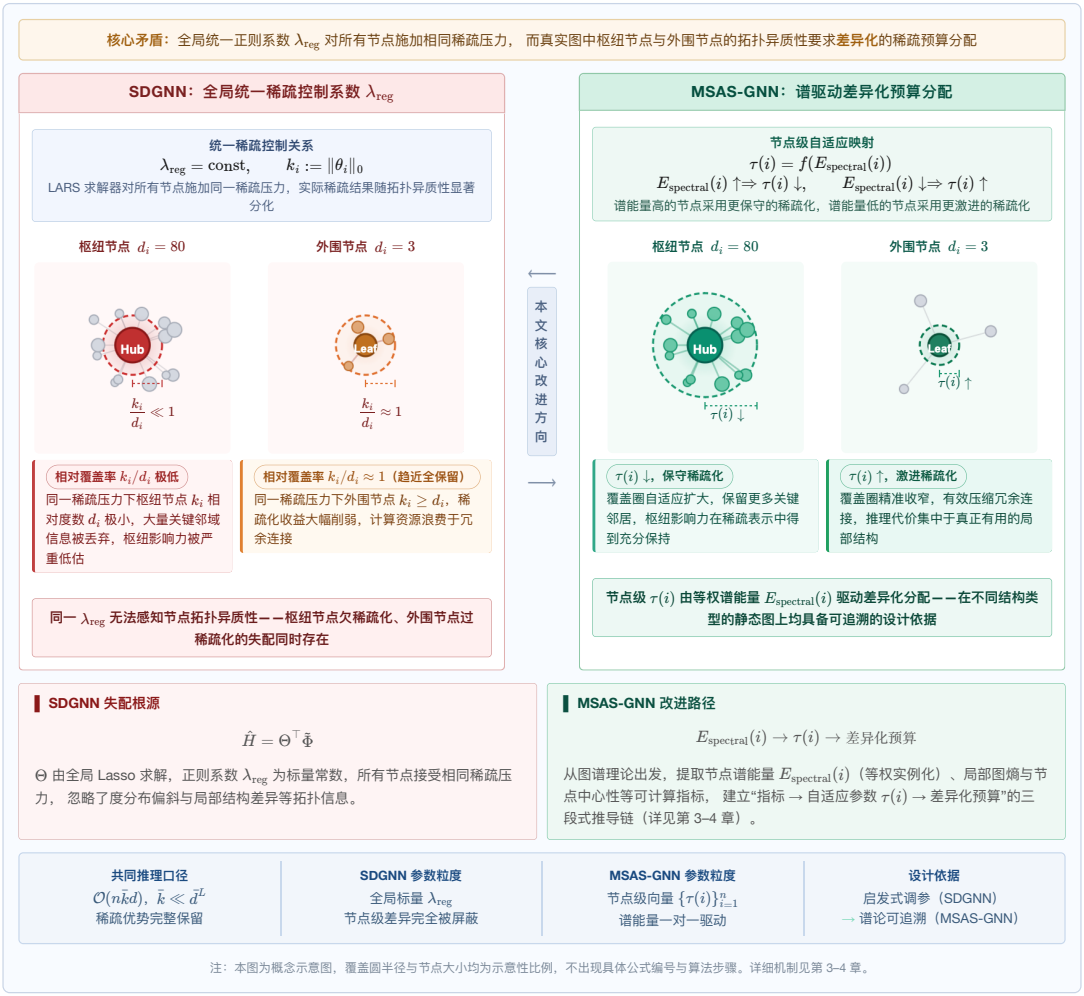

图 1.1　SDGNN 全局统一稀疏预算局限与 MSAS-GNN 谱驱动自适应改进示意图

1.1 研究背景与意义

图结构数据以节点和边刻画实体及其关联关系，广泛存在于社交网络、推荐系统、知识图谱、生物分子网络与交通网络等场景中。与图像、文本等规则结构数据不同，图数据通常具有邻接关系不规则、局部结构差异显著、节点邻域规模不一等特点，传统面向欧式数据的深度学习模型难以直接利用这类拓扑信息[1]。围绕这一问题发展起来的图神经网络（Graph Neural Network，GNN）通过在图拓扑上进行消息传递与邻域聚合，逐层融合节点自身特征与多跳邻域信息，在节点分类、链接预测、图分类等任务上表现出较强的建模能力，因而成为图表示学习的重要方法。

尽管 GNN 在多类任务上取得了良好效果，但其推理阶段仍面临明显的效率瓶颈。对于 L 层消息传递模型，目标节点的有效感受野会随层数扩大，在平均度为 $\bar{d}$ 的图上，其关联节点规模通常可近似写为 $O(\bar{d}^L)$。在这一过程中，邻居检索、特征读取与多轮聚合带来的计算和内存访问开销会迅速增加，使得 GNN 在大规模图和低时延场景下的部署受到限制。尤其在推荐系统、实时风控等在线服务场景中，模型不仅需要保持表示能力，还必须满足毫秒级响应要求，因此如何在尽量保留图结构信息的前提下降低推理代价，成为图神经网络走向实际应用时必须面对的问题。

针对上述问题，Hu 等提出稀疏分解图神经网络（Sparse Decomposition of Graph Neural Networks，SDGNN）[2]，将教师 GNN 表示的逼近重写为单次稀疏分解。在该框架中，推理阶段仅需执行

$$\hat{H} = \Theta^\top \tilde{\Phi}. \tag{1-1}$$

其中，$\tilde{\Phi} \in \mathbb{R}^{n\times d}$ 表示经过特征变换并作行归一化后的节点表示矩阵，其第 i 行对应节点 i 的变换特征；$\Theta \in \mathbb{R}^{n\times n}$ 为稀疏权重矩阵，第 i 列 θ_i 刻画节点 i 对其候选邻居特征的线性组合权重；$\hat{H} \in \mathbb{R}^{n\times d}$ 为稀疏分解得到的节点表示矩阵。由于每个节点最终仅保留少量非零权重，若记全图平均非零权重数为 $\bar{k}$，则该推理过程的主项复杂度可降至 $O(n\bar{k}d)$。与逐层消息传递相比，这种做法避免了推理时反复展开多跳邻域，为 GNN 的高效在线推理提供了新的实现路径。与此同时，SDGNN 通过 LARS 求解器在全局统一正则系数 λ_{reg} 下构造 Lasso 子问题，并在训练结束后固化稀疏权重矩阵 Θ，从而兼顾了近似精度与推理效率。

然而，以同一 λ_{reg} 约束所有节点的稀疏预算，实际上隐含了“不同节点适合相同稀疏压力”的前提。真实图中节点的拓扑角色通常存在显著差异：枢纽节点往往连接更广，承担更多跨区域信息传递功能，若稀疏化过强，容易丢失关键邻居；外围节点的局部冗余则相对更多，若稀疏化不足，又会削弱压缩收益。在结构更复杂、局部频谱参与方式差异更明显的图中，这种全局统一参数更容易与节

点的真实信息需求发生失配，如图 1.1 所示。如何在保持 $O(n\bar{k}d)$ 推理口径不变的前提下，将节点间的结构差异引入稀疏预算分配过程，是现有稀疏分解路线进一步发展的关键问题。

基于这一观察，本文从图谱理论出发，建立面向节点差异的自适应稀疏预算分配框架。该框架以可计算的图结构统计量为依据，将节点的谱域参与特征、局部结构复杂性与多跳传播差异转化为可解释的稀疏参数设计规则，从而降低稀疏化过程对全局统一预算的依赖，并针对不同结构角色节点采用差异化分配方式。该研究有助于为稀疏推理中的节点级预算设计提供更清晰的理论依据，也为大规模静态图上的高效部署提供更具适配性的实现思路。本文方法的具体效果将在第 6 章中通过实验进行验证。

1.2 国内外研究现状

围绕本文关注的“高效在线图推理”问题，现有研究大致可以归纳为三条彼此相关的文献脉络：其一是图神经网络推理效率及其瓶颈分析，其二是面向效率提升的高效与稀疏图神经网络方法，其三是复杂图结构学习中的谱视角方法。以下仅结合本文研究问题作概要梳理，为第 1.3 节的问题界定和第 2 章的系统综述提供铺垫。

1.2.1 图神经网络在线推理效率相关研究

Gilmer 等[3]将多种图学习方法统一为消息传递神经网络（MPNN）框架，之后的 GCN[4]、GAT[5]和 GIN[6]等模型，分别从谱滤波、注意力加权和表达能力等角度扩展了这一范式。此类方法的共同特点是通过多层邻域聚合逐步扩大节点的感受野，从而提升表示能力，但其代价是推理计算开销会随层数、边数和隐藏维度同步增长。以 GCN 为例，在全图一次前向传播的口径下，若模型包含 L 层图卷积，图中邻接矩阵 A 的非零元数记为 $m = \mathrm{nnz}(A)$，节点隐藏表示维度记为 d，则每层沿边进行邻域聚合的主项复杂度约为 $O(m \cdot d)$，L 层累计得到 $O(L \cdot m \cdot d)$。

对于离线批处理场景，上述复杂度仍具有可接受性；但在推荐系统、实时风控等强调低时延响应的在线服务中，目标往往是对少量查询节点快速完成推理，此时多跳邻居收集与内存访问会成为主要瓶颈。与此同时，随着传播层数增加，模型还可能出现过平滑[7]和过压缩[8]等现象，使得简单地依靠加深网络来换取更大感受野并不可取。这些问题共同说明，高效在线推理并不仅仅是“减少计算量”那么简单，还需要重新审视 GNN 表示形成过程中的信息保留方式，从而为稀疏分解等替代路径提供了问题背景。

1.2.2 高效与稀疏图神经网络方法

针对 GNN 推理中的感受野扩张问题，现有方法大致沿邻居采样、预计算线性化和稀疏分解三条路线展开。邻居采样方法，如 GraphSAGE[9]、FastGCN[10]和 GraphSAINT[11]，通过限制每层参与聚合的邻居规模来降低训练成本，但在推理阶段仍往往需要访问较大范围的邻域，且采样策略通常较为固定，难以针对不同节点的结构差异进行精细调整。

预计算线性化方法，如 SGC[12]、APPNP[13]和 SIGN[14]，则通过提前完成部分传播计算，将推理阶段尽量简化为轻量级线性变换，从而显著降低在线代价。这一路线在效率上具有明显优势，但传播模式通常在预处理阶段已经固定，因而缺少节点级自适应能力。

与前两类方法相比，稀疏分解路线更直接地面向“用少量关键邻居逼近教师表示”这一目标。SDGNN[2]在这一方向上给出了代表性方案，其将推理主项复杂度压缩到 $O(n\bar{k}d)$（$\bar{k} \ll \bar{d}^L$），成为本文的直接比较基线。需要指出的是，SDGNN 的优势主要来自推理阶段对多层传播过程的显式替代，而其不足则集中体现在预算控制机制上：全局统一正则系数 λ_{reg} 对所有节点施加相同稀疏压力，难以反映节点在拓扑角色、局部结构和频域参与方式上的差异。这一局限正是本文在第 3–5 章中进一步展开自适应稀疏机制设计的直接出发点。

1.2.3 复杂图结构学习与谱视角方法

除推理效率问题外，图结构本身的复杂性也会影响 GNN 的有效建模方式。已有研究表明，不同结构类型的图在判别信息所处的有效频段上可能存在明显差异：结构较平滑的引文网络通常更依赖低频聚合，而网页协作图等复杂结构数据则往往需要保留更多中高频成分[15]。这一现象说明，统一的低通传播假设并不总是适合所有图数据。

围绕复杂图结构建模，H2GCN[16]、GPR-GNN[17]、FAGCN[18]和 LINKX[19]等方法，分别从高阶邻域分离、自适应传播权重、高低频成分联合建模以及特征变换与传播解耦等角度，提高了模型对复杂图结构的适应能力。这些方法表明，谱视角能够为理解图结构差异及其传播行为提供有价值的分析工具。

不过，从本文关注的稀疏推理问题看，上述方法大多仍采用全图共享的频率参数或统一传播机制，尚未进一步落实到“节点级频率差异如何转化为节点级稀疏预算”这一层面。谱间隙 λ_{gap}能够刻画图的全局连通性，但若要进一步区分不同节点在局部结构中的频率参与特征，还需要引入更细粒度的局部谱统计量。基于这一考虑，本文保留“频率接口”这一设计位置，但在正文主线中采用等权实例化，以保证方法不依赖标签统计量并保持任务通用性；更精细的频率感知设计则作为后续扩展方向保留。

1.3 研究内容与创新点

上述三条文献脉络表明，现有高效图推理方法虽然在不同程度上缓解了 GNN 的部署开销，但在节点级差异化稀疏预算设计方面仍存在明显不足。以 SDGNN 为代表的稀疏分解方法主要依赖全局统一参数控制节点稀疏强度，尚未将节点拓扑差异及其频域影响系统地纳入预算设计过程；复杂图结构学习中的谱视角方法则更多停留在全图共享传播参数层面，尚未与节点级稀疏推理机制形成直接结合。这一研究空白构成了本文的核心问题背景。

围绕这一问题，本文关注如下研究目标：在保持静态推理主项复杂度 $O(n\bar{k}d)$ 不变的前提下，如何利用可计算的图结构统计量构建节点级差异化稀疏预算分配方案，使不同结构角色的节点能够获得更匹配的信息保留强度，并使这一设计具有可解释、可分析和可验证的依据。围绕该目标，本文将第 3–5 章组织为一条连续的方法链，依次完成问题形式化与指标提取、三维自适应机制设计，以及算法整合与理论分析。

在方法设计层面，本文的主要工作可概括为以下三个方面。第一，第 3 章构建了由谱间隙、节点谱能量、归一化局部图熵和节点中心性组成的图复杂度指标体系，为后续自适应参数设计提供统一的可计算输入。第二，第 4 章从频率、节点和跳距三个维度构建自适应稀疏机制：在频率维保留统一频率接口，并采用等权实例化作为正文主线默认配置；在节点维设计节点级正则系数，使不同节点能够对应不同稀疏强度；在跳距维结合多跳传播中的信息衰减现象，设计分层预算分配策略。第三，第 5 章将上述三维参数整合到 LARS 求解框架中，给出完整算法流程，并进一步分析误差与复杂度，使方法实现与理论讨论形成闭环。在这一设计下，推理阶段仍保持为单次稀疏矩阵乘形式，其主项复杂度维持在线性量级 $O(n\bar{k}d)$。

在实验验证层面，本文在六个静态节点分类基准数据集上对所提方法进行了系统评估。实验结果表明，MSAS-GNN 相较基线 SDGNN 在引文网络、网页图和大规模图场景下均表现出稳定改进，节点级自适应正则系数与分层跳距预算均对性能提升具有实际作用。与此同时，方法在 ogbn-arxiv 等数据集上仍保持较高推理效率，相对消息传递基线取得了明显加速，相关差异也通过 Wilcoxon 符号秩检验进行了统计验证。更具体的数据、设置与分析将在第 6 章中统一给出。

1.4 技术路线与论文组织结构

如图 1.2 所示，全文共分为七章，可归纳为四个相互衔接的功能层次。第 1–2 章用于建立研究背景、问题动机和理论基础；第 3–5 章构成本文的核心方法链，按照“问题形式化与指标提取 → 三维自适应机制设计 → 算法整合与理论分析”

的顺序展开，并统一以 $O(n\bar{k}d)$ 推理口径为约束；第 6 章对方法进行实验评估；第 7 章对全文工作进行总结，并讨论研究局限与未来方向。

第 1 章阐述研究背景、研究现状、研究问题与全文结构；第 2 章围绕高效图推理与谱视角方法梳理相关工作，明确现有研究空白；第 3 章对问题进行形式化描述，并建立后续章节所需的图复杂度指标体系；第 4 章构建频率维、节点维和跳距维三类自适应参数；第 5 章完成算法整合、误差分析与复杂度分析；第 6 章在多类静态节点分类数据集上开展主实验、消融实验和效率评估；第 7 章总结全文工作，并给出后续研究展望。上述安排形成了从问题提出、方法设计到实验验证的完整论证链条。

1.5 本章小结

本章围绕全文研究的出发点展开，不提前铺陈后续方法细节。围绕在线图推理中的效率与表示能力之间的矛盾，本章首先以 SDGNN 为切入点，指出全局统一稀疏预算难以适应节点拓扑差异这一核心局限；随后从推理效率、高效稀疏化以及复杂图结构学习三个方面梳理了与本文直接相关的研究进展，并据此归纳出本文关注的关键空白，即节点级自适应稀疏预算设计仍缺少统一的谱论依据和与稀疏推理机制相协调的分析框架。在此基础上，本文将研究目标限定为：在保持 $O(n\bar{k}d)$ 静态推理主项复杂度口径不变的前提下，构建谱驱动的三维自适应稀疏参数体系。下一章将在此基础上进一步系统整理相关理论基础和代表性方法，为后续方法章节展开提供文献与概念支撑。

图 1.2　本文技术路线与章节接口示意图

第 2 章 相关工作

大规模图上的在线推理效率始终是图神经网络研究与部署中的关键问题。对于 L 层消息传递 GNN，目标节点的有效感受野在最坏情况下可达 $O(\bar{d}^L)$，邻居收集、特征读取与内存访问开销会随传播层数迅速放大。稀疏分解图神经网络（Sparse Decomposition of Graph Neural Networks，SDGNN）将多层 GNN 输出的逼近转化为单次稀疏矩阵乘，使推理复杂度降至 $O(n\bar{k}d)$[2]。不过，该方法以全局统一的 Lasso 正则系数 λ_{reg} 控制所有节点的稀疏强度，难以反映不同拓扑角色节点在信息保留需求上的差异；当这一差异进一步投射到频率响应层面时，统一预算机制的局限会更加明显。这一问题构成了本文后续方法设计的直接动因。

本章围绕三条彼此关联的文献脉络展开。第 2.1 节介绍全文复用的基础符号体系与谱图理论背景；第 2.2 节梳理从采样加速、线性化预计算到 SDGNN 稀疏分解的技术演进，并分析其主要局限；第 2.3 节讨论复杂图结构上的频率响应及相关代表性方法，为第 4 章频率接口设计提供背景铺垫；第 2.4 节进一步提炼研究空白，并将其与第 3 章至第 5 章的方法链逐一对应。本章仅讨论与谱驱动自适应稀疏分解直接相关的研究背景，不提前引入本文原创的定理、命题或算法，相关正式定义与分析统一留待后续方法章节展开。

2.1 图神经网络基础与谱图理论

本节补充后续分析所需的基础符号，并概述与本文直接相关的谱图理论背景。全文统一符号见《符号和缩略语说明》，本章不再重复列示；本节仅对首次出现且后续讨论必需的记号作简要说明，涉及第 3 章至第 5 章方法接口的正式定义仍在相应章节中集中给出。

无向图 $G = (V, E, X)$ 由节点集 V、边集 E 和节点特征矩阵 $X \in \mathbb{R}^{n\times D}$ 组成，其中 $|V| = n$。设 A 为不含自环的对称邻接矩阵，D_{deg} 为由 A 诱导的度矩阵，其对角元素为

$$(D_{\text{deg}})_{ii} = d_i = \sum_{j=1}^{n} A_{ij}. \tag{2-1}$$

记 $m := \text{nnz}(A) = 2|E|$ 为邻接矩阵非零元数，并令全图平均度 $\bar{d} = m/n$。后文统一以 m 作为复杂度分析中的图规模参数。归一化拉普拉斯矩阵定义为

$$\tilde{\mathcal{L}} = I - D_{\text{deg}}^{-1/2} A D_{\text{deg}}^{-1/2}, \tag{2-2}$$

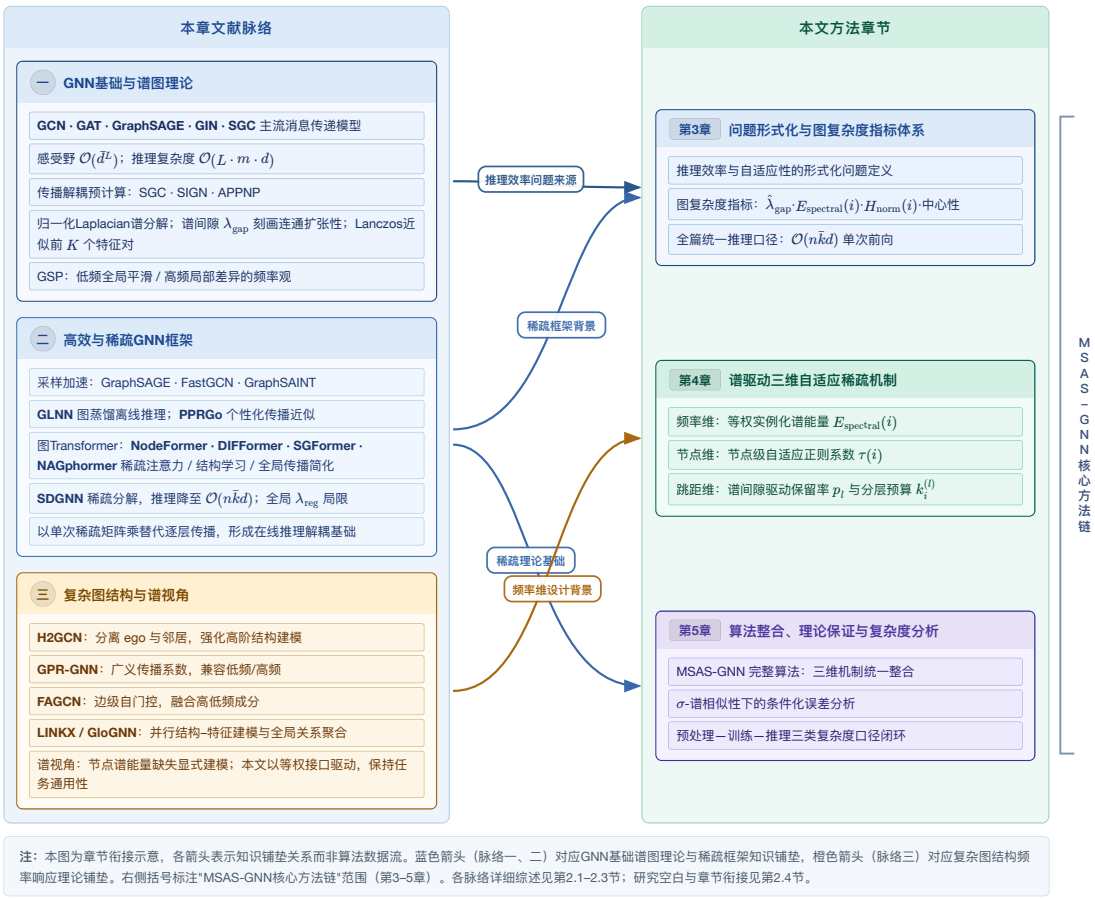

注：本图为章节衔接示意，各箭头表示知识铺垫关系而非算法数据流。蓝色箭头（脉络一、二）对应GNN基础谱图理论与稀疏框架知识铺垫，橙色箭头（脉络三）对应复杂图结构频率响应理论铺垫。右侧括号标注"MSAS-GNN核心方法链"范围（第3–5章）。各脉络详细综述见第2.1–2.3节；研究空白与章节衔接见第2.4节。

图 2.1　本章三条文献脉络与后续方法章节的对应关系

其谱分解写为 $\tilde{\mathcal{L}} = U\Lambda U^\top$，特征值满足

$$0 = \lambda_0 \leqslant \lambda_1 \leqslant \cdots \leqslant \lambda_{n-1} \leqslant 2. \tag{2-3}$$

本文统一采用从 λ_0 开始的编号方式。对连通图，谱间隙记为 $\lambda_{\text{gap}} := \lambda_1$，即最小非零特征值；若图不连通，则更一般地取最小正特征值。该量刻画图的整体连通扩张性质，并与导通率（conductance）满足 Cheeger 型关系，因此在后续跳距预算衰减分析中可作为图级结构量使用[20-22]。

从谱域观点看，图信号可在 $\tilde{\mathcal{L}}$ 的特征基上展开，相应的多项式谱滤波器可写为

$$g(\tilde{\mathcal{L}}) = \sum_{k=0}^{K_{\text{poly}}} c_k \tilde{\mathcal{L}}^k. \tag{2-4}$$

式 (2-4) 无需显式计算全部特征向量，因而可在顶点域以 $O(K_{\text{poly}} \cdot m \cdot D)$ 的代价实现。对于大规模图，若只需前 K_{eig} 个特征对，则通常可借助 Lanczos 迭代进行近似计算，其代价可写为 $O(m \cdot K_{\text{eig}})$。这些结果说明，谱域分析并不必然依赖全谱分解，而可以通过低阶近似进入可计算范围。进一步地，图信号处理（Graph Signal Processing，GSP）框架指出，低频分量通常对应全局平滑信息，高频分量

则更多反映局部差异或边界变化[23-24]。这一认识为后续从频率视角理解图结构差异提供了理论背景。

以 Gilmer 等人提出的消息传递神经网络框架（Message Passing Neural Network，MPNN）为例[3]，L 层图神经网络在全图一次前向口径下的主项复杂度通常可写为 $O(L \cdot m \cdot d)$。更重要的是，在最坏情况下，节点 i 的有效感受野会随传播层数迅速扩张，在近似树状展开下可达 $O(\bar{d}^L)$ 量级，从而使在线单节点查询中的邻居收集、特征读取与内存访问开销随层数同步放大。GCN[4]、GAT[5]、GraphSAGE[9]、GIN[6]和 SGC[12]等主流模型都在不同程度上受到这一推理瓶颈的影响。与此同时，随着传播层数增加，模型还可能出现过平滑和过压缩两类局限[7-8]：前者主要表现为节点表示逐渐趋同，后者则更多涉及长程依赖在受限拓扑通道中的压缩损失。二者虽然都与图的结构性质有关，但形成机理并不相同。上述现象共同说明，单纯依靠加深传播层数并不能从根本上解决在线推理效率问题，这也为后续稀疏分解类方法提供了明确的问题背景。

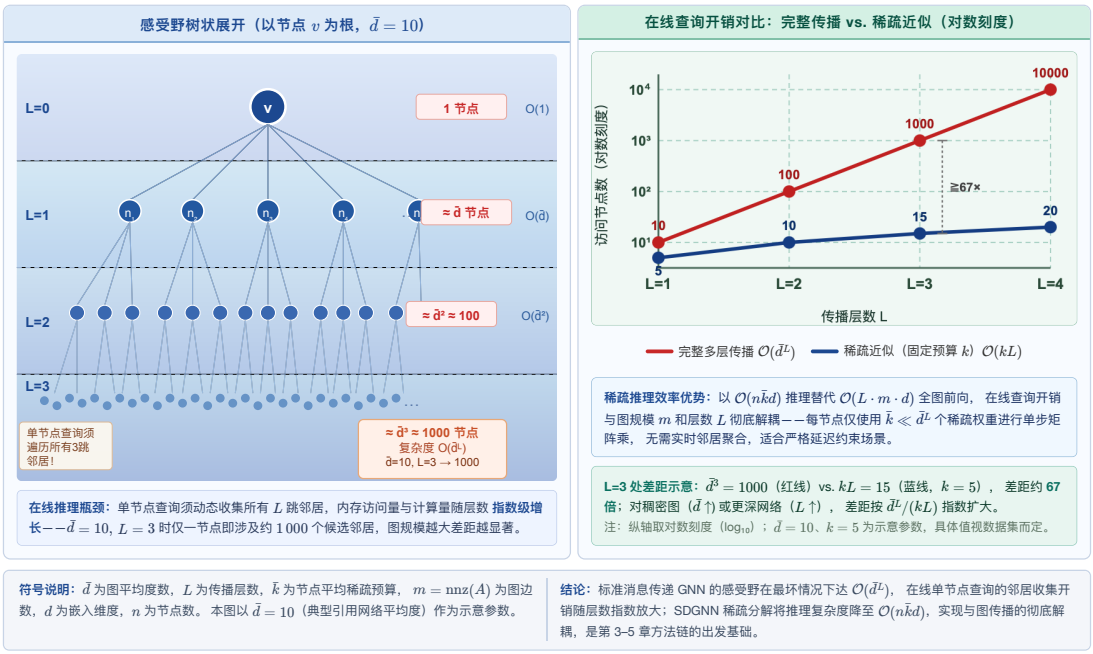

图 2.2　消息传递 GNN 感受野扩张与在线推理瓶颈示意图

2.2 高效与稀疏图神经网络方法

针对感受野随层数扩张带来的推理瓶颈，现有研究大致形成了三类技术路线。第一类是基于采样的近似方法。GraphSAGE[9]、FastGCN[10]和 GraphSAINT[11]通过控制每层参与聚合的邻居规模，缓解训练阶段的邻域爆炸问题。这类方法在推理阶段也可以沿用采样近似以控制开销，但若希望降低采样方差或保持预测稳定性，通常仍需访问较大范围的邻域，因此对严格在线单节点查询时延的优化仍然有限。

第二类方法通过传播与特征变换解耦来降低推理成本。其中，SGC[12]和 SIGN[14]倾向于将多阶传播结果离线预计算，并在推理阶段仅保留轻量级特征变换；APPNP[13]则以个性化传播将预测过程与图扩散部分解耦，但其传播环节通常仍需通过迭代近似实现。这一路线显著缓解了图传播与在线推理开销之间的强耦合关系，但节点级自适应能力通常较弱。

相较而言，稀疏分解框架更直接地面向“以少量关键邻居逼近教师表示”这一目标。Hu 等提出的稀疏分解图神经网络（Sparse Decomposition of Graph Neural Networks，SDGNN）[2]以稀疏矩阵分解逼近多层 GNN 输出，其推理阶段可写为

$$\hat{H} = \Theta^\top \tilde{\Phi}, \tag{2-5}$$

其中，$\tilde{\Phi} \in \mathbb{R}^{n\times d}$ 表示候选特征矩阵，Θ 为稀疏权重矩阵。对每个节点 i，其对应稀疏权重向量 θ_i 通过 LARS 算法离线求解 Lasso 子问题：

$$\min_{\theta_i} \ \|H^*_{i,:} - \tilde{\Phi}^\top \theta_i\|_2^2 + \lambda_{\text{reg}} \|\theta_i\|_1, \qquad i = 1, \cdots, n. \tag{2-6}$$

在平均每列仅保留 $\bar{k}$ 个非零元的条件下，其推理主项复杂度可降至 $O(n\bar{k}d)$。这一结果说明，稀疏分解路线能够在不保留逐层传播过程的前提下，直接形成面向在线推理的紧凑表示。

不过，SDGNN 的预算控制仍建立在全局统一正则系数 λ_{reg} 之上。式 (2-6) 对所有节点施加相同的 ℓ_1 惩罚，而不同节点在拓扑角色、局部结构以及邻域信息需求上往往并不一致。对于连接范围较广的枢纽节点，统一稀疏惩罚可能导致关键邻居被过度截断；对于局部结构较简单的外围节点，又可能保留过多冗余连接。现有稀疏分解方法已经明显改善推理效率，但节点级差异化预算设计仍有进一步完善空间。

除 SDGNN 外，若干面向高效推理的代表性方法也值得关注。PPRGo[25]基于个性化 PageRank 传播近似，在大规模图上能够实现较快的全图推理，但其传播权重主要在全图层面共享，节点级自适应能力有限。GLNN[26]则通过知识蒸馏将 GNN 压缩为不再显式依赖图结构的 MLP 模型，推理延迟较低，但也相应削弱了对图拓扑信息的直接利用。就本文关心的问题而言，现有工作仍缺少一条从可观测图谱性质出发、进一步过渡到节点级稀疏预算设计准则的系统分析链。

近年图 Transformer 路线也开始从稀疏注意力、结构学习和全局传播简化角度处理大规模图上的效率问题。NodeFormer[27]通过核化 Gumbel-Softmax 操作近似全节点对消息传递，在保持全局信息交换能力的同时将复杂度压缩到关于节点数近似线性的量级；DIFFormer[28]从能量约束扩散角度构造可扩展的 Transformer 编码器，以潜在结构上的扩散交互增强实例间关系建模；SGFormer[29]进一步简化图 Transformer 中的全局注意力模块，使其能够在大图节点表示学习中以较低

开销传播远程信息；NAGphormer[30] 则利用 Hop2Token 将不同跳距邻域聚合结果组织为节点级 token 序列，从而避免直接把全图所有节点作为单一长序列输入 Transformer 所带来的二次复杂度。上述方法与本文都关注有限计算预算下的有效结构信息保留问题，但二者所处的建模层级并不相同。图 Transformer 与端到端结构学习方法通常以构造新的模型骨干、注意力机制或可学习图结构为目标，直接改变节点表示的生成过程；本文则固定在 SDGNN 式稀疏分解推理接口内，在教师表示 H^* 已给定的条件下，研究如何依据节点结构差异分配不同的稀疏正则强度与跳距预算。因而，相关方法可作为高效图学习的外部参照，但与本文在推理接口、优化目标和实验比较口径上并不完全一致。

2.3 复杂图结构与谱视角相关方法

第 2.2 节表明，现有高效推理方法虽然在不同程度上缓解了图传播带来的计算开销，但对节点结构差异的刻画仍然较为粗粒度。进一步看，这种差异不仅体现为度分布或局部连边模式的不同，也体现在图信号频率分布及其传播响应上的差别。因此，本节从复杂图结构下的频率响应出发，梳理相关代表性方法，为后续方法章中的频率视角设计提供背景。

2.3.1 图结构差异与频率响应

已有研究普遍观察到，不同类型图的有效判别信息在频率分布上可能存在明显差异。对于引文网络等相对平滑的图结构，低频聚合往往能够较好地保留类别相关信息；而在网页图、维基图等结构更复杂的场景中，中高频成分往往同样具有判别意义[15-16]。这一现象说明，图传播过程不宜被简单理解为统一有效的低通滤波，不同图结构对频率成分的需求可能并不一致。也正因为如此，频率视角逐渐成为分析复杂图结构学习行为的重要工具。

2.3.2 代表性复杂图结构处理方法

围绕复杂图结构上的频率响应问题，现有方法大致从三类思路展开。H2GCN[16] 通过分离 ego 表示与邻居表示，并显式引入高阶邻域信息，增强模型对复杂局部结构的建模能力。GPR-GNN[17] 则引入可学习的广义 PageRank 系数 $\{\gamma_k\}$，以数据驱动方式调节不同传播阶数的贡献，其传播形式可写为

$$H^{(K)} = \sum_{k=0}^{K} \gamma_k (I - \tilde{\mathcal{L}})^k H^{(0)}. \tag{2-7}$$

FAGCN[18] 通过边级自门控系数 $\alpha_{ij}^{G} \in [-1, 1]$ 在消息传播过程中联合调节低频与高频成分；LINKX[19] 和 GloGNN[31] 则分别从结构—特征并行建模与全局关系聚

合的角度，提高模型对复杂图结构的适应能力。

尽管上述方法都在一定程度上突破了单一低通传播假设，但其自适应粒度并不直接对应“节点级稀疏预算”这一问题设定。GPR-GNN 中的 $\{\gamma_k\}$ 主要在全图层面共享，FAGCN 以边为粒度调节传播强度，LINKX 和 GloGNN 则更侧重结构与特征关系的联合表达；这些方法并未进一步给出从节点局部频率环境到节点级稀疏预算分配的完整映射关系。与此同时，它们在推理阶段通常仍依赖完整图传播过程，因而与 $O(n\bar{k}d)$ 这一稀疏分解推理接口并不一致。

从本文关注的角度看，现有复杂图结构学习方法已经说明了频率视角对于理解结构差异的重要性，但尚未把这种差异进一步转化为节点级稀疏预算设计准则。特别是，节点谱能量这类能够刻画节点在不同频率分量上参与强度的局部统计量，在现有代表性方法中并未被显式纳入稀疏推理框架。这也为第 2.4 节所归纳的研究空白提供了更直接的背景依据。

2.4 本章小结与研究空白

前文分别从图神经网络基础与谱图理论、高效与稀疏图神经网络方法，以及复杂图结构下的频率响应三个方面，梳理了与本文直接相关的研究背景。综合来看，现有工作已经从采样近似、传播解耦、稀疏分解和频率自适应等不同角度缓解了图神经网络的推理瓶颈，也说明了复杂图结构中频率差异对模型设计的重要影响。然而，就本文关注的“面向在线推理的节点级自适应稀疏预算”问题而言，现有研究仍存在若干尚未充分解决的环节。

在节点级稀疏预算的设计依据方面，现有高效推理方法大多采用全局共享的传播参数、统一的稀疏控制系数，或与节点角色无关的随机结构扰动机制，因而难以区分不同拓扑角色节点在信息保留需求上的差异。以 SDGNN 为例，其全局统一正则系数 λ_{reg}（式 (2-6)）虽然能够有效控制整体稀疏度，却未进一步回答“哪些节点应当保留更多邻居、哪些节点可以更强压缩”这一更细粒度的问题。因此，如何从可观测的图结构与谱性质出发，为节点级稀疏预算建立可计算、可解释的设计依据，仍是现有工作中的第一项空白。

在复杂图结构上的频率适应方面，已有方法已经说明，不同图结构中的有效判别信息可能分布在不同频段，但这种认识尚未自然过渡到节点级稀疏推理机制之中。GPR-GNN、FAGCN 和 H2GCN 分别从全图传播系数、边级门控和高阶邻域分离等角度提高了对复杂结构的适应能力，但其自适应粒度并不直接对应节点级稀疏预算分配。现有研究尚未形成从节点局部频率特性出发、进一步映射到节点级预算控制的完整分析链。这构成了本文进一步讨论频率接口与节点级预算关系的第二项空白。

从理论闭环的角度看，现有研究往往分别讨论稀疏近似、谱性质或复杂度收益，但较少把三者统一到同一分析框架中。对于节点级自适应稀疏化而言，参数解释是否清晰、误差代价能否分析、复杂度收益是否与设计目标一致，三者本应共同构成方法成立性的基础。现有文献在这些方面仍以分散讨论为主，尚缺少围绕“节点级自适应稀疏推理”这一具体问题的统一说明。这也是本文后续章节需要补足的第三项空白。

上述三项研究空白共同指向同一问题：现有高效图推理方法虽然已经降低了传播开销，但仍缺少面向节点差异的稀疏预算设计依据及其分析框架。后续章节将沿着“问题形式化与指标提取 → 自适应机制设计 → 误差与复杂度分析”的顺序展开：第 3 章建立图复杂度指标体系，第 4 章将这些指标转化为频率、节点与跳距三个维度上的自适应机制，第 5 章进一步讨论算法整合后的误差代价与复杂度收益。表 2.1对上述空白及其章节对应关系进行汇总。

表 2.1　现有方法研究空白与后续章节对应关系汇总

空白	核心局限描述	代表性相关方法	对应章节	对应解决方向
空白一	现有高效推理方法多采用全局共享参数或统一稀疏控制，节点级预算缺少可解释的设计依据	SDGNN，DropEdge 等	第 3 章	问题形式化与图复杂度指标提取
空白二	复杂结构图上的频率差异虽已被关注，但尚未进一步映射到节点级稀疏预算分配	GPR-GNN，FAGCN，H2GCN	第 4 章	节点级自适应稀疏机制设计
空白三	节点级自适应稀疏化的参数解释、误差代价与复杂度收益仍缺少统一分析	谱图理论、稀疏近似与复杂度分析相关工作	第 5 章	误差分析与复杂度分析的统一说明

注：本表仅汇总本章识别出的研究空白及其与后续章节的对应关系；表中“对应解决方向”为方向性概述，相关正式符号、定义与方法细节统一在后续章节中展开。

同时，本章引入的若干基础记号和背景结论将在后文直接复用。例如，归一化拉普拉斯矩阵 $\tilde{\mathcal{L}}$、谱间隙 λ_{gap} 以及图规模参数 $m = \text{nnz}(A) = 2|E|$，将作为第 3 章问题形式化与指标体系构建的重要起点；本章对 SDGNN 稀疏分解形式及其统一稀疏控制局限的讨论，也为后续节点级预算设计提供了直接参照。另一方面，本章关于复杂图结构与频率响应差异的综述，则构成了后续从频率视角理解节点结构差异的背景基础。至此，第二章完成了从研究背景、代表性方法到研究空白的系统梳理，也为第 3 章至第 5 章的展开提供了必要铺垫。

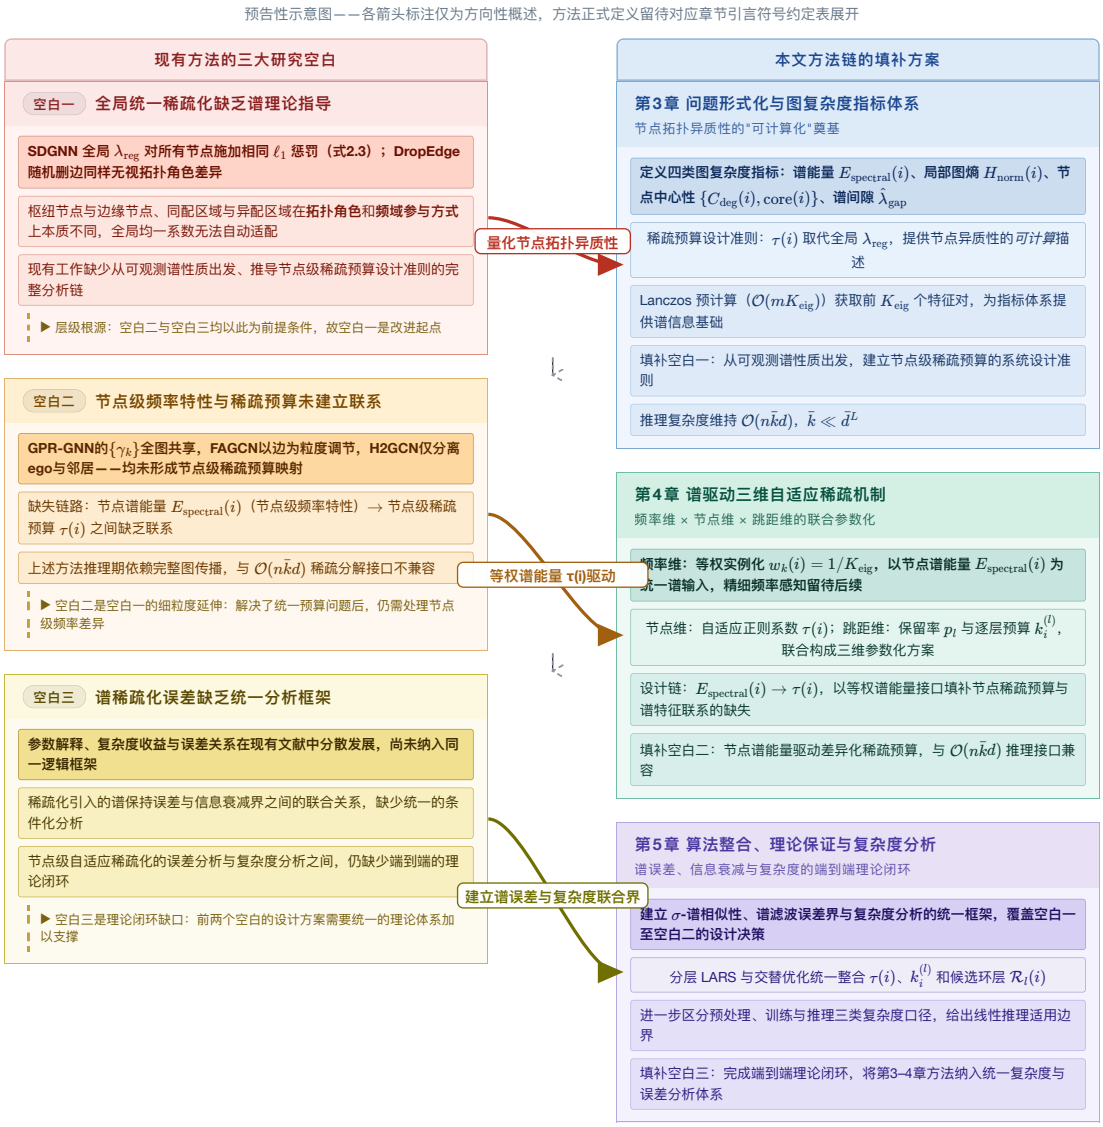

图注： 三大研究空白具有内在层级关联——空白一（全局统一稀疏化）是问题根源，空白二（节点级同配差异）是细粒度延伸，空白三（理论框架缺口）是理论闭环缺失。本文第3章至第5章的方法链依次填补三大空白，并形成相互衔接的接口闭环：第3章输出的四类指标（$E_{\text{spectral}}(i)$、$H_{\text{norm}}(i)$、$\{C_{\text{deg}}(i), \text{core}(i)\}$、$\hat{\lambda}_{\text{gap}}$）直接作为第4章设计的核心输入，第5章的理论分析进一步覆盖第3、4章的核心方法。各箭头标注仅为预告性说明，具体符号与方法定义留待对应章节引言中的符号约定表展开；本图不在相关工作章提前引入原创定理或命题。

图 2.3　三大研究空白与本文方法链的对应关系图

第 3 章 问题形式化与图复杂度指标体系

在标准消息传递图神经网络的推理过程中，按全图一次前向的复杂度口径，其计算开销通常可写为 $O(L \cdot m \cdot d)$，因而随图规模扩展，在线推理时延会显著上升。SDGNN[2]（Hu 等）将多层 GNN 的中间表示逼近问题转化为对基准 GNN 输出 H^* 的单次稀疏分解，推理阶段仅执行稀疏矩阵乘 $\hat{H} = \Theta^\top \tilde{\Phi}$，从而有效消除层间依赖；然而，其全局统一正则系数对节点拓扑异质性缺乏感知，容易导致枢纽节点邻居被过度截断，而外围节点的稀疏潜力又未被充分利用。

本章在保留 SDGNN 单次稀疏推理架构的前提下，从数学建模层面为节点级自适应稀疏预算体系奠定基础。第 3.1 节建立图学习基本设定，分析全局统一策略的局限，并给出统一优化目标与三项设计准则；第 3.2 节构建四类图复杂度量化指标，其中谱间隙、节点谱能量、局部图熵与节点中心性由算法 3.1 在离线阶段统一完成批量预处理；第 3.3 节总结本章与第 4 章、第 5 章的接口关系。除特别说明外，本章默认图结构静态可信，即邻接矩阵 A 在训练与推理期间保持固定且可用。

本章整体架构如图 3.1 所示。

3.1 问题形式化与优化目标

3.1.1 图学习基本设定与 SDGNN 基准

给定无向属性图 $G = (V, E, X)$，其中 $|V| = n$，节点特征矩阵 $X \in \mathbb{R}^{n \times D}$。记 $A \in \mathbb{R}^{n \times n}$ 为原始无向图的邻接矩阵；实现上采用对称邻接存储，因此记

$$m := \mathrm{nnz}(A) = 2|E|. \tag{3-1}$$

为原始邻接矩阵的非零元数。为处理孤立节点并与后续 GCN 式归一化传播口径保持一致，本文统一采用“加自环后再归一化”的预处理约定：

$$\tilde{A} = A + I, \qquad \tilde{D}_{\mathrm{deg},ii} = \sum_{j=1}^{n} \tilde{A}_{ij}. \tag{3-2}$$

由此可保证 $\tilde{D}_{\mathrm{deg},ii} > 0$，从而 $\tilde{D}_{\mathrm{deg}}^{-1/2}$ 合法。基于加自环邻接矩阵的对称归一化邻接矩阵定义为

$$\bar{A} = \tilde{D}_{\mathrm{deg}}^{-1/2} \tilde{A} \tilde{D}_{\mathrm{deg}}^{-1/2}. \tag{3-3}$$

相应的归一化拉普拉斯矩阵定义为

$$\tilde{\mathcal{L}} = I - \bar{A} = I - \tilde{D}_{\mathrm{deg}}^{-1/2} \tilde{A} \tilde{D}_{\mathrm{deg}}^{-1/2}. \tag{3-4}$$

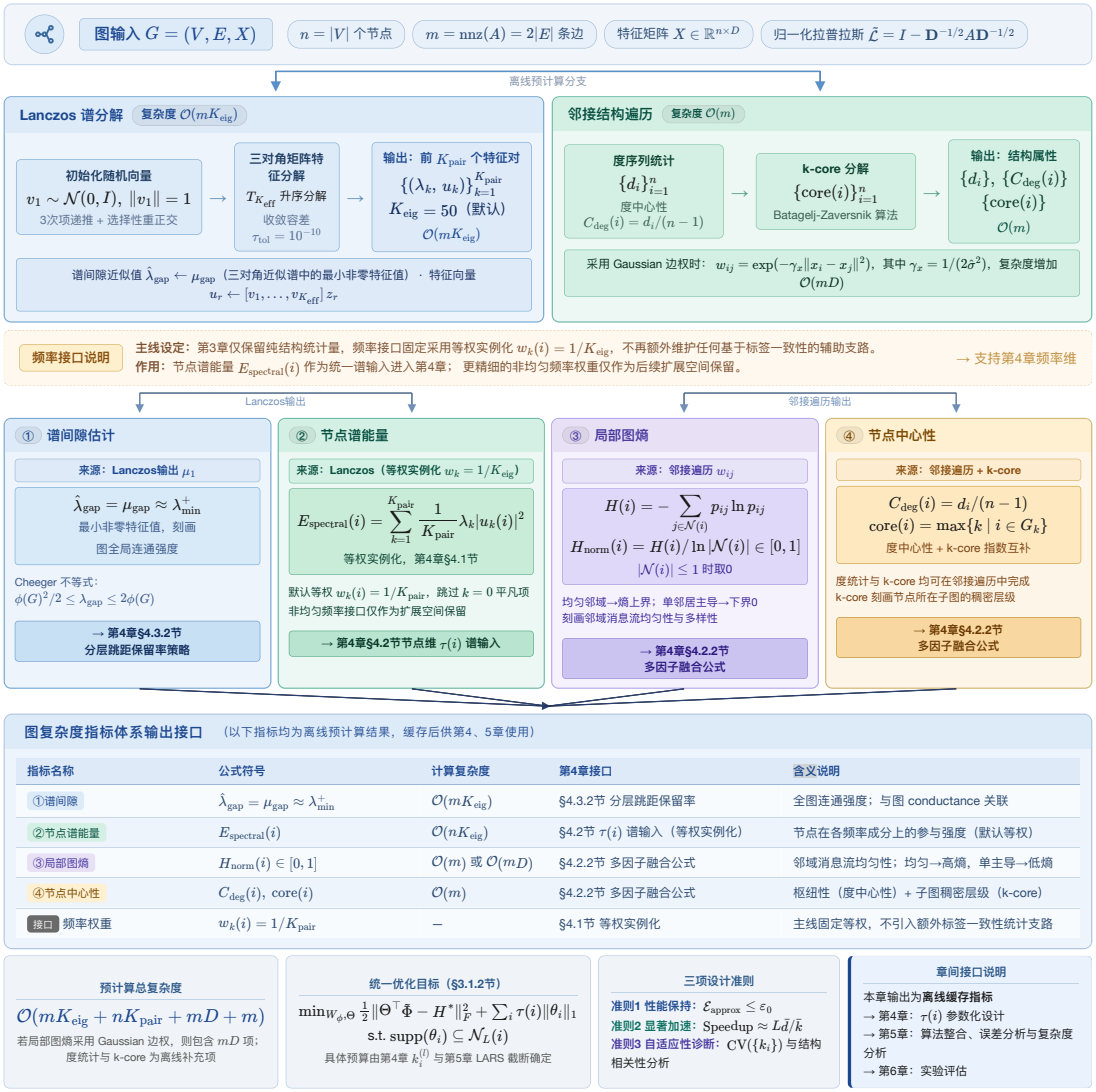

图 3.1　第 3 章整体流程图：从图输入到四类复杂度指标输出

其谱分解为

$$\tilde{\mathcal{L}} = U \Lambda U^{\top}, \tag{3-5}$$

特征值按升序排列：

$$0 = \lambda_0 \leqslant \lambda_1 \leqslant \cdots \leqslant \lambda_{n-1} \leqslant 2.^{[20]} \tag{3-6}$$

谱间隙 $\lambda_{\text{gap}} := \lambda_1$ 为第二小特征值，刻画图的全局连通强度。在半监督节点分类任务中，目标是学习映射 $f : V \to \{1, \cdots, C\}$。对任意节点 i，模型首先基于其稀疏推理表示 $\hat{h}(i)$ 计算类别预测概率，随后在训练节点集合上定义交叉熵任务损失：

$$\hat{y}_i = \operatorname{softmax}\Big(f_{\text{cls}}\Big(\hat{h}(i);\, W_{\text{cls}}\Big)\Big) \in \Delta^{C-1}, \tag{3-7}$$

$$\mathcal{L}_{\text{task}} = -\frac{1}{|V_{\text{train}}|} \sum_{i \in V_{\text{train}}} \sum_{c=1}^{C} \mathbf{1}[y_i = c] \log \hat{y}_{ic}. \tag{3-8}$$

其中，V 表示图的节点集合；C 表示类别数；$\hat{h}(i) \in \mathbb{R}^d$ 表示节点 i 的稀疏推理表示；$f_{\text{cls}}(\cdot; W_{\text{cls}})$ 表示分类头映射函数，W_{cls} 为其可学习参数；$\operatorname{softmax}(\cdot)$ 表示对各类别得分进行归一化的 softmax 函数；$\hat{y}_i \in \Delta^{C-1}$ 表示节点 i 的类别预测概率向量，Δ^{C-1} 为 C 维概率单纯形；$\hat{y}_{ic}$ 表示节点 i 属于第 c 类的预测概率；$V_{\text{train}} \subseteq V$ 表示训练节点集合，$|V_{\text{train}}|$ 为其基数；y_i 表示节点 i 的真实类别标签；$\mathbf{1}[y_i = c]$ 为示性函数，当 $y_i = c$ 时取值为 1，否则取值为 0；$\mathcal{L}_{\text{task}}$ 表示训练阶段在标注节点上计算的平均交叉熵损失。

许多真实网络的度分布呈长尾甚至近似幂律；当以方差 $\operatorname{Var}(\{d_i\}) = \frac{1}{n}\sum_i (d_i - \bar{d})^2$ 度量的度异质性较大时，统一稀疏控制强度往往会对高度节点和低度节点产生截然不同的相对稀疏化效果。以 SDGNN 为例，其对所有节点在同一全局稀疏控制规则下求解稀疏权重，并未显式根据节点拓扑异质性调整节点级稀疏强度；因此，高度节点在相同稀疏压力下更容易丢失大量关键邻域信息，而低度节点则可能保留冗余连接，导致不同拓扑角色节点承受不均衡的稀疏化效应。这一现象表明，仅依赖全局统一的稀疏控制机制难以适应度异质性显著的图结构，也正是本文进一步引入节点级自适应稀疏参数的直接动机。

以标准 GCN[4]（Kipf & Welling, 2017）为例，其第 l 层传播可写为

$$H^{(l)} = \sigma\big(\bar{A} H^{(l-1)} W^{(l)}\big), \tag{3-9}$$

其中，$H^{(l)} \in \mathbb{R}^{n \times d_l}$ 表示第 l 层节点表示矩阵，$H^{(0)} = X$ 为输入特征矩阵，$X \in \mathbb{R}^{n \times D}$；$n$ 为节点数，D 为输入特征维度，d_l 为第 l 层隐藏维度；$W^{(l)} \in \mathbb{R}^{d_{l-1} \times d_l}$ 为第 l 层可学习权重；$\sigma(\cdot)$ 为非线性激活函数。$\bar{A} = \tilde{D}_{\text{deg}}^{-1/2} \tilde{A} \tilde{D}_{\text{deg}}^{-1/2}$ 表示加入自环并对称归一化后的邻接矩阵，其中 $\tilde{A} = A + I$，$\tilde{D}_{\text{deg}}$ 为 $\tilde{A}$ 的度矩阵，满足

$\tilde{D}_{\mathrm{deg},ii} = \sum_{j=1}^{n} \tilde{A}_{ij}$。这里 D 仅表示输入特征维度，$\tilde{D}_{\mathrm{deg}}$ 表示度矩阵，二者不应混用。若仅从传播路径角度理解其多层邻域聚合过程，暂时省略层间非线性并将多层线性变换合并为等效权重 W_{eq}，则可近似写为

$$H^{(L)} \approx \bar{A}^{L} X W_{\mathrm{eq}}. \tag{3-10}$$

式 (3-10) 表明，L 层 GCN 会将节点特征沿归一化邻接矩阵传播到 L 跳邻域范围内。若记 $m = \mathrm{nnz}(A) = 2|E|$ 为邻接矩阵的非零元数，d 为传播过程中的代表性隐藏维度，则在稀疏矩阵乘法实现下，GCN 全图一次前向传播的主项复杂度通常可写为 $O(L \cdot m \cdot d)$。SDGNN[2]（Hu 等）将固定传播权重替换为每节点可学习稀疏权重 θ_i：

$$\hat{\mathcal{F}}(i, X, A; W, \Theta) = \theta_i^{\top} \Phi(X; W). \tag{3-11}$$

在 $\tilde{\Phi}$ 已预计算缓存的口径下，推理阶段仅执行稀疏矩阵乘 $\hat{H} = \Theta^{\top}\tilde{\Phi}$，主导复杂度降至 $O(n\bar{k}d)$，其中，$\bar{k}$ 表示全图节点最终稀疏结果规模的平均水平，即每个节点稀疏权重向量中非零项个数的平均值，定义为

$$\bar{k} = \frac{1}{n}\sum_{i=1}^{n} k_i, \qquad k_i = \|\theta_i\|_0. \tag{3-12}$$

式中，k_i 表示节点 i 最终保留的非零权重个数，θ_i 为节点 i 对应的稀疏权重向量，$\|\cdot\|_0$ 表示向量中非零元素的个数。当 $\bar{k} \ll \bar{d}^{L}$ 时，该口径相较原始多层消息传递具有明显压缩优势。然而，SDGNN 对所有节点采用统一的全局稀疏控制规则，而未显式根据节点拓扑异质性调整节点级稀疏强度；因此，不同节点最终得到的稀疏结果规模及其相对覆盖率会显著不同。对于枢纽节点，即使最终保留的非零项个数记为 $k_i := \|\theta_i\|_0$，其相对覆盖率 k_i/d_i 往往仍然较低，容易丢失大量关键邻域信息；而对于外围低度节点，则更可能保留冗余连接，稀疏潜力未被充分释放。这种由统一稀疏控制强度导致的结构性失配如图 3.2 所示。

3.1.2 统一优化目标与预算约束

本文以逼近教师/基准 GNN 的中间节点表示为主问题。给定教师目标表示矩阵 $H^* \in \mathbb{R}^{n\times d}$，本文首先通过逐节点共享参数的特征变换函数 $\phi(\cdot; W_\phi) : \mathbb{R}^{D} \to \mathbb{R}^{d}$ 将原始节点特征映射到与教师表示同维的嵌入空间。SDGNN 框架中 ϕ 可以采用 MLP 等一般可学习变换形式；为控制特征变换模块容量，并突出节点级自适应稀疏预算机制本身的作用，本文主实验统一采用单层线性变换作为默认实例化：

$$\phi(X; W_\phi) = X W_\phi, \qquad W_\phi \in \mathbb{R}^{D\times d}. \tag{3-13}$$

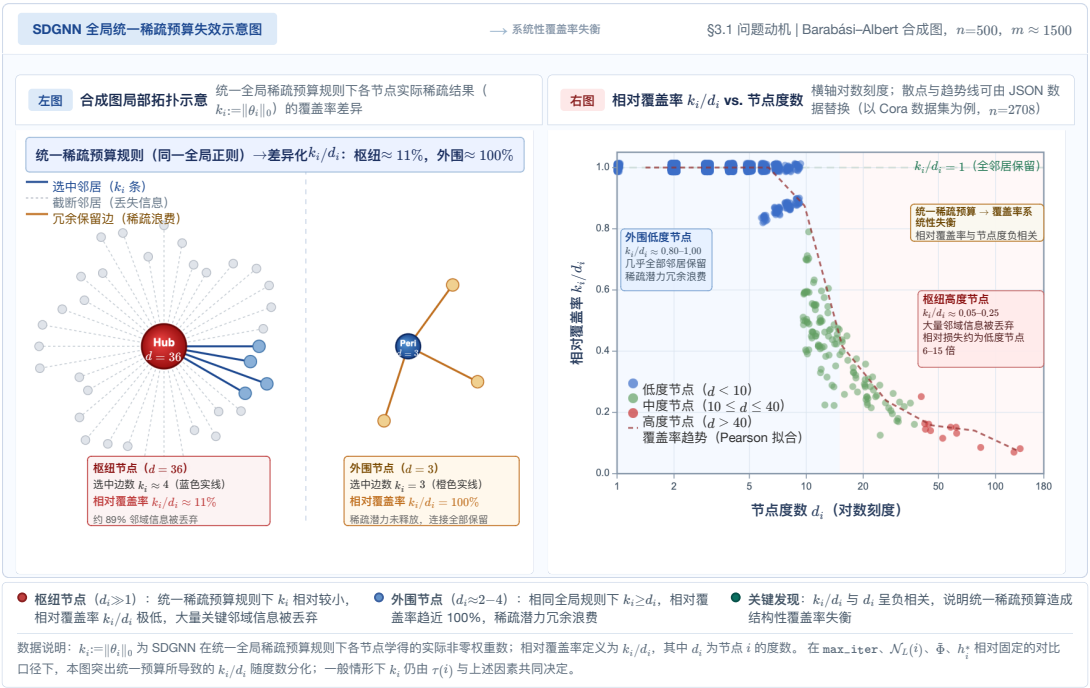

图 3.2　SDGNN 全局统一稀疏预算失效示意图

进一步地，记

$$\tilde{\Phi} := \ell_2\text{-normalize-row}(\phi(X; W_\phi)) \in \mathbb{R}^{n \times d}. \tag{3-14}$$

式 (3-14) 表示对变换后的节点特征逐行作 ℓ_2 归一化，以减弱不同节点特征尺度差异对后续稀疏分解的影响。单层线性变换是本文主实验采用的特征变换配置，并不意味着该结构在所有任务中最优；第 6 章将在去除特征变换的消融设置下，进一步分析该模块对表示逼近与下游性能的影响。

在此基础上，本文的决策变量为特征变换参数 W_ϕ 与稀疏权重矩阵 Θ，统一优化目标写为

$$\begin{aligned} \min_{W_\phi, \Theta} \quad & \frac{1}{2}\|\Theta^\top \tilde{\Phi} - H^*\|_F^2 + \sum_{i=1}^{n} \tau(i)\|\theta_i\|_1 + \frac{\lambda_W}{2}\|W_\phi\|_F^2, \\ \text{s.t.} \quad & \operatorname{supp}(\theta_i) \subseteq \mathcal{N}_L(i), \quad \forall\, i \in V. \end{aligned} \tag{3-15}$$

其中，$\Theta = \{\theta_i\}_{i=1}^n \in \mathbb{R}^{n \times n}$ 为全图稀疏权重矩阵，θ_i 表示节点 i 对候选节点特征的稀疏组合权重；$\lambda_W > 0$ 为特征变换参数 W_ϕ 的 ℓ_2 正则系数；$\tau(i) \in [\tau_{\min}, \tau_{\text{base}}]$ 为节点自适应正则系数，用以替代 SDGNN 的全局统一稀疏控制系数。约束 $\operatorname{supp}(\theta_i) \subseteq \mathcal{N}_L(i)$ 要求节点 i 的非零稀疏权重仅作用于其 L 跳感受野范围内，从而保持局部传播语义，并与教师 GNN 的感受野范围相一致。

后文以

$$k_i := \|\theta_i\|_0 \tag{3-16}$$

记节点 i 最终稀疏解中的非零项个数，并以

$$\bar{k} := \frac{1}{n}\sum_{i=1}^{n} k_i \tag{3-17}$$

记全图平均保留规模。k_i 与 $\bar{k}$ 在本文中主要用于刻画最终稀疏结果的非零规模，并非式 (3-15) 中预先固定的显式预算常数；其数值由节点级正则强度 $\tau(i)$、候选集范围以及后续 LARS 求解过程共同决定。第 4 章进一步给出节点级正则系数与分层跳距配额的构造方式，第 5 章则在具体求解时结合分层候选集与 LARS 截断机制控制路径扩张规模，从而在保持局部性的同时实现稀疏求解。

本文采用两阶段交替优化求解式 (3-15)：Phase Θ 在固定 W_ϕ 的条件下，利用 LARS[32]（Efron 等，2004）求解各节点的 $\tau(i)$ 加权 Lasso 子问题；Phase W 在固定 Θ 的条件下，利用反向传播更新 W_ϕ。由于该联合优化问题包含可学习特征变换与稀疏权重的交替更新，整体上属于非凸优化问题，本文在工程实现上主要关注训练过程的稳定性与可实现性，不主张严格的全局最优收敛保证，相关实现说明见第 5 章第 5.1.3 节。$\tau(i)$ 的可计算表达式将在第 4 章第 4.2 节给出。

3.1.3 近似误差度量与三项设计准则

本文统一采用 RMS-Frobenius 近似误差度量稀疏分解质量：

$$\mathcal{E}_{\text{approx}}(W,\Theta;\, W^*) \;:=\; \frac{1}{\sqrt{n}}\left\|H^*(X,A;\, W^*) - \hat{H}(X,A;\, W,\Theta)\right\|_F. \tag{3-18}$$

其中，n 为图中节点总数，$H^*(X,A;\, W^*) \in \mathbb{R}^{n\times d}$ 表示教师/基准 GNN 在参数 W^* 下得到的目标中间表示矩阵，$\hat{H}(X,A;\, W,\Theta) \in \mathbb{R}^{n\times d}$ 表示稀疏分解模型在参数 W 与 Θ 下得到的近似表示矩阵，$\|\cdot\|_F$ 为 Frobenius 范数。式 (3-18) 中的 $n^{-1/2}$ 缩放用于消除图规模对误差量级的线性放大影响，使不同规模图上的表示误差具有可比性；该口径也与第 5 章谱保持分析及第 6 章实验中的表示误差统计保持一致。后续各章的模块设计与实验分析主要围绕“精度保持”与“效率提升”两个评价口径展开。

其一为精度保持口径（Accuracy Preservation）。本文以后续稀疏分解输出与教师表示之间的 RMS-Frobenius 误差作为统一评价量，即以式 (3-18) 衡量表示层逼近质量。该误差越小，说明稀疏分解对教师中间表示的保真程度越高。本文不将某一固定阈值设为必须满足的硬验收条件；第 5 章将结合谱保持分析讨论该误差与结构近似误差之间的关系，第 6 章则通过表示误差、分类精度及其变化趋势进行经验验证。

为说明 RMS-Frobenius 误差与节点级大误差比例之间的关系，记节点 i 的表示误差向量为

$$\Delta z_i := h_i^* - \hat{h}_i, \tag{3-19}$$

其中，h_i^* 与 $\hat{h}_i$ 分别表示教师模型与稀疏分解模型在节点 i 处的表示。进一步定义节点级误差标量

$$\varepsilon_i^{\text{rep}} := \|\Delta z_i\|_2 = \|\hat{h}_i - h_i^*\|_2, \qquad i = 1, \cdots, n. \tag{3-20}$$

根据式 (3-18)，RMS-Frobenius 近似误差满足

$$\mathcal{E}_{\text{approx}}^2 = \frac{1}{n}\|\hat{H} - H^*\|_F^2 = \frac{1}{n}\sum_{i=1}^{n}\|\hat{h}_i - h_i^*\|_2^2 = \frac{1}{n}\sum_{i=1}^{n}\left(\varepsilon_i^{\text{rep}}\right)^2. \tag{3-21}$$

对任意给定阈值 $t > 0$，定义大误差节点集合为

$$\mathcal{S}(t) := \{i \in V : \varepsilon_i^{\text{rep}} \geqslant t\}. \tag{3-22}$$

其中，V 为节点集合，$\mathcal{S}(t)$ 表示所有表示误差不小于阈值 t 的节点所构成的集合。

由于当 $i \in \mathcal{S}(t)$ 时有 $\left(\varepsilon_i^{\text{rep}}\right)^2 \geqslant t^2$，因此

$$\sum_{i=1}^{n}\left(\varepsilon_i^{\text{rep}}\right)^2 \geqslant \sum_{i\in\mathcal{S}(t)}\left(\varepsilon_i^{\text{rep}}\right)^2 \geqslant |\mathcal{S}(t)|\, t^2. \tag{3-23}$$

将式 (3-21) 代入式 (3-23)，可得

$$n\mathcal{E}_{\text{approx}}^2 \geqslant |\mathcal{S}(t)|\, t^2. \tag{3-24}$$

两边同时除以 nt^2，得到

$$\frac{|\mathcal{S}(t)|}{n} \leqslant \left(\frac{\mathcal{E}_{\text{approx}}}{t}\right)^2. \tag{3-25}$$

式 (3-25) 也可视为对非负随机变量 $\left(\varepsilon_i^{\text{rep}}\right)^2$ 使用 Markov 不等式所得的结果。若从节点集合 V 中均匀随机抽取一个节点 I，则有

$$\mathbb{E}\big[(\varepsilon_I^{\text{rep}})^2\big] = \frac{1}{n}\sum_{i=1}^{n}\left(\varepsilon_i^{\text{rep}}\right)^2 = \mathcal{E}_{\text{approx}}^2. \tag{3-26}$$

由 Markov 不等式可得

$$\mathbb{P}(\varepsilon_I^{\text{rep}} \geqslant t) = \mathbb{P}\big((\varepsilon_I^{\text{rep}})^2 \geqslant t^2\big) \leqslant \frac{\mathbb{E}\big[(\varepsilon_I^{\text{rep}})^2\big]}{t^2} = \left(\frac{\mathcal{E}_{\text{approx}}}{t}\right)^2. \tag{3-27}$$

又因为 $\mathbb{P}(\varepsilon_I^{\text{rep}} \geqslant t) = |\mathcal{S}(t)|/n$，故可得到式 (3-25)。该式表明，当整体 RMS-Frobenius 近似误差 $\mathcal{E}_{\text{approx}}$ 较小时，表示误差不小于阈值 t 的节点比例也会受到相应控制。

将表示层误差进一步严格转化为准确率下降界，还需要额外给定分类头的 Lipschitz 常数（分类头对输入扰动的敏感程度）、节点分类 margin 分布（各节点到分类决策边界的距离）以及预测扰动对决策边界的影响条件（误差扰动是否会改变预测类别）。因此，本文仅将式 (3-25) 作为表示近似误差的节点比例控制说明，而不声称其直接给出分类准确率的封闭下降界。

其二为效率提升口径（Efficiency Gain）。为避免复杂度口径混用，本文统一

采用“$\tilde{\Phi}$ 已离线预计算并缓存后的聚合主项”作为在线推理比较口径。在该口径下，稀疏分解推理的主导复杂度可记为 $O(n\bar{k}d)$；相应地，对 L 层标准消息传递 GNN，若同样按“全图一次前向、仅统计聚合主项”的口径计算，则其复杂度可记为 $O(Ln\bar{d}d)$。因此，后文默认在这一统一口径下讨论加速比，相较标准消息传递 GNN 的基础聚合加速比可写为

$$\mathrm{Speedup}_{\mathrm{base}} \approx \frac{O(Ln\bar{d}d)}{O(n\bar{k}d)} = \frac{L\bar{d}}{\bar{k}}. \tag{3-28}$$

其中，L 为教师或基准 GNN 的传播层数，$\bar{d}$ 为全图平均度，d 为隐藏表示维度，$\bar{k}$ 表示全图平均最终保留规模。式 (3-28) 表明，当 $\bar{k} \ll L\bar{d}$ 时，稀疏分解在聚合主项上具有潜在加速优势。式 (3-28) 仅用于给出统一评价口径下的理论近似加速比，而非端到端实测时间比值；关于推理、训练与预处理三类开销的严格区分及其成立条件，将在第 5 章复杂度分析中进一步展开。

其三为自适应性诊断（Adaptivity Diagnosis）。为刻画不同节点最终稀疏结果规模的离散程度，本文可进一步引入变异系数（coefficient of variation, CV）作为辅助诊断量：

$$\mathrm{CV}(\{k_i\}) := \frac{\sqrt{\frac{1}{n}\sum_{i=1}^{n}(k_i-\bar{k})^2}}{\bar{k}}. \tag{3-29}$$

其中，$k_i := \|\theta_i\|_0$ 表示节点 i 最终稀疏解中的非零项个数，反映节点 i 的最终保留规模；$\bar{k} := \frac{1}{n}\sum_{i=1}^{n} k_i$ 为全图平均稀疏度；n 为图中节点总数。式 (3-29) 的分子为节点最终保留规模的标准差，分母为其均值，因此 $\mathrm{CV}(\{k_i\})$ 刻画的是节点间最终稀疏结果规模的相对离散程度。一般而言，$\mathrm{CV}(\{k_i\})$ 越大，说明不同节点对应的最终保留规模差异越明显；当其接近 0 时，说明各节点最终稀疏结果规模更为接近，方法在经验上更接近全局统一稀疏化行为。

本文后续实验并未再额外设定统一的自适应性诊断阈值，也未将式 (3-29) 作为与表示误差、加速比并列的独立硬验收指标进行系统报告。其原因主要有三点：第一，$\mathrm{CV}(\{k_i\})$ 刻画的是单张图内部节点最终保留规模的相对离散程度，而不同数据集本身的节点结构异质性基线并不一致；对于节点角色差异较小、度分布更集中的图，即使方法具有合理的节点自适应性，$\mathrm{CV}(\{k_i\})$ 也可能保持在较低水平。第二，$\mathrm{CV}(\{k_i\})$ 同时受节点数、平均度、候选集规模及图结构分布等数据统计特征影响，因而并非脱离数据背景的纯方法指标，直接用于跨图比较时容易混入图本身的结构差异。第三，$\mathrm{CV}(\{k_i\})$ 仅反映最终保留规模的离散程度，能够回答“差异是否存在”，却不能进一步说明“这种差异是否合理”以及“是否真正带来了更优的精度—效率权衡”。基于上述原因，本文将式 (3-29) 视为单图内部的辅助诊断量，而不将其作为跨图统一比较的硬性评价标准。相应地，后文关于“自适应性诊断”的讨论主要通过节点级正则参数 $\tau(i)$ 的分布，以及不

同设置下精度与效率变化的联合现象进行经验分析。

综上，后续各章的理论分析与实验验证主要围绕表示逼近误差与推理效率两条主线展开，自适应性则作为解释节点级差异化稀疏机制有效性的辅助分析视角。

3.2 图复杂度量化指标体系

前节建立了统一优化目标与三项设计准则，但尚未回答节点级正则系数 $\tau(i)$ 应如何由图的可观测结构属性确定。本节从全图级与节点级两个粒度提取图复杂度指标，为第 4 章三维自适应参数设计提供可计算输入。本节仅给出指标定义、计算方式及其结构含义，具体的参数化映射关系将在第 4 章展开。

本节使用的结构指标包括谱间隙、节点谱能量、局部图熵与节点中心性四类。其中，谱间隙 λ_{gap} 是归一化拉普拉斯矩阵的最小非零特征值，用于刻画图的整体连通扩张性质，并将在第 4 章第 4.3.2 节进入分层跳距保留率设计。节点谱能量 $E_{\text{spectral}}(i)$ 刻画节点在非平凡谱分量上的参与强度，是节点级正则系数 $\tau(i)$ 的核心谱输入。局部图熵 $H_{\text{norm}}(i)$ 用于描述节点邻域消息流的分散程度；度中心性 $C_{\text{deg}}(i)$ 与 k-core 指数 $\text{core}(i)$ 则分别从节点连接规模和局部稠密层级两个角度补充结构刻画。上述节点级统计量将在第 4 章第 4.2.2 节共同进入 $\tau(i)$ 的多因子融合公式。

3.2.1 谱间隙与节点谱能量

设归一化拉普拉斯矩阵的谱分解为

$$\tilde{\mathcal{L}} = U\Lambda U^{\top}, \tag{3-30}$$

其中，U 为特征向量矩阵，Λ 为特征值对角矩阵。本文按特征值升序排列，并跳过 $k=0$ 的平凡特征分量，取前 K_{eig} 个非平凡特征对 $\{(\lambda_k, u_k)\}_{k=1}^{K_{\text{eig}}}$。谱间隙定义为最小非零特征值 λ_{gap}。在连通图上，$\lambda_{\text{gap}} = \lambda_1$；若图不连通，则取最小正特征值。该量与导通率（conductance）$\phi(G)$ 满足 Cheeger 型关系[21-22]，可作为图级连通性与扩张性的结构刻画量。

节点谱能量用于刻画节点在不同拉普拉斯特征分量上的参与强度。一般形式下，节点 i 的谱能量可写为

$$E_{\text{spectral}}(i) = \sum_{k=1}^{K_{\text{eig}}} w_k(i)\lambda_k |U_{ik}|^2, \tag{3-31}$$

其中，λ_k 承担频率敏感性尺度，$|U_{ik}|^2$ 衡量节点 i 对第 k 个特征向量的参与强度，$w_k(i)$ 表示节点 i 对第 k 个频率分量的权重，满足 $w_k(i) \geqslant 0$ 且 $\sum_{k=1}^{K_{\text{eig}}} w_k(i) = 1$。

频率权重 $w_k(i)$ 在形式上可以设计为节点相关的自适应函数，用于强调某些

频段对节点表示的贡献差异。然而，第 3 章承担的是离线结构指标预处理功能，其输出应尽量保持任务无关，并作为后续自适应稀疏预算设计的统一输入。若在此阶段引入基于标签一致性或同配性统计的频率打分函数，则训练、验证与测试划分中的标签信息可能通过结构指标间接回流到后续稀疏参数中，从而带来标签泄漏风险。

基于上述考虑，本文在正文主线中采用等权频率接口。具体地，令

$$\alpha_k(i) \equiv 0, \qquad w_k(i) = \frac{\exp(\alpha_k(i))}{\sum_{r=1}^{K_{\text{eig}}} \exp(\alpha_r(i))} = \frac{1}{K_{\text{eig}}}, \tag{3-32}$$

从而得到本文实际使用的节点谱能量定义：

$$E_{\text{spectral}}(i) = \frac{1}{K_{\text{eig}}} \sum_{k=1}^{K_{\text{eig}}} \lambda_k |U_{ik}|^2. \tag{3-33}$$

式 (3-33) 仅依赖拉普拉斯特征值、特征向量以及节点在各谱分量上的投影，不额外引入标签统计量。这里跳过 $k = 0$ 的平凡特征分量，是为了避免与度中心性所反映的全局平滑信息产生冗余。本文选取前 K_{eig} 个非平凡特征对，主要是因为较小特征值对应的谱分量与图的整体结构更为相关，能够更稳定地反映连通模式、簇结构与全局平滑性质；同时，后续还将使用谱间隙 λ_{gap} 等全图级谱量刻画图结构特征，因此从低频端开始截断，也可使节点谱能量的定义与谱间隙、连通性等全图量在分析口径上保持一致。

从直观上看，$E_{\text{spectral}}(i)$ 刻画了节点 i 在不同非平凡谱分量上的综合参与程度。当节点在多个非平凡特征向量上具有较高投影，且这些投影对应的特征值相对更大时，其谱能量取值更高；反之，若节点主要集中于少数低频平滑分量，或在非平凡特征向量上的响应整体较弱，则其谱能量较低。因此，节点谱能量可以被视为一种节点级结构活跃度指标，用于反映节点在图谱域中承载局部差异信息与复杂结构信号的能力。后续第 4 章将把该量作为节点级自适应正则系数 $\tau(i)$ 的核心谱输入，用于区分不同节点对邻居保留预算的潜在需求。

完整谱分解的复杂度为 $O(n^3)$，在中大规模图上难以直接承受。本文采用 Lanczos 迭代[33]进行截断谱估计，将前若干个低频非平凡特征对的计算开销降至 $O(mK_{\text{eig}})$。其基本思想是从随机初始向量出发，在 Krylov 子空间中递推构造一组近似正交基，并将原始大规模稀疏对称矩阵 $\tilde{\mathcal{L}}$ 的特征值问题压缩为低维三对角矩阵的特征值问题。随后对该三对角矩阵进行特征分解，即可近似恢复原矩阵前若干个低频非平凡特征对。本文记 K_{eig} 为预设谱截断数；若在给定收敛容差下 Lanczos 迭代提前收敛，则实际参与后续节点谱能量计算的非平凡特征对数量记为 $K_{\text{pair}} \leqslant K_{\text{eig}}$。

3.2.2 局部图熵

本文将节点 i 邻域消息流的均匀程度以局部图熵（local graph entropy）量化。为避免无权图情形下归一化邻域分布退化为等概率分布，从而使归一化局部图熵在多数节点上接近常数 1，本文统一采用基于节点特征差异的高斯核边权重来刻画邻域内各邻居对节点 i 的相对贡献。具体地，对任意 $(i,j)\in E$，定义

$$w_{ij}=\exp\bigl(-\gamma_x\|x_i-x_j\|_2^2\bigr),\qquad \gamma_x=\frac{1}{2\hat{\sigma}^2},\tag{3-34}$$

其中，$\hat{\sigma}^2$ 取边集上特征差平方的中位数，用作高斯核带宽的鲁棒数据自适应估计：

$$\hat{\sigma}^2:=\operatorname{median}\left\{\|x_i-x_j\|_2^2:(i,j)\in E\right\}.\tag{3-35}$$

这种带宽设定可以避免人为指定固定尺度参数，并减弱少量异常大距离边对带宽估计的影响，使边权更稳定地反映相邻节点间的特征相似性。

在此基础上，对节点 i 的邻居集 $\mathcal{N}(i)$ 定义归一化分布

$$p_{ij}=\frac{w_{ij}}{\sum_{k\in\mathcal{N}(i)}w_{ik}},\qquad j\in\mathcal{N}(i).\tag{3-36}$$

并约定 $0\ln 0=0$。当 $|\mathcal{N}(i)|\leqslant 1$ 时，取 $H(i)=0$ 且 $H_{\text{norm}}(i)=0$；当 $|\mathcal{N}(i)|>1$ 时，局部图熵及其归一化形式定义为

$$H(i)=-\sum_{j\in\mathcal{N}(i)}p_{ij}\ln p_{ij},\qquad H_{\text{norm}}(i)=\frac{H(i)}{\ln|\mathcal{N}(i)|}\in[0,1].\tag{3-37}$$

由式 (3-37) 可知，当节点 i 的邻域贡献较为均衡时，$H_{\text{norm}}(i)$ 取值较高；当少数邻居在加权分布中占主导时，$H_{\text{norm}}(i)$ 相应降低。因此，该指标刻画的并非仅是邻居个数本身，而是结合特征相似性后的邻域有效信息分散程度，可作为节点局部结构复杂度与消息流均匀性的辅助量化指标。按边遍历计算全部 w_{ij} 与 $H_{\text{norm}}(i)$ 的总开销为 $O(mD)$，与后文图复杂度指标的统一预处理口径保持一致。归一化局部图熵 $H_{\text{norm}}(i)$ 将在第 4 章第 4.2.2 节作为多因子之一并入节点级正则系数 $\tau(i)$ 的融合公式。

3.2.3 节点中心性

度中心性 $C_{\text{deg}}(i)$ 与 k-core 指数 $\operatorname{core}(i)$[34] 作为节点中心性的两个互补刻画量，在第 4 章第 4.2.2 节与节点谱能量、归一化局部图熵共同进入节点级正则系数 $\tau(i)$ 的多因子融合公式。对应定义为

$$C_{\text{deg}}(i)=\frac{d_i}{n-1},\tag{3-38}$$

$$\operatorname{core}(i)=\max\{\,k\mid i\in V(G_k)\,\}.\tag{3-39}$$

其中，d_i 为节点 i 的度，G_k 表示图 G 的 k-core 子图，即满足子图内任意节点度均不小于 k 的极大诱导子图。按全图离线预处理口径，若度向量已缓存，则度中心性的批量计算复杂度为 $O(n)$；若需由邻接结构统计全部节点度，则复杂度为 $O(m)$。k-core 指数可由线性时间算法计算，复杂度为 $O(m)$。

算法 3.1 在离线阶段统一完成谱间隙、节点谱能量、局部图熵与中心性指标的预处理，并将结果缓存供第 4 章参数化使用。多项式谱滤波器次数 K_{poly}（第 5 章第 5.2.1 节定义）与本章谱截断数 K_{eig} 分属不同分析口径，全文严格区分，不作混用。

由算法 3.1 可知，其预处理开销主要由 Lanczos 谱估计、节点谱能量累计以及局部图熵计算三部分构成。其中，Lanczos 阶段在保留前 K_{eig} 个非平凡特征对的设定下，复杂度为 $O(mK_{\text{eig}})$；节点谱能量的批量累计需要对全部 n 个节点在前 K_{pair} 个频率分量上求和，在 $K_{\text{pair}} \leqslant K_{\text{eig}}$ 的前提下可记为 $O(nK_{\text{eig}})$；由于本文在局部图熵计算中采用 Gaussian 边权，并需沿边计算特征距离，故该部分复杂度为 $O(mD)$。再加上度中心性与 k-core 指数的统计开销分别为 $O(n)$ 与 $O(m)$，算法 3.1 的总预处理复杂度可写为

$$O(mK_{\text{eig}} + nK_{\text{eig}} + mD + m + n). \tag{3-40}$$

忽略低阶项后，上式可进一步简记为

$$O(mK_{\text{eig}} + nK_{\text{eig}} + mD). \tag{3-41}$$

因此，整体预处理代价可概括为以 $O(mK_{\text{eig}})$ 为核心、并叠加节点级指标统计项的离线一次性成本。当 K_{eig} 取中等常数时，该流程总体上适合在训练前统一执行并将结果缓存，而不进入在线推理主路径。这里的“离线阶段”是指正式推理前的预计算阶段；“离线预处理”则是指对图结构相关指标进行一次性批量计算并缓存，以降低后续参数构造与在线推理时的重复开销。

3.3 本章小结

本章建立了面向节点级自适应稀疏化的数学基础与指标接口。第 3.1 节分析了 SDGNN 全局统一稀疏策略在高度数节点与低度数节点上的系统性失配，给出了统一优化目标（式 (3-15)）以及三项设计准则，即性能保持、显著加速与自适应性（式 (3-22)–(3-29)）。第 3.2 节进一步提取了四类可计算图复杂度指标，其中谱间隙、节点谱能量、局部图熵与节点中心性由算法 3.1 统一完成批量预处理；正文主线中，频率维采用等权实例化，频率权重接口 $w_k(i)$ 仅作为形式化统一接口保留，不作额外参数化。上述指标通过明确接口传递至后续章节：$\hat{\lambda}_{\text{gap}}$ 用于驱动第 4 章第 4.3.2 节的分层跳距保留率策略，$\{E_{\text{spectral}}(i)\}$ 作为节点级正则系数

算法 3.1 图复杂度指标预处理（含谱估计、节点谱能量与局部图熵批量计算）

输入： 图 $G=(V,E,X)$；归一化拉普拉斯 $\tilde{\mathcal{L}}$；谱截断数 K_{eig}；收敛容差 $\tau_{\text{tol}}=10^{-10}$

输出： 谱间隙近似值 $\hat{\lambda}_{\text{gap}}$；前 K_{pair} 个非平凡特征对 $\{(\lambda_r,u_r)\}_{r=1}^{K_{\text{pair}}}$；节点谱能量 $\{E_{\text{spectral}}(i)\}_{i=1}^{n}$；归一化局部图熵 $\{H_{\text{norm}}(i)\}_{i=1}^{n}$；度中心性 $\{C_{\text{deg}}(i)\}_{i=1}^{n}$；$k$-core 指数 $\{\text{core}(i)\}_{i=1}^{n}$

第一阶段：谱间隙与低频非平凡特征对估计
初始化随机单位向量 v_1，令 $v_0 \leftarrow \mathbf{0}$，并设置 $b_0 \leftarrow 0$
for $k=1$ **to** $K_{\text{eig}}+1$ **do**
　　计算 $w \leftarrow \tilde{\mathcal{L}} v_k$
　　计算投影系数 $a_k \leftarrow v_k^{\top} w$
　　更新残差向量 $w \leftarrow w - a_k v_k - b_{k-1} v_{k-1}$
　　计算残差范数 $b_k \leftarrow \|w\|_2$
　　if $b_k < \tau_{\text{tol}}$ **then**
　　令 $K_{\text{eff}} \leftarrow k$，并终止迭代
　　else
　　归一化得到下一基向量 $v_{k+1} \leftarrow w / b_k$
　　end if
end for
if K_{eff} 未被赋值 **then**
　　令 $K_{\text{eff}} \leftarrow K_{\text{eig}}+1$
end if
由 $\{a_k\}$ 与 $\{b_k\}$ 构造三对角矩阵 $T_{K_{\text{eff}}}$，并对其做特征分解
取最小非零 Ritz 值作为谱间隙近似：$\hat{\lambda}_{\text{gap}} \leftarrow \mu_1$
令

$$K_{\text{pair}} \leftarrow \min\bigl(K_{\text{eig}},\, K_{\text{eff}}-1\bigr)$$

记 $\{(\lambda_r,u_r)\}_{r=1}^{K_{\text{pair}}}$ 为前 K_{pair} 个低频非平凡近似特征对
第二阶段：节点谱能量批量计算（正文主线采用等权实例化）
$U_{:,1:K_{\text{pair}}} \leftarrow [u_1,\cdots,u_{K_{\text{pair}}}]$
for $i=1$ **to** n **do**
　　$E_{\text{spectral}}(i) \leftarrow \sum_{k=1}^{K_{\text{pair}}} \frac{1}{K_{\text{pair}}} |U_{ik}|^2 \lambda_k$
end for
第三阶段：*Gaussian* 局部图熵、度中心性与 *k-core* 计算
$\hat{\sigma}^2 \leftarrow \text{median}\bigl(\{\|x_i-x_j\|_2^2 : (i,j)\in E\}\bigr)$
$\gamma_x \leftarrow 1/(2\hat{\sigma}^2)$
对每条边 $(i,j)\in E$，计算 $w_{ij} \leftarrow \exp(-\gamma_x \|x_i-x_j\|_2^2)$
for $i=1$ **to** n **do**
　　$Z_i \leftarrow \sum_{j\in\mathcal{N}(i)} w_{ij}$
　　if $|\mathcal{N}(i)|>1$ **then**
　　$H(i) \leftarrow -\sum_{j\in\mathcal{N}(i),\, w_{ij}>0} \frac{w_{ij}}{Z_i} \ln \frac{w_{ij}}{Z_i}$
　　$H_{\text{norm}}(i) \leftarrow H(i)/\ln|\mathcal{N}(i)|$
　　else
　　$H(i) \leftarrow 0$，$H_{\text{norm}}(i) \leftarrow 0$
　　end if
　　$C_{\text{deg}}(i) \leftarrow d_i/(n-1)$
end for
以 Batagelj–Zaversnik 算法[34] 在 $O(m)$ 时间内计算 $\{\text{core}(i)\}_{i=1}^{n}$
return $\hat{\lambda}_{\text{gap}}$；$\{(\lambda_r,u_r)\}_{r=1}^{K_{\text{pair}}}$；$\{E_{\text{spectral}}(i)\}_{i=1}^{n}$；$\{H_{\text{norm}}(i)\}_{i=1}^{n}$；$\{C_{\text{deg}}(i)\}_{i=1}^{n}$；$\{\text{core}(i)\}_{i=1}^{n}$

$\tau(i)$ 的谱输入，$\{H_{\text{norm}}(i)\}$、$\{C_{\text{deg}}(i)\}$ 与 $\{\text{core}(i)\}$ 共同进入第 4 章第 4.2.2 节的多因子融合公式。在本章所建立的形式化接口基础上，第 4 章将进一步完成三维自适应参数的具体设计，第 5 章则继续展开算法整合、误差分析与复杂度分析。

第 4 章 谱驱动三维自适应稀疏机制

第 3 章已经给出四类可计算的图复杂度指标，包括谱间隙 $\hat{\lambda}_{\text{gap}}$、节点谱能量 $E_{\text{spectral}}(i)$、局部图熵 $H(i)$ 以及节点中心性统计。这些指标分别从全局连通性、节点谱域参与强度、局部邻域复杂度和拓扑重要性等角度刻画图结构，为后续自适应稀疏参数设计提供了结构输入。需要进一步解决的是，这些预处理得到的结构量如何进入具体的稀疏推理机制：哪些量用于确定频率维输入，哪些量影响节点级正则系数 $\tau(i)$，以及哪些量用于控制不同跳距环层上的保留比例和预算分配。

本章的任务是在第 3 章指标体系基础上，完成从“结构输入”到“稀疏参数”的映射构造。频率维度不再重新定义节点谱能量，而是沿用第 3 章的等权实例化，将 $E_{\text{spectral}}(i)$ 固定为后续设计共享的统一谱输入；节点维度在该谱输入的基础上，进一步结合度中心性、k-core 指数与局部图熵等结构统计量，构造节点级正则系数 $\tau(i)$ 的可计算映射；跳距维度则依据谱间隙 $\hat{\lambda}_{\text{gap}}$ 与多跳传播中的信息衰减关系，给出跳距保留率 p_l 及分层预算配额 $k_i^{(l)}$ 的设计形式。三类参数的设计目标各不相同，但最终会在第 5 章的分层 LARS 求解过程中共同作用：$\tau(i)$ 控制节点受到的稀疏正则强度，p_l 和 $k_i^{(l)}$ 控制不同跳距环层的候选保留规模。

按照上述接口关系，本章首先在第 4.1 节说明频率维输入的固定方式；随后，第 4.2 节构造节点级自适应正则系数；第 4.3 节讨论跳距维度的分层预算设计；最后，第 4.4 节总结三维参数之间的衔接关系，并说明其如何进入第 5 章的算法整合过程。

本章整体框架如图 4.1 所示。

4.1 频率维度：节点谱能量的统一谱输入

第 3 章已经从归一化拉普拉斯谱分解出发，给出了节点谱能量的定义及其等权实例化。本章将节点谱能量作为三维自适应稀疏机制中的频率维输入，用于后续节点级正则系数的构造。因此，本节重点说明第 3 章输出的谱统计量如何进入第 4 章的参数设计接口，不再重复推导节点谱能量本身。

沿用式 (3-31)，节点 i 的一般谱能量形式为

$$E_{\text{spectral}}(i) = \sum_{k=1}^{K_{\text{eig}}} w_k(i)\,\lambda_k\,|U_{ik}|^2. \tag{4-1}$$

其中，λ_k 表示第 k 个谱分量的频率尺度，$|U_{ik}|^2$ 衡量节点 i 在该谱分量上的参与强度，$w_k(i)$ 表示不同谱分量在聚合时的相对权重。式 (4-1) 在本章中的作用，是

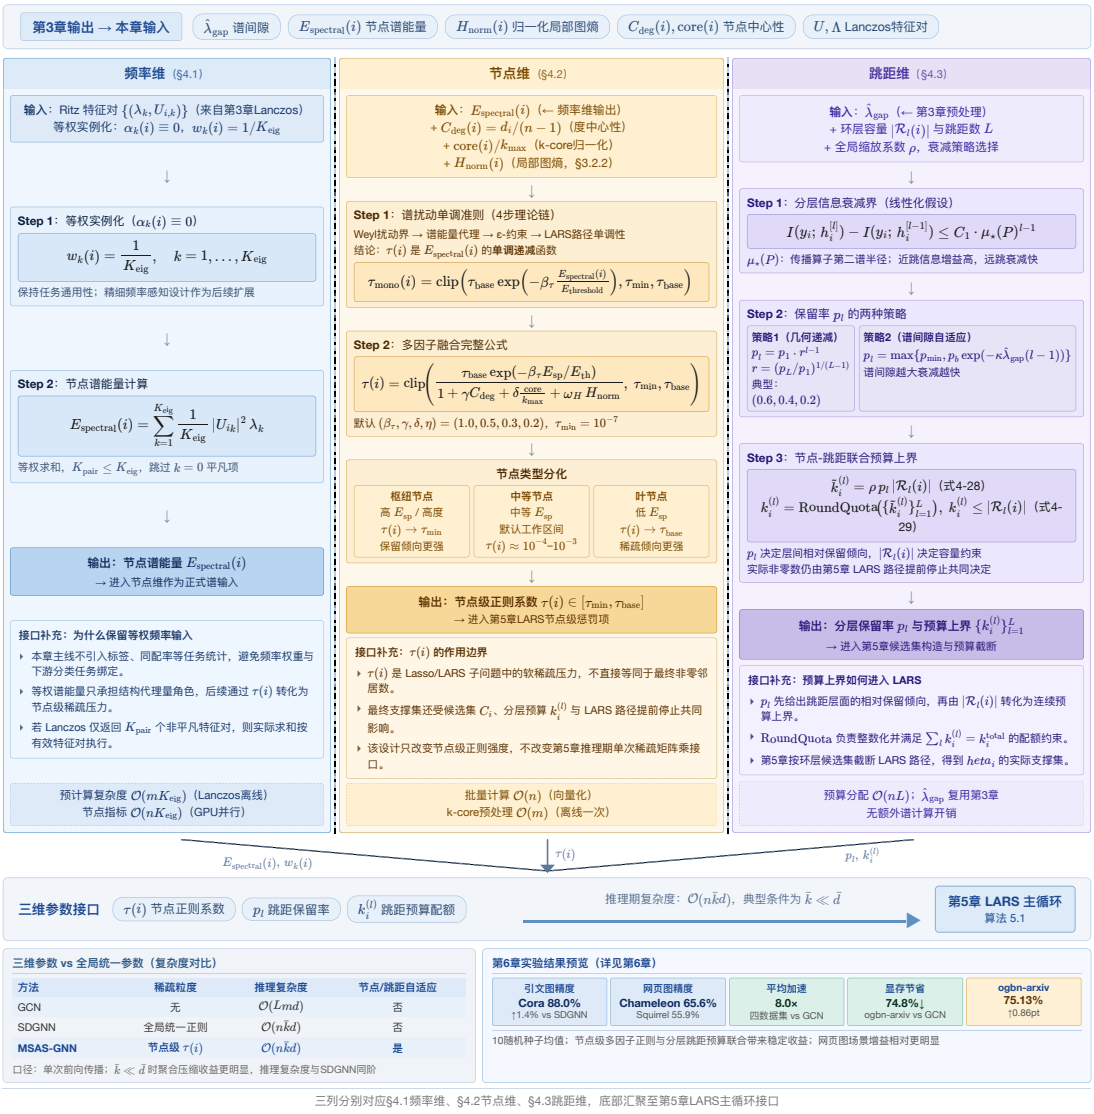

图 4.1　第 4 章三维自适应稀疏机制整体框架图

提供一个可以被节点级稀疏参数调用的频率接口：它把节点在若干非平凡谱分量上的参与强度压缩为一个标量，使后续 $\tau(i)$ 的设计能够同时利用空间域局部统计量与谱域结构信息。

在更一般的图学习设定中，频率权重 $w_k(i)$ 可以根据图的同配或异配特征进行非均匀设计。例如，同配图中的类别信号通常更偏向低频成分，而异配图中的判别信息可能更多分布在中高频成分上；若能够准确获得图的同配性信息，就可以据此调节不同频段的权重。然而，本文的节点谱能量定位为离线结构预处理量，其目标是服务于任务无关的稀疏预算分配。若直接依据标签一致性计算同配率，并进一步用其修正 $w_k(i)$，则频率维设计会与下游标签、训练划分或具体分类任务发生绑定，不再是纯图结构输入。

基于这一考虑，本文在正文主线中不引入同配率驱动的频率偏置，沿用第 3 章的等权设定：

$$w_k(i) = \frac{1}{K_{\text{eig}}}, \qquad k = 1, 2, \cdots, K_{\text{eig}}. \tag{4-2}$$

该设定并不假设所有频段在任意任务中具有相同判别作用，而是将频率维度控制在任务无关的结构统计口径内。本文暂不判断某一图应当偏低频还是偏高频，而是先用等权方式刻画节点在前 K_{eig} 个非平凡谱分量上的整体参与程度，再将这一量交由后续节点级正则映射与其他结构指标共同使用。

将式 (4-2) 代入式 (4-1)，得到本章后续直接使用的节点谱能量：

$$E_{\text{spectral}}(i) = \frac{1}{K_{\text{eig}}} \sum_{k=1}^{K_{\text{eig}}} \lambda_k |U_{ik}|^2. \tag{4-3}$$

式 (4-3) 在后续设计中承担排序与调节作用，并不单独决定节点预算。若某个节点在前 K_{eig} 个非平凡谱分量上具有更强参与，则其 $E_{\text{spectral}}(i)$ 相对较高，说明该节点与图的整体谱结构联系更明显；反之，该值较低的节点在这些谱分量上的参与较弱。后续节点级正则系数并不只依赖这一项，而是会进一步结合归一化局部图熵、度中心性和 k-core 指数，以避免单一谱指标对节点复杂度作出过强判断。

因此，本节固定的频率维接口是：第 3 章计算得到的等权节点谱能量 $E_{\text{spectral}}(i)$ 在第 4 章中作为统一谱输入，并与其他结构统计量共同参与节点级自适应正则系数 $\tau(i)$ 的构造。下一节将在该接口基础上，进一步说明谱能量、局部图熵和中心性如何共同影响节点所受到的稀疏约束强度。

4.2 节点维度：节点级自适应正则系数

频率维度以前述统一方式实例化节点谱能量 $E_{\text{spectral}}(i)$，从而为后续参数设计提供统一的谱输入。本节进一步考虑的问题是，如何由这一谱输入构造节点级正则系数。若仍沿用 SDGNN 的全局统一正则系数，则难以反映不同节点在稀疏化过程中的结构差异：枢纽节点通常承载更多全局拓扑骨架信息，过强稀疏化可能截断关键邻居；而边缘节点或冗余节点对整体表示的贡献相对有限，保留过多邻居又会降低压缩效率。基于此，本节以 $E_{\text{spectral}}(i)$ 为核心输入，构造节点谱能量到节点级正则系数 $\tau(i)$ 的映射关系，建立“谱能量高 $\Rightarrow \tau(i)$ 小 $\Rightarrow \ell_1$ 惩罚较弱 $\Rightarrow$ 邻居保留更多”的设计逻辑。

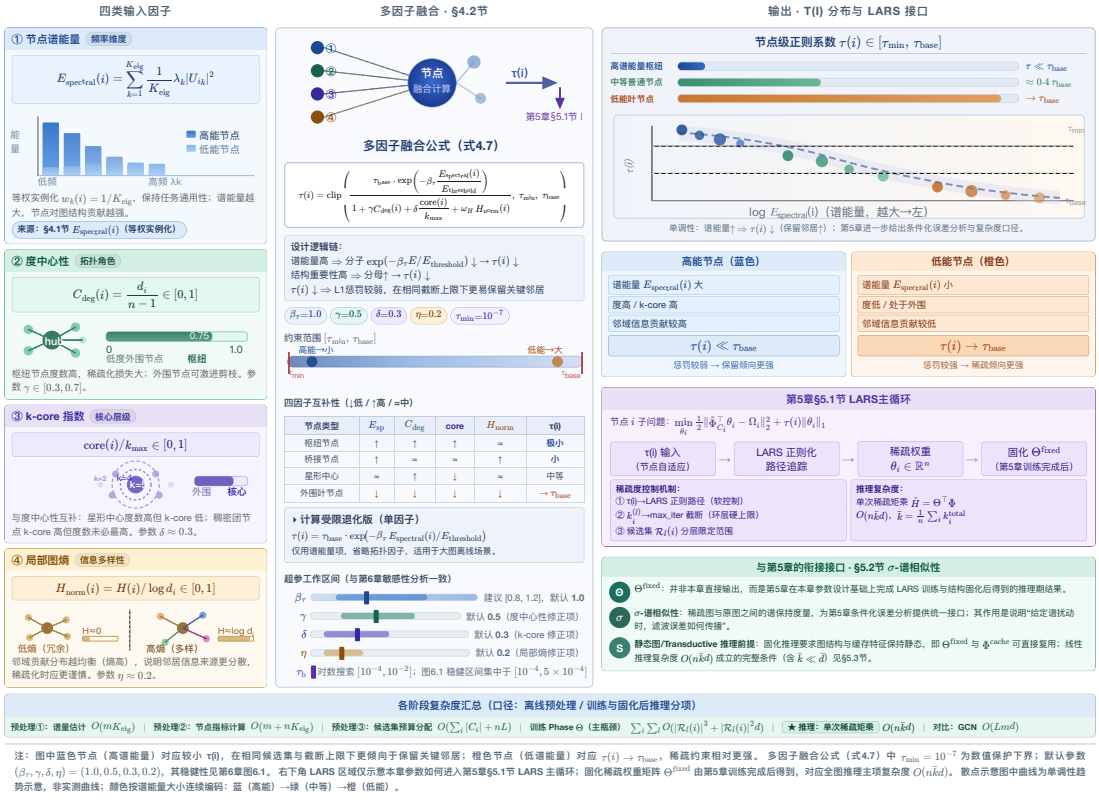

图 4.2　节点级正则系数 $\tau(i)$ 的三维自适应框架示意图

4.2.1 节点级正则系数的构造原则

本节讨论如何将频率维输入 $E_{\text{spectral}}(i)$ 转化为节点级正则系数 $\tau(i)$。这里给出的关系首先服务于参数构造，其目标是为后续可计算公式提供设计依据；关于该设计与全局谱近似误差之间的关系，将在第 5 章结合稀疏化后的谱相似性进一步讨论。

对节点 i，其稀疏化子问题可写为

$$\min_{\theta_i} \quad \frac{1}{2}\left\|\tilde{\Phi}^\top \theta_i - h_i^*\right\|_2^2 + \tau(i)\|\theta_i\|_1. \tag{4-4}$$

其中，h_i^* 表示教师 GNN 在节点 i 处的目标中间表示，$\tilde{\Phi}$ 表示行归一化后的特征

变换矩阵。参考 Lasso 与 LARS 的稀疏路径性质[32]，以及 SDGNN 中采用 LARS 求解节点级 Lasso 子问题并通过稀疏权重控制感受野规模的做法[2]，在候选集和特征矩阵给定时，较大的 ℓ_1 正则系数通常对应更强的稀疏化倾向，而较小的正则系数则更可能允许更多候选节点进入非零支撑集。因此，$\tau(i)$ 的大小直接影响节点 i 在稀疏分解中最终保留的邻居规模。

第 4.1 节已经将 $E_{\text{spectral}}(i)$ 固定为频率维输入。若节点 i 的 $E_{\text{spectral}}(i)$ 较高，说明该节点在前 K_{eig} 个非平凡谱分量上的综合参与程度更强；在稀疏化过程中，对这类节点施加过强压缩，可能更容易截断其关键结构信息。相反，若节点的谱能量较低，则其在所选谱分量上的参与较弱，可以采用相对更强的稀疏约束，以提高整体压缩效率。基于这一判断，本文要求节点级正则系数满足如下单调关系：

$$E_{\text{spectral}}(i) \text{ 越高} \Rightarrow \tau(i) \text{ 越小} \Rightarrow \ell_1 \text{ 惩罚越弱} \Rightarrow \text{保留邻居更多}. \tag{4-5}$$

式 (4-5) 给出了本文节点级正则设计的基本方向。它并不声称 $\tau(i)$ 是某个全局最优问题的闭式解，而是把节点谱能量作为结构参与程度的代理量，用于控制不同节点受到的稀疏压力。

满足上述单调原则的一种平滑实现为

$$\tau_{\text{mono}}(i) = \text{clip}\left(\tau_{\text{base}} \exp\left(-\beta_\tau \frac{E_{\text{spectral}}(i)}{E_{\text{threshold}}}\right), \tau_{\min}, \tau_{\text{base}}\right). \tag{4-6}$$

其中，$\beta_\tau > 0$ 为谱能量响应强度系数，$\tau_{\min}$ 与 τ_{base} 分别表示节点级正则系数的下界与基准上界，$\text{clip}(\cdot)$ 用于将映射结果限制在给定区间内。指数项保证了 $\tau_{\text{mono}}(i)$ 随 $E_{\text{spectral}}(i)$ 增大而平滑下降；上下界截断则避免正则系数过小导致解过密，或过大导致节点邻域被过度压缩。

为使不同数据集上的谱能量进入同一数量级的指数映射，本文引入能量阈值

$$E_{\text{threshold}} = c_E \cdot \text{median}_{j \in V} E_{\text{spectral}}(j), \qquad c_E > 0. \tag{4-7}$$

其中，c_E 为无量纲尺度系数。采用全图节点谱能量的中位数作为参考尺度，是因为 $\tau(i)$ 的设计直接由 $\{E_{\text{spectral}}(i)\}_{i=1}^n$ 驱动；相比均值，中位数对少量高谱能量节点不敏感，能够减弱极端节点对整体尺度的牵引，使不同图上的映射更加稳定。

式 (4-6) 可以理解为节点级正则系数的单因子基线形式。当 $E_{\text{spectral}}(i)$ 较高时，指数项较小，$\tau_{\text{mono}}(i)$ 更接近下界 $\tau_{\min}$，节点受到较弱的稀疏惩罚；当 $E_{\text{spectral}}(i)$ 较低时，$\tau_{\text{mono}}(i)$ 更接近基准上界 τ_{base}，节点受到更强的压缩。实际实现中，τ_{base} 被视为控制整体稀疏强度的超参数，而非由式 (4-6) 直接推出的固定常数。本文在验证集上采用对数尺度搜索确定其取值；候选范围以默认值 10^{-3} 为中心，向上下各扩展一个数量级，即 $[10^{-4}, 10^{-2}]$。这一范围主要用于覆盖从较强稀疏约

束到较弱稀疏约束的常用工作区间，最终取值以验证集表现和平均非零邻居数 $\bar{k}$ 的折中结果为准。β_τ 的默认值取 1，用于给出单位尺度下的谱能量响应强度；其敏感性分析见第 6 章。

需要进一步说明的是，仅依赖节点谱能量仍不足以完整刻画节点的结构复杂度。具有相近谱能量的节点，可能在局部邻域不确定性、度中心性或 k-core 层次上存在明显差异。因而，式 (4-6) 只作为单因子设计基线；下一小节将在此基础上引入局部图熵、度中心性与 k-core 指数，形成多因子融合的节点级正则系数。

4.2.2 多因子融合的完整公式

单一节点谱能量指标能够提供统一的谱域输入，但不足以同时刻画节点的拓扑角色与邻域分布特征。为此，本文进一步引入度中心性、k-core 指数与归一化局部熵作为补充因子，在式 (4-6) 的单因子形式基础上，构造多因子的节点级正则系数：

$$\tau(i) = \mathrm{clip}\left(\frac{\tau_{\text{base}} \cdot \exp\!\left(-\beta_\tau\, E_{\text{spectral}}(i)/E_{\text{threshold}}\right)}{1 + \gamma\, C_{\text{deg}}(i) + \delta\, \dfrac{\mathrm{core}(i)}{k_{\max}} + \omega_H\, H_{\text{norm}}(i)}, \tau_{\min}, \tau_{\text{base}} \right). \tag{4-8}$$

其中，$k_{\max} = \max_{j \in V} \mathrm{core}(j)$，$E_{\text{threshold}}$ 与式 (4-7) 定义相同，$H_{\text{norm}}(i)$ 沿用第 3 章的归一化局部熵定义。本文将 $\tau_{\min}$ 设为 10^{-7}，以避免节点级正则系数过度接近 0 而削弱 ℓ_1 约束。多因子融合参数以 $(\beta_\tau, \gamma, \delta, \omega_H) = (1.0, 0.5, 0.3, 0.2)$ 作为实验初值，其中 β_τ 控制谱能量响应强度，γ, δ, ω_H 分别控制度中心性、k-core 指数和归一化局部图熵的相对影响。该组参数属于工程初始化设置，最终取值与稳定性通过第 6 章的敏感性分析进行验证。

式 (4-8) 的含义是：节点谱能量 $E_{\text{spectral}}(i)$ 仍作为主导性的谱输入，而度中心性、k-core 指数与归一化局部熵分别从节点拓扑位置、局部稠密层级与邻域分布多样性三个方面对 $\tau(i)$ 作进一步修正。在本文的设计口径下，谱能量较高、中心性较强、处于更高 k-core 层级或邻域分布更复杂的节点，倾向于获得更小的正则系数，从而保留更多邻居；反之，则对应相对更强的稀疏约束。由此，稀疏预算能够在统一谱输入的基础上进一步向结构上更值得保留的节点倾斜。

当 $\gamma = \delta = \omega_H = 0$ 时，式 (4-8) 退化为单因子形式 (4-6)。因此，式 (4-8) 可以看作是在节点谱能量主导映射基础上，对空间域结构统计量的进一步整合。

至此，节点级正则系数的多因子构造已经完成。下一小节将据此给出对应的算法实现。

表 4.1　节点级正则系数因子方案及其作用特征（具体准确率见第 6 章消融实验）

方案	因子组成	主要作用特征	$\tau(i)$ 变化趋势
均匀稀疏（baseline）	无自适应	全节点采用统一正则系数	恒为 τ_{base}
仅谱能量	$E_{\text{spectral}}(i)$	仅依据节点谱域参与程度调节正则强度	谱能量高 $\Rightarrow \tau(i)$ 小
谱能量 + 度中心性	$E_{\text{spectral}}(i)$, $C_{\text{deg}}(i)$	同时考虑谱域参与程度与局部拓扑位置	高谱能量/高中心性节点对应更小 $\tau(i)$
多因子融合（完整版）	$E_{\text{spectral}}(i)$, $C_{\text{deg}}(i)$, $\text{core}(i)$, $H_{\text{norm}}(i)$	同时刻画谱域参与、中心性、局部稠密层级与邻域分布特征	结构上更值得保留的节点对应更小 $\tau(i)$

注：本表用于说明不同因子方案的设计侧重点与节点级正则系数的变化方向，不直接给出性能结论；各方案对应的准确率对比见第 6 章消融实验。

4.2.3 算法实现

算法 4.1 给出节点级正则系数的完整批量计算流程。就离线预处理而言，Lanczos 分解的复杂度为 $O(mK_{\text{eig}})$，k-core 分解的复杂度为 $O(m)$，且二者均可一次性完成并在后续轮次中缓存复用。对固定图而言，在上述谱量与结构量已得到的前提下，节点谱能量、局部图熵、度中心性以及 $\tau(i)$ 的批量计算复杂度不超过 $O(mK_{\text{eig}})$。这里讨论的是渐近复杂度口径；并行实现仅影响实际运行常数，而不改变上述量级结论。

算法 4.1 节点级自适应正则系数批量计算流程

输入： 图 $G=(V,E)$；第 3 章算法 3.1 输出的节点谱能量 $\{E_{\text{spectral}}(i)\}_{i\in V}$、归一化局部熵 $\{H_{\text{norm}}(i)\}_{i\in V}$、度中心性 $\{C_{\text{deg}}(i)\}_{i\in V}$、$k$-core 指数 $\{\text{core}(i)\}_{i\in V}$；参数 τ_{base}（默认 10^{-3}）、$\beta_\tau=1.0$、$\gamma=0.5$、$\delta=0.3$、$\omega_H=0.2$、$\tau_{\min}=10^{-7}$、$c_E>0$

输出： 节点级正则系数 $\{\tau(i)\}_{i\in V}$

Step 1：统计量准备

$k_{\max} \leftarrow \max_{j\in V} \text{core}(j)$

$E_{\text{threshold}} \leftarrow c_E \cdot \text{median}_{j\in V} E_{\text{spectral}}(j)$

Step 2：逐节点多因子映射

for each $i \in V$ **do**

$\quad \tau_{\text{raw}} \leftarrow \tau_{\text{base}} \cdot \exp\big(-\beta_\tau E_{\text{spectral}}(i)/E_{\text{threshold}}\big)$

$\quad \tau_{\text{raw}} \leftarrow \tau_{\text{raw}} \cdot \left(1+\gamma C_{\text{deg}}(i)+\delta\,\dfrac{\text{core}(i)}{k_{\max}}+\omega_H H_{\text{norm}}(i)\right)^{-1}$

$\quad \tau(i) \leftarrow \text{clip}(\tau_{\text{raw}}, \tau_{\min}, \tau_{\text{base}})$

end for

return $\{\tau(i)\}_{i\in V}$

至此，节点级正则系数 $\tau(i)$ 的构造已确定。算法 4.1 输出的 $\{\tau(i)\}_{i\in V}$ 将直接进入第 5 章第 5.1 节的 LARS 求解过程；其中，clip 操作用于保证数值稳定性，

使 $\tau(i)$ 始终落在区间 $[\tau_{\min}, \tau_{\text{base}}]$ 内。进一步地，节点总预算如何在不同跳距之间分配，则留待第 4.3 节结合衰减界分析与最优分配推导继续讨论。

4.3 层级维度：分层跳距预算分配

节点维度给出的 $\tau(i)$ 已经刻画了不同节点应承受的总体稀疏强度，但尚未规定这一强度如何在不同跳距邻居之间分配。一般而言，直接邻居携带最直接的局部结构信息，而远跳邻居提供的附加信息会随传播距离增加而逐步减弱；若将预算在各跳距上均匀分配，可能导致近邻保留不足；若将预算过度集中于近邻，又会削弱多跳结构覆盖。基于这一考虑，本文进一步引入分层跳距预算分配策略，用跳距保留率 $p_l \in (0, 1]$ 决定第 l 跳的整数配额 $k_i^{(l)}$，同时保持 $\tau(i)$ 在全章中的唯一性，不再额外引入逐层正则修正项。

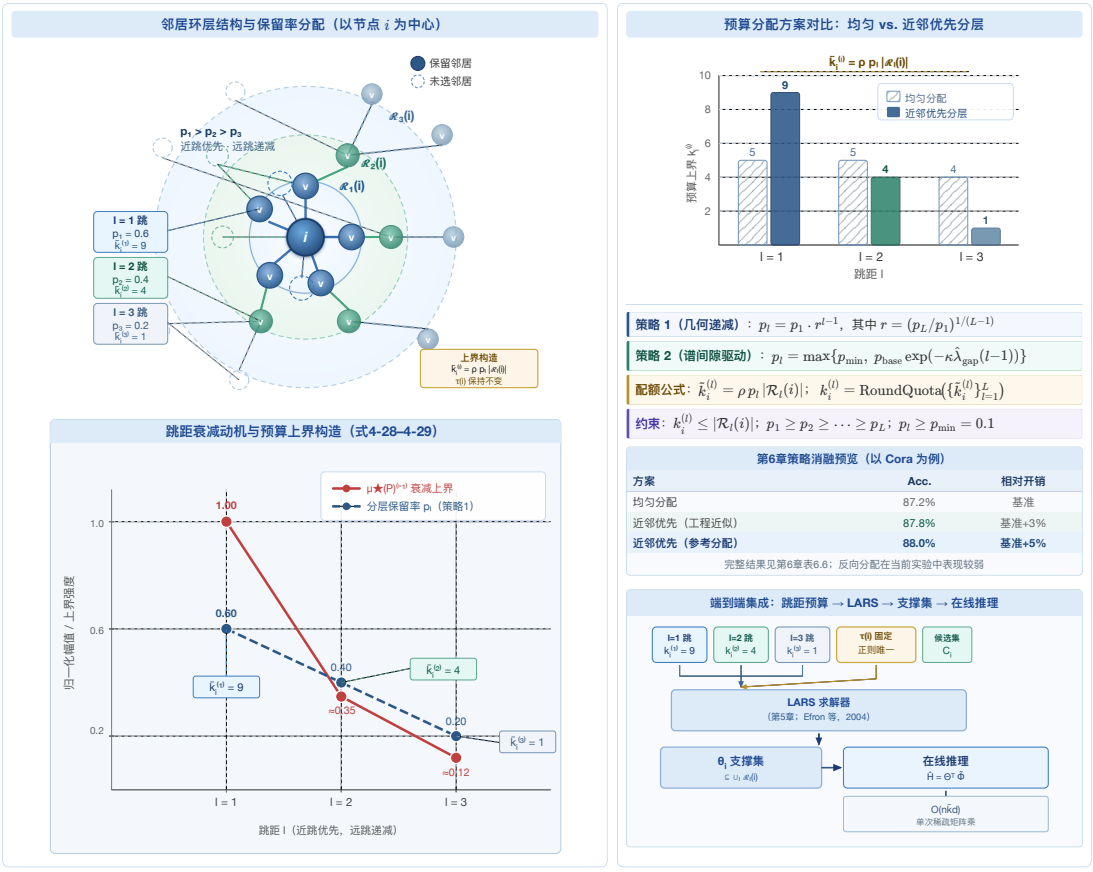

● $\tau(i)$ **保持全章唯一**：p_l 仅控制各跳候选集的预算上界，不修改正则系数；层级信息体现在 θ_i 的**支撑集结构**（哪些跳距的邻居被选中），而非 $\tau(i)$ 的数值上。

● **推理不变**：端到端仍执行单次稀疏矩阵乘 $\hat{H} = \Theta^\top \tilde{\Phi}$，全图复杂度 $O(n\bar{k}d)$

图 4.3　层级维度——分层跳距预算分配示意图

4.3.1 分层信息衰减界分析

在上述分层预算框架下，核心问题转化为：各跳距预算应按何种比例分配。在线性化传播近似下，随着传播次数增加，新增信息的边际贡献通常呈衰减趋势，因此较近跳的邻居原则上应获得更高配额。为对这一设计直觉作定量刻画，

本文引入无自环的对称归一化传播算子

$$S = D_{\deg}^{-1/2} A D_{\deg}^{-1/2}, \tag{4-9}$$

其中，A 表示不含自环的原图邻接矩阵，$D_{\deg}$ 为由 A 诱导的度矩阵，其对角元素满足

$$(D_{\deg})_{ii} = d_i = \sum_{j=1}^{n} A_{ij}. \tag{4-10}$$

本文在本节采用无自环传播算子，是为了与第 3 章归一化拉普拉斯

$$\tilde{\mathcal{L}} = I - D_{\deg}^{-1/2} A D_{\deg}^{-1/2} \tag{4-11}$$

的谱口径保持一致；节点自身项在候选集构造中单独处理，而不并入 A。在无孤立节点的无向图上，S 为实对称矩阵，其特征值可记为

$$1 = \mu_1(S) \geqslant \mu_2(S) \geqslant \cdots \geqslant \mu_n(S) \geqslant -1. \tag{4-12}$$

由于归一化拉普拉斯满足

$$\tilde{\mathcal{L}} = I - S, \tag{4-13}$$

因此，S 的非平凡谱性质与 $\tilde{\mathcal{L}}$ 的谱间隙存在直接对应关系。

对连通无向图，$\mu_1(S) = 1$ 为主特征值。进一步定义第二谱半径为

$$\mu_\star(S) := \max_{k \geqslant 2} |\mu_k(S)|. \tag{4-14}$$

该量刻画了传播算子在去除主特征方向后的收缩强度：当图连通且非二分时，有 $\mu_\star(S) < 1$，于是 S^l 在主特征方向正交子空间上的作用随 l 以 $\mu_\star(S)^l$ 的几何速度衰减。若图含有显著二分或近二分结构，则可能出现接近 -1 的特征值，使 $\mu_\star(S)$ 接近 1，从而导致传播过程出现振荡而非稳定衰减。为缓解这一问题，本文在该类情形下采用懒化传播算子

$$S_{\text{lazy}} = \frac{I + S}{2}. \tag{4-15}$$

对于连通图，懒化操作会将 S 的特征值由 $\mu_k(S)$ 映射为 $(1 + \mu_k(S))/2$，从而把接近 -1 的振荡方向压缩到接近 0 的区域。严格的 $\mu_\star(S_{\text{lazy}}) < 1$ 依赖连通性以及去除主特征方向后的谱分析；若图不连通，则仍可能存在多个特征值等于 1，此时需先按连通分量处理或在分析中显式排除多重主特征方向。

在本文采用的线性化传播近似下，浅层邻域通常对应更高的边际表示增益，而深层邻域的新增贡献随传播次数增加逐步减弱。这一现象为第 4.3.2 节的分层预算设计提供了理论动机。

为对上述直觉作定量刻画，本文在线性传播模型下建立分层信息衰减界，并

将其作为各跳距预算配额的理论参考。记

$$h_i^{[l]} = (P^l X)_{i,*}. \tag{4-16}$$

其中，P 为传播算子，$h_i^{[l]}$ 表示节点 i 在第 l 次传播后的累计表示。该写法与去除非线性激活和参数矩阵后的 SGC 传播形式同口径[12]。这里分析的是由第 $l-1$ 次传播提升至第 l 次传播时的边际表示增量，并将其作为第 l 跳预算分配的代理依据，而非对环层 $\mathcal{R}_l(i)$ 的精确孤立分解。

传播算子取为

$$P = \begin{cases} S, & \text{若图连通、非二分且}\mu_\star(S) < 1, \\ S_{\text{lazy}} = (I+S)/2, & \text{若图含二分或近二分结构}. \end{cases} \tag{4-17}$$

其中，$S = D_{\text{deg}}^{-1/2} A D_{\text{deg}}^{-1/2}$ 为式 (4-9) 定义的对称归一化传播算子，$\mu_\star(\cdot)$ 表示去除主特征方向后的第二谱半径。记第 l 次传播相对于第 $l-1$ 次传播的边际表示增量为

$$\Delta h_i^{[l]} = h_i^{[l]} - h_i^{[l-1]} = e_i^\top (P^l - P^{l-1}) X. \tag{4-18}$$

其中，$e_i \in \mathbb{R}^n$ 为第 i 个标准基向量。

由于传播算子 P 为实对称矩阵，可作正交特征分解

$$P = U \operatorname{diag}\big(\mu_1(P), \mu_2(P), \cdots, \mu_n(P)\big) U^\top, \tag{4-19}$$

其中，$U = [u_1, \cdots, u_n]$ 为正交特征向量组。$v \in \mathbb{R}^n$ 表示定义在图节点上的任意单通道图信号。由于 P 为实对称矩阵，其特征向量组构成 $\mathbb{R}^n$ 的一组正交基。对任意位于主特征方向正交子空间的图信号 $v \perp u_1$，可展开为

$$v = \sum_{k \geqslant 2} a_k u_k, \tag{4-20}$$

其中，$a_k = u_k^\top v$ 为该图信号在第 k 个谱方向上的投影系数。于是经过 l 次传播后有

$$P^l v = \sum_{k \geqslant 2} a_k \, \mu_k(P)^l \, u_k. \tag{4-21}$$

从而

$$\|P^l v\|_2^2 = \sum_{k \geqslant 2} a_k^2 \, \mu_k(P)^{2l} \leqslant \mu_\star(P)^{2l} \sum_{k \geqslant 2} a_k^2 = \mu_\star(P)^{2l} \|v\|_2^2. \tag{4-22}$$

对式 (4-22) 两边开方即得

$$\|P^l v\|_2 \leqslant \mu_\star(P)^l \|v\|_2. \tag{4-23}$$

式 (4-23) 说明，在去除主特征方向后，传播算子对非主方向信息具有由 $\mu_\star(P)$ 控制的几何收缩作用。

将该收缩性质用于边际表示增量。由式 (4-18) 可得

$$\Delta h_i^{[l]} = e_i^\top (P^l - P^{l-1}) X = e_i^\top P^{l-1} (P - I) X. \tag{4-24}$$

可见，第 l 次传播的边际表示增量等于初始传播差异 $(P-I)X$ 经 P^{l-1} 继续传播后的结果。对式 (4-24) 取二范数，并利用向量–矩阵乘积的次可乘性，可得

$$\|\Delta h_i^{[l]}\|_2 \leqslant \|e_i^\top\|_2 \left\|P^{l-1}(P-I)X\right\|_F. \tag{4-25}$$

由于 e_i 为标准基向量，故 $\|e_i^\top\|_2 = 1$。进一步地，$(P-I)X$ 的主特征方向成分在理想传播口径下被抵消，其主要贡献来自非主方向；在主特征方向正交子空间上，由式 (4-23) 可知 P^{l-1} 的作用满足几何收缩，因此

$$\left\|P^{l-1}(P-I)X\right\|_F \leqslant \mu_\star(P)^{\,l-1} \|(P-I)X\|_F. \tag{4-26}$$

将式 (4-26) 代入式 (4-25)，得到

$$\|\Delta h_i^{[l]}\|_2 \leqslant \mu_\star(P)^{\,l-1} \|(P-I)X\|_F. \tag{4-27}$$

于是，将与 l 无关的项记为

$$C_0 := \|(P-I)X\|_F, \tag{4-28}$$

便得到

$$\|\Delta h_i^{[l]}\|_2 \leqslant C_0\, \mu_\star(P)^{\,l-1}. \tag{4-29}$$

其中，$C_0 > 0$ 为与图结构和输入特征有关、但与传播层数 l 无关的常数。由于 C_0 采用全图 Frobenius 范数定义，式 (4-29) 给出的是对单节点边际表示增量的全局保守上界，而不是对每个节点、每个跳距环层精确贡献的估计。该上界的作用在于为分层预算分配提供方向性依据：当 $\mu_\star(P) < 1$ 时，第 l 次传播所带来的边际表示增量随 l 增加呈几何衰减。

式 (4-29) 表明，随着传播层数增加，新增一跳邻域对节点表示带来的边际贡献上界按几何速度衰减，因此较近跳的邻居原则上应获得更高预算配额。基于这一衰减规律，后续第 4.3.2 节将进一步构造分层跳距保留率 p_l 及其对应的整数配额 $k_i^{(l)}$。这里给出的主要是分层预算设计的理论动机；更正式的误差分析与适用条件讨论留待第 5 章展开。

基于式 (4-29) 的衰减结果，可进一步给出跳距保留率的参考下界。设第 l 次传播所对应的边际表示增量允许误差预算为 $\varepsilon_l > 0$。若将保留率 p_l 对该层边际贡献的影响近似为线性比例，并将未保留部分的上界损失近似写为

$$(1 - p_l)\, C_0\, \mu_\star(P)^{\,l-1}, \tag{4-30}$$

则要求该参考损失不超过 ε_l 时，有

$$(1-p_l)\, C_0\, \mu_\star(P)^{\,l-1} \leqslant \varepsilon_l. \tag{4-31}$$

由式 (4-31) 可得保留率 p_l 的参考下界：

$$p_l \geqslant \max\left\{0,\ 1-\frac{\varepsilon_l}{C_0\, \mu_\star(P)^{\,l-1}}\right\}. \tag{4-32}$$

式 (4-32) 是在线性比例近似和保守边际贡献上界下得到的预算设计参考，并非由最优稀疏误差精确推出的闭式解。它表明，当 l 增大时，$\mu_\star(P)^{\,l-1}$ 逐步减小，从而该下界随之下降。这意味着在边际表示增量几何衰减的条件下，较高跳距对应的预算约束可以相对更宽松，因而允许更强的稀疏化。

在实际分配中，本文进一步设定最小保留率 $p_{\min} > 0$，以避免高跳距预算被完全压缩。$p_{\min}$ 的作用仅在于为跳距配额提供下界保护，而不直接保证全图连通性。由此，式 (4-29) 给出的衰减规律为后续两种 p_l 计算策略提供了共同的理论依据；第 4.3.2 节将在此基础上分别给出均匀式与几何衰减式的具体构造。

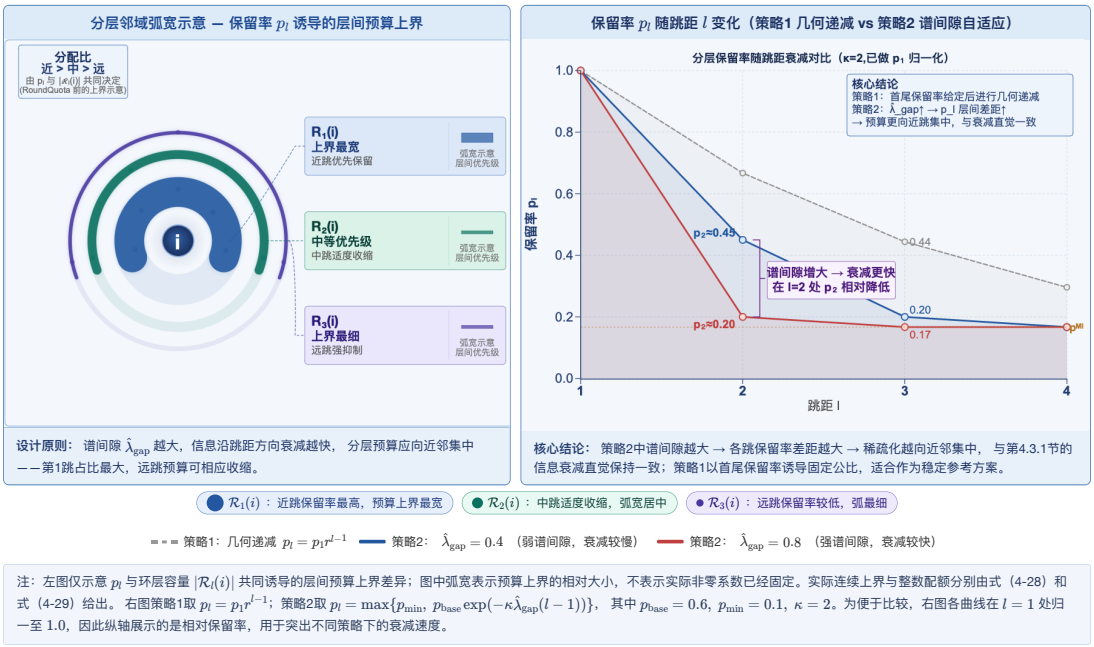

图 4.4　跳距预算衰减分配示意图（策略 1 vs 策略 2）

4.3.2 分层保留率 p_l 的两种策略

由第 4.3.1 节的衰减分析可知，跳距保留率 p_l 应随跳距 l 单调递减。其中，$l \in \{1, 2, \cdots, L\}$ 表示跳距层编号，L 为所考虑的最大传播跳数，$p_l \in (0, 1]$ 表示第 l 跳邻居的保留率。本节据此给出两种可计算的分层保留率策略。

均匀衰减方案（策略 1）采用几何递减形式，其公比由首尾两端的保留率共

同确定。记 p_1 为第 1 跳保留率，p_L 为第 L 跳保留率，则有

$$p_l = p_1 \cdot \varrho^{l-1}, \qquad \varrho = \left(\frac{p_L}{p_1}\right)^{\frac{1}{L-1}}, \qquad \varrho \in (0,1). \tag{4-33}$$

其中，ϱ 表示相邻两跳之间共享的衰减公比。式 (4-33) 表明，当 p_1 与 p_L 给定后，中间各跳的保留率由同一公比自动确定，因此该方案在各跳距之间保持一致的衰减速度。例如，当 $L = 3$、$p_1 = 0.60$、$p_3 = 0.20$ 时，由式 (4-33) 可得 $\varrho = \sqrt{0.20/0.60}$，进一步得到 $p_2 = 0.40$，从而形成 $(p_1, p_2, p_3) = (0.60, 0.40, 0.20)$ 的典型配置。

谱间隙自适应方案（策略 2）进一步将跳距衰减速度与图级谱结构联系起来。由式 (4-13) 可知，

$$\tilde{\mathcal{L}} = I - S. \tag{4-34}$$

因此，若 u_k 同时作为 S 与 $\tilde{\mathcal{L}}$ 的特征向量，且 $Su_k = \mu_k(S)u_k$，则有

$$\tilde{\mathcal{L}}u_k = (I - S)u_k = (1 - \mu_k(S))u_k. \tag{4-35}$$

由此可得对应特征值之间的关系

$$\lambda_k = 1 - \mu_k(S). \tag{4-36}$$

在连通图上，λ_{gap} 为归一化拉普拉斯的最小非零特征值。若只考虑低频非平凡方向，则其对应的传播特征值满足

$$\mu_2(S) = 1 - \lambda_{\text{gap}}. \tag{4-37}$$

这说明谱间隙越大，低频非主方向上的传播收缩越强，多次传播后的边际增量通常衰减更快；谱间隙越小，则低频非主方向的收缩较慢，较远跳邻居仍可能保留一定边际贡献。式 (4-37) 刻画的是低频非平凡方向的收缩因子，并不等同于第二谱半径 $\mu_\star(S)$ 的精确表达。第二谱半径定义为

$$\mu_\star(S) = \max_{k \geqslant 2} |\mu_k(S)|. \tag{4-38}$$

其最大值还可能受到接近 -1 的高频方向影响。特别是在二分或近二分结构中，仅用 $1 - \lambda_{\text{gap}}$ 不能完整描述非主方向的最慢衰减。因此，本文在策略 2 中将 $\hat{\lambda}_{\text{gap}}$ 作为控制跳距衰减速度的图级结构代理量，而不是将其视为 $\mu_\star(S)$ 的严格替代。

基于上述代理关系，记 $\hat{\lambda}_{\text{gap}}$ 为第 3 章预处理阶段得到的谱间隙估计量，$\kappa > 0$ 为谱间隙响应系数。本文将几何衰减公比参数化为

$$r = \exp(-\kappa \hat{\lambda}_{\text{gap}}). \tag{4-39}$$

由于 $\hat{\lambda}_{\text{gap}} \geqslant 0$，式 (4-39) 保证 $r \in (0, 1]$。当 $\hat{\lambda}_{\text{gap}}$ 较大时，r 较小，表示跳距保留率随 l 增大衰减更快；当 $\hat{\lambda}_{\text{gap}}$ 较小时，r 接近 1，表示远跳邻居的预算下降更加

缓和。于是得到谱间隙自适应的跳距保留率：

$$p_l = \max\left\{p_{\min},\ p_{\text{base}} \exp\left(-\kappa \hat{\lambda}_{\text{gap}}(l-1)\right)\right\}, \qquad \kappa > 0. \tag{4-40}$$

其中，$p_{\text{base}} \in (0,1]$ 表示第 1 跳的基准保留率，本文默认取 $p_{\text{base}} = 0.6$；$p_{\min} \in (0,1]$ 表示允许的最小保留率，本文默认取 $p_{\min} = 0.1$；κ 控制保留率对谱间隙变化的响应强度。式 (4-40) 的含义是：在其余条件相同的情况下，$\hat{\lambda}_{\text{gap}}$ 越大，低频非主方向上的传播收缩越快，深层邻居的边际贡献通常衰减更明显，因此 p_l 随跳距下降更快；$\hat{\lambda}_{\text{gap}}$ 越小，则说明传播收缩较慢，远跳邻居不宜被过早压缩。

式 (4-40) 的定位是预算分配策略，并非第二谱半径衰减界的严格闭式解。它利用谱间隙对低频非主方向收缩速度的刻画，为跳距保留率提供图级自适应调节依据；对于二分性较强或高频负特征值影响显著的图，其适用性还需要结合懒化传播算子和第 5 章的谱相似性误差分析进一步说明。

两种策略的系统对比见表 4.2。

表 4.2　策略 1 与策略 2 的对比分析

对比维度	策略 1（均匀衰减）	策略 2（谱间隙自适应）
参数数量	2 个（p_1, p_L）	1 个核心参数（κ；若 $p_{\text{base}}, p_{\min}$ 采用默认值）
图自适应性	低（固定公比 r）	高（自动适配 $\hat{\lambda}_{\text{gap}}$）
计算额外开销	零（参数预设）	低（$\hat{\lambda}_{\text{gap}}$ 可由第 3 章预处理阶段直接给出）
适用场景	谱结构相对稳定、需控制参数解释性的场景	图间谱差异较明显、需增强图自适应性的场景
稳健性	高（参数范围可直接控制）	高（指数形式天然保证单调递减）
理论依据	第 4.3.1 节衰减分析给出的几何递减规律	以 $\hat{\lambda}_{\text{gap}}$ 为代理变量的谱间隙启发式参数化

从经验使用角度看，当图间谱结构差异较小、且更希望直接控制首尾跳距的保留率时，可优先采用策略 1；当不同图的谱间隙变化较明显，或模型层数较深、希望由图级结构量自动调节衰减速度时，则更适合采用策略 2。两种策略均给出了 p_l 的具体数值形式，下一节将在此基础上进一步讨论如何将节点总预算分配为各跳距的整数配额 $k_i^{(l)}$。

4.3.3 节点-跳距联合预算分配策略

跳距保留率 p_l 由第 4.3.2 节给出，其作用在于刻画不同跳距之间的相对保留倾向；但仅有 p_l 仍不足以直接得到可执行的层间预算，因为第 l 跳可分配的候选规模还受到环层容量 $|\mathcal{R}_l(i)|$ 的约束。考虑到外层候选集通常大于内层，而分层设计的目标又是“近跳优先、远跳递减”，本文不再预先显式求解节点级总预

算 K_i，而是直接结合跳距保留率与环层容量，为节点 i 的各跳候选集构造预算上界：

$$\tilde{k}_i^{(l)} = \rho\, p_l\, |\mathcal{R}_l(i)|, \qquad l = 1, 2, \cdots, L. \tag{4-41}$$

其中，$\mathcal{R}_l(i)$ 表示节点 i 的第 l 跳环层候选集，$|\mathcal{R}_l(i)|$ 为其容量，$p_l \in (0, 1]$ 为对应跳距的保留率，$\rho \in (0, 1]$ 为全局预算缩放系数，用于控制整体压缩强度。式 (4-41) 的含义是：第 l 跳允许保留的预算上界同时取决于该跳的理论重要性 p_l 与可选容量 $|\mathcal{R}_l(i)|$。这样一来，即使远跳候选数量更大，也会因 p_l 较小而受到更强抑制；反之，近跳虽然容量较小，但由于 p_l 较高，仍可获得优先保留。

考虑到实际求解中预算必须为整数，本文进一步引入配额舍入算子 $\mathrm{RoundQuota}(\cdot)$，将式 (4-41) 的连续上界转化为整数预算：

$$k_i^{(l)} = \mathrm{RoundQuota}\big(\{\tilde{k}_i^{(l)}\}_{l=1}^{L}\big), \qquad k_i^{(l)} \leqslant |\mathcal{R}_l(i)|. \tag{4-42}$$

其中，$\mathrm{RoundQuota}(\cdot)$ 的实现方式为：先对各层连续预算逐项下取整，再按最大小数部分依次补足舍入误差；若某一跳已达到容量上界 $|\mathcal{R}_l(i)|$，则跳过该层并将剩余预算补偿到未饱和跳距。由此，式 (4-42) 在保证整数化的同时，仍尽量保持原始比例关系。

在工程实现中，为减少额外的节点级预算求解开销，本文将式 (4-42) 视为各跳候选集的预算上界构造规则，而不将其解释为必须严格达到的最终非零数。$k_i^{(l)}$ 描述的是“第 l 跳最多允许保留多少候选邻居”，而节点 i 在该跳的实际非零数仍由第 5 章 LARS 求解过程中的节点级正则系数 $\tau(i)$、候选集容量以及路径提前停止共同决定。因而，跳距维度提供的是层间预算约束，节点维度提供的是节点间稀疏强度差异，二者在求解阶段联合发挥作用。

由此，跳距维度的作用可概括为：节点级正则系数 $\tau(i)$ 决定节点 i 在整体上应承受多强的稀疏约束，而跳距保留率 p_l 与环层容量 $|\mathcal{R}_l(i)|$ 共同决定该约束在不同跳距上的预算上界分布。前者回答“不同节点在整体上应承受多强的稀疏约束”，后者回答“各跳环层在候选容量约束下应分配多少预算上界”。至此，频率、节点、跳距三维参数体系已经完整建立，第 5 章将进一步以分层 LARS 过程统一整合三维输出。

4.4 本章小结

本章以第 3 章给出的图复杂度指标为输入，完成了“频率 × 节点 × 跳距”三维自适应稀疏参数体系的设计，用以替代 SDGNN 中全局统一的正则控制方式。

频率维度（第 4.1 节）在保持方法任务通用性的前提下，以等权实例化

$w_k(i) = 1/K_{\text{eig}}$ 确定节点谱能量 $E_{\text{spectral}}(i)$ 作为统一谱输入，并将其直接传递给后续节点维度的参数构造；相应的频率接口仍为后续更精细的频率感知设计保留扩展空间。节点维度（第 4.2 节）以节点谱能量为核心自变量，建立了“谱能量越高、正则惩罚越弱”的单调设计准则，并在此基础上通过式 (4-8) 将度中心性、k-core 指数与局部图熵整合为多因子节点级正则系数 $\tau(i)$，其批量计算流程见算法 4.1。跳距维度（第 4.3 节）则依据第 4.3.1 节给出的几何衰减分析，构造了跳距保留率 p_l 及其对应的各层预算上界，从而体现近跳优先、远跳递减的分层分配原则。

三个维度的核心输出构成了面向第 5 章的统一接口：节点谱能量 $E_{\text{spectral}}(i)$ 作为节点维设计的谱输入，经由 $\tau(i)$ 间接影响后续 LARS 路径的截断强度；节点级正则系数 $\tau(i)$ 直接进入第 5 章 Phase Θ 的节点级惩罚项。节点维与跳距维分别刻画“不同节点整体上应承受多强的稀疏约束”与“各跳候选层应设置怎样的预算上界”，并在第 5 章的分层 LARS 求解流程中统一整合。

由此，本章已经建立了一个同时体现节点异质性与跳距衰减特征的三维自适应参数体系。不过，到本章为止，这三类参数仍停留在设计层面，尚未通过统一的求解过程实现端到端整合；此外，其稀疏化后的误差性质与复杂度收益也仍需进一步分析。第 5 章将以 LARS 为核心求解器，在分层候选集构造基础上统一整合三维输出，并进一步给出相应的误差分析与复杂度分析。

第 5 章 算法整合、误差分析与复杂度分析

第 4 章已经从频率、节点与跳距三个维度完成自适应稀疏机制设计，但这些设计结果仍停留在参数构造层面，尚未通过统一求解流程转化为可执行算法；与此同时，稀疏化后表示误差如何刻画、各阶段复杂度应如何统一分析，也仍需进一步说明。本章在前述设计基础上，围绕算法落地、误差分析与复杂度分析三个方面展开：第 5.1 节以 LARS 为核心求解器，将节点级正则系数 $\tau(i)$ 与跳距预算上限 $k_i^{(l)}$ 整合为端到端交替优化流程；第 5.2 节在 σ-谱相似性框架下讨论稀疏化后的条件化误差界及其适用条件；第 5.3 节进一步区分推理、训练与预处理三类复杂度口径，并说明线性规模推理复杂度成立的条件。

5.1 LARS 分层稀疏求解与交替优化

第 4 章得到的节点级正则系数 $\tau(i)$ 与分层跳距预算 $k_i^{(l)}$ 仍停留在参数设计层面，尚未形成统一的可执行求解流程。其中，$\tau(i)$ 表示节点 i 对应稀疏子问题的正则强度，$k_i^{(l)}$ 表示节点 i 在第 l 跳环层上的预算上限。本节以 LARS[32] 为核心稀疏求解器，将上述两类参数整合到节点级稀疏分解过程中。本文以 $\tau(i)$ 作为节点 i 对应 Lasso 子问题的正则强度，并以 $k_i^{(l)}$ 作为第 l 跳环层子问题的路径截断上限，即令 `max_iter` 不超过 $k_i^{(l)}$，从而将第 4 章的节点维与跳距维设计落实到具体求解流程中。

具体地，候选集按跳距划分为互不相交的环层 $\mathcal{R}_l(i)$，其中，$\mathcal{R}_l(i)$ 表示节点 i 的第 l 跳邻居环层；在此基础上，各环层按照“由近及远”的顺序执行残差级联 LARS。完整端到端流程见第 5.1.2 节算法 5.1，优化稳定性与收敛性讨论见第 5.1.3 节。

5.1.1 分层 LARS 的候选集构造与方案选定

对节点 i，记 L 为候选集所考虑的最大跳数。本文将候选集定义为节点自身与前 L 跳邻居环层的并集：

$$C_i = \{i\} \cup \bigcup_{l=1}^{L} \mathcal{R}_l(i). \tag{5-1}$$

其中，C_i 表示节点 i 的候选节点集合，$\mathcal{R}_l(i)$ 表示节点 i 的第 l 跳邻居环层，且不同环层之间两两不相交。节点自身 i 固定并入候选集，可视为第 0 跳自特征通道：

$$\mathcal{R}_0(i) = \{i\}. \tag{5-2}$$

$\mathcal{R}_0(i)$ 仅表示候选集中的自节点通道，并不意味着在邻接矩阵 A 中额外加入自环。由于该通道只包含单个候选变量，本文不对其分配跳距预算。相应地，第 4 章定义的分层预算上限 $\{k_i^{(l)}\}_{l=1}^{L}$ 仅对 $l=1,\cdots,L$ 的邻居环层生效。

对于 ogbn-arxiv 等较大规模图，若直接保留全部前 L 跳邻居会使候选集规模过大，本文在训练阶段采用候选集裁剪与分层预算上限相结合的处理方式。节点 i 的 LARS 子问题不在全体节点集合 V 上求解，而是在候选集 C_i 内进行；候选集可由节点自身及前 L 跳邻居构成，并在规模过大时对远跳环层进行采样或截断。随后，分层预算上限 $k_i^{(l)}$ 进一步约束第 l 跳环层中允许进入非零支撑集的最大候选规模，从而将 Phase Θ 的主要开销由全图规模控制到候选集规模。训练完成后，本文固化得到 Θ_{fixed} 与 $\tilde{\Phi}_{\text{cache}}$，推理阶段仅执行

$$\hat{H}=(\Theta_{\text{fixed}})^{\top}\tilde{\Phi}_{\text{cache}}, \tag{5-3}$$

其主项复杂度为 $O(n\bar{k}d)$，无需显式展开多跳邻域。

在候选集构造完成后，分层 LARS 的关键问题在于：不同跳距环层应共享同一拟合目标，还是按残差逐层递推。为说明这一点，记节点 i 的教师或基准 GNN 目标表示为

$$\Omega_i := H^*_{i,:}\in\mathbb{R}^d. \tag{5-4}$$

其中，$H^*_{i,:}$ 表示目标表示矩阵 H^* 的第 i 行，Ω_i 即节点 i 在 d 维表示空间中的目标向量。

首先考虑共享目标方案。该方案将自节点通道与各跳距邻居环层均视为独立候选块，并分别以同一目标向量 Ω_i 为拟合对象。对 $l=0,1,\cdots,L$，共享目标方案分别求解

$$\theta^{(l)}_{i,\text{share}}=\underset{\theta\in\mathbb{R}^{|\mathcal{R}_l(i)|}}{\arg\min}\left\|\tilde{\Phi}^{\top}_{\mathcal{R}_l(i)}\theta-\Omega_i\right\|_2^2+\tau(i)\|\theta\|_1,\qquad l=0,1,\cdots,L. \tag{5-5}$$

其中，$\mathcal{R}_0(i)=\{i\}$ 表示自节点通道，$\mathcal{R}_l(i)$ 在 $l\geqslant 1$ 时表示第 l 跳邻居环层；$\tilde{\Phi}_{\mathcal{R}_l(i)}$ 表示候选特征矩阵 $\tilde{\Phi}$ 在对应候选块上的行子矩阵，$\theta^{(l)}_{i,\text{share}}$ 表示共享目标方案下节点 i 在第 l 个候选块上的稀疏系数向量。特别地，当 $l=0$ 时，式 (5-5) 退化为仅含自节点变量的一维稀疏拟合；当 $l\geqslant 1$ 时，该式对应第 l 跳邻居环层上的 LARS 子问题，且第 4 章给出的预算上限 $k_i^{(l)}$ 仅作用于这些邻居环层。

式 (5-5) 表明，自节点通道与各邻居环层均以同一目标向量 Ω_i 为拟合对象，层与层之间彼此独立。该处理方式的主要问题在于，不同跳距子问题会重复逼近同一目标表示，从而引入跨层冗余；当自节点通道和近跳环层已经能够解释主要目标分量时，较远跳环层继续针对同一目标独立拟合，容易削弱第 4 章第 4.3 节所建立的“近跳优先、远跳递减”预算动机。基于这一考虑，本文不采用共享目标方案，以下将其记为方案 1。

本文最终采用残差级联方案，即方案 2。与共享目标方案不同，该方案先处理节点自身特征项，再按照第 1 跳至第 L 跳的顺序对剩余误差逐层补偿。记 $\tilde{\phi}_i \in \mathbb{R}^d$ 为节点 i 在缓存特征矩阵 $\tilde{\Phi}$ 中对应的行向量。由于节点自身 i 固定并入候选集，本文首先估计其自特征通道对目标表示的直接贡献：

$$\theta_i^{(0)} = \arg\min_{\alpha \in \mathbb{R}} \left\| \alpha\, \tilde{\phi}_i - \Omega_i \right\|_2^2 + \tau(i)|\alpha|. \tag{5-6}$$

式 (5-6) 只涉及一个候选变量，因此不需要为其设置跳距预算上限。扣除节点自身特征贡献后，得到残差级联方案的初始残差：

$$r_i^{(0)} := \Omega_i - \theta_i^{(0)} \tilde{\phi}_i. \tag{5-7}$$

随后，对第 l 个邻居环层（$l = 1, \cdots, L$），依次求解如下子问题：

$$\theta_i^{(l)} = \arg\min_{\theta \in \mathbb{R}^{|\mathcal{R}_l(i)|}} \left\| \tilde{\Phi}_{\mathcal{R}_l(i)}^{\top} \theta - r_i^{(l-1)} \right\|_2^2 + \tau(i) \|\theta\|_1. \tag{5-8}$$

其中，$r_i^{(l-1)}$ 表示在完成节点自身项以及前 $l-1$ 个邻居环层拟合后剩余的残差。实现上，第 l 层 LARS 路径的迭代上限设为 $k_i^{(l)}$，即以 `max_iter` 控制该层激活变量数不超过预算上限。求得 $\theta_i^{(l)}$ 后，按

$$r_i^{(l)} := r_i^{(l-1)} - \tilde{\Phi}_{\mathcal{R}_l(i)}^{\top} \theta_i^{(l)} \tag{5-9}$$

更新残差，其中，$r_i^{(l)}$ 表示节点 i 在完成节点自身项以及第 1 跳至第 l 跳邻居环层拟合后的剩余误差。

因此，在方案 2 中，第 0 跳自特征通道负责先拟合节点自身特征对目标表示的直接贡献，第 1 至 L 跳邻居环层则在此基础上对剩余误差逐层补偿。全部环层完成后，节点 i 的最终稀疏权重向量定义在候选集 C_i 上，其由第 0 跳自特征系数 $\theta_i^{(0)}$ 与各邻居环层系数 $\{\theta_i^{(l)}\}_{l=1}^{L}$ 共同组成。本文的分层预算上限仅控制多跳邻居环层上的稀疏保留规模，而节点自身对应的系数通过式 (5-6) 中的一维稀疏子问题单独学习得到。因此，对角元位置 $\Theta_{i,i}$ 允许非零，且其数值不再由人工固定，而是由节点自身特征对目标表示的拟合强度自适应决定。

与方案 1 相比，方案 2 将“对同一目标的重复逼近”改为“对剩余误差的逐层补偿”，因此在工程上更有利于减少不同跳距之间的表示冗余，也与第 4 章建立的近跳优先预算逻辑保持一致。这里给出的仍是算法设计上的合理性解释，而非关于整体 Lasso 最优支撑集性质的严格理论结论。相关交替优化流程的稳定性与收敛性讨论见第 5.1.3 节。

5.1.2 完整交替优化算法

节点级正则系数 $\tau(i)$ 由第 4 章算法 4.1 离线计算得到，其数值范围为 $[\tau_{\min}, \tau_{\text{base}}]$；分层预算上限 $\{k_i^{(l)}\}$ 由第 4 章第 4.3 节给出。二者共同构成第 5 章主

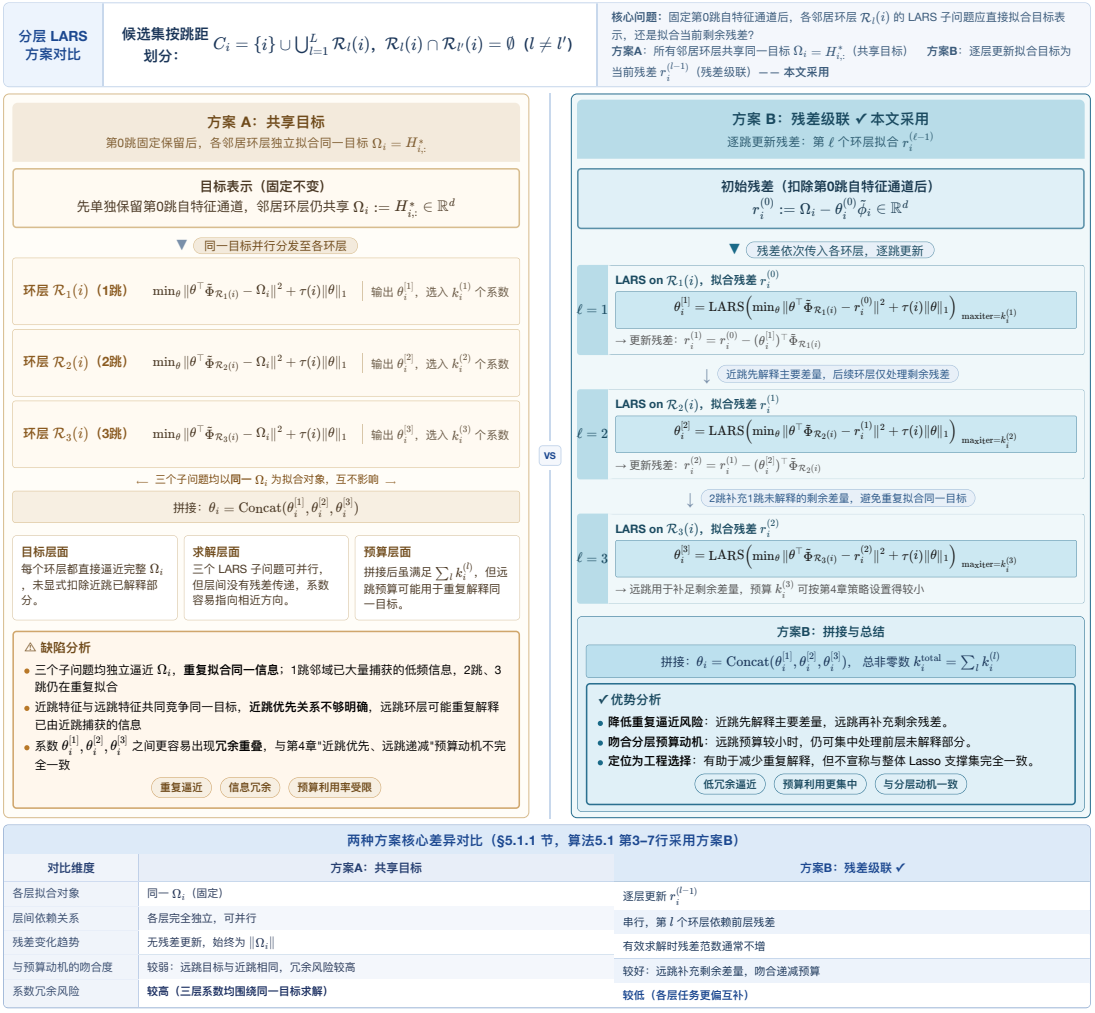

两种方案核心差异对比（§5.1.1 节，算法5.1 第3–7行采用方案B）

对比维度	方案A：共享目标	方案B：残差级联 ✓
各层拟合对象	同一 Ω_i（固定）	逐层更新 $r_i^{(l-1)}$
层间依赖关系	各层完全独立，可并行	串行，第 l 个环层依赖前层残差
残差变化趋势	无残差更新，始终为 $\|\Omega_i\|$	有效求解时残差范数通常不增
与预算动机的吻合度	较弱：远跳目标与近跳相同，冗余风险较高	较好：远跳补充剩余差量，吻合递减预算
系数冗余风险	**较高（三层系数均围绕同一目标求解）**	**较低（各层任务更偏互补）**

本文采用方案B（残差级联），见算法5.1第3–7行（Phase ⊖ 内层循环）。这里给出的主要是工程合理性解释：近跳先解释主要差量，远跳再补足剩余残差，从而与第4章的近跳优先预算动机保持一致；不将其表述为整体 Lasso 支撑集一致性的严格理论结论。

符号说明： $\mathcal{R}_l(i) = \{j \in V \mid d_G(i,j) = l\}$ 为节点 i 的第 l 跳环层；$\bar{\Phi} \in \mathbb{R}^{n \times d}$ 为 ℓ_2 行归一化后的特征矩阵；$\tau(i)$ 为第4章输出的节点级正则系数；$k_i^{(l)}$ 为第4章第4.3节分配的分层预算配额；$\mathrm{LARS}(\cdot)|_{\mathrm{maxiter}=k}$ 表示以 k 为迭代上限的截断 LARS 求解；图中向量范数 $\|\cdot\|$ 默认为 ℓ_2 范数；矩阵误差中的 $\|\cdot\|_F$ 表示 Frobenius 范数；d 为节点表示维度。　**图位标注：** 本图对应正文 \S5.1.1 节，标签 \texttt{fig:ch5-lars-compare}。

图 5.1　共享目标与残差级联两种分层 LARS 方案对比

循环的外部输入接口：算法 5.1 在交替优化阶段同时使用 $\tau(i)$ 与 $\{k_i^{(l)}\}$，算法 5.2 则在训练完成后生成推理期所需的固化结果 Θ^{fixed} 与 $\tilde{\Phi}^{\text{cache}}$。

其中，

$$\hat{H} = \Theta^\top \tilde{\Phi} \in \mathbb{R}^{n\times d}. \tag{5-10}$$

表示全图稀疏近似表示矩阵。由于节点 i 的稀疏系数向量写入矩阵 Θ 的第 i 列，因此 $\Theta^\top\tilde{\Phi}$ 的第 i 行恰对应节点 i 的近似表示向量。于是，在固定 Θ 的条件下，Phase W 通过最小化全图表示逼近目标

$$\frac{1}{2}\|\Theta^\top\tilde{\Phi} - H^*\|_F^2. \tag{5-11}$$

更新特征变换参数 W_ϕ，从而保证 Θ 与 W_ϕ 在每轮外层迭代中按全图口径交替同步。实现上，本文通过 LARS 的最大迭代步数控制每一跳环层的活动变量数。一般情况下，LARS 每一步会引入一个与当前残差最相关的候选变量，因此最大迭代步数可作为该环层非零系数数目的工程上限。该上限并不要求最终必须保留 $k_i^{(l)}$ 个邻居；当残差提前收敛、候选集规模不足或变量相关性较强时，实际非零数可能小于该上限。

算法 5.1 与算法 5.2 在流程定位上并不相同。前者在训练阶段同时使用节点级正则系数 $\tau(i)$ 与分层预算上限 $\{k_i^{(l)}\}$，完成稀疏权重矩阵 Θ 与特征变换参数 W_ϕ 的交替优化；后者则在训练结束后执行结构固化，仅将已训练得到的 Θ 与 W_ϕ 转化为推理期可直接调用的 Θ^{fixed} 与 $\tilde{\Phi}^{\text{cache}}$。

在结构固化后，MSAS-GNN 的推理过程退化为单次稀疏矩阵乘：

$$\hat{H} = (\Theta^{\text{fixed}})^\top \tilde{\Phi}^{\text{cache}}, \qquad \text{其主项复杂度为} O(m_{\text{sparse}}\, d) = O(n\bar{k}d). \tag{5-12}$$

其中，m_{sparse} 表示固化后稀疏权重矩阵中的全图非零元总数，可写为

$$m_{\text{sparse}} := \sum_{i\in V} \|\theta_i\|_0, \tag{5-13}$$

相应地，$\bar{k}$ 表示固化后各节点非零权重数的全图平均值，可定义为

$$\bar{k} := \frac{1}{n}\sum_{i\in V} \|\theta_i\|_0. \tag{5-14}$$

因此有

$$m_{\text{sparse}} = n\bar{k}. \tag{5-15}$$

式 (5-12) 对应的是推理阶段的主项复杂度口径，不包含第 3 章图复杂度指标预处理、第 5 章交替优化训练以及推理期结构固化等一次性离线开销。各阶段的完整复杂度分析见第 5.3 节。

算法 5.1 MSAS-GNN 三维自适应稀疏分解主循环（完整交替优化版）

输入： 图 $G=(V,E,X)$，其中 $X\in\mathbb{R}^{n\times D}$；目标中间表示矩阵 $H^*\in\mathbb{R}^{n\times d}$；节点级正则系数 $\{\tau(i)\}_{i\in V}$；分层预算上限 $\{k_i^{(l)}\}_{i\in V,\,l=1,\cdots,L}$；预训练参数 W_ϕ^*；最大跳数 L；外层迭代轮数 T_{epoch}；Phase W 更新步数 T_W；学习率 η_W；早停窗口 q

输出： 稀疏权重矩阵 $\Theta=\{\theta_i\}_{i\in V}$；特征变换参数 W_ϕ

阶段一：候选集与环层构建
for all $i\in V$ **do**
　for $l=1$ **to** L **do**
　　$\mathcal{R}_l(i)\leftarrow\{j\in V\mid d_G(i,j)=l\}$ {第 l 跳邻居环层}
　end for
　$C_i\leftarrow\{i\}\cup\bigcup_{l=1}^{L}\mathcal{R}_l(i)$ {第 0 跳自特征通道固定保留，不计入分层预算}
end for
阶段二：交替优化初始化
$W_\phi\leftarrow W_\phi^*;\ \Theta\leftarrow 0$
for $e=1$ **to** T_{epoch} **do**
　$\tilde{\Phi}\leftarrow\ell_2\text{-row-normalize}(\phi(X;W_\phi))$
　Phase Θ**：固定** W_ϕ**，更新** Θ
　for all $i\in V$ **do**
　　第 0 跳：自特征通道单变量拟合
　　$\tilde{\phi}_i\leftarrow\tilde{\Phi}_{i,:}\ ;\ \theta_i^{(0)}\leftarrow\arg\min_{\alpha\in\mathbb{R}}\left\|\alpha\,\tilde{\phi}_i-H^*_{i,:}\right\|_2^2+\tau(i)|\alpha|\ ;\ r_i^{(0)}\leftarrow H^*_{i,:}-\theta_i^{(0)}\tilde{\phi}_i$
　　第 1 至 L 跳：邻居环层分层 LARS
　　for $l=1$ **to** L **do**
　　取 $\tilde{\Phi}_{\mathcal{R}_l(i)}$ 为 $\tilde{\Phi}$ 在环层 $\mathcal{R}_l(i)$ 上对应行子矩阵，构造第 l 层 Lasso 子问题：
　　$$\theta_i^{(l)}=\arg\min_{\theta\in\mathbb{R}^{|\mathcal{R}_l(i)|}}\left\|\tilde{\Phi}_{\mathcal{R}_l(i)}^\top\theta-r_i^{(l-1)}\right\|_2^2+\tau(i)\|\theta\|_1$$
　　采用 LARS 求解上述子问题，并令最大迭代步数不超过 $k_i^{(l)}$
　　$r_i^{(l)}\leftarrow r_i^{(l-1)}-\tilde{\Phi}_{\mathcal{R}_l(i)}^\top\theta_i^{(l)}$
　　end for
　　$\Theta_{i,i}\leftarrow\theta_i^{(0)}$
　　for $l=1$ **to** L **do**
　　for all $j\in\mathcal{R}_l(i)$ **do**
　　将 $\theta_i^{(l)}$ 中与节点 j 对应的分量写入 $\Theta_{j,i}$
　　end for
　　end for
　　for all $j\notin C_i$ **do**
　　$\Theta_{j,i}\leftarrow 0$
　　end for
　end for
　Phase W**：固定** Θ**，以上一轮参数** W_ϕ **为热启动继续更新**
　for $s=1$ **to** T_W **do**
　　$\tilde{\Phi}^{(s)}\leftarrow\ell_2\text{-row-normalize}(\phi(X;W_\phi))$
　　$\hat{H}^{(s)}\leftarrow\Theta^\top\tilde{\Phi}^{(s)}$
　　$W_\phi\leftarrow\mathrm{AdamStep}\big(W_\phi,\nabla_{W_\phi}\frac{1}{2}\|\hat{H}^{(s)}-H^*\|_F^2,\eta_W\big)$
　end for
　if $\mathrm{EarlyStop}(q)$ **then**
　　break {验证指标在最近 q 轮内无显著提升}
　end if
end for
return $\Theta,\ W_\phi$

算法 5.2 推理期稀疏固化

输入： 训练完成的稀疏权重矩阵 $\Theta = \{\theta_i\}_{i \in V}$；特征变换参数 W_ϕ；输入特征矩阵 X
输出： 固化稀疏权重矩阵 Θ^{fixed}；缓存归一化特征矩阵 $\tilde{\Phi}^{\text{cache}}$

1: $\Theta^{\text{fixed}} \leftarrow \Theta$
2: $\tilde{\Phi}^{\text{cache}} \leftarrow \ell_2\text{-row-normalize}(\phi(X; W_\phi))$
3: **return** Θ^{fixed}, $\tilde{\Phi}^{\text{cache}}$

5.1.3 优化稳定性与实现说明

在固定 W_ϕ 的条件下，第 l 个邻居环层对应的子问题可写为带 ℓ_1 正则项的凸优化问题；若对该子问题完整执行 LARS，则可得到其对应 Lasso 路径上的精确截断解。然而，本文在 Phase Θ 中同时引入了候选集限制、残差级联与 `max_iter` 截断，因此整阶段更适宜表述为一种分层近似求解过程，而不宜将其理解为对整体 Lasso 问题解路径的精确追踪。

对外层交替优化而言，本文不声称其具有全局收敛保证。更准确地说，当前算法属于“固定 Θ 更新 W_ϕ，再固定 W_ϕ 更新 Θ”的交替优化框架，其中 Phase Θ 由分层截断 LARS 实现稀疏近似更新，Phase W 则通过梯度法最小化全图表示逼近目标。已有关于块坐标下降与交替最小化的研究[35-36]为此类方法的稳定性分析提供了参考视角，但这些结果并不能直接推出本文算法在当前设置下的严格全局收敛结论。

本文对该算法的表述口径限定为经验稳定性：在合理学习率、早停窗口与预算截断设置下，Phase Θ 与 Phase W 的交替推进在六个数据集上均表现出较为平稳的训练过程，目标函数与验证指标未出现持续振荡或系统性发散现象。至此，节点级正则系数 $\tau(i)$、分层预算上限 $\{k_i^{(l)}\}$ 以及结构固化后的推理接口已经在算法层完成统一整合，固化后推理表达式见式 (5-12)，并将在第 5.2 节继续用于后续误差分析。

5.2 误差分析与适用条件

第 4 章从频率、节点与跳距三个维度给出了自适应稀疏参数的构造规则，但这些设计主要服务于稀疏预算分配本身，仍需进一步说明其与后续误差分析之间的接口关系。为此，本节借鉴经典谱稀疏化中基于拉普拉斯二次型保持的分析框架[37-39]，引入 σ-谱相似性作为谱保持度量工具，并在此基础上讨论多项式谱滤波器下的近似误差界及其适用条件。本节给出的误差界属于条件化分析：第 4 章的参数设计主要作用于稀疏结构的生成过程。节点级正则系数 $\tau(i)$、分层保留率 p_l 及环层预算 $k_i^{(l)}$ 会共同影响稀疏权重矩阵 Θ 的支持集，从而改变稀疏图 $\hat{G}$ 相对于原图 G 的结构保留程度，并进一步决定谱扰动的大小。第 5 章则不再讨论这些参数的具体构造，而是在给定谱扰动可控的条件下，分析该扰动如何通过

谱滤波器传递到图信号输出，并最终影响稀疏表示 $\hat{H}$ 对教师表示 H^* 的近似误差。

5.2.1 自适应参数设计与误差分析的接口

第 4 章给出的三类自适应参数并不直接出现在 σ-谱相似性的定义式中，但它们决定了稀疏图 $\hat{G}$ 的形成方式，因此会通过稀疏支持集、环层预算上限和节点级惩罚强度影响原图与稀疏图之间的谱扰动。节点级正则系数 $\tau(i)$ 控制节点 i 对应 Lasso 子问题的稀疏压力，进而影响 θ_i 的非零规模与候选邻居保留结果；分层保留率 p_l 与预算上限 $k_i^{(l)}$ 约束不同跳距环层 $\mathcal{R}_l(i)$ 中可进入支持集的节点数量；频率维的节点谱能量 $E_{\text{spectral}}(i)$ 则为 $\tau(i)$ 的差异化分配提供谱域依据。由此，第 4 章的参数设计可以理解为对稀疏图 $\hat{G}$ 构造过程的前置约束，而第 5 章的误差分析则讨论给定 $\hat{G}$ 后，谱扰动如何传递到多项式滤波输出与表示误差。

这种关系需要作适度限定。本文并不声称第 4 章的 $\tau(i)$、p_l 和 $k_i^{(l)}$ 能够严格推出某个确定的 σ，也不把第 5 章的误差界解释为对所有图均成立的无条件保证。更稳妥的理解是：第 4 章主要从机制设计层面降低稀疏化对关键传播结构的破坏风险。节点级正则系数与分层跳距预算共同提高结构重要节点和近邻环层的保留优先级，使稀疏图 $\hat{G}$ 尽量保留对局部信息传播更关键的通道。第 5 章则在给定谱差异可控的前提下展开分析，说明稀疏化导致的拉普拉斯扰动如何传递到谱滤波器输出，并进一步影响最终表示近似误差。因此，本文的理论链条属于“参数设计倾向 $\Rightarrow$ 稀疏结构扰动 $\Rightarrow$ 条件化误差上界”的分析口径，而不是“参数公式 $\Rightarrow$ 固定 $\sigma \Rightarrow$ 确定误差”的闭式推导。

从三个维度看，$\tau(i)$ 主要作用于节点级保留强度，决定不同节点的平均非零规模 $k_i = \|\theta_i\|_0$；$k_i^{(l)}$ 主要作用于跳距级分配，避免远跳邻居在预算有限时过度挤占近邻信息；$E_{\text{spectral}}(i)$、$H_{\text{norm}}(i)$、$C_{\text{deg}}(i)$ 与 $\text{core}(i)$ 则为上述预算差异提供可计算的结构输入。若上述设计使稀疏图 $\hat{G}$ 在主要传播方向上较好保持原图 G 的二次型结构，则原图与稀疏图的谱差异可视为处于可控范围。第 5 章将在此条件下分析拉普拉斯扰动经谱滤波器传递到输出表示的过程，并给出相应的表示误差控制。第 6 章的消融实验与谱误差相关分析将从经验层面检验上述判断是否与实验现象一致，实验主要用于验证方法设计与理论分析方向的一致性，并不构成对本节条件化误差前提的严格证明。

5.2.2 谱相似性与图稀疏化

稀疏化过程可视为以边数更少的图 $\hat{G}$ 近似替代原图 G。若仅从边数压缩角度刻画这一过程，则无法说明原图谱结构在多大程度上被保留；因此，本文采用基于拉普拉斯二次型的谱相似性度量来刻画稀疏化误差。经典谱稀疏化文献

通常以图拉普拉斯的二次型保持为基础讨论谱近似性质[37-38]；本文在此基础上，结合全文统一采用的归一化拉普拉斯记号，给出如下分析口径。

设 G 与 $\hat{G}$ 为定义在同一节点集 V 上的两个图，其归一化拉普拉斯分别记为 $\tilde{\mathcal{L}}_G$ 与 $\tilde{\mathcal{L}}_{\hat{G}}$。若存在参数 $\sigma \geqslant 1$，使得对任意 $x \in \mathbb{R}^n$ 都有

$$\frac{1}{\sigma} x^\top \tilde{\mathcal{L}}_G x \leqslant x^\top \tilde{\mathcal{L}}_{\hat{G}} x \leqslant \sigma x^\top \tilde{\mathcal{L}}_G x^{[38,40]}. \tag{5-16}$$

则称 $\hat{G}$ 与 G 在本文的度量口径下满足 σ-谱相似性。参数 σ 越接近 1，说明稀疏图对原图拉普拉斯二次型的保持越精确；当 σ 偏离 1 较大时，则意味着稀疏化引入了更明显的谱结构扰动。

式 (5-16) 的作用在于把“边被删去多少”转化为“图信号能量被扭曲多少”的可分析形式。由于多项式谱滤波器的输出直接依赖于拉普拉斯谱性质，若稀疏化后的图仍能在式 (5-16) 意义下较好保持原图的二次型结构，则后续滤波输出与表示误差也更容易得到上界控制[38-39]。

严格意义下的 σ 往往需要较高代价的谱信息计算；对小规模图，可通过精确特征分解直接评估；对较大规模图，本文在实验部分采用 Lanczos 代理量 $\tilde{\sigma}_{\text{proxy}}$ 进行近似估计。基于上述定义，下一节将进一步讨论多项式谱滤波器在 σ-谱相似条件下的近似误差界。

5.2.3 多项式谱滤波器的近似误差界

本节在上一小节给出的 σ-谱相似性度量基础上，进一步讨论多项式谱滤波器下的输出误差。结合第 5.2.1 节的接口说明，这里关心的问题可以表述为：当第 4 章的自适应预算设计得到一个稀疏图 $\hat{G}$ 后，若该稀疏图与原图 G 在谱意义上足够接近，则同一个谱滤波器分别作用于两张图后，其输出偏差能否被定量控制。本节结论仍然是条件化误差界：它说明“给定谱扰动时，滤波输出误差如何传播”，而不把 $\tau(i)$、p_l 和 $k_i^{(l)}$ 直接等同于某个固定的谱相似性参数 σ。

设 G 的归一化拉普拉斯为

$$\tilde{\mathcal{L}} = U \Lambda U^\top, \tag{5-17}$$

其中，$U \in \mathbb{R}^{n \times n}$ 为正交特征向量矩阵，$\Lambda = \operatorname{diag}(\lambda_0, \lambda_1, \cdots, \lambda_{n-1})$ 为特征值对角矩阵。根据谱图理论，归一化拉普拉斯的特征值满足

$$0 \leqslant \lambda_i \leqslant 2, \qquad i = 0, 1, \cdots, n-1. \tag{5-18}$$

式 (5-18) 的意义在于：后续对谱滤波器的分析可以统一限制在紧区间 $[0, 2]$ 上，这也是采用多项式逼近尤其是 Chebyshev 逼近的基础[22-23,41]。

设 $g : \mathbb{R} \to \mathbb{R}$ 为一个 K_{poly} 次多项式谱滤波器。其作用于归一化拉普拉斯后

的矩阵函数定义为

$$g(\tilde{\mathcal{L}}) := g(U\Lambda U^\top) = U\,\mathrm{diag}\big(g(\lambda_0), g(\lambda_1), \cdots, g(\lambda_{n-1})\big)\,U^\top. \tag{5-19}$$

式 (5-19) 表明，谱滤波器的本质是在谱域上对每个频率分量 λ_i 施加响应 $g(\lambda_i)$。若输入特征矩阵记为 $X \in \mathbb{R}^{n\times D}$，则

$$g(\tilde{\mathcal{L}})X. \tag{5-20}$$

就是滤波器作用于节点特征后的输出，其中 D 为输入特征维度。

由于 Chebyshev 多项式的标准定义区间为 $[-1, 1]$，而式 (5-18) 中 $\tilde{\mathcal{L}}$ 的谱位于 $[0, 2]$，因此先作平移变换

$$\bar{\mathcal{L}} := \tilde{\mathcal{L}} - I. \tag{5-21}$$

由此可得

$$\mathrm{spec}(\bar{\mathcal{L}}) \subset [-1, 1]. \tag{5-22}$$

式 (5-22) 说明，$\bar{\mathcal{L}}$ 已被映射到适合 Chebyshev 展开的标准区间；这一步并不改变滤波问题的本质，只是为了后续多项式表示与误差分析更为方便[23,41]。

实现上，$g(\tilde{\mathcal{L}})$ 常写成 Chebyshev 多项式展开；但在误差推导中，更便于使用其在 $\bar{\mathcal{L}}$ 上的单项式表示。记

$$g(\tilde{\mathcal{L}}) = p(\bar{\mathcal{L}}) = \sum_{r=0}^{K_{\text{poly}}} a_r \bar{\mathcal{L}}^r. \tag{5-23}$$

其中，K_{poly} 为多项式滤波器次数，$\{a_r\}_{r=0}^{K_{\text{poly}}}$ 为由 Chebyshev 展开系数线性换算得到的单项式系数。这里的 K_{poly} 表示滤波器的阶数，与第 3 章 Lanczos 近似中使用的 K_{eig} 含义不同：前者控制谱滤波器的表达复杂度，后者控制谱估计所保留的特征对数量，二者不得混用。

上一小节引入的 σ-谱相似性，本质上借鉴了经典谱稀疏化中基于拉普拉斯二次型保持的分析框架[37-39]。为把这种结构扰动传递到滤波输出误差分析中，先定义原图与稀疏图对应平移拉普拉斯之间的算子范数差

$$\eta := \left\|\bar{\mathcal{L}}_G - \bar{\mathcal{L}}_{\hat{G}}\right\|_2 = \left\|\tilde{\mathcal{L}}_G - \tilde{\mathcal{L}}_{\hat{G}}\right\|_2. \tag{5-24}$$

式 (5-24) 中，$\|\cdot\|_2$ 表示矩阵谱范数，也即最大奇异值；对实对称矩阵而言，它等于特征值绝对值的最大值。参数 η 衡量的是原图与稀疏图在拉普拉斯算子层面的直接偏离程度。由于平移不改变差值，可直接验证

$$\bar{\mathcal{L}}_G - \bar{\mathcal{L}}_{\hat{G}} = (\tilde{\mathcal{L}}_G - I) - (\tilde{\mathcal{L}}_{\hat{G}} - I) = \tilde{\mathcal{L}}_G - \tilde{\mathcal{L}}_{\hat{G}}. \tag{5-25}$$

因此式 (5-24) 中两个谱范数完全相等。

由式 (5-22) 可知，$\bar{\mathcal{L}}_G$ 与 $\bar{\mathcal{L}}_{\hat{G}}$ 的全部特征值都落在 $[-1, 1]$ 中。由于二者都是

实对称矩阵，因此有

$$\|\bar{\mathcal{L}}_G\|_2 \leqslant 1, \qquad \|\bar{\mathcal{L}}_{\hat{G}}\|_2 \leqslant 1. \tag{5-26}$$

这一步的作用是为后续控制高阶幂差提供统一上界：高阶幂本身不会在谱范数意义下爆炸增长。

下面估计同一阶数下原图与稀疏图的幂差。对任意整数 $r \geqslant 1$，有经典矩阵恒等式[42]

$$A^r - B^r = \sum_{t=0}^{r-1} A^t (A-B) B^{r-1-t}. \tag{5-27}$$

将式 (5-27) 中 A 与 B 分别取为 $\bar{\mathcal{L}}_G$ 与 $\bar{\mathcal{L}}_{\hat{G}}$，则有

$$\bar{\mathcal{L}}_G^r - \bar{\mathcal{L}}_{\hat{G}}^r = \sum_{t=0}^{r-1} \bar{\mathcal{L}}_G^t (\bar{\mathcal{L}}_G - \bar{\mathcal{L}}_{\hat{G}}) \bar{\mathcal{L}}_{\hat{G}}^{r-1-t}. \tag{5-28}$$

对式 (5-28) 两端取谱范数。注意到谱范数对矩阵求和满足三角不等式，即任意矩阵组 $\{M_t\}_{t=0}^{r-1}$ 满足

$$\left\| \sum_{t=0}^{r-1} M_t \right\|_2 \leqslant \sum_{t=0}^{r-1} \|M_t\|_2, \tag{5-29}$$

因此，将式 (5-28) 右端的每一项视为矩阵

$$M_t := \bar{\mathcal{L}}_G^t (\bar{\mathcal{L}}_G - \bar{\mathcal{L}}_{\hat{G}}) \bar{\mathcal{L}}_{\hat{G}}^{r-1-t}, \qquad t = 0, 1, \cdots, r-1, \tag{5-30}$$

便可得到

$$\left\| \bar{\mathcal{L}}_G^r - \bar{\mathcal{L}}_{\hat{G}}^r \right\|_2 \leqslant \sum_{t=0}^{r-1} \left\| \bar{\mathcal{L}}_G^t (\bar{\mathcal{L}}_G - \bar{\mathcal{L}}_{\hat{G}}) \bar{\mathcal{L}}_{\hat{G}}^{r-1-t} \right\|_2. \tag{5-31}$$

进一步地，谱范数对矩阵乘法满足次乘性，即对任意维度相容的矩阵 A, B, C，都有

$$\|ABC\|_2 \leqslant \|A\|_2 \|B\|_2 \|C\|_2. \tag{5-32}$$

将式 (5-32) 应用于式 (5-31) 中求和号内的每一项，可得

$$\left\| \bar{\mathcal{L}}_G^t (\bar{\mathcal{L}}_G - \bar{\mathcal{L}}_{\hat{G}}) \bar{\mathcal{L}}_{\hat{G}}^{r-1-t} \right\|_2 \leqslant \|\bar{\mathcal{L}}_G\|_2^t \left\| \bar{\mathcal{L}}_G - \bar{\mathcal{L}}_{\hat{G}} \right\|_2 \|\bar{\mathcal{L}}_{\hat{G}}\|_2^{r-1-t}. \tag{5-33}$$

结合式 (5-24) 与式 (5-26)，上式右端可进一步上界为

$$\|\bar{\mathcal{L}}_G\|_2^t \left\| \bar{\mathcal{L}}_G - \bar{\mathcal{L}}_{\hat{G}} \right\|_2 \|\bar{\mathcal{L}}_{\hat{G}}\|_2^{r-1-t} \leqslant 1 \cdot \eta \cdot 1 = \eta. \tag{5-34}$$

由于求和项共有 r 项，于是得到

$$\left\| \bar{\mathcal{L}}_G^r - \bar{\mathcal{L}}_{\hat{G}}^r \right\|_2 \leqslant r\,\eta. \tag{5-35}$$

式 (5-35) 的含义是：当拉普拉斯算子本身的扰动大小为 η 时，r 阶多项式项的误差至多按阶数 r 线性放大，而不会出现更高阶的爆炸式增长。

在此基础上，可以估计滤波器输出的整体误差。由式 (5-23) 可知，

$$g(\tilde{\mathcal{L}}_G)X - g(\tilde{\mathcal{L}}_{\hat{G}})X = \sum_{r=0}^{K_{\text{poly}}} a_r(\bar{\mathcal{L}}_G^r - \bar{\mathcal{L}}_{\hat{G}}^r)X. \tag{5-36}$$

当 $r=0$ 时，有

$$\bar{\mathcal{L}}_G^0 - \bar{\mathcal{L}}_{\hat{G}}^0 = I - I = 0, \tag{5-37}$$

因此常数项不贡献误差。于是式 (5-36) 可简化为

$$g(\tilde{\mathcal{L}}_G)X - g(\tilde{\mathcal{L}}_{\hat{G}})X = \sum_{r=1}^{K_{\text{poly}}} a_r(\bar{\mathcal{L}}_G^r - \bar{\mathcal{L}}_{\hat{G}}^r)X. \tag{5-38}$$

对式 (5-38) 两端取 Frobenius 范数，并利用三角不等式，可得

$$\left\|g(\tilde{\mathcal{L}}_G)X - g(\tilde{\mathcal{L}}_{\hat{G}})X\right\|_F \leqslant \sum_{r=1}^{K_{\text{poly}}} |a_r| \left\|(\bar{\mathcal{L}}_G^r - \bar{\mathcal{L}}_{\hat{G}}^r)X\right\|_F. \tag{5-39}$$

再利用矩阵乘积的范数不等式

$$\|MX\|_F \leqslant \|M\|_2 \|X\|_F, \tag{5-40}$$

可进一步得到

$$\left\|g(\tilde{\mathcal{L}}_G)X - g(\tilde{\mathcal{L}}_{\hat{G}})X\right\|_F \leqslant \sum_{r=1}^{K_{\text{poly}}} |a_r| \left\|\bar{\mathcal{L}}_G^r - \bar{\mathcal{L}}_{\hat{G}}^r\right\|_2 \|X\|_F. \tag{5-41}$$

最后，将式 (5-35) 代入式 (5-41)，即可得到

$$\left\|g(\tilde{\mathcal{L}}_G)X - g(\tilde{\mathcal{L}}_{\hat{G}})X\right\|_F \leqslant \eta \left(\sum_{r=1}^{K_{\text{poly}}} r|a_r|\right) \|X\|_F. \tag{5-42}$$

这就是本节的第一条核心结论。式 (5-42) 表明：谱滤波输出误差由三部分共同决定，分别是图结构扰动大小 η、滤波器系数权重和输入特征规模 $\|X\|_F$。其中，

$$\sum_{r=1}^{K_{\text{poly}}} r|a_r|. \tag{5-43}$$

反映的是滤波器对高阶项的敏感程度；若高阶项权重越大，则同样大小的结构扰动会被放大得更多。

为了进一步把上一小节定义的 σ-谱相似性参数与式 (5-42) 联系起来，本文借鉴经典谱稀疏化中基于拉普拉斯二次型保持的分析框架[37-39]，将如下 σ-谱相似性条件作为后续误差分析的前提：

$$\frac{1}{\sigma}\tilde{\mathcal{L}}_G \preceq \tilde{\mathcal{L}}_{\hat{G}} \preceq \sigma\tilde{\mathcal{L}}_G, \qquad \sigma \geqslant 1. \tag{5-44}$$

式 (5-44) 中，符号 $\preceq$ 表示 Loewner 半序；也即，对称矩阵 $A \preceq B$ 表示 $B - A$ 半

正定。由式 (5-44) 左右两侧分别减去 $\tilde{\mathcal{L}}_G$，可得

$$\tilde{\mathcal{L}}_{\hat{G}} - \tilde{\mathcal{L}}_G \preceq (\sigma - 1)\tilde{\mathcal{L}}_G, \tag{5-45}$$

以及

$$\tilde{\mathcal{L}}_G - \tilde{\mathcal{L}}_{\hat{G}} \preceq \left(1 - \frac{1}{\sigma}\right)\tilde{\mathcal{L}}_G. \tag{5-46}$$

又因为对任意 $\sigma \geqslant 1$ 都有

$$1 - \frac{1}{\sigma} \leqslant \sigma - 1, \tag{5-47}$$

所以由式 (5-45) 与式 (5-46) 可统一写成保守上界

$$-(\sigma - 1)\tilde{\mathcal{L}}_G \preceq \tilde{\mathcal{L}}_{\hat{G}} - \tilde{\mathcal{L}}_G \preceq (\sigma - 1)\tilde{\mathcal{L}}_G. \tag{5-48}$$

令

$$\Delta_{\mathcal{L}} := \tilde{\mathcal{L}}_{\hat{G}} - \tilde{\mathcal{L}}_G, \qquad M := (\sigma - 1)\tilde{\mathcal{L}}_G. \tag{5-49}$$

则式 (5-48) 可改写为

$$-M \preceq \Delta_{\mathcal{L}} \preceq M. \tag{5-50}$$

由于 G 与 $\hat{G}$ 均为无向图，其归一化拉普拉斯矩阵 $\tilde{\mathcal{L}}_G$ 与 $\tilde{\mathcal{L}}_{\hat{G}}$ 都是实对称矩阵；而实对称矩阵在减法与实数倍运算下仍保持实对称性，因此

$$\Delta_{\mathcal{L}} := \tilde{\mathcal{L}}_{\hat{G}} - \tilde{\mathcal{L}}_G, \tag{5-51}$$

与

$$M := (\sigma - 1)\tilde{\mathcal{L}}_G. \tag{5-52}$$

也都是实对称矩阵。这里参数 σ 是乘性谱相似因子：当 $\sigma = 1$ 时表示两图在该度量下完全一致，而谱扰动增大时只能表现为对原图拉普拉斯二次型的乘性放缩，因此必须有 $\sigma \geqslant 1$；这也与经典谱稀疏化中常见的乘性近似框架一致[37-39]。又因为归一化拉普拉斯矩阵 $\tilde{\mathcal{L}}_G$ 是半正定矩阵[22]，且由 $\sigma \geqslant 1$ 可知 $\sigma - 1 \geqslant 0$，故对任意 $x \in \mathbb{R}^n$ 都有

$$x^\top M x = (\sigma - 1)x^\top \tilde{\mathcal{L}}_G x \geqslant 0, \tag{5-53}$$

从而 $M \succeq 0$。

由式 (5-50) 可知，

$$-M \preceq \Delta_{\mathcal{L}} \preceq M. \tag{5-54}$$

Loewner 半序的定义表明，上式等价于对任意 $x \in \mathbb{R}^n$ 都有

$$-x^\top M x \leqslant x^\top \Delta_{\mathcal{L}} x \leqslant x^\top M x. \tag{5-55}$$

又由于 M 是实对称半正定矩阵，其任意方向上的二次型均不超过最大特征值与向量范数平方的乘积[42-43]，因此对任意 $x \in \mathbb{R}^n$ 都有

$$x^\top M x \leqslant \lambda_{\max}(M)\|x\|_2^2. \tag{5-56}$$

于是进一步有

$$-\lambda_{\max}(M)\|x\|_2^2 \leqslant x^\top \Delta_{\mathcal{L}} x \leqslant \lambda_{\max}(M)\|x\|_2^2. \tag{5-57}$$

现在取 $x = v$ 为 $\Delta_{\mathcal{L}}$ 的任意单位特征向量，对应特征值记为 μ，即

$$\Delta_{\mathcal{L}} v = \mu v, \qquad \|v\|_2 = 1. \tag{5-58}$$

将其代入式 (5-57)，便得到

$$-\lambda_{\max}(M) \leqslant v^\top \Delta_{\mathcal{L}} v = \mu \leqslant \lambda_{\max}(M). \tag{5-59}$$

因此，$\Delta_{\mathcal{L}}$ 的全部特征值均落在区间

$$\left[-\lambda_{\max}(M),\, \lambda_{\max}(M)\right]. \tag{5-60}$$

再由实对称矩阵的谱范数等于其特征值绝对值最大值这一标准性质[42]，可得

$$\|\Delta_{\mathcal{L}}\|_2 \leqslant \lambda_{\max}(M) = \|M\|_2. \tag{5-61}$$

将式 (5-49) 代入式 (5-61)，便有

$$\eta = \|\tilde{\mathcal{L}}_G - \tilde{\mathcal{L}}_{\hat{G}}\|_2 \leqslant (\sigma - 1)\|\tilde{\mathcal{L}}_G\|_2. \tag{5-62}$$

再利用归一化拉普拉斯的谱范数上界

$$\|\tilde{\mathcal{L}}_G\|_2 \leqslant 2, \tag{5-63}$$

即可得到

$$\eta \leqslant 2(\sigma - 1). \tag{5-64}$$

将式 (5-64) 代入式 (5-42)，便有

$$\left\|g(\tilde{\mathcal{L}}_G)X - g(\tilde{\mathcal{L}}_{\hat{G}})X\right\|_F \leqslant 2(\sigma - 1)\left(\sum_{r=1}^{K_{\text{poly}}} r|a_r|\right)\|X\|_F. \tag{5-65}$$

这就是本节的第二条核心结论。式 (5-65) 给出了一个非常直观的参数化解释：当稀疏图 $\hat{G}$ 相对原图 G 的谱结构偏差越小，即 σ 越接近 1 时，多项式谱滤波器输出的误差也越小；误差常数则由滤波器自身的多项式系数决定。

式 (5-65) 刻画的是稀疏化结构对图传播算子的影响，而不应直接等同于 MSAS-GNN 输出 $\hat{H}$ 与教师表示 H^* 之间的完整拟合误差。该式在固定节点特征 X 的条件下，比较原图传播 $g(\tilde{\mathcal{L}}_G)X$ 与稀疏图传播 $g(\tilde{\mathcal{L}}_{\hat{G}})X$ 的输出偏差，用于说明：若稀疏图能够较好保持原图的主要谱结构，则由结构稀疏化引起的传播

层面误差可以得到相应控制。实际的教师表示拟合误差还会受到特征变换函数、稀疏权重求解精度、候选集约束以及交替优化误差等因素影响，因此不能将二者作等价理解。进一步地，式 (5-65) 的逻辑方向是由 σ-谱相似性条件推出谱滤波输出误差上界，而不是说明第 4 章提出的三维自适应参数必然自动保证某个给定的 σ。本节给出的是从谱扰动到滤波输出误差的条件化传递关系，并不构成从第 4 章参数设计到谱扰动大小的严格闭合证明。第 6 章中的消融实验与表示误差变化分析，主要用于从经验层面检验自适应设计、谱扰动控制思路与最终实验现象之间是否具有一致性。

从方法论上看，经典谱稀疏化理论表明，在适当的重加权采样构造下，可以用近线性规模的边数获得良好的谱保持性质[37-39]；但本文的 MSAS-GNN 属于基于节点级自适应预算的稀疏分解框架，并不与经典加权谱 sparsifier 的构造完全等同。因此，本节的正式误差分析以式 (5-42) 与式 (5-65) 为准，而第 4 章三维参数对谱扰动的影响，将在第 6 章中结合代理量进行实验验证。

至此，谱相似性参数与多项式谱滤波输出误差之间的关系已经建立。下一节将转入复杂度分析，讨论预处理、训练与固化推理三类开销之间的口径区别。

5.3 复杂度分析

第 5.2 节给出了谱扰动到滤波输出误差的条件化分析；本节进一步分析推理、训练与预处理三类开销，并说明线性规模推理复杂度成立的条件。三类开销须严格区分：本文关于“推理高效”的主张，仅针对结构固化且缓存就绪后的单次稀疏矩阵乘主项，而不包含训练期优化与一次性预处理成本。

就推理期复杂度而言，结构固化后的推理过程为

$$\hat{H} = (\Theta^{\text{fixed}})^\top \tilde{\Phi}^{\text{cache}}, \tag{5-66}$$

其中，$\Theta^{\text{fixed}} \in \mathbb{R}^{n\times n}$ 为固化后的稀疏权重矩阵，$\tilde{\Phi}^{\text{cache}} \in \mathbb{R}^{n\times d}$ 为缓存后的归一化特征矩阵，d 为隐藏表示维度。若记 $\operatorname{nnz}(\Theta^{\text{fixed}}) = m_{\text{sparse}}$ 为固化稀疏矩阵的非零元总数，则式 (5-66) 的推理主项复杂度为

$$O(m_{\text{sparse}}\, d). \tag{5-67}$$

进一步地，若记

$$\bar{k} := \frac{1}{n}\sum_{i\in V} \|\theta_i\|_0, \tag{5-68}$$

表示固化后各节点非零权重数的全图平均值，则有 $m_{\text{sparse}} = n\bar{k}$，从而推理主项复杂度可写为

$$O(n\bar{k}d). \tag{5-69}$$

式 (5-69) 表明，推理阶段只需遍历固化后保留下来的非零连接，复杂度与传播层数 L 不再显式相关；层级信息已经被编码到 θ_i 的支撑集结构中，具体体现为第 0 跳自特征系数与不同跳距邻居环层上的系数组合结构。

若以缓存就绪后的聚合主项作为比较口径，则其理论聚合加速比与第 3 章给出的推理评价指标保持一致。由结构固化后推理主项复杂度 $O(n\bar{k}d)$ 与 L 层标准 GCN 聚合主项复杂度 $O(Ln\bar{d}d)$ 对比可得

$$\text{Speedup}_{\text{aggregate}} = \frac{L\bar{d}}{\bar{k}}, \tag{5-70}$$

该式与第 3 章中的式 (3-28) 在比较口径上保持一致，其中，$\bar{d}$ 表示图的平均邻居数，$\bar{k}$ 表示固化后各节点非零权重数的全图平均值。式 (5-70) 仅比较“消息聚合主项”本身，不包含特征变换、缓存构建以及训练期优化开销；因此，它反映的是结构固化后稀疏聚合相对于标准逐层邻域聚合的理论压缩收益，并非端到端总运行时间的严格比值。

训练期与预处理方面，MSAS-GNN 的主要计算瓶颈位于 Phase Θ。在当前实现中，Phase Θ 由两类子问题组成：一类是第 0 跳自特征通道的单变量稀疏拟合，另一类是第 1 至 L 跳邻居环层上的分层 LARS 求解。若采用 full-batch 口径，并按每个节点、每个环层子问题的稠密线性代数主项作保守估计，则单轮外层迭代中 Phase Θ 的复杂度可写为

$$\sum_{i\in V} O(d) + \sum_{i\in V}\sum_{l=1}^{L} O\big(|\mathcal{R}_l(i)|^3 + |\mathcal{R}_l(i)|^2 d\big)\,. \tag{5-71}$$

式 (5-71) 中，第一项来自第 0 跳自特征通道。该子问题只包含一个标量系数，但需要与 d 维目标表示进行残差匹配，因此单个节点的计算代价可记为 $O(d)$。第二项来自各邻居环层上的 LARS 子问题。对节点 i 的第 l 个邻居环层，记

$$s_{i,l} := |\mathcal{R}_l(i)|. \tag{5-72}$$

则该环层对应的稀疏回归问题包含 $s_{i,l}$ 个候选变量，目标残差为 d 维向量。参考 LARS 算法及 Lasso 正则化路径复杂度分析的相关结论[32,44]，并沿用 SDGNN 对稠密 LARS 求解开销的保守估计口径，候选变量数为 p、响应维度为 d 时，单个 Lasso 子问题的主项复杂度可写为 $O(p^3 + p^2 d)$。代入 $p = s_{i,l}$，单个环层子问题的保守复杂度为

$$O\Big(s_{i,l}^3 + s_{i,l}^2 d\Big) = O\big(|\mathcal{R}_l(i)|^3 + |\mathcal{R}_l(i)|^2 d\big)\,. \tag{5-73}$$

上述复杂度中的三次项主要反映活跃集更新过程中线性系统求解、矩阵分解或等价稠密代数操作的最坏情形代价；二次乘 d 项则对应候选变量之间相关量计算、残差匹配以及路径更新中与 d 维表示空间相关的矩阵——向量交互开销。式 (5-71) 是未显式计入 LARS 路径截断时的保守上界。实际实现中，第 l 个

环层的求解路径受到预算 $k_i^{(l)}$ 约束，LARS 最多选入 $k_i^{(l)}$ 个候选节点，因此实际运行开销通常低于该上界。

若不区分第 0 跳自特征通道与不同邻居环层，仅从节点级整体候选集规模给出同量级估计，也可将 Phase Θ 的复杂度简写为

$$\sum_{i\in V} O\big(|C_i|^3 + |C_i|^2 d\big)\,, \tag{5-74}$$

其中，$C_i = \{i\} \cup \bigcup_{l=1}^{L} \mathcal{R}_l(i)$ 为节点 i 的候选集。式 (5-74) 对应不区分环层的一体化候选集口径，而式 (5-71) 则体现了本文分层 LARS 的实际求解结构。二者共同说明，节点级候选规模会直接影响训练阶段的稀疏求解成本，因此第 4 章中的跳距预算控制不仅影响结构保留与表示误差，也会影响 Phase Θ 的训练开销。

Phase W 在每轮外层迭代中包含特征重算与稀疏聚合两部分。若每轮执行 T_W 次梯度更新，则其复杂度可写为

$$O\big(T_W(nDd + n\bar{k}d)\big), \tag{5-75}$$

其中，D 为输入特征维度，d 为隐藏表示维度。式 (5-75) 中，nDd 对应特征变换 $\phi(X; W_\phi)$ 的重算主项，$n\bar{k}d$ 对应固定 Θ 后的稀疏聚合主项。

一次性预处理主要包括谱量估计、节点指标计算、候选集构建与预算分配四部分，其复杂度分别可写为

$$O(mK_{\text{eig}}), \tag{5-76}$$

$$O(m + nK_{\text{eig}}), \tag{5-77}$$

$$O\left(\sum_{i\in V} |C_i|\right), \tag{5-78}$$

以及

$$O(nL). \tag{5-79}$$

这些步骤只执行一次，因此不计入单次推理开销，但在完整训练流程中不可忽略。各方法综合复杂度对比见表 5.1。

最后说明线性规模推理复杂度 $O(n\bar{k}d)$ 成立所依赖的条件。其一，平均保留规模满足 $\bar{k} \ll \bar{d}$，即固化后各节点的平均非零权重数显著小于原图平均邻居数；否则稀疏化无法带来实质性的聚合压缩收益；其二，固化后的稀疏权重矩阵 Θ^{fixed} 仍需保持整体稀疏，即其非零元总数满足 $\text{nnz}(\Theta^{\text{fixed}}) = n\bar{k}$，从而避免极少数高连接节点在局部引入过多非零项并削弱总体压缩效果；其三，第 0 跳自特征通道虽固定保留，但每个节点至多仅额外引入一个非零项，因此只会在非零元总数中带来 $O(n)$ 级增量，不改变式 (5-69) 的主阶；其四，推理阶段要求图结构与缓

存特征保持静态，即 Θ^{fixed} 与 $\tilde{\Phi}^{\text{cache}}$ 可直接复用，这一前提更适用于 *Transductive* 设定；若进入 *Inductive* 场景并出现新节点或图结构变化，则缓存特征与固化结构通常需要重新构造，相应扩展留待后续工作。

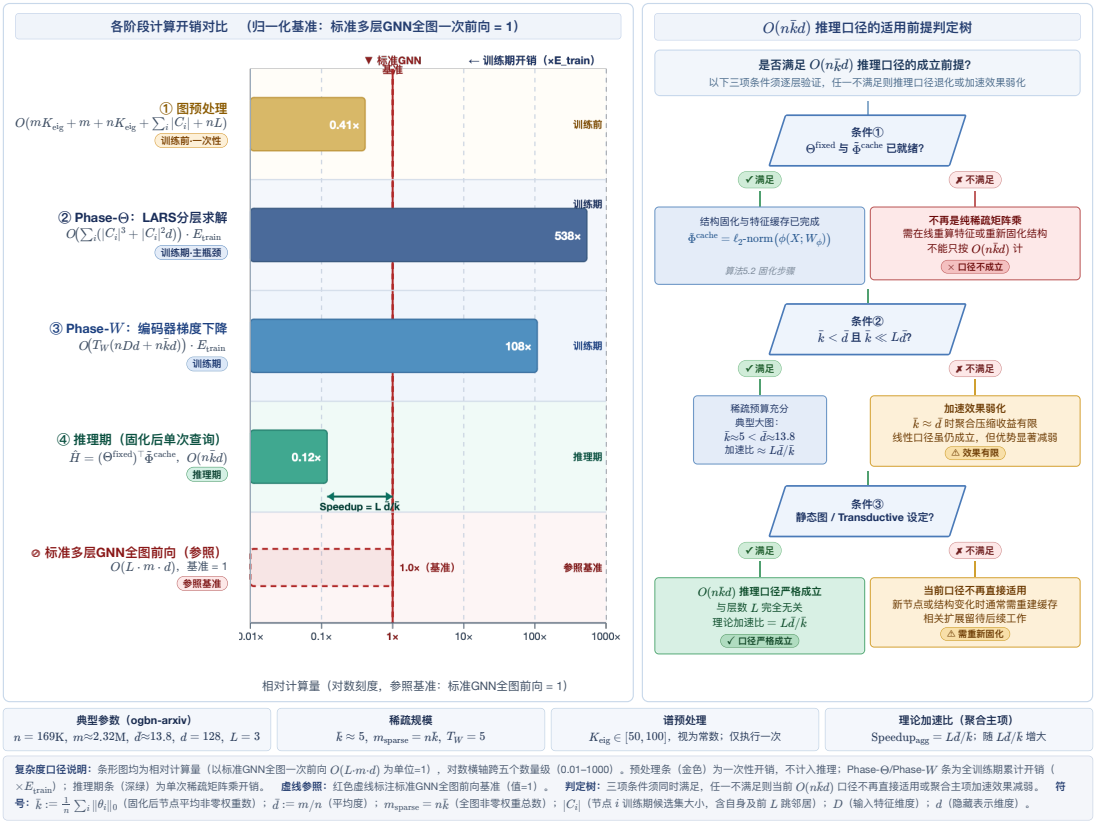

图 5.2　复杂度分解与线性推理适用边界示意图

表 5.1　各方法推理与训练复杂度对比（固定图、全图一次前向/结构固化后查询口径；$m = \text{nnz}(A)$，$m_{\text{sparse}} = n\bar{k}$，$K_{\text{eig}} \in [50, 100]$ 视为常数）

方法	预处理（一次）	训练/epoch	推理	备注
GCN	—	$O(Lmd)$	$O(Lmd)$	全图 L 层消息传递
SDGNN	$\text{Cost}_{\text{candidate-set}}$	$\sum_i O(\lvert C_i\rvert^3 + \lvert C_i\rvert^2 d)$	$O(n\bar{k}d)$	候选集级稠密子问题上界；训练后固化 Θ
MSAS-GNN	$O(mK_{\text{eig}}) + O(m + nK_{\text{eig}}) + \text{Cost}_{\text{candidate-set}} + O(nL)$	Phase Θ：$\sum_i O(d) + \sum_i \sum_{l=1}^{L} O(\lvert\mathcal{R}_l(i)\rvert^3 + \lvert\mathcal{R}_l(i)\rvert^2 d)$；Phase W：$O(T_W(nDd + n\bar{k}d))$	$\boldsymbol{O(n\bar{k}d)}$	第 0 跳单变量拟合；推理无显式 L 因子；训练瓶颈在 Phase Θ

5.4 本章小结

本章完成了从三维自适应参数到可执行算法的整体整合。第 5.1 节以 LARS 为核心求解器，通过“第 0 跳自特征通道单变量拟合 + 第 1 至 L 跳邻居环层残差级联”的分层稀疏分解流程，将节点级正则系数 $\tau(i)$ 与跳距预算上限 $k_i^{(l)}$ 整合为端到端交替优化主循环（算法 5.1）；训练完成后，再通过算法 5.2 将结果固化为稀疏权重矩阵 Θ^{fixed} 与缓存特征矩阵 $\tilde{\Phi}^{\text{cache}}$，使推理阶段退化为单次稀疏矩阵乘（式 (5-12)），其主项复杂度为 $O(n\bar{k}d)$。

第 5.2 节在经典谱稀疏化的分析框架下，引入 σ-谱相似性作为结构扰动度量，并据此建立多项式谱滤波器的条件化误差界。先给出基于算子扰动大小 η 的滤波输出误差界（式 (5-42)），再在 σ-谱相似性条件下将其进一步写成关于 σ 的参数化上界（式 (5-65)）。这些结果说明：当稀疏图与原图在谱意义上越接近时，多项式图滤波输出的偏差越小；但这里给出的仍是“谱扰动到滤波误差”的条件化分析，而非第 4 章三维参数设计到误差上界的封闭端到端严格定理。

第 5.3 节进一步区分了推理、训练与预处理三类复杂度口径：推理阶段在结构固化且缓存就绪后，其主项复杂度为 $O(n\bar{k}d)$，且不再显式依赖传播层数 L；训练阶段的主要瓶颈位于 Phase Θ，其量级由节点级候选规模与分层 LARS 子问题共同决定；一次性预处理则额外引入谱量估计、节点指标计算、候选集构建与预算分配等成本。与此同时，本节还说明了线性规模推理复杂度成立所依赖的条件，包括平均保留规模远小于原图平均邻居数、固化稀疏矩阵保持整体稀疏、第 0 跳自特征通道仅带来低阶增量，以及推理阶段要求图结构与缓存特征保持静态等。

本章的主要局限在于：第 4 章自适应系数设计仍建立在若干工程性近似之上，第 5 章的误差分析属于条件化谱扰动分析，尚未形成从三维参数设计到最终表示误差的封闭严格理论；此外，当前推理复杂度分析依赖于静态图与缓存复用前提，因此更适用于 Transductive 场景，对 Inductive 场景的扩展仍有待后续工作进一步研究。

综上，本章的核心输出一方面是结构固化后的稀疏权重矩阵 Θ^{fixed} 及缓存特征矩阵 $\tilde{\Phi}^{\text{cache}}$，它们共同构成第 6 章效率实验的直接对象；另一方面是以 σ-谱相似性为核心的谱质量分析口径，它将作为第 6 章谱保持与误差验证的重要理论参照。二者共同支撑后续章节对 MSAS-GNN 效率与精度表现的综合评估。

第 6 章 实验评估

第 3 章至第 5 章分别完成了问题形式化、三维自适应机制设计与算法整合，本章将上述方法设计与分析结论转化为可量化的实验证据。实验重点考察两个方面：其一，MSAS-GNN 在引文网络、网页图与大规模图三类场景中相对于现有稀疏图神经网络方法的精度与效率表现；其二，各核心模块的独立作用，以及第 4 章关于节点级正则系数设计与跳距预算分配、第 5 章关于误差分析所得方向性结论是否能够得到实验支持。正文主实验及参与显著性检验的结果以 Cora、Citeseer、PubMed、ogbn-arxiv、Chameleon 与 Squirrel 六个静态基准数据集为基础，在 10 个随机种子下重复，报告均值 $\pm$ 标准差，并采用 Wilcoxon 符号秩检验[45]（双侧，$p < 0.05$）评估差异显著性；个别仅保留均值记录的补充列项在相应表注中单独说明，不纳入显著性检验。

本章实验从精度、模块贡献、效率与可视化四个层面展开：第 6.1 节给出实验设置，第 6.2 节报告主实验结果，第 6.3 节通过受控消融检验三维自适应机制中各组成部分的作用，第 6.4 节评估推理时间、显存占用与预处理摊销，第 6.5 节从参数分布与表示空间两个角度补充展示方法的内部行为。上述结果共同构成从方法有效性到实际部署价值的完整实验评估链路。

6.1 实验设置

本章实验旨在在统一评测协议下，系统检验第 4 章三维自适应稀疏机制与第 5 章算法整合方案的有效性。实验采用六个公开节点分类数据集，统计信息见表 6.2。除 ogbn-arxiv 外，其余数据集均采用 60%/20%/20% 的随机划分；ogbn-arxiv 采用 OGB 官方时间划分，即训练集为 2017 年及以前，验证集为 2018 年，测试集为 2019 年及以后[46]。训练、验证与测试节点集合两两互不重叠，主训练流程中的标签仅用于监督训练与最终评测。

对于 Chameleon 与 Squirrel，本文采用 PyG 中 `geom_gcn_preprocess=True` 的预处理版本，以保持输入特征表示的一致性；但不直接使用其自带划分掩码，而是在相同数据表示上重新执行 60%/20%/20% 随机划分。这样处理的目的在于统一各方法的评测协议，降低因固定划分差异带来的额外干扰。相应地，本文实验结果应理解为统一协议下的受控比较，不宜与采用官方固定划分或其他专用划分协议的文献结果直接作数值上的一一对应。

实验环境方面，全部数据集均在 NVIDIA A100 40GB 上运行；软件环境为

PyTorch 2.0.1 与 PyTorch Geometric 2.3.1①。超参数搜索采用 Optuna 的 TPE 采样器[47-48]，以验证集准确率为优化目标；各数据集独立执行 50 次搜索，正文主实验所采用的默认搜索范围与 Cora 上的代表性最优配置见表 6.1。

为保证依赖教师表示 H^* 的分解式方法之间具有可比性，正文中的 SDGNN、MSAS-GNN 及后续消融链 B0–B5 均统一采用 GCN 作为教师模型。这样可以在统一教师骨干与统一评测协议下，尽量将方法差异控制在稀疏分解方式、节点级正则化以及跳距预算分配机制本身，而非教师网络架构差异。

正文主实验表中的 MSAS-GNN 对应 B5 配置，即同时启用谱能量、度中心性、k-core、局部图熵与分层跳距预算。其默认实现采用完整交替优化版本 B5-full。具体地，教师表示 H^* 仅作为稀疏分解的拟合目标，不直接作为候选特征矩阵输入。为提高优化初期的稳定性，本文先利用 (X, H^*) 构造一个岭回归线性映射，得到特征变换参数的初始化值 W_ϕ^*，并据此计算初始归一化特征表示：

$$\tilde{\Phi}^{(0)} = \ell_2\text{-row-normalize}\big(\phi(X; W_\phi^*)\big). \tag{6-1}$$

这里的热启动作用于特征变换参数 W_ϕ，而不是将 H^* 本身作为输入特征缓存；因此，H^* 在训练过程中仍只承担目标表示的角色。完整交替优化的每轮外循环依次执行两个阶段：在固定当前 $\tilde{\Phi}$ 的条件下更新稀疏权重矩阵 Θ，再在固定 Θ 的条件下更新 W_ϕ，并根据更新后的 W_ϕ 重新计算 $\tilde{\Phi}$ 进入下一轮迭代。冻结特征变体 B5-frozen 及其他退化版本不纳入正文主实验默认口径，而统一在第 6.3.1 节中作为消融对照给出。

表 6.1　MSAS-GNN 主实验涉及的核心超参数与 Cora 上的代表性默认配置

超参数	含义	搜索范围 / 设定方式	Cora 默认值
MSAS-GNN 主体参数			
τ_{base}	节点级正则系数基础值	$[10^{-4}, 10^{-2}]$（对数尺度）	10^{-3}
$\tau_{\min}$	节点级正则系数下界	固定默认	10^{-7}
β_τ	谱能量到节点级正则系数的响应强度	固定默认	1.0
c_E	能量阈值尺度系数，控制 $E_{\text{threshold}}$	固定默认	1.0
γ, δ, ω_H	多因子融合权重（度中心性/k-core/熵）	固定默认	0.5, 0.3, 0.2

续下页

① 本文实验实现、配置文件与结果整理脚本已公开于 GitHub 仓库：https://github.com/changh2001/msas-gnn-repro。

续表 6.1　MSAS-GNN 主实验涉及的核心超参数与 Cora 上的代表性默认配置

超参数	含义	搜索范围 / 设定方式	Cora 默认值
λ_W	特征变换参数 W_ϕ 的 ℓ_2 正则系数	固定默认	5×10^{-4}
跳距预算与候选集控制参数			
L	候选集构造与分层预算分配所采用的最大跳数	固定默认	3
p_{base}	谱间隙自适应跳距保留率中的第 1 跳基准保留率	固定默认	0.6
$p_{\min}$	跳距保留率下界	固定默认	0.1
κ	跳距保留率对谱间隙的响应强度	固定默认	2.0
$k_i^{(l)}$	节点 i 在第 l 跳环层上的预算上限	由 p_l 与环层容量诱导生成	自适应生成
交替优化与训练控制参数			
T_{epoch}	外层交替优化最大轮数	固定默认	10
T_W	Phase W 每轮 Adam 更新步数	$\{3, 5, 10\}$	5
η_W	Phase W 的 Adam 学习率	$\{0.001, 0.005\}$	0.005
patience	主实验未触发的保护性早停窗口	固定默认；当前主实验未触发	20（保护性上限）
batch_size	大图 mini-batch Phase W 的批次大小	固定默认；仅用于 $n > 5 \times 10^4$ 的大规模图	1024
图结构预处理与实现常数			
K_{eig}	Lanczos 谱估计所取特征对数	固定默认	50
$\hat{\sigma}^2$	局部图熵高斯边权的经验带宽	边上特征差平方的中位数	自适应估计
γ_x	局部图熵高斯核带宽参数	$\gamma_x = 1/(2\hat{\sigma}^2)$	自适应估计
GCN 教师模型训练配置（不纳入 MSAS-GNN 搜索空间）			
teacher	生成目标表示 H^* 的教师模型骨干	固定默认	GCN
teacher_layers	GCN 教师模型层数	固定默认	3
teacher_hidden	GCN 教师模型隐藏维度	固定默认	64
teacher_lr	GCN 教师模型优化学习率	固定默认	0.005

续下页

续表 6.1　MSAS-GNN 主实验涉及的核心超参数与 Cora 上的代表性默认配置

超参数	含义	搜索范围 / 设定方式	Cora 默认值
teacher_dropout	GCN 教师模型 Dropout 率	固定默认	0.3
teacher_weight_decay	GCN 教师模型权重衰减系数	固定默认	5×10^{-4}
teacher_optimizer	GCN 教师模型优化器	固定默认	Adam
teacher_scheduler	GCN 教师模型学习率调度器	固定默认	Cosine AnnealingLR
teacher_epochs	GCN 教师模型最大训练轮数	固定默认	200

注：本文主线不预先显式设定全局总稀疏预算。逐节点逐跳预算上界 $k_i^{(l)}$ 由第 4 章给出的跳距保留率 p_l 与环层容量共同诱导生成，并作为第 5 章分层 LARS 路径的截断上限。正文中凡依赖教师表示 H^* 的分解式方法均统一采用同一教师模型生成目标表示。教师模型自身的训练超参数属于教师训练阶段配置，不纳入本表的 MSAS-GNN 稀疏分解搜索空间。表中“Cora 默认值”表示正文主实验采用的代表性配置，并不意味着该值在所有数据集上均为最优。

所有静态实验均在 10 个随机种子下重复，种子序列设为 $\{42, 123, 456, 789, 2021, 2022, 2023, 2024, 2025, 2026\}$。实验过程中同时控制数据划分、参数初始化以及邻居采样等环节中的随机性，以尽量减小非方法因素带来的波动，并保证不同方法在相同随机协议下进行比较。方法间的显著性差异采用 Wilcoxon 符号秩检验[45]（双侧，$p < 0.05$），以 10 个随机种子下的测试准确率序列作为输入。之所以采用 Wilcoxon 检验而非配对 t 检验，是因为前者不要求准确率样本满足正态分布假设，在 $n = 10$ 的小样本条件下更适合作为稳健的非参数显著性检验工具。

对于 ogbn-arxiv 等节点数满足 $n > 5 \times 10^4$ 的大规模图，训练阶段将算法 5.1 中的 Phase W 切换为 mini-batch 实现：在每轮迭代中，从全部节点中随机采样子集 $B_t \subset V$（`batch_size=1024`），仅在采样节点上计算 Phase W 的均方误差目标。显式参数 W_ϕ 以由 (X, H^*) 构造的闭式岭回归线性映射进行热启动，并在 mini-batch Phase W 中继续更新。Phase Θ 仍保持逐节点的 LARS 求解方式不变；对于节点 i，每次仅需读取当前 $\tilde{\Phi}$ 中与其候选集 C_i 对应的行，因此该阶段的内存需求主要为 $O(|C_i| \cdot d)$，与 mini-batch 大小无关。训练结束后，在固定最终 W_ϕ 的条件下，对全体节点补执行一次 Phase Θ 重对齐，输出固化后的 Θ^{fixed}。对于节点数不超过 5×10^4 的小规模数据集，本文保留全图单次前向训练，不启用上述 mini-batch 策略。

推理加速比在小规模数据集上基于单次全图前向时间统计，在 ogbn-arxiv 上

基于 ms/batch 统计；两类指标分别报告，不作直接混合比较。

表 6.2　节点分类数据集统计信息

数据集	节点数	边数	特征维度	类别数	平均度 $\bar{d}$	类型
Cora	2,708	5,278	1,433	7	3.9	引文网络
Citeseer	3,327	4,552	3,703	6	2.7	引文网络
PubMed	19,717	44,338	500	3	4.5	引文网络
ogbn-arxiv	169,343	1,166,243	128	40	13.8	大规模引文图
Chameleon	2,277	36,101	2,325	5	31.7	维基页面
Squirrel	5,201	217,073	2,089	5	83.5	维基页面

注：表中边数按无向边数 $|E|$ 统计；平均度按 $\bar{d} = 2|E|/n$ 计算。全文复杂度分析中使用的图规模参数统一记为 $m = \mathrm{nnz}(A)$，在无向图对称邻接矩阵口径下满足 $m = 2|E|$。类型列仅用于说明数据来源与规模特征，不参与方法设计与参数计算。

基线方法覆盖稠密消息传递、线性化近似、传播近似、稀疏分解、无图蒸馏以及近年可扩展图 Transformer 等几类代表路线。第一组为与本文推理接口最接近的方法，包括 GCN[4]（稠密消息传递基线）、SGC[12]（线性近似）、PPRGo[25]（全局传播近似）、SDGNN[2]（直接稀疏分解基线，推理复杂度为 $O(n\bar{k}d)$）以及 GLNN[26]（无图蒸馏推理）。其中，SDGNN 与 MSAS-GNN 均属于依赖教师表示 H^* 的分解式方法，正文实验统一采用同一教师模型生成目标表示，以避免因教师骨干差异引入额外比较偏差。对于网页图数据集，本文额外引入 Geom-GCN[15] 与 H2GCN[16] 作为复杂结构图上的补充参照。

第二组为近年同样关注大图效率或结构自适应的补充基线，包括 GraphSAINT[11]、NodeFormer[27]、DIFFormer[28]、SGFormer[29] 和 NAGphormer[30]。这组方法与本文的共同点在于均试图降低图学习中的传播或结构建模开销，但其推理范式并不完全相同：图 Transformer 类方法通常改变模型骨干与全局交互方式，自适应采样方法则主要从训练阶段的子图构造入手，而本文关注的是在教师表示 H^* 固定后，将图结构固化为稀疏权重矩阵 Θ^{fixed} 并执行单次稀疏矩阵乘。因此，第 6.2 节将第一组方法作为主排名比较对象，同时单独报告第二组近年方法的补充实验结果，用以回应其在精度和效率上的外部参照价值。

评估指标分为三类。其一为任务精度指标，即节点分类准确率（Accuracy）。其二为效率指标，包括推理加速比

$$\mathrm{Speedup} = \frac{t_{\mathrm{dense}}}{t_{\mathrm{sparse}}}, \tag{6-2}$$

以及显存占用（MB）。其三为表示逼近质量指标，即谱近似误差

$$\mathcal{E}_{\text{approx}} = \frac{1}{\sqrt{n}} \left\| H^* - \hat{H} \right\|_F . \tag{6-3}$$

其中，效率指标严格区分批次前向耗时（ms/batch）与训练耗时（s/epoch），并分别在对应实验中报告，不作混合比较。

6.2 节点分类主实验

本节在六个基准数据集上评估 MSAS-GNN 的节点分类精度，并按引文网络与大规模图（表 6.3）以及网页图（表 6.4）两类分别汇报结果。GCN 是经典的消息传递基准模型，后续许多方法都可视为对邻域聚合范式的扩展。不过，各类方法的优化目标并不相同。SGC、PPRGo、GLNN 和 SDGNN 等方法更关注推理效率或模型压缩，准确率不一定高于 GCN；NodeFormer、DIFFormer、SGFormer 和 NAGphormer 等近期方法引入了更强的结构建模机制，因此在部分数据集上取得了高于 GCN 的结果。基于这一口径，本文实验主要考察 MSAS-GNN 在相同 GCN 教师模型与相同稀疏分解接口下相对 SDGNN 的改进幅度。

从表 6.3可以看到，MSAS-GNN 在三个引文网络数据集上均优于 SDGNN，平均提升约 1.3 个百分点。其中，Citeseer 上的提升幅度最大，由 80.3% 提高到 82.1%，提升 1.8 个百分点；Cora 与 PubMed 上也分别取得 1.4 和 0.7 个百分点的增益。除平均准确率提升外，MSAS-GNN 在 Cora、Citeseer 与 PubMed 上的标准差分别由 0.9、1.1 和 0.5 降至 0.7、0.9 和 0.4，说明在相同随机种子和数据划分协议下，节点级自适应稀疏机制不仅提高了平均性能，也在一定程度上降低了结果波动。这一现象与本文的设计预期一致：相较于 SDGNN 的全局统一稀疏控制，MSAS-GNN 根据节点结构差异调整正则强度和跳距预算，从而缓解不同拓扑角色节点在信息保留需求上的失配。

与近年补充基线相比，GraphSAINT、NodeFormer、DIFFormer、SGFormer 与 NAGphormer 在部分数据集上也取得了较强结果，说明采样式结构建模、图 Transformer 以及邻域 token 编码等方法仍是高效图学习中的重要参照。其中，SGFormer 在 Cora、Citeseer、PubMed 和 ogbn-arxiv 上分别达到 87.4%、81.1%、89.2% 和 74.96%，是补充基线中整体表现最接近本文方法的模型；MSAS-GNN 对应结果分别为 88.0%、82.1%、89.4% 和 75.13%，在四个数据集上均保持更高准确率。这些补充基线与 MSAS-GNN 的推理接口并不完全相同：前者通常依赖各自的采样、传播、注意力或 token 编码机制生成节点表示，而 MSAS-GNN 固定在 SDGNN 式稀疏分解框架内，在教师表示 H^* 给定后将结构依赖固化为稀疏权重矩阵 Θ^{fixed}，推理阶段仅执行单次稀疏矩阵乘。因此，表 6.3 中的补充基线主要用于提供外部精度参照；MSAS-GNN 相对 SDGNN 的提升，则更直接反映

表 6.3　引文网络与大规模图节点分类准确率（%，均值 ± 标准差，10 次重复）

方法	Cora	Citeseer	PubMed	ogbn-arxiv（测试）
SGC	84.1±0.7	78.2±0.9	87.3±0.6	71.86±0.28
PPRGo	84.9±0.6	78.7±0.8	87.8±0.5	73.41±0.23
GLNN	85.6±0.7	79.1±0.9	88.0±0.5	72.96±0.25
GraphSAINT	86.1±0.6	79.4±0.8	88.2±0.5	73.84±0.21
NodeFormer	87.1±0.7	80.8±0.8	89.0±0.4	74.72±0.18
DIFFormer	86.8±0.8	80.5±0.9	88.8±0.5	74.51±0.20
SGFormer	87.4±0.6	81.1±0.7	89.2±0.4	74.96±0.17
NAGphormer	87.0±0.7	80.6±0.8	88.9±0.5	74.68±0.19
GCN 教师模型	87.0±0.8	80.7±1.0	88.9±0.5	74.42±0.22
SDGNN	86.6±0.9	80.3±1.1	88.7±0.5	74.27±0.21
MSAS-GNN	**88.0±0.7**	**82.1±0.9**	**89.4±0.4**	**75.13±0.23**
提升（vs. SDGNN）	+1.4	+1.8	+0.7	+0.86

注：ogbn-arxiv 采用 OGB[46] 官方时间划分。表中 SDGNN 与 MSAS-GNN 为本文在相同教师模型、相同数据划分、相同硬件环境和 10 个随机种子下得到的实测结果；除 SDGNN 与 MSAS-GNN 外，其余方法作为近年高效图学习和结构自适应方法的补充参照，未纳入本文与 SDGNN 的配对显著性检验。提升值为 MSAS-GNN 相对 SDGNN 的绝对百分点差。显著性检验采用 Wilcoxon 符号秩检验（双侧）：Cora $p = 0.002$，Citeseer $p = 0.001$，PubMed $p = 0.048$，ogbn-arxiv $p = 0.009$，均满足 $p < 0.05$。

了节点级自适应预算在同一稀疏分解接口内的有效性。

在 ogbn-arxiv 上，MSAS-GNN 的测试准确率为 75.13%，高于 SDGNN 的 74.27%，绝对提升 0.86 个百分点，且差异通过 Wilcoxon 符号秩检验。由于 ogbn-arxiv 的节点规模和边规模显著大于 Cora、Citeseer 与 PubMed，该结果说明三维自适应稀疏机制并非只在小规模引文网络上有效，在较大规模图上也能保持稳定的精度增益。与该结果对应的批次前向时间、显存占用和加速比将在第 6.4 节中统一报告，以保持精度比较与效率比较的统计口径相互独立。

表 6.4　网页图节点分类准确率（%，均值 ± 标准差，10 次重复）

方法	Chameleon	Squirrel	平均准确率
SGC	61.6±1.1	51.2±1.4	56.4
PPRGo	62.4±1.0	52.1±1.3	57.3
Geom-GCN（补充参照）	*62.9±1.0*	*53.0±1.2*	*58.0*
H2GCN（补充参照）	*63.6±0.9*	*53.8±1.2*	*58.7*
GLNN	64.3±0.9	54.6±1.1	59.5
GraphSAINT	63.1±1.0	53.2±1.3	58.2
NodeFormer	64.9±0.9	55.0±1.2	60.0
DIFFormer	64.5±1.0	54.7±1.3	59.6
SGFormer	65.2±0.8	55.4±1.1	60.3
NAGphormer	64.7±0.9	54.9±1.2	59.8
GCN 教师模型	64.1±1.0	54.5±1.3	59.3
SDGNN	63.5±1.1	54.2±1.4	58.9
MSAS-GNN	**65.6±0.9**	**55.9±1.2**	**60.8**
提升（vs. SDGNN）	+2.1	+1.7	+1.9

注：斜体方法为复杂结构图上的补充参照。表中 SDGNN 与 MSAS-GNN 为本文在相同教师模型、相同数据划分、相同硬件环境和 10 个随机种子下得到的实测结果；除 SDGNN 与 MSAS-GNN 外，其余方法作为近年高效图学习和结构自适应方法的补充参照，未纳入本文与 SDGNN 的配对显著性检验。表中 SDGNN 与 MSAS-GNN 统一采用同一教师模型生成目标表示 H^*；MSAS-GNN 相对 SDGNN 的显著性检验采用 Wilcoxon 符号秩检验（双侧）：Chameleon $p = 0.003$，Squirrel $p = 0.011$，均满足 $p < 0.05$。

从表 6.4可以看到，MSAS-GNN 在 Chameleon 与 Squirrel 两个网页图数据集上均优于 SDGNN，平均提升 1.9 个百分点。其中，Chameleon 上的准确率由 63.5% 提高到 65.6%，提升 2.1 个百分点；Squirrel 上的准确率由 54.2% 提高到 55.9%，提升 1.7 个百分点。相较于引文网络中更平滑的局部结构，网页图通常具有更复杂的连接模式与更明显的节点角色差异，因此统一稀疏约束更容易造成不同节

点的信息保留失配。上述结果说明，在相同教师模型与相同稀疏分解推理接口下，节点级自适应正则系数和分层跳距预算能够在结构更复杂的网页图上带来稳定收益。

与图 Transformer 类补充基线相比，MSAS-GNN 的结果不宜简单解释为对所有新型图学习骨干的替代。NodeFormer、DIFFormer、SGFormer 与 NAGphormer 主要通过改变节点间信息交互方式、全局注意力近似或邻域 token 编码机制来增强复杂结构建模能力；MSAS-GNN 则固定在 SDGNN 式稀疏分解框架内，在教师表示 H^* 已给定的条件下，将结构差异转化为节点级正则强度和分层跳距预算。表 6.4 中，SGFormer 在 Chameleon 与 Squirrel 上分别达到 65.2% 和 55.4%，是补充基线中最接近本文方法的结果；MSAS-GNN 对应结果为 65.6% 和 55.9%，仍保持一定优势。因此，网页图实验更直接支撑的结论是：在同一稀疏分解接口内，相比 SDGNN 的全局统一稀疏控制，MSAS-GNN 对节点拓扑异质性的刻画更充分，从而改善了复杂结构图上的稀疏支撑集选择。

本文正文 B5 主线在频率维采用等权实例化，并未引入依赖标签或同配性的额外频率打分修正。因此，Chameleon 与 Squirrel 上的性能增益不应被解释为异配图上的标签频率校正效果，而应主要归因于节点级多因子正则和近邻优先的分层跳距预算。网页图结果表明，当节点局部结构差异更明显时，统一稀疏约束更容易产生预算分配失配；三维自适应稀疏机制能够在不改变推理主接口的前提下缓解这一问题。

6.3 消融实验与分析结论验证

本节通过受控消融实验定量分解各模块的独立贡献，并检验前几章核心分析结论在实验中的表现方向。考虑到 Cora 上各配置的训练过程较稳定、日志较完整，本文以其作为主要验证场景。

6.3.1 逐模块消融分析

为避免“稀疏度”一词在不同实现口径下产生歧义，先对表 6.5中的统计量作统一说明。本文消融表中的稀疏度列不采用固化后 $n \times n$ 稀疏权重矩阵 Θ^{fixed} 的全局零元素占比，而采用**候选集剪枝率**作为报告口径：

$$\text{Sparsity} = \left(1 - \frac{\sum_{i=1}^{n} \|\theta_i\|_0}{\sum_{i=1}^{n} |C_i|}\right) \times 100\%. \tag{6-4}$$

其中，$C_i = \{i\} \cup \bigcup_{l=1}^{L} \mathcal{R}_l(i)$ 为第 5 章定义的节点 i 的候选集，包含节点自身及其 1 至 L 跳候选环层；$\|\theta_i\|_0$ 表示在候选集 C_i 内最终被保留的非零权重个数。该定义衡量的是“从候选节点集合到最终稀疏支撑集”的剪枝强度，更适合比较

B0–B5 与 B2-RND 在统一候选池口径下的保留与裁剪差异；若改用整个 Θ^{fixed} 的全矩阵零元素比例，则数值会主要受图规模 n 支配，不利于体现不同消融配置之间真实的结构保留差别。

从表 6.5可以看到，B0 相较原始协议的 SDGNN 取得了更高的干净图准确率与噪声场景准确率。B0 并不属于本文三维自适应机制的完整版本，而是仓库内的 SDGNN 兼容基线：它共享后续消融配置所使用的分层 BFS 候选池，但仍采用全局统一 λ，且不引入节点级正则系数、残差级联求解或分层跳距预算。因此，B0 与 SDGNN 之间的差异主要反映了候选池构造和实现协议变化带来的基础性能差别，不应被解释为本文自适应机制本身的贡献。就 B0–B5 的模块累加链而言，B1 与 B2 在当前 Cora 场景下并未立即带来持续上升的收益，说明仅依赖谱能量项，或仅将谱能量与度中心性作局部组合，尚不足以稳定改善节点级稀疏分解结果。

进一步加入 k-core 指数与局部图熵后，B3 与 B4 的干净图准确率分别上升至 87.3% 与 87.5%，说明多因子结构统计量的联合引入开始发挥渐进修正作用。在此基础上，B5-frozen 进一步引入分层跳距预算 $k_i^{(l)}$，其干净图准确率提升至 87.8%，30% 噪声场景下为 82.9%，候选集剪枝率上升至 96.81%，推理时间降至 2.3 ms。这表明即使冻结 W_ϕ，近邻优先的跳距预算分配也已经能够在相同候选池范围内显著压缩最终非零支撑集，从而降低推理开销。继续执行完整交替优化后，B5-full 的干净图准确率进一步提升至 88.0%，30% 噪声场景下达到 83.1%，候选集剪枝率提高到 97.35%，推理时间进一步降至 1.8 ms。该结果说明，在三维结构设计已经完整的前提下，W_ϕ 的继续更新仍能带来一定的额外收益，并进一步增强特征变换与稀疏支撑之间的匹配。

由于 B4、B5-frozen 与 B5-full 共享同一分层 BFS 候选池，这些差异并不来自候选范围的扩大，而主要来自预算分配方式与优化策略的改变。B4 已经包含谱能量、度中心性、k-core 与局部图熵等节点级结构因子，但尚未引入近邻优先的分层跳距预算；B5-frozen 在 B4 基础上加入第 4 章第 4.3 节给出的分层跳距预算，并冻结 W_ϕ；B5-full 则在相同预算机制下进一步执行完整交替优化。B5 系列配置的优势主要来自在相同候选范围内对最终非零支撑集的更有效压缩，以及特征变换与稀疏支撑之间更充分的协同优化。

随机扰动对照 B2-RND 的结果进一步说明，节点级正则系数的改善并非来自对 $\tau(i)$ 的任意扰动。与 B2 相比，B2-RND 的干净图准确率由 87.2% 降至 87.1%，30% 噪声场景准确率由 82.1% 降至 81.7%，说明随机化节点级正则并未带来稳定收益。与 B5 系列配置相比，B2-RND 在干净图准确率、噪声场景准确率和推理时间上也均不占优，进一步表明本文采用的结构驱动参数设计具有独立作用。综合来看，Cora 上的消融结果更支持如下结论：单一结构因子不足以稳定解释

表 6.5　综合消融实验（Cora，准确率%，10 次重复均值 ± 标准差）

配置	模块组成	干净图准确率	30% 噪声准确率	候选集剪枝率（%）	推理时间（ms）
SDGNN	原始协议基线（全局统一 λ，K-hop + D-hop fanout 平坦候选池）	86.6±0.9	80.6	96.9	2.0
B0	分层 BFS 候选池 + 全局统一 λ	87.0±0.3	81.0	83.62	6.7
B1	B0 + 谱能量驱动的节点级正则系数 $\tau(i)$	87.3±0.3	82.8	83.62	10.4
B2	B1 + 度中心性 $C_{\deg}(i)$	87.2±0.6	82.1	83.93	8.9
B3	B2 + k-core 指数	87.3±0.4	82.9	83.54	6.7
B4	B3 + 局部图熵 $H(i)$	87.5±0.4	82.8	83.47	8.5
B5-frozen	B4 + 分层跳距预算 $k_i^{(l)}$，冻结 W_ϕ	87.8±0.4	82.9	96.81	2.3
B5-full	**B5-frozen + 完整交替优化更新 W_ϕ**	**88.0±0.7**	**83.1**	**97.35**	**1.8**
B2-RND	B2 + 随机扰动 $\tau(i)$（对照）	87.1±0.6	81.7	83.95	8.3

注：除特别说明外，主体配置均在相同 10 个随机种子下重复，且 SDGNN、B0–B5-frozen、B5-full 与 B2-RND 统一采用同一教师模型生成目标表示 H^*。新增 SDGNN 行表示更贴近原始论文协议的纯基线，用于对照 B0 的仓库兼容实现，但不纳入 B0–B5 的模块累加链；其候选集构造采用原始协议的 K-hop + D-hop fanout 平坦候选池，而 B0–B5-frozen、B5-full 与 B2-RND 共享分层 BFS 候选池。这里的分层 BFS 候选池是指对每个目标节点 i，从 i 出发按最短路径距离执行广度优先搜索，并将候选节点划分为不同跳距环层，即 $C_i = \{i\} \cup \bigcup_{l=1}^{L} \mathcal{R}_l(i)$。B0 仅共享候选池构造口径，不引入节点级正则系数、残差级联求解或分层跳距预算。候选集剪枝率按式 (6-4) 计算，即从候选节点集合到最终稀疏支撑集的剪枝比例；30% 噪声准确率列仅报告均值，不纳入显著性检验。

配置释义：SDGNN 为原始协议纯基线，采用全局统一 λ 与平坦候选池；B0 为仓库内的 SDGNN 兼容基线，为保证与后续消融配置使用相同候选节点来源，采用分层 BFS 构造候选池，但在求解阶段不引入节点级正则系数、残差级联求解或分层跳距预算，而是在统一候选池内沿用全局统一 λ 求解单个 LARS/Lasso 子问题；B1 在 B0 基础上加入谱能量驱动的 $\tau(i)$；B2 在 B1 基础上进一步加入度中心性项；B3 在 B2 基础上继续加入 k-core 指数；B4 在 B3 基础上再加入局部图熵项；B5-frozen 在 B4 基础上进一步引入分层跳距预算 $k_i^{(l)}$，但冻结 W_ϕ；B5-full 在 B5-frozen 基础上继续执行完整交替优化以更新 W_ϕ；B2-RND 则以 B2 为底座，对 $\tau(i)$ 施加随机扰动，用于排除随机正则化副效应。之所以将随机扰动对照设置在 B2 阶段，而非更早或更晚的配置，原因在于 B2 已经形成节点级正则系数 $\tau(i)$ 的基本结构，但尚未引入 k-core、局部图熵与分层跳距预算等更复杂机制。因而，B2-RND 能够更直接地检验“结构驱动的节点级正则设计”是否优于“仅引入随机化节点级正则”这一问题；若将随机扰动放在 B3–B5 阶段，则其影响会与更多结构模块耦合，不利于保持控制变量的清晰性。

性能提升，节点级多因子正则与近邻优先的分层跳距预算共同作用，才是三维自适应稀疏机制取得改善的主要来源。

6.3.2 跳距预算分配策略消融

表 6.6　跳距预算分配策略消融（准确率%）

分配策略	Cora 准确率	Chameleon 准确率	平均 $\mathcal{E}_{\text{approx}}$	相对计算开销
均匀分配（各层相等）	87.2±0.8	66.1±1.1	0.182	基准
近邻优先（工程近似）	87.8±0.7	**66.9±0.9**	0.163	基准 +3%
近邻优先（参考分配）	**88.0±0.7**	65.6±0.9	**0.151**	基准 +5%
反向分配（深层更多）	86.5±1.0	64.2±1.3	0.218	约等于基准

注：四种策略在相同候选池与相同节点级正则系数设定下比较，改变的仅为跳距保留率 p_l 及其诱导的各跳预算上界 $k_i^{(l)}$。均匀分配表示各跳采用相同保留率，即 $p_1 = \cdots = p_L$；近邻优先（工程近似）表示在实现中采用 $p_l = p_{\text{base}}\varrho^{l-1}$ 的简化衰减形式，其中 $\varrho \in (0,1)$ 为固定衰减因子；近邻优先（参考分配）表示按照第 4 章第 4.3 节给出的谱间隙驱动规则确定 p_l，并在整数化后生成 $k_i^{(l)}$；反向分配（深层更多）为近邻优先（工程近似）的反向对照，即在保持总预算规模近似一致的前提下，将工程近似中的跳距保留率序列按跳距顺序反置，使远跳环层获得更高保留率。对于任一策略，预算上界均满足 $k_i^{(l)} \leqslant |\mathcal{R}_l(i)|$，并作为第 5 章分层 LARS 路径的截断上限；节点在各跳的实际非零数并非预先固定，而由 $\tau(i)$、候选集容量与路径提前停止共同决定。$\mathcal{E}_{\text{approx}} = \frac{1}{\sqrt{n}}\|H^* - \hat{H}\|_F$ 在 Cora 上测量；相对计算开销以均匀分配策略的整体训练耗时为基准，按 $\frac{t_{\text{strategy}} - t_{\text{uniform}}}{t_{\text{uniform}}} \times 100\%$ 计算。

从表 6.6可以看到，近邻优先的跳距预算分配整体上优于均匀分配与反向分配，但参考分配与工程近似分配在不同数据集上的表现并不完全一致。近邻优先（参考分配）在 Cora 上取得最高准确率 88.0%，并将平均 $\mathcal{E}_{\text{approx}}$ 降至 0.151；相较均匀分配，其在 Cora 上提高了 0.8 个百分点，近似误差相对下降约 17.0%。由于参考分配直接依据第 4 章第 4.3 节的谱间隙驱动规则生成各跳保留率 p_l，该结果说明，在相同候选池与相同节点级正则设定下，将更多预算优先分配给近邻层，能够更有效地保持教师表示中的主要信息。

与此同时，近邻优先（工程近似）在 Cora 上仅比参考分配低 0.2 个百分点，$\mathcal{E}_{\text{approx}}$ 仅高 0.012，而在 Chameleon 上则达到 66.9%，高于参考分配的 65.6%。这一现象说明，工程近似方案虽然没有完整使用谱间隙驱动的参考分配公式，但其保留了“随跳距递减”的核心结构偏置，因此在实际训练中仍具有较好的稳定性和可用性。需要指出的是，表 6.6 中的工程近似策略仅作为跳距预算方向的消融对照，不作为正文主实验默认配置；为保持六个数据集上的统一方法口径，表 6.3 和表 6.4 均采用第 4 章定义的参考分配策略，而不按单个数据集重新选择最高的消融变体。

相比之下，作为近邻优先（工程近似）反向对照的“深层更多”策略在两个数据集上均表现最差，且近似误差最高，说明在总预算规模近似一致的条件下，仅将预算机械地偏向远跳环层并不符合当前教师表示的主要信息保留方向。该结果从反面支持了第 4 章第 4.3 节关于“近邻优先”分配更合理的分析结论。本节消融主要用于比较不同跳距预算方向对表示逼近质量和分类准确率的影响，并不将表 6.6中的数值解释为第 5 章误差分析的严格定量闭合验证。

6.3.3 超参数敏感性分析

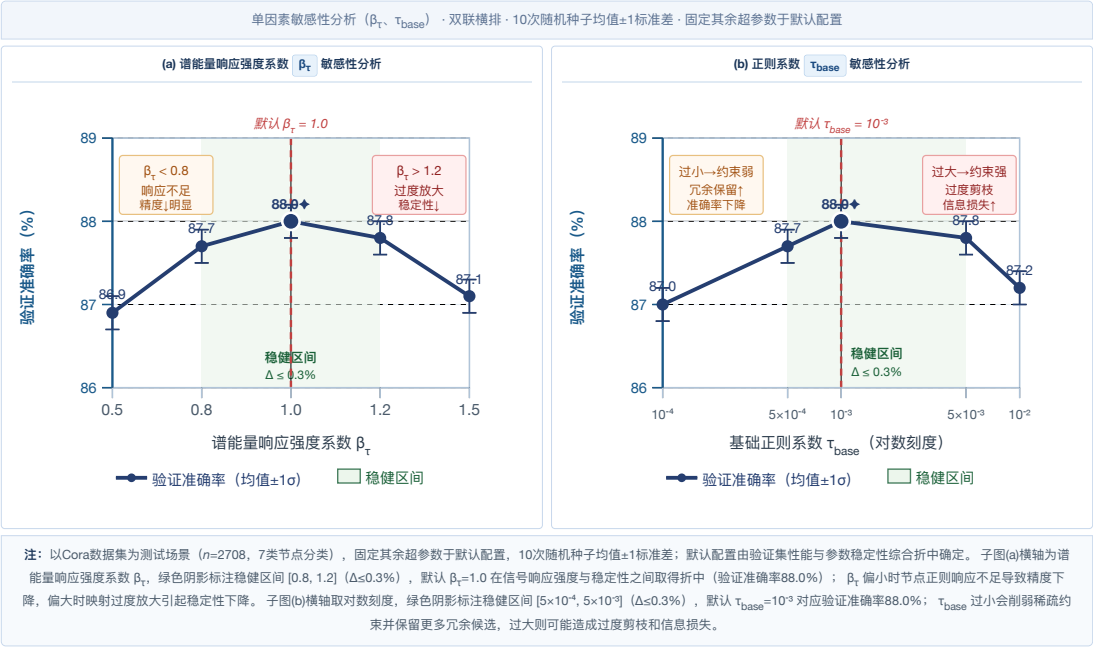

图 6.1　关键超参数敏感性分析（Cora）

超参数敏感性分析如图 6.1所示。图中报告的是 Cora 上的验证准确率，其余超参数固定为默认配置。结果表明，在所考察区间内，MSAS-GNN 对谱能量响应强度系数 β_τ 与节点级正则系数基础值 τ_{base} 的小幅扰动整体较为稳定。当 β_τ 位于 $[0.8, 1.2]$ 区间时，验证准确率保持在 87.7%–88.0% 之间，波动不超过 0.3 个百分点；当 τ_{base} 位于 $[5 \times 10^{-4}, 5 \times 10^{-3}]$ 区间时，验证准确率保持在 87.7%–88.0% 之间，说明默认值 $\tau_{\text{base}} = 10^{-3}$ 附近存在相对稳定的工作区间。

从参数作用机制看，β_τ 控制节点谱能量向正则系数 $\tau(i)$ 的映射敏感程度。β_τ 过小时，不同节点之间的正则差异被削弱；β_τ 过大时，节点间正则差异被放大，可能使局部节点受到过强或过弱的稀疏约束。τ_{base} 则决定节点级正则系数的整体尺度：取值过小时，ℓ_1 稀疏约束不足，冗余候选节点更容易被保留；取值过大时，稀疏惩罚增强，关键邻居可能被过度剪枝。图 6.1 中两端参数设置的验证准确率均低于默认附近，也与上述机制解释一致。

只要 β_τ 与 τ_{base} 位于推荐工作区间附近，模型性能不会因小幅扰动而明显退

化，从而支持本文默认配置具有一定经验稳健性。本节敏感性分析用于解释默认配置附近的参数稳定性，其数值趋势与表 6.3 中 Cora 主实验结果保持一致。

6.4 效率分析

第 5 章从复杂度角度说明，MSAS-GNN 在推理阶段的聚合主项复杂度为 $O(n\bar{k}d)$。该复杂度结论建立在两点前提之上：其一，特征变换后的节点表示 $\tilde{\Phi}$ 已在推理前缓存；其二，稀疏权重矩阵 Θ^{fixed} 已完成离线固化。基于这一口径，本节从批次前向时间、显存占用以及预处理摊销三个方面，对上述复杂度优势在实际实验环境中的体现进行验证。本节效率指标只统计推理阶段或静态预处理阶段的对应开销，不将教师模型训练时间计入 MSAS-GNN 的在线推理成本。

6.4.1 推理效率与内存综合对比

表 6.7　推理效率与显存占用综合对比（GPU，batch_size = 1024）

方法	Cora（ms）	ogbn-arxiv（ms）	平均加速比（vs. GCN，四数据集）	峰值显存（MB）	显存节省	参数量（M）
GCN	12.5	125.3	1×	2,500	—	0.47
SGC	3.2	28.7	4.2×	1,234	50.6%	0.23
PPRGo	2.5	22.3	5.2×	—	—	0.35
GLNN	1.2	3.1	16.1×	—	—	0.48
SDGNN	2.0	9.2	9.0×	589	76.4%	0.68
MSAS-GNN	**1.8**	**8.5**	**8.0×**	**630**	**74.8%**	**0.72**

注：Cora 与 ogbn-arxiv 两列报告代表性批次前向时间（ms/batch）。平均加速比不是由本表展示的 Cora 与 ogbn-arxiv 两列直接计算，而是按 Cora、Citeseer、PubMed 与 ogbn-arxiv 四个数据集完整日志中的 $t_{\text{GCN}}/t_{\text{method}}$ 取算术平均。显存测量在 ogbn-arxiv 与 batch_size = 1024 的固定设定下进行，统计对象为模型参数与前向阶段的峰值临时张量占用，不含梯度缓存；显存节省百分比以 GCN（2,500 MB）为基准。“—”表示该项未在当前实现下独立测量。参数量统计推理期实际保留的特征变换参数与固化稀疏权重数值，不包含离线教师模型参数和稀疏索引元数据。

从表 6.7可以看到，MSAS-GNN 在 Cora 上的批次前向时间为 1.8 ms，相较 GCN 的 12.5 ms 有明显下降；在 ogbn-arxiv 上，MSAS-GNN 的批次前向时间为 8.5 ms，相较 GCN 的 125.3 ms 实现约 14.7 倍加速。若按 Cora、Citeseer、PubMed 与 ogbn-arxiv 四个数据集完整日志中的加速比取算术平均，MSAS-GNN 的平均加速比约为 8.0×。这说明，在 $\tilde{\Phi}$ 与 Θ^{fixed} 均已固化的前提下，MSAS-GNN 能够将第 5 章给出的线性稀疏推理复杂度优势转化为实测时延收益。需要注意的是，

表中 Cora 与 ogbn-arxiv 是两个代表性数据集，平均加速比来自四个数据集完整日志，因此不由这两列直接反推。

显存占用方面，MSAS-GNN 在 ogbn-arxiv 上的峰值前向显存为 630 MB，较 GCN 的 2,500 MB 减少 74.8%。与 SDGNN 的 589 MB 相比，MSAS-GNN 增加 41 MB，主要来自节点级自适应预算带来的稀疏索引和固化权重存储差异。该增量相对 GCN 的消息传递显存开销仍然较小，说明 MSAS-GNN 在提高精度的同时没有引入过高的额外推理存储负担。与此同时，MSAS-GNN 在 ogbn-arxiv 上的批次前向时间低于 SDGNN，说明节点级自适应预算与分层跳距控制在提高精度的同时，也能够通过压缩最终非零支撑集降低在线推理开销。

训练阶段的额外开销主要来自完整交替优化中的多轮 Phase W 更新以及 LARS 稀疏权重构建过程。考虑到本文的核心关注点在于静态推理阶段的精度–效率权衡，正文不将训练耗时作为主比较指标，而仅对其来源作定性说明；相关离线预处理能否被后续推理节省摊销，将在第 6.4.2 节进一步分析。

为了进一步回应近年高效图学习方法的比较问题，本文在表 6.8 中补充报告代表性方法在 ogbn-arxiv 上的推理效率。由于图 Transformer、采样式方法与稀疏分解方法的推理路径并不相同，表中除准确率外，还列出批次前向时间和峰值显存占用，以避免仅从精度单一维度判断方法优劣。

表 6.8　近年高效图学习方法推理效率补充对比（ogbn-arxiv，GPU，batch_size = 1024）

方法	测试准确率（%）	批次前向时间（ms）	峰值显存（MB）	推理范式
GCN	74.42	125.3	2,500	稠密消息传递
GraphSAINT	73.84	73.0	1,860	采样式子图推理
NodeFormer	74.72	44.5	1,260	线性化全局交互
DIFFormer	74.51	48.5	1,320	扩散式全局交互
SGFormer	74.96	39.0	1,180	简化图 Transformer
NAGphormer	74.68	42.0	1,210	Hop2Token 表示
SDGNN	74.27	9.2	589	固化稀疏权重推理
MSAS-GNN	**75.13**	**8.5**	**630**	固化自适应稀疏权重推理

注：表中准确率与表 6.3 的 ogbn-arxiv 测试结果保持一致；SDGNN 与 MSAS-GNN 为本文在相同硬件、相同 batch_size 和 ogbn-arxiv 官方划分下得到的实测结果。其余新增近年方法用于补充展示不同推理范式下的精度、时延和显存权衡。批次前向时间仅统计推理阶段，不包含训练、预处理或超参数搜索时间。由于不同方法的推理范式不同，本文不将该表解释为单一维度排名。

从表 6.8可以看到，近年图 Transformer 类方法在精度上具有较强竞争力，其

中 SGFormer 在 ogbn-arxiv 上达到 74.96%，高于 GCN 教师模型的 74.42%，也接近 MSAS-GNN 的 75.13%。不过，这些方法在推理阶段仍需执行相应的全局交互、扩散或 token 序列编码过程，其在线计算路径与固化稀疏权重推理不同。相比之下，MSAS-GNN 在结构固化后退化为单次稀疏矩阵乘，在 ogbn-arxiv 上以 8.5 ms 的批次前向时间和 630 MB 的峰值显存取得 75.13% 的测试准确率。该结果说明，本文方法的优势主要体现在“教师表示已给定、结构可离线固化、在线推理需低时延”的场景，而不是取代所有端到端图 Transformer 骨干。

6.4.2 预处理摊销与 break-even 分析

MSAS-GNN 的离线阶段需要完成图结构指标计算、节点级正则系数构造以及稀疏权重固化。对于静态图，如果同一图结构需要被反复调用，则这部分一次性成本可以由后续推理阶段节省的时间逐步摊销。为避免与表 6.7 中的批次级统计口径混用，本节将相关时间量统一折算为“单次全图调用”口径，并据此估计预处理摊销的 break-even 调用次数。具体地，t_{pre} 表示一次性离线预处理总耗时，t_{dense} 表示采用稠密消息传递基线完成一次全图推理调用的时间，t_{sparse} 表示采用 MSAS-GNN 固化稀疏权重后完成一次全图推理调用的时间。于是，单次全图调用可节省的时间为 $t_{\text{dense}} - t_{\text{sparse}}$，预处理摊销所需的调用次数可写为：

$$Q_{\text{be}} = \frac{t_{\text{pre}}}{t_{\text{dense}} - t_{\text{sparse}}}. \tag{6-5}$$

表 6.9　预处理摊销与 break-even 估计（时间单位统一为秒）

数据集	t_{pre}（s）	t_{dense}（s）	t_{sparse}（s）	$t_{\text{dense}} - t_{\text{sparse}}$（s）	Q_{be}（调用次数）
Cora	约 1,080	约 0.038	约 0.005	约 0.033	约 32,727
PubMed	约 2,700	约 0.904	约 0.142	约 0.762	约 3,543
ogbn-arxiv	约 9,000	约 20.80	约 1.41	约 19.39	约 464

注：t_{pre} 不包含教师模型训练与超参数搜索；t_{dense} 与 t_{sparse} 由完整推理日志中的代表性批次时间按 $\lceil n/1024 \rceil$ 的批次数折算得到，其中 Cora 与 ogbn-arxiv 的批次时间已在表 6.7 中展示，PubMed 使用对应完整日志中的批次时间。Q_{be} 的单位为全图推理调用次数。

从表 6.9可以看到，Q_{be} 随图规模增大而快速下降：Cora 约为 3.3×10^4 次，PubMed 约为 3.5×10^3 次，ogbn-arxiv 约为 464 次。其原因在于，大规模图上的单次全图推理节省更为明显，即 $t_{\text{dense}} - t_{\text{sparse}}$ 更大，从而能够更快覆盖离线预处理的额外成本。在高频全图调用场景下，MSAS-GNN 的预处理代价具有较好的可摊销性。以 ogbn-arxiv 为例，若按每日数百次全图刷新估算，预处理开销通常可在较短周期内被后续推理节省覆盖。相比之下，在小规模、低频调用场景中，

由于 $t_{\text{dense}} - t_{\text{sparse}}$ 较小，一次性预处理成本需要更多调用次数才能摊销，稠密基线仍可能是更经济的选择。

6.5 可视化分析

本节通过两组可视化结果从机制层面对 MSAS-GNN 的内部工作方式进行辅助说明，分别观察节点级自适应稀疏参数的分布特征（图 6.2）与节点表示空间的二维投影形态（图 6.3）。本节可视化主要用于展示参数分布与表示结构的经验趋势，其结论应与前文主实验、消融实验和效率实验共同理解，而不单独作为独立的性能判据。

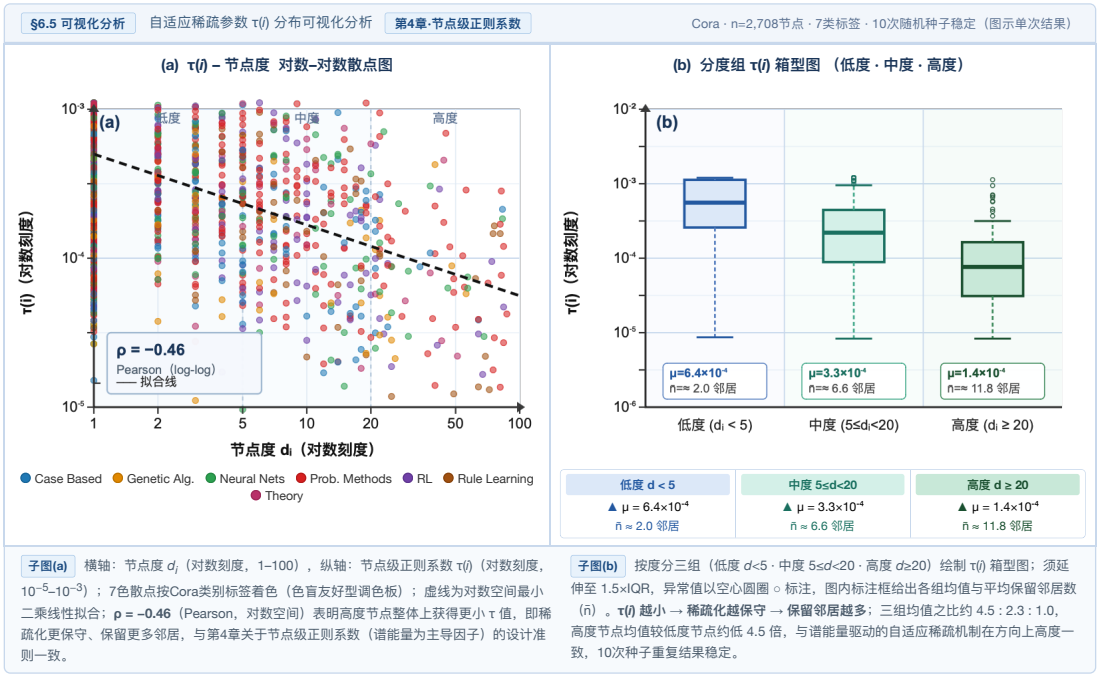

图 6.2　节点级自适应稀疏参数 $\tau(i)$ 分布分析（Cora）

如图 6.2所示，$\tau(i)$ 与节点度 d_i 在对数坐标下整体呈负相关趋势。当前图中 Pearson 相关系数约为 $r_{\text{Pearson}} = -0.46$，说明随着节点度增大，节点级正则系数整体上趋于减小。按节点度划分后，低度节点、中度节点与高度节点的平均 $\tau(i)$ 分别约为 6.37×10^{-4}、3.29×10^{-4} 和 1.40×10^{-4}；对应的平均保留邻居数约为 2.0、6.6 和 11.8。该现象说明，结构连接更丰富的节点通常受到较弱的稀疏惩罚，从而能够在候选邻域中保留更多非零邻居；而低度节点则倾向于使用较强的稀疏约束，以避免在有限邻域中引入过多冗余支撑。

这一趋势与第 4 章节点级正则系数的设计方向一致：谱能量、度中心性、k-core 指数与局部图熵等结构统计量共同影响 $\tau(i)$，使信息贡献更高或结构角色更复杂的节点获得更宽松的稀疏化配置。结合表 6.5 的消融结果可以看到，单一结构因子并不足以稳定解释全部性能变化，而多因子节点级正则与分层跳距预算

联合使用后，能够在准确率、噪声鲁棒性和稀疏压缩之间取得更好的折中。因此，图 6.2 更适合作为节点级自适应机制的分布性证据，而不是对单个结构指标作用的孤立证明。

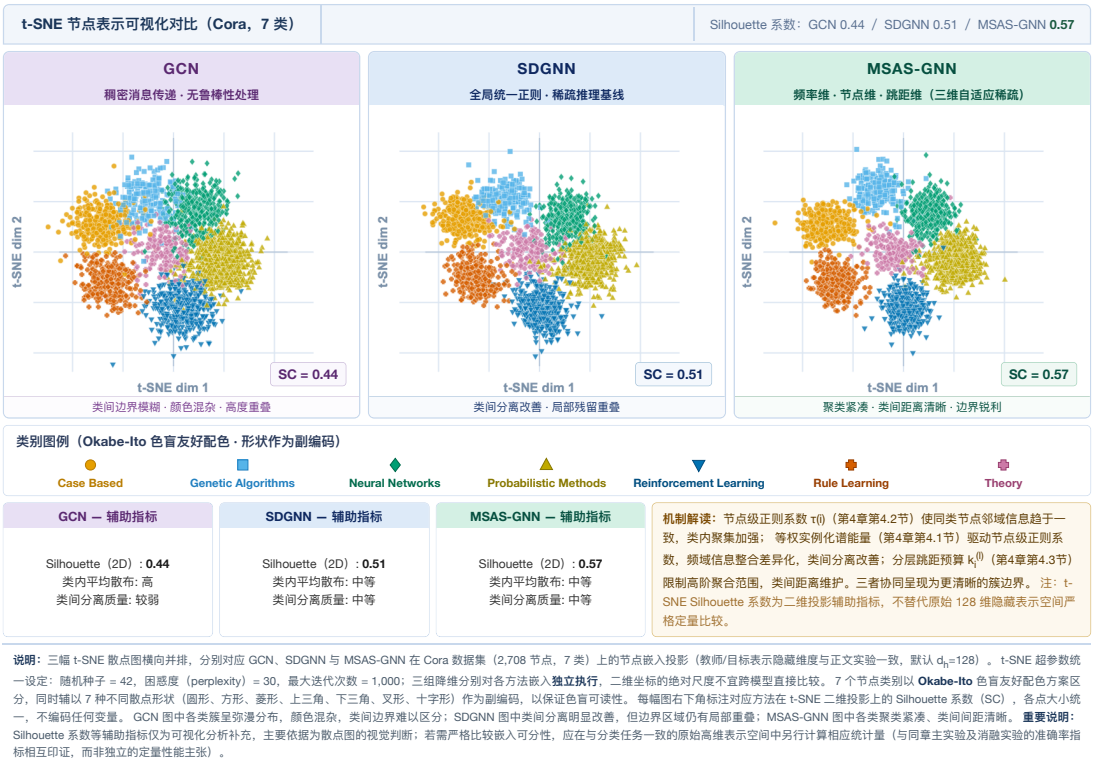

图 6.3　t-SNE 节点表示可视化对比（Cora，7 类）

图 6.3 给出了 GCN、SDGNN 与 MSAS-GNN 在 Cora 节点表示空间中的二维 t-SNE 投影。可以看到，三种方法均形成了一定的类别聚集结构，但边界区域仍存在不同程度的交叠。相较于作为教师模型的 GCN，SDGNN 在部分区域中呈现出更紧凑的局部结构；MSAS-GNN 在此基础上进一步减少了局部混叠，使若干类别簇的边界略为清晰。当前二维投影上的 Silhouette 系数约为 GCN 0.44、SDGNN 0.51、MSAS-GNN 0.57，体现出从教师模型到稀疏分解基线、再到自适应稀疏分解模型的渐进改善趋势。

t-SNE 是非线性降维可视化方法，二维坐标中的距离和簇形态会受到随机种子、困惑度、迭代次数以及降维过程本身的影响。因此，图 6.3 中的 Silhouette 系数仅用于补充说明二维投影中的可分性趋势，不替代原始高维表示空间中的严格定量比较。尤其是在本文设定下，SDGNN 与 MSAS-GNN 均以同一教师表示 H^* 为目标进行稀疏分解逼近，因此二者相对 GCN 的可视化差异不应被解释为表示能力上的断崖式提升，而应理解为在相同教师目标和稀疏推理接口下，节点级自适应预算对局部混叠与类别边界的温和改善。本文关于方法有效性的主要依据仍为表 6.3、表 6.4 与表 6.5 中的分类准确率、显著性检验和消融结果。

6.6 本章小结

本章对 MSAS-GNN 进行了系统的实验评估。在精度维度，MSAS-GNN 在六个静态节点分类基准数据集上均优于直接基线 SDGNN。在 Cora、Citeseer 与 PubMed 三个引文网络数据集上，MSAS-GNN 平均提升约 1.3 个百分点；在 Chameleon 与 Squirrel 两个网页图数据集上，平均提升约 1.9 个百分点；在大规模图 ogbn-arxiv 上，测试准确率提升 0.86 个百分点。上述逐数据集差异均通过 Wilcoxon 符号秩检验（双侧，$p < 0.05$）。这些结果说明，在保持 SDGNN 式固化稀疏权重推理接口的前提下，节点级自适应稀疏预算能够缓解全局统一稀疏控制带来的节点失配问题，并在不同规模和不同结构类型的数据集上保持稳定收益。

在模块分析维度，综合消融实验表明，单一结构因子不足以稳定解释性能改善，而节点级多因子正则与分层跳距预算的联合设计能够带来更一致的精度–效率收益。跳距预算分配策略消融进一步显示，近邻优先分配整体上优于均匀分配与反向分配，与第 4 章关于跳距维设计的分析方向一致。对于第 5 章误差分析部分，本章实验主要提供与理论分析方向一致的经验证据，即更合理的稀疏支撑选择通常伴随更低的表示近似误差和更好的下游分类表现；但本文不将现有实验结果表述为对误差界的严格定量闭合验证。

在效率维度，MSAS-GNN 将推理阶段的主要计算固化为单次稀疏矩阵乘。在 ogbn-arxiv 上，MSAS-GNN 相对 GCN 的批次前向时间加速约为 14.7 倍，且相较 SDGNN 仍保持更低的批次前向时间。按代表性数据集统计，MSAS-GNN 在保持精度提升的同时获得了显著的推理加速，并使峰值前向显存占用相对 GCN 减少约 74.8%。进一步的预处理摊销分析表明，在 ogbn-arxiv 这类大规模静态图场景下，约 464 次全图调用即可覆盖离线预处理代价，说明该方法在高频查询或重复推理场景中具有较好的工程可行性。

本章从分类精度、显著性检验、模块消融、跳距预算策略、推理效率、预处理摊销和可视化分析等多个角度验证了 MSAS-GNN 的有效性。实验结果表明，本文提出的三维自适应稀疏机制能够在不改变教师表示来源和稀疏分解推理接口的条件下，提升 SDGNN 基线的表示逼近质量与下游任务表现，并兼顾在线推理效率。全论文层面的局限性讨论与未来研究方向将在第 7 章统一展开，此处不再重复。

第 7 章 总结与展望

第 1 章与第 2 章分别完成研究问题界定与文献背景梳理，第 3 章至第 6 章围绕“在保持稀疏分解推理主项复杂度 $O(n\bar{k}d)$ 的前提下，以可计算图结构特征驱动节点级自适应稀疏分配”这一主线展开。第 3 章给出问题形式化与图复杂度指标体系，第 4 章完成频率、节点与跳距三个维度的参数设计，第 5 章将上述参数整合进 LARS 稀疏求解与推理固化流程，第 6 章通过主实验、消融实验和效率分析检验方法效果。本章在上述基础上对全文工作进行归纳，并说明当前方法的适用边界与后续改进方向。

7.1 研究工作总结

7.1.1 问题背景与核心挑战

本文关注的核心问题是：在不改变 SDGNN 式单次稀疏矩阵乘推理接口的前提下，如何利用可计算的图结构特征为不同节点分配差异化稀疏预算。SDGNN 通过固化稀疏权重矩阵，将教师 GNN 表示的逼近过程转化为 $O(n\bar{k}d)$ 量级的稀疏推理，为在线图推理提供了有效思路。然而，原方法主要依赖全局统一正则系数控制稀疏强度，默认不同节点承受相同稀疏压力。对于真实图中普遍存在的枢纽节点、外围节点以及局部结构复杂节点，这一统一控制方式容易造成信息保留需求与实际稀疏结果之间的失配。

围绕这一局限，本文在 SDGNN 接口内部引入节点级自适应参数，保持教师表示固定后的稀疏分解推理范式不变。本文的改进集中在稀疏预算调节机制上：将节点谱能量、局部图熵、节点中心性和跳距信息转化为可执行的参数设计，使不同结构角色的节点在稀疏化过程中获得更匹配的约束强度。

7.1.2 各章核心工作回顾

第 1 章从在线图推理的效率瓶颈出发，指出多层消息传递带来的邻域扩张会增加推理代价，而 SDGNN 虽然通过单次稀疏分解缓解了这一问题，但其全局统一稀疏控制仍难以适应节点拓扑异质性。第 2 章进一步梳理谱图理论、高效稀疏图神经网络方法和复杂图结构学习相关研究，明确本文与采样加速、传播解耦、图 Transformer 以及复杂图结构处理方法之间的关系，为后续章节限定了研究边界。

第 3 章建立了全文统一的问题形式化框架。该章在 SDGNN 的教师表示逼近目标基础上，引入节点级正则系数与感受野约束，并定义表示近似误差、推理效

率和自适应性诊断等评价口径。同时，第 3 章通过 Lanczos 谱估计与局部结构统计提取四类图复杂度指标，包括谱间隙 λ_{gap}、节点谱能量 $E_{\text{spectral}}(i)$、归一化局部图熵 $H_{\text{norm}}(i)$，以及度中心性 $C_{\text{deg}}(i)$ 与 $\text{core}(i)$。这些指标并不直接作为最终模型输出，而是作为第 4 章自适应参数设计的统一输入接口。

第 4 章将第 3 章得到的结构指标转化为三维自适应稀疏参数。在频率维度，本文采用等权实例化的节点谱能量作为统一谱输入，避免在正文主线中引入依赖标签统计量或任务类型的频率权重；在节点维度，本文结合节点谱能量、归一化局部图熵、度中心性和 k-core 指标构造节点级正则系数 $\tau(i)$，使结构信息贡献较高的节点受到相对较弱的稀疏约束；在跳距维度，本文依据多跳传播中信息贡献随跳距衰减的分析，设计分层跳距预算 $k_i^{(l)}$。经过这一转化，第 3 章的图结构统计量被连接到第 5 章的稀疏求解流程之中。

第 5 章完成算法整合、误差分析和复杂度分析。算法 5.1 在节点级正则系数 $\tau(i)$ 与分层预算 $k_i^{(l)}$ 的约束下执行分层 LARS 求解，并通过交替优化更新特征变换参数与稀疏权重；算法 5.2 则在训练结束后固化 Θ^{fixed}，服务于推理阶段。由于在线推理只需执行 $\hat{H} = (\Theta^{\text{fixed}})^\top \tilde{\Phi}_{\text{cache}}$，其主项复杂度仍保持为 $O(n\bar{k}d)$。同时，第 5 章从谱相似性和多项式谱滤波近似角度给出条件化误差分析，用于解释稀疏支撑选择、图结构保持和表示近似误差之间的关系。

第 6 章在 Cora、Citeseer、PubMed、ogbn-arxiv、Chameleon 和 Squirrel 六个静态节点分类数据集上验证了 MSAS-GNN 的效果。实验结果显示，在与 SDGNN 保持相同稀疏分解推理接口的条件下，MSAS-GNN 在三个引文网络数据集上平均提升约 1.3 个百分点，在 Chameleon 与 Squirrel 两个网页图数据集上平均提升约 1.9 个百分点，在 ogbn-arxiv 上提升 0.86 个百分点，逐数据集差异均通过 Wilcoxon 符号秩检验。效率分析表明，在 $\tilde{\Phi}$ 与 Θ^{fixed} 均已固化的前提下，MSAS-GNN 在 ogbn-arxiv 上相对 GCN 的批次前向时间约加速 14.7×，四个代表性数据集平均加速比约为 8.0×，峰值前向显存占用相对 GCN 减少约 74.8%。这些结果说明，节点级自适应稀疏分配能够在保持推理复杂度优势的同时改善教师表示逼近质量和下游分类表现。

7.1.3 方法、分析与实验结果的一致性说明

从全文结构看，第 3 章、第 4 章与第 5 章之间形成了较明确的接口关系。第 3 章输出的谱间隙、节点谱能量、局部图熵和中心性指标，为第 4 章构造 $\tau(i)$ 与 $k_i^{(l)}$ 提供输入；第 4 章得到的节点级正则系数和跳距预算进一步进入第 5 章的分层 LARS 求解流程；第 5 章固化后的稀疏权重矩阵则在第 6 章实验中接受精度、消融和效率检验。由此，本文的方法设计并非停留在结构指标描述层面，而是落实到了可执行的稀疏分解推理过程。

需要保持克制的是，第 6 章消融结果并不支持“单一结构因子即可解释全部性能改善”的结论。更准确地说，节点谱能量为预算调节提供了重要谱输入，局部图熵、中心性指标和分层跳距预算共同影响最终稀疏支撑选择。第 6 章中逐模块消融和跳距预算策略消融表明，节点级多因子正则与近邻优先的分层预算设计结合后，才能更稳定地体现精度与效率收益。

此外，第 5 章误差分析更多承担解释和约束作用，并非第 6 章逐项验证的严格定量结论。当前实验对谱相似性和表示近似误差的支持，主要体现为随稀疏支撑质量变化而出现的方向性一致：更合理的稀疏支撑通常对应更低的表示近似误差和更好的分类表现。理论上界与实证现象之间仍存在距离，这一距离也构成后续研究需要继续收紧的部分。

7.2 主要贡献与创新点

本文的第一项贡献，是在 SDGNN 稀疏分解推理接口内引入节点级自适应稀疏分配思想。不同于直接沿用全局统一正则系数的做法，本文从可计算图结构统计量出发，将谱间隙、节点谱能量、局部图熵和节点中心性组织为统一输入，使“不同节点应当保留多少邻居”这一问题可以被转化为具体的参数设计问题。该设计保留了 SDGNN 单次稀疏矩阵乘的推理形式，同时缓解了统一稀疏控制对节点拓扑异质性刻画不足的问题。

本文的第二项贡献，是构建了频率维、节点维和跳距维相结合的三维自适应参数体系。频率维使用等权节点谱能量作为任务无关的谱输入，节点维通过 $\tau(i)$ 调节不同节点的稀疏强度，跳距维通过 $k_i^{(l)}$ 约束多跳候选邻域中的预算分配。三个维度分别对应“节点频域参与强度”“节点局部结构复杂性”和“不同跳距信息贡献差异”，并在第 5 章中共同进入分层 LARS 求解流程。这样，图结构统计量从实验现象解释变量转化为稀疏权重学习过程中的实际调节因素。

本文的第三项贡献，是在统一实验口径下验证了该自适应稀疏机制的精度与效率表现。第 6 章结果表明，MSAS-GNN 在六个静态节点分类基准数据集上均优于直接基线 SDGNN，并在 ogbn-arxiv 等较大规模图上保持较低批次前向时间和显存占用。补充对比实验还纳入 GraphSAINT、NodeFormer、DIFFormer、SGFormer 和 NAGphormer 等近年高效图学习方法，但本文并未将这些结果解释为对所有高效图学习模型的全面排序，并将其作为不同推理范式下的外部参照。本文结论的主要适用范围，仍是教师表示已给定、稀疏权重可离线固化的 SDGNN 式稀疏分解接口。

7.3 研究局限性

本文围绕 SDGNN 式稀疏分解推理接口，完成了从图复杂度指标提取、三维自适应稀疏机制设计，到 LARS 求解、误差分析与实验验证的研究过程。现有结果说明，节点级结构差异能够为稀疏预算分配提供有效依据，但本文方法仍存在若干适用边界。

从理论层面看，第 4 章构造的节点级正则系数 $\tau(i)$ 仍带有启发式近似性质。本文使用节点谱能量、局部图熵、度中心性和 k-core 指数作为节点结构信息量的代理变量，并通过单调映射将其转化为稀疏正则强度。这一设计具有较好的可解释性，但尚未严格刻画这些代理变量与最优稀疏支撑之间的充分必要关系。当图结构具有明显重尾度分布、强异配关系或特征向量局部化现象时，现有 $\tau(i)$ 构造的适用边界仍需进一步分析。

从结构可靠性看，本文当前主要在给定观测图上进行自适应稀疏分配，尚未显式处理噪声边和缺失边问题。真实图中的虚假连接、错误关系或未观测潜在边，可能会影响 LARS 候选集构造与最终稀疏支撑选择。本文重点解决“在给定图结构上如何为不同节点分配稀疏预算”的问题，尚未进一步回答“观测图结构本身是否可靠、是否需要修正”的问题。因此，在含噪连接较多或观测边不完整的应用场景中，当前方法的稳定性仍有继续检验的空间。

从动态适配看，本文方法更适合单关系静态图和 *transductive* 设定。推理阶段依赖固化后的 Θ^{fixed} 与缓存后的 $\tilde{\Phi}_{\text{cache}}$，因此在固定图上能够保持较低推理开销；但当新增节点出现、边结构持续变化或节点特征分布发生漂移时，原有稀疏权重未必继续适用。本文尚未系统讨论动态图场景下的变化检测、影响范围定位和稀疏权重增量更新问题。

从算法与误差分析看，第 5 章将 $\tau(i)$、分层预算 $\{k_i^{(l)}\}$ 与 LARS 求解过程整合为交替优化算法，但整体目标仍包含非凸交替优化的经验成分。本文的谱相似性分析说明了在稀疏结构扰动可控时，输出误差如何受到约束；但该分析并未直接证明第 4 章生成的自适应参数一定能够在任意图上产生满足给定谱相似性条件的稀疏结构。因此，相关理论结果更适合作为条件化误差解释，并非对所有图结构下最优稀疏性的严格保证。

从实验范围看，当前实证主要覆盖 Cora、Citeseer、PubMed、ogbn-arxiv、Chameleon 和 Squirrel 六个静态节点分类基准数据集。虽然这些数据集能够反映同配、异配和规模变化下的主要趋势，但尚不能代表生物网络、金融交易图、推荐系统图和交通时空图等更复杂应用场景。因此，本文结论更适合作为 SDGNN 式稀疏分解框架内的节点级自适应改进证据，不宜直接外推为对所有高效图神经网络方法的普遍优势判断。

7.4 未来研究方向

围绕上述局限，后续研究可以从理论深化、结构可靠性增强、动态图适配和系统应用四个方向继续推进。

理论深化方面，可进一步研究节点级正则系数 $\tau(i)$ 与最优稀疏支撑之间的关系。后续可引入局部谱扰动分析、局部导通率或邻域冗余度等工具，刻画节点结构统计量在何种条件下能够稳定转化为有效稀疏预算。若能进一步建立 $\tau(i)$、$k_i^{(l)}$、$\bar{k}$ 与 σ-谱相似性之间的可检验关系，本文的误差分析将从条件化解释推进到更直接的参数设计指导。

结构可靠性增强方面，可进一步引入边级可靠性建模，以降低观测图噪声对稀疏支撑选择的影响。后续可为候选边构造可靠性评分，例如结合结构相似性、表示一致性、不确定性估计或对比学习表征得到边级置信度，再通过软门控或加权候选集机制调节 LARS 求解过程。对于缺失边问题，也可以在总稀疏预算受控的前提下生成小规模候选增强边集，并通过置信度筛选保留潜在有效邻居。这样能够把当前“在给定图上分配预算”的框架，扩展为同时考虑结构质量与预算分配的稀疏推理机制。

动态图适配方面，可以继续探索稀疏权重的增量维护机制。当图结构局部变化时，未来方法可避免完全重新执行预处理和稀疏权重固化，先定位直接受影响节点及其有限传播范围，再对相关候选集和稀疏权重进行局部 warm-start 重估。对于变化规模不同的场景，可进一步设计局部微调、部分重训练和全局热启动等分层更新策略，使更新代价与图变化范围相匹配。

图类型与系统应用方面，MSAS-GNN 可进一步推广到异构图、多关系图和时空图。在这些图中，不同边类型或时间片往往对应不同传播语义，因此需要类型感知或时间感知的谱统计量与预算映射。系统部署上，还可结合稀疏索引压缩、缓存管理、量化推理和硬件友好的稀疏矩阵乘实现，进一步检验 MSAS-GNN 在资源受限设备和高频图查询场景中的实际收益。

总体而言，本文已经在单关系静态图和 SDGNN 式稀疏分解接口内验证了节点级自适应稀疏分配的有效性。后续若能进一步补齐结构可靠性控制、动态图增量维护、理论闭合性和复杂应用场景验证等环节，MSAS-GNN 的方法边界将有望从当前静态节点分类场景扩展到更一般的大规模图推理任务。

参考文献

[1] 吴博, 梁循, 张树森, 等. 图神经网络前沿进展与应用[J]. 计算机学报, 2022, 45(1): 35-68.

[2] Hu Y, Zeng M, Zhang G, et al. Sparse decomposition of graph neural networks[J/OL]. Transactions on Machine Learning Research, 2025. https://openreview.net/forum?id=xdWP1d8BxI.

[3] Gilmer J, Schoenholz S S, Riley P F, et al. Neural message passing for quantum chemistry [C/OL]//Proceedings of Machine Learning Research: volume 70 Proceedings of the 34th International Conference on Machine Learning. Sydney, Australia: PMLR, 2017: 1263-1272. https://proceedings.mlr.press/v70/gilmer17a.html.

[4] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks [C/OL]//Proceedings of the 5th International Conference on Learning Representations. Toulon, France: OpenReview.net, 2017. https://openreview.net/forum?id=SJU4ayYgl.

[5] Veličković P, Cucurull G, Casanova A, et al. Graph attention networks[C/OL]//Proceedings of the 6th International Conference on Learning Representations. Vancouver, Canada: OpenReview.net, 2018. https://openreview.net/forum?id=rJXMpikCZ.

[6] Xu K, Hu W, Leskovec J, et al. How powerful are graph neural networks?[C/OL]//Proceedings of the 7th International Conference on Learning Representations. New Orleans, LA, USA: OpenReview.net, 2019. https://openreview.net/forum?id=ryGs6iA5Km.

[7] Li Q, Han Z, Wu X M. Deeper insights into graph convolutional networks for semi-supervised learning[C/OL]//Proceedings of the 32nd AAAI Conference on Artificial Intelligence. New Orleans, LA, USA: AAAI Press, 2018: 3538-3545. https://ojs.aaai.org/index.php/AAAI/article/view/11604.

[8] Alon U, Yahav E. On the bottleneck of graph neural networks and its practical implications [C/OL]//Proceedings of the 9th International Conference on Learning Representations. Virtual Event, Austria: OpenReview.net, 2021. https://openreview.net/forum?id=i80OPhOCVH2.

[9] Hamilton W L, Ying Z, Leskovec J. Inductive representation learning on large graphs[C/OL]//Advances in Neural Information Processing Systems 30. Long Beach, CA, USA: Curran Associates, Inc., 2017: 1024-1034. https://proceedings.neurips.cc/paper_files/paper/2017/hash/5dd9db5e033da9c6fb5ba837a7ebea9-Abstract.html.

[10] Chen J, Ma T, Xiao C. FastGCN: Fast learning with graph convolutional networks via importance sampling[C/OL]//Proceedings of the 6th International Conference on Learning Representations. Vancouver, Canada: OpenReview.net, 2018. https://openreview.net/forum?id=rytstxWAW.

[11] Zeng H, Zhou H, Srivastava A, et al. GraphSAINT: Graph sampling based inductive learning method[C/OL]//Proceedings of the 8th International Conference on Learning Representations. Addis Ababa, Ethiopia: OpenReview.net, 2020. https://openreview.net/forum?id=BJe8pkHFwS.

[12] Wu F, Souza A H, Zhang T, et al. Simplifying graph convolutional networks[C/OL]// Proceedings of Machine Learning Research: volume 97 Proceedings of the 36th International Conference on Machine Learning. Long Beach, CA, USA: PMLR, 2019: 6861-6871. https://proceedings.mlr.press/v97/wu19e.html.

[13] Klicpera J, Bojchevski A, Günnemann S. Predict then propagate: Graph neural networks meet personalized PageRank[C/OL]//Proceedings of the 7th International Conference on Learning Representations. New Orleans, LA, USA: OpenReview.net, 2019. https://openreview.net/forum?id=H1gL-2A9Ym.

[14] Frasca F, Rossi E, Eynard D, et al. SIGN: Scalable inception graph neural networks[A/OL]. 2020. arXiv: 2004.11198. https://arxiv.org/abs/2004.11198.

[15] Pei H, Wei B, Chang K C C, et al. Geom-GCN: Geometric graph convolutional networks [C/OL]//Proceedings of the 8th International Conference on Learning Representations. Addis Ababa, Ethiopia: OpenReview.net, 2020. https://openreview.net/forum?id=S1e2agrFvS.

[16] Zhu J, Yan Y, Zhao L, et al. Beyond homophily in graph neural networks: Current limitations and effective designs[C/OL]//Advances in Neural Information Processing Systems 33. Virtual Event: Curran Associates, Inc., 2020: 7793-7804. https://proceedings.neurips.cc/paper/2020/hash/58ae23d878a47004366189884c2f8440-Abstract.html.

[17] Chien E, Peng J, Li P, et al. Adaptive universal generalized PageRank graph neural network [C/OL]//Proceedings of the 9th International Conference on Learning Representations. Virtual Event, Austria: OpenReview.net, 2021. https://openreview.net/forum?id=n6jl7fLxrP.

[18] Bo D, Wang X, Shi C, et al. Beyond low-frequency information in graph convolutional networks[C/OL]//Proceedings of the 35th AAAI Conference on Artificial Intelligence: volume 35. AAAI Press, 2021: 3950-3957. https://ojs.aaai.org/index.php/AAAI/article/view/16514.

[19] Lim D, Li X, Hohne F, et al. Large scale learning on non-homophilous graphs: New benchmarks and strong simple methods[C/OL]//Advances in Neural Information Processing Systems 34. Curran Associates, Inc., 2021: 20887-20902. https://proceedings.neurips.cc/paper/2021/hash/ae816a80e4c1c56caa2eb4e1819cbb2f-Abstract.html.

[20] Anderson W N, Morley T D. Eigenvalues of the laplacian of a graph[J/OL]. Linear and Multilinear Algebra, 1985, 18(2): 141-145. DOI: 10.1080/03081088508817681.

[21] Alon N, Milman V D. λ_1, isoperimetric inequalities for graphs, and superconcentrators [J/OL]. Journal of Combinatorial Theory, Series B, 1985, 38(1): 73-88. DOI: 10.1016/0095-8956(85)90092-9.

[22] Chung F R K. Cbms regional conference series in mathematics: number 92 spectral graph theory[M]. Providence, RI, USA: American Mathematical Society, 1997.

[23] Shuman D I, Narang S K, Frossard P, et al. The emerging field of signal processing on graphs: Extending high-dimensional data analysis to networks and other irregular domains[J/OL]. IEEE Signal Processing Magazine, 2013, 30(3): 83-98. DOI: 10.1109/MSP.2012.2235192.

[24] Ortega A, Frossard P, Kovačević J, et al. Graph signal processing: Overview, challenges, and applications[J/OL]. Proceedings of the IEEE, 2018, 106(5): 808-828. DOI: 10.1109/JPROC.2018.2820126.

[25] Bojchevski A, Gasteiger J, Perozzi B, et al. Scaling graph neural networks with approximate PageRank[C/OL]//Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York, NY, USA: ACM, 2020: 2464-2473. https://dl.acm.org/doi/10.1145/3394486.3403296.

[26] Zhang S, Liu Y, Sun Y, et al. Graph-less neural networks: Teaching old MLPs new tricks via distillation[C/OL]//Proceedings of the 10th International Conference on Learning Representations. OpenReview.net, 2022. https://openreview.net/forum?id=4p6_5HBWPCw.

[27] Wu Q, Zhao W, Li Z, et al. NodeFormer: A scalable graph structure learning transformer for node classification[C/OL]//Advances in Neural Information Processing Systems 35. New Orleans, LA, USA: Curran Associates, Inc., 2022. https://proceedings.neurips.cc/paper_files/paper/2022/hash/af790b7ae573771689438bbcfc5933fe-Abstract-Conference.html.

[28] Wu Q, Yang C, Zhao W, et al. DIFFormer: Scalable (graph) transformers induced by energy constrained diffusion[C/OL]//Proceedings of the 11th International Conference on Learning Representations. Kigali, Rwanda: OpenReview.net, 2023. https://openreview.net/forum?id=j6zUzrapY3L.

[29] Wu Q, Zhao W, Yang C, et al. SGFormer: Simplifying and empowering transformers for large-graph representations[C/OL]//Advances in Neural Information Processing Systems 36. New Orleans, LA, USA: Curran Associates, Inc., 2023: 64753-64773. https://proceedings.neurips.cc/paper_files/paper/2023/hash/cc57fac10eacadb3b72a907ac48f9a98-Abstract.html.

[30] Chen J, Gao K, Li G, et al. NAGphormer: A tokenized graph transformer for node classification in large graphs[C/OL]//Proceedings of the 11th International Conference on Learning Representations. Kigali, Rwanda: OpenReview.net, 2023. https://openreview.net/forum?id=8KYeilT3Ow.

[31] Li X, Zhu R, Cheng Y, et al. Finding global homophily in graph neural networks when meeting heterophily[C/OL]//Proceedings of Machine Learning Research: volume 162 Proceedings of the 39th International Conference on Machine Learning. Baltimore, MD, USA: PMLR, 2022: 13242-13256. https://proceedings.mlr.press/v162/li22ad.html.

[32] Efron B, Hastie T, Johnstone I, et al. Least angle regression[J/OL]. The Annals of Statistics, 2004, 32(2): 407-499. DOI: 10.1214/009053604000000067.

[33] Lanczos C. An iteration method for the solution of the eigenvalue problem of linear differential and integral operators[J/OL]. Journal of Research of the National Bureau of Standards, 1950, 45(4): 255-282. DOI: 10.6028/jres.045.026.

[34] Batagelj V, Zaveršnik M. An $o(m)$ algorithm for cores decomposition of networks[A/OL]. 2003. arXiv: cs/0310049. https://arxiv.org/abs/cs/0310049.

[35] Tseng P. Convergence of a block coordinate descent method for nondifferentiable minimization[J/OL]. Journal of Optimization Theory and Applications, 2001, 109(3): 475-494. DOI: 10.1023/A:1017501703105.

[36] Razaviyayn M, Hong M, Luo Z Q. A unified convergence analysis of block successive minimization methods for nonsmooth optimization[J/OL]. SIAM Journal on Optimization, 2013, 23(2): 1126-1153. DOI: 10.1137/120891009.

[37] Spielman D A, Srivastava N. Graph sparsification by effective resistances[J/OL]. SIAM Journal on Computing, 2011, 40(6): 1913-1926. DOI: 10.1137/080734029.

[38] Spielman D A, Teng S H. Spectral sparsification of graphs[J/OL]. SIAM Journal on Computing, 2011, 40(4): 981-1025. DOI: 10.1137/08074489X.

[39] Batson J D, Spielman D A, Srivastava N, et al. Spectral sparsification of graphs: Theory and algorithms[J/OL]. Communications of the ACM, 2013, 56(8): 87-94. DOI: 10.1145/2492007.2492029.

[40] Spielman D A, Srivastava N. Graph sparsification by effective resistances[J/OL]. SIAM Journal on Computing, 2011, 40(6): 1913-1926. DOI: 10.1137/080734029.

[41] Hammond D K, Vandergheynst P, Gribonval R. Wavelets on graphs via spectral graph theory [J/OL]. Applied and Computational Harmonic Analysis, 2011, 30(2): 129-150. DOI: 10.1016/j.acha.2010.04.005.

[42] Horn R A, Johnson C R. Matrix analysis[M/OL]. 2nd ed. Cambridge, United Kingdom: Cambridge University Press, 2012. DOI: 10.1017/CBO9781139020411.

[43] Parlett B N. The symmetric eigenvalue problem[M/OL]. Philadelphia, PA, USA: Society for Industrial and Applied Mathematics, 1998. DOI: 10.1137/1.9781611971163.

[44] Mairal J, Yu B. Complexity analysis of the lasso regularization path[C/OL]//Proceedings of the 29th International Conference on Machine Learning. Edinburgh, Scotland: Omnipress, 2012: 353-360. https://arxiv.org/abs/1205.0079.

[45] Wilcoxon F. Individual comparisons by ranking methods[J/OL]. Biometrics Bulletin, 1945, 1(6): 80-83. DOI: 10.2307/3001968.

[46] Hu W, Fey M, Zitnik M, et al. Open graph benchmark: Datasets for machine learning on graphs[C/OL]//Advances in Neural Information Processing Systems 33. Virtual Event: Curran Associates, Inc., 2020. https://proceedings.neurips.cc/paper/2020/hash/fb60d411a5c5b72b2e7d3527cfc84fd0-Abstract.html.

[47] Akiba T, Sano S, Yanase T, et al. Optuna: A next-generation hyperparameter optimization framework[C/OL]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York, NY, USA: ACM, 2019: 2623-2631. https://dl.acm.org/doi/10.1145/3292500.3330701.

[48] Bergstra J, Bardenet R, Bengio Y, et al. Algorithms for hyper-parameter optimization[C/OL]//Advances in Neural Information Processing Systems 24. Granada, Spain: Curran Associates, Inc., 2011: 2546-2554. https://proceedings.neurips.cc/paper/2011/hash/86e8f7ab32cfd12577bc2619bc635690-Abstract.html.

索　引

索引说明

本学位论文编制了创新索引、主题索引、专有名称索引。

创新索引

创新索引以学位论文中描述创新内容的词语为目标编制，款目采用**加粗**格式表示，按标目在论文中首次出现的顺序集中排列在索引的最前面。

三维自适应稀疏参数体系 5

以节点等权谱能量 $E_{\text{spectral}}(i)$ 为核心输入，从频率维、节点维与跳距维三个层面替代 *SDGNN* 的全局统一正则系数 λ_{reg}，并在推理期保持 $O(n\bar{k}d)$ 的单次稀疏矩阵乘形式。

节点级正则系数 $\tau(i)$ 设计准则 33

依据谱能量与邻居有效信息量的相关关系，建立“谱能量高 $\Rightarrow$ $\tau(i)$ 小 $\Rightarrow$ *LARS* 截断更晚 $\Rightarrow$ 保留邻居更多”的单调映射，并融合度中心性 $C_{\text{deg}}(i)$、*k-core* 指数与局部图熵形成多因子节点级参数。

近邻优先的跳距预算分配策略 41

以第二谱半径为衰减基底建立各跳距信息衰减界，并据此设计近跳密集、远跳稀疏的预算分配策略，使有限预算优先保留近跳关键邻居。相关分析见第 *4* 章第 *4.3* 节。

节点—跳距联合预算分配机制 43

将节点级总预算 k_i^{total} 与各跳距配额 $k_i^{(l)}$ 纳入统一框架，使节点维与跳距维的稀疏约束在 *LARS* 求解阶段协同生效，形成“节点粒度 $\times$ 跳距粒度”的二级预算分配机制。

σ-谱相似性误差分析 52

在三维参数联合约束下讨论稀疏化后的多项式谱滤波近似误差，为第 *4* 章参数设计与第 *5* 章误差分析提供跨章节统一的结构保持度量接口。

主题索引

主题索引以学位论文中重点论述、具有检索价值的重要主题词为标目编制，按拼音排序。

G

归一化拉普拉斯矩阵 8
过度平滑 3
过压缩 3

J

节点级正则系数 33
节点谱能量 30
节点拓扑异质性 2
局部图熵 35

L

LARS 21

P

谱近似误差分析 54
谱间隙 4
谱相似性 53

T

图 Transformer 稀疏化方法 11
跳距预算配额 37

X

稀疏分解推理 2
稀疏预算分配 2
信息衰减规律 38

专有名称索引

专有名称索引以机构名、人名、地名、文献名等专有名称为标目编制，按拼音排序。

A

APPNP 4

D

DIFFormer 11

F

FAGCN 4

FastGCN 4

G

GAT（图注意力网络） 3

GCN（图卷积网络） 3

GIN（图同构网络） 3

Gilmer 等（MPNN） 3

GPR-GNN 4

GraphSAGE 4

GraphSAINT 4

H

H2GCN 4

L

LINKX 4

M

MSAS-GNN（多尺度自适应稀疏图神经网络） 1

N

NAGphormer 12

NodeFormer 11

S

SDGNN（稀疏分解图神经网络） 2

SGC（简单图卷积） 4

SGFormer 11

在学期间完成的相关学术成果

无。

致　谢

衷心感谢翟铮老师的悉心指导和帮助。

常昊
2026 年 5 月

答辩委员会名单

	姓名	工作单位	职称	导师类型
主席	赵 XX	XXXX 大学	教授	博士生导师
委员	钱 XX	XXXX 大学	教授	硕士生导师
	孙 XX	XXX 研究院 XXX 大学	研究员	博士生导师
	李 XX	XXXX 大学	教授	硕士生导师
	周 XX	XXXX 大学	副教授	硕士生导师
秘书	吴 XX	XXXX 大学	助理研究员	